

Corso di Laurea in *Scienze Cognitive Psicologiche e Psicobiologiche*

I Criteri di Qualità Psicometrica Spiegati Abbastanza Facili

Enrico Toffalini – enrico.toffalini@unipd.it

Il problema è sempre lo stesso: in psicologia usiamo punteggi numerici per stimare cose che non vediamo direttamente («latenti»)

Come faccio a dire che quei punteggi vanno bene?

→ Quali sono i «criteri» di qualità psicometrica dei test?

La qualità di un test psicologico richiede diverse valutazioni:

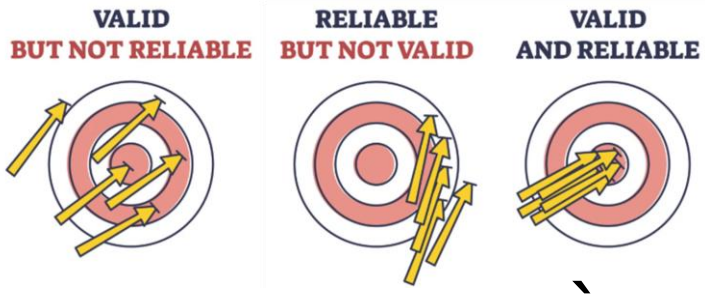
VALIDITÀ →

Il test **misura** davvero **proprio la cosa che dovrebbe** misurare?

È davvero **predittivo** di cose che dovrebbe predire?

il QI totale della WAIS-IV, dell'IDS-2, o il totale delle Matrici di Raven, sono realmente indicatori di g? lo sono in modo teoricamente sensato?

il QI predice esiti clinici, personali, sociali rilevanti?



ATTENDIBILITÀ O AFFIDABILITÀ →

Il punteggio rispecchia in modo **preciso** il costrutto latente?

quanto il QI totale della batteria è correlato a g? (??? 😳)

Il punteggio è **stabile** nel tempo?

se risomministro la batteria a distanza di tempo riottengo lo stesso punteggio?

SENSIBILITÀ →

Lo strumento distingue bene tutti i **livelli di abilità**?

Se è diagnostico: **discrimina** bene chi ha una condizione da chi no?

«ROBUSTEZZA» →

Il test rimane valido e attendibile anche in condizioni **non ottimali**?

es. popolazione leggermente diversa per contesto culturale, condizione del neurosviluppo, somministrazione non standard, risomministrazione, ecc.

I test d'intelligenza presentano elevatissimi indici di qualità psicometrica su tutti i criteri

VALIDI → «*indifferenza dell'indicatore*» di Spearman / trovare test che misurino g è «facile» (cf. Warne, 2020), si tratta solo di bilanciarli decentemente

ATTENDIBILI → Deary / *Lothian Birth Cohort study*: r = +0.66 tra 11 (1932) e 70 anni d'età (1991)

Tipica stabilità entro mesi > +0.90. Coerenza interna > +0.90

SENSIBILI → per progetto coprono ampi range di abilità (tipico QI ~ 40-160); effetti soffitto rari e giustificati (es. Leiter-3 su non-verbale per casistiche con difficoltà marcate; Raven colore per bambini; Raven standard in certe fasce d'età sostituite da Raven avanzate)

«ROBUSTI» → non sempre e in ogni circostanza (come qualsiasi test), ma siamo attrezzati con le contromisure (es. IAG invece di QI totale per ADHD; Leiter-3 per stranieri o autismo; sostituzioni, prorating, ecc.)

VALIDITÀ

DI CONTENUTO: copre in modo appropriato tutto il dominio che vuole misurare? – per intelligenza all'inizio valeva «indifferenza dell'indicatore», oggi si predilige dare una base teorica col CHC

STRUTTURALE: struttura delle correlazioni tra item, subtest, indici, segue un modello teorico sensato (es. CHC, con buoni indici di fit, es. RMSEA ≤ 0.08, CFI ≥ 0.95)

CONVERGENTE: correla molto con altri test dello stesso costrutto – per l'intelligenza di solito è ottima: i QI di diversi strumenti hanno correlazioni di almeno 0.70, ma spesso molto superiori

PREDITTIVA: il punteggio è un buon predittore di esiti rilevanti della vita reale che il costrutto dovrebbe in teoria predire? – è il pezzo forte per i test d'intelligenza

DISCRIMINANTE: non misura «troppo» anche costrutti diversi? es. correla abbastanza poco con variabili cliniche o socio-demografiche in teoria *non* relate all'intelligenza? – qui può essere ambiguo perché l'intelligenza ha molti motivi teorici per correlare con molte cose

INVARIANZA: è interpretabile ugualmente anche per gruppi, condizioni, background diversi?

→ Rimanda alla robustezza, ed è criterio che coinvolge anche l'interpretazione che si dà al punteggio (non è una proprietà fissa del test): es. posso interpretare il QI totale di un bambino con ADHD o ASD (autismo) nello stesso modo in cui interpreto il QI di un bambino a sviluppo tipico? e per bambini con background sociale e linguistico diverso?

ATTENDIBILITÀ

la bilancia è uno strumento valido per la misura del peso, ma...

usereste una bilancia che pesa la pasta con ± 15 grammi di errore? O che pesa voi con ± 3 kg di errore?

eppure possiamo figurarcelo idealmente come la quantità di incertezza, in termini di **precisione** e di **stabilità,** per gli indici d'intelligenza ~ 0.70-0.98 (comunque eccellenti nel panorama dei test psicologici)

Attendibilità come **Stabilità nel tempo**

Uno strumento restituisce un punteggio **molto correlato** con sé stesso se risomministrato **a distanza di tempo**?

Variazioni possono essere dovute a:

- Errore di misura casuale, contingente (oscillazioni di attenzione durante la prova, effetti *time of day*, ecc.)
- Reali cambiamenti stabili nel funzionamento (modesti nel QI e altri indici cognitivi)

Effetto pratica può esserci, ma si assume «prevedibile»

$r < 0.70$ si considera problematico *se si escludono cambiamenti reali rilevanti*

Stabilità - esempi

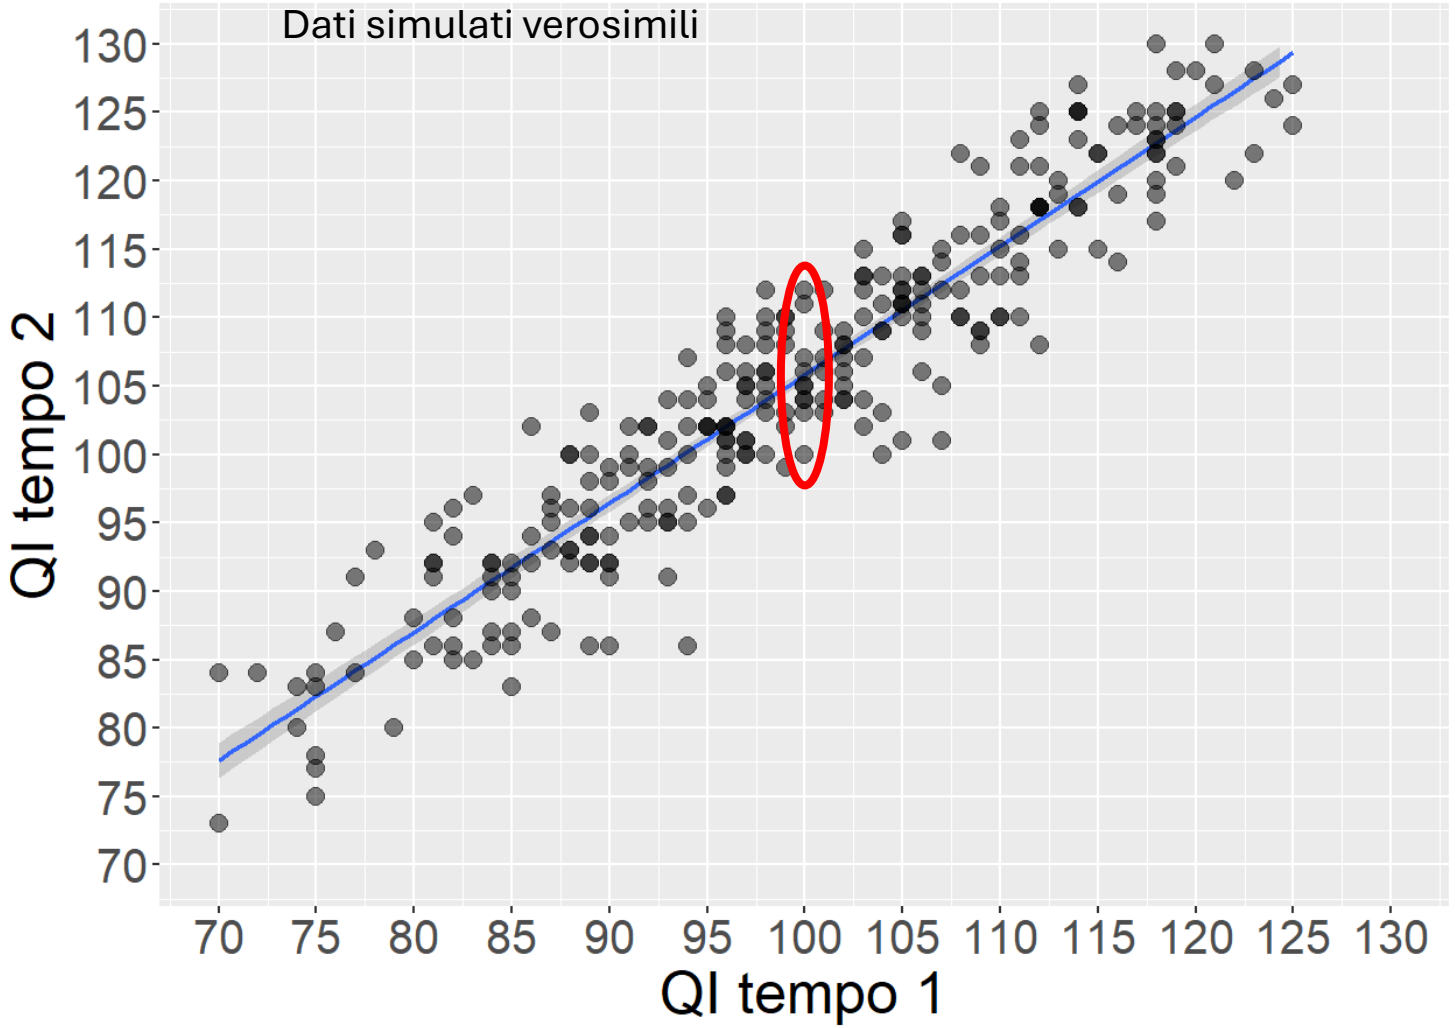
WAIS-IV *technical and Interpretive Manual*

QI totale a distanza di 22 giorni,
N = 298: **r ≈ 0.96**

Effetto pratica a parte, ho una forchetta di almeno **≈ ±5 punti** in risomministrazione recente

Ed è l'indice più stabile!

In età evolutiva e su tempi più lunghi può essere anche «peggio»



Stabilità - esempi

WISC-IV *technical and Interpretive Manual* + Watkins et al. (2013)

N di 243 e 131

QI totale a distanza di circa un mese in età evolutiva (**WISC-IV**)

r ≈ 0.89

dopo circa **tre anni: r ≈ 0.70**

Altri indici

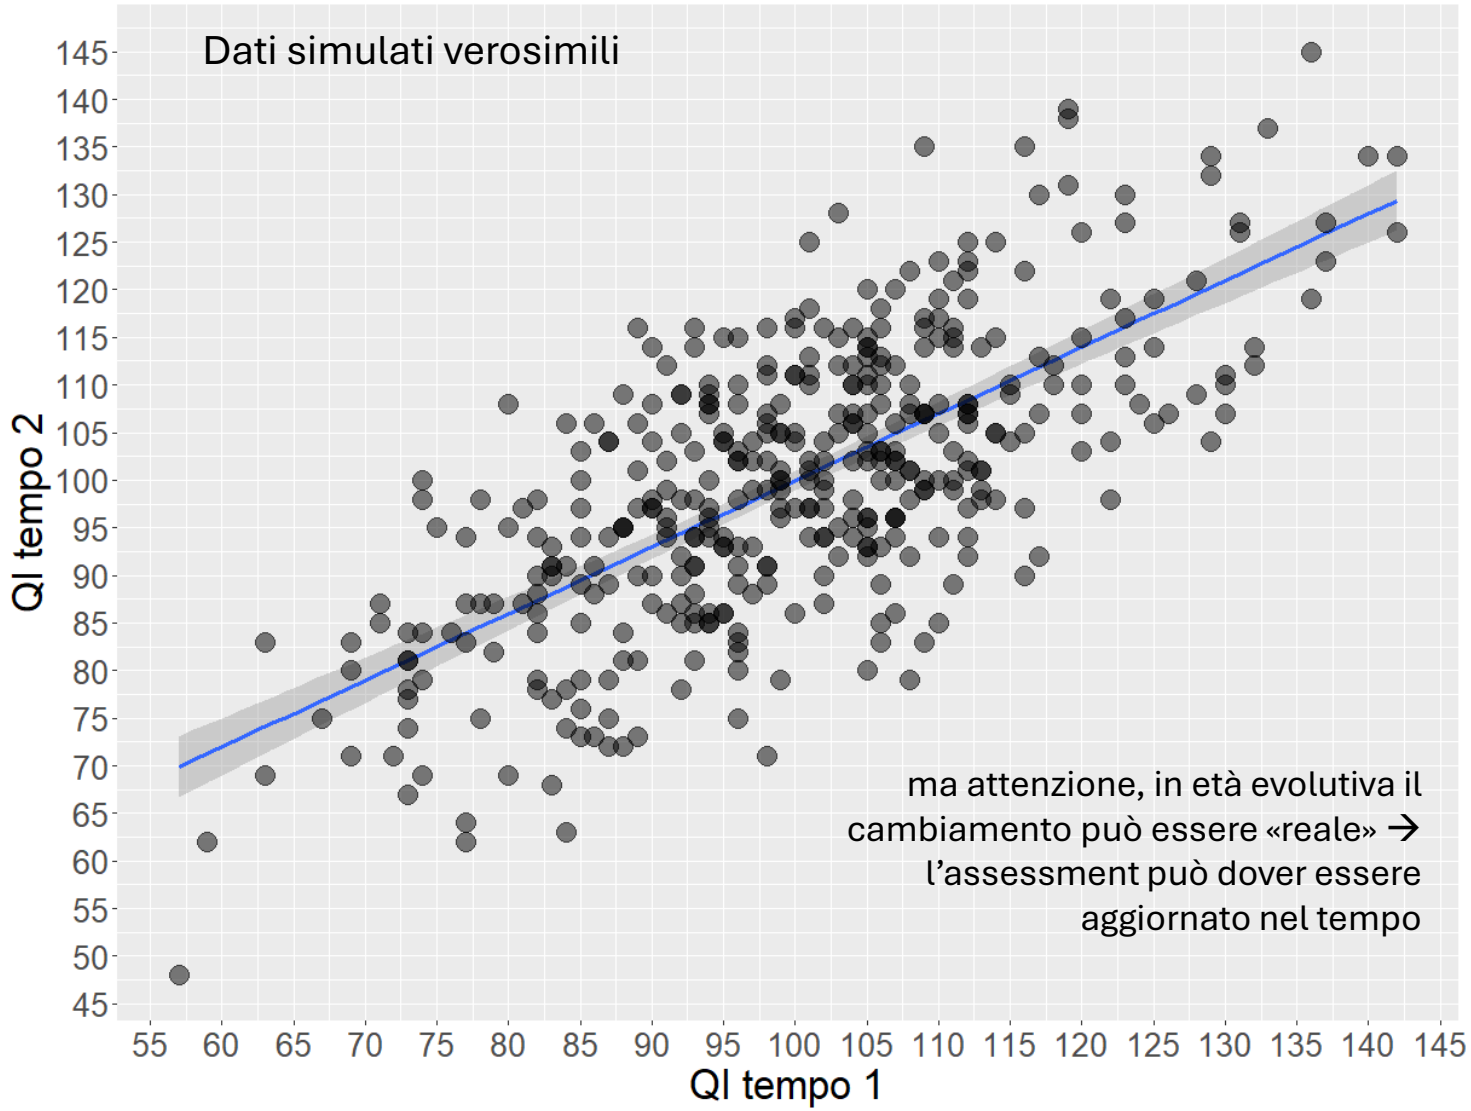
Verbal Comprehension
0.89 e 0.65

Perceptual Reasoning
0.85 e 0.62

Working Memory
0.62 e 0.54

Processing Speed
0.79 e 0.52

Per capirsi, con **r ≈ 0.70**, arriviamo a forchetta di **±15-20 punti**



Attendibilità come **Consistenza interna**

“Alpha di Cronbach” (α)
si usa spesso per massima semplicità sotto certe assunzioni (tau-equivalenza)
oggi si preferiscono indici tipo **McDonald’s omega (ω)**, che riflette un modello fattoriale

Spiegazione tipica: *“quanto gli item/subtest misurano tutti la stessa cosa”*

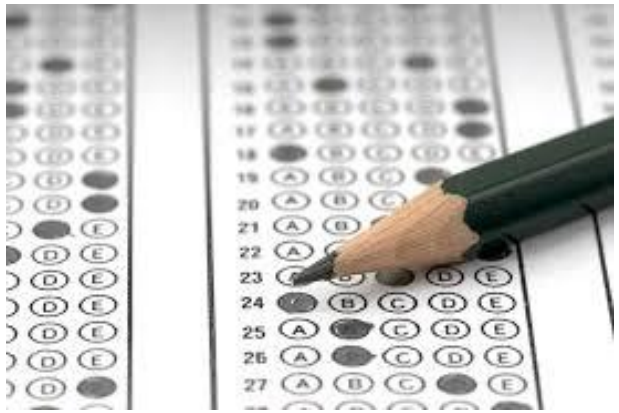
Qual è la soglia di accettabilità?
anche qui si cita spesso > **0.70**

Ma cosa significa?

Da cosa dipende?

Attendibilità come **Consistenza interna**

“Alpha di Cronbach” (α)



→ Somma di punteggi ad item

assumiamo siano tutti ugualmente rappresentativi del costrutto latente e tutti con stessa metrica e variabilità

“Alpha di Cronbach” (α)
= QUANTO la somma totale degli item rispecchia il costrutto latente … in % di varianza comune?

Come si fa a dirlo se il costrutto latente non si vede?

Sono stime sotto assunzioni! Basate su **forza delle correlazioni** tra item/punteggi (più alte è meglio) o dei **loading** fattoriali + **numero** di item/punteggi (più item/subtest è meglio)

Attendibilità come **Consistenza interna**

La consistenza interna fornisce un **coefficiente** che stima quanto il **punteggio osservato totale o derivato** da un modello sulla base degli item **osservati** rifletta i *«veri punteggi»* del costrutto **latente** in **% di varianza condivisa**

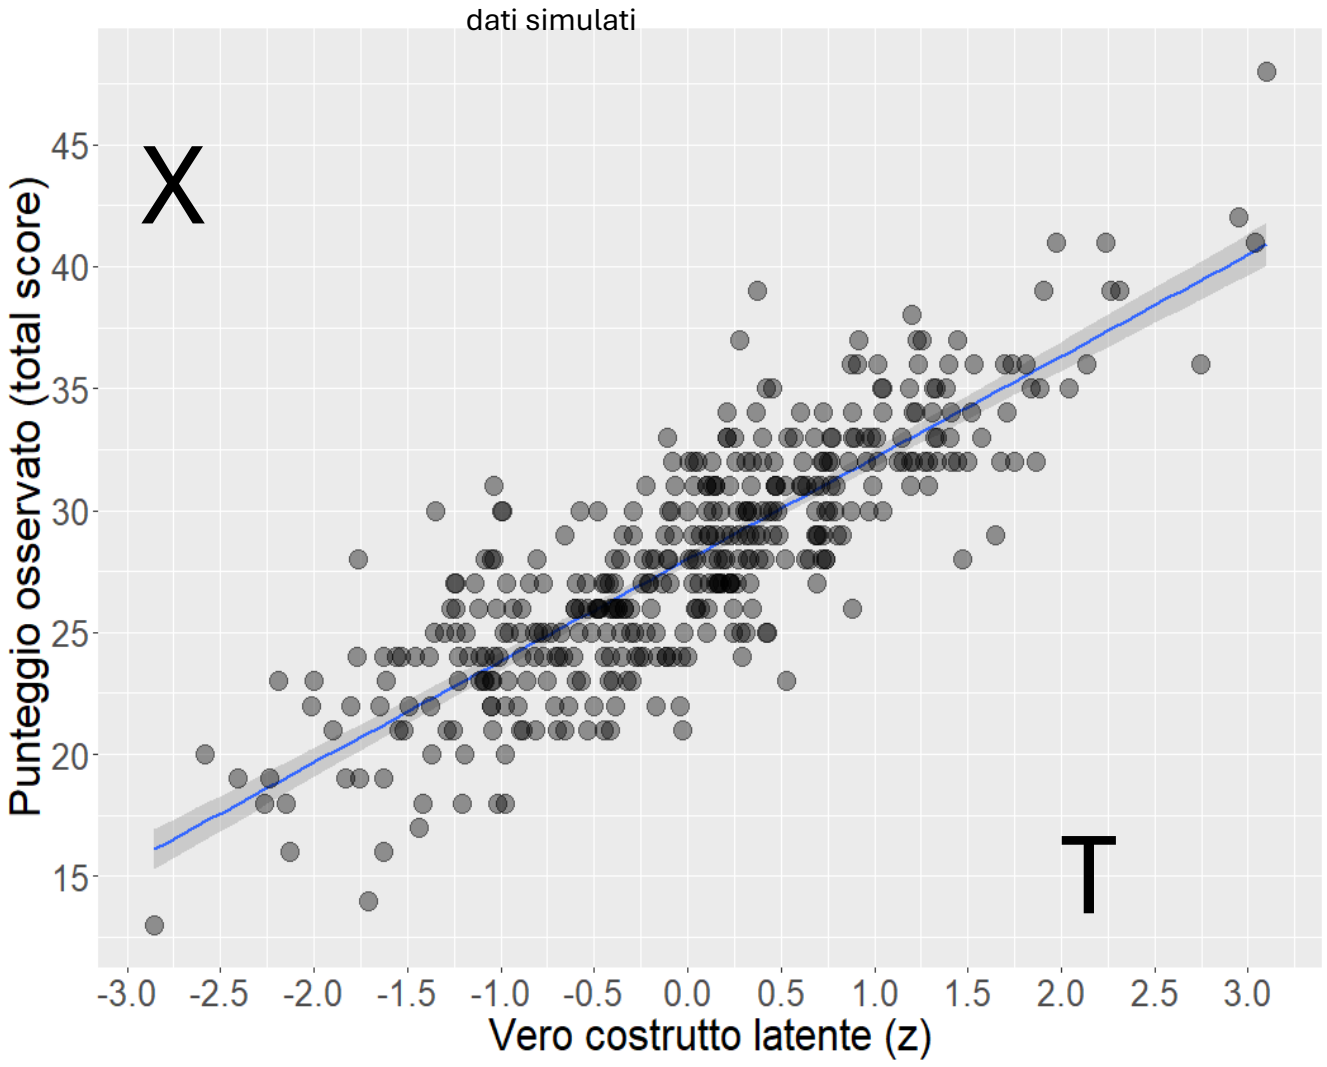
es. **alpha di Cronbach = 0.70**

→ la somma (o media) semplice dei punteggi osservati (non serve modello fattoriale) condivide il **70% della varianza** con il **vero costrutto latente**, quindi $r \approx \sqrt{0.70} \approx 0.84$

es. **McDonald's omega = 0.70**

→ il punteggio fattoriale, calcolato da modello fattoriale, condivide il **70% della varianza** con il **vero costrutto latente**, quindi $r \approx \sqrt{0.70} \approx 0.84$

Relazione punteggio totale – punteggio latente, con α = 0.70



Teoria Classica dei Test

$$X \sim T + E$$

- punteggio osservato
- punteggio vero costrutto latente («g»)
- errore di misura («s» + ε)

Come faccio ad avere un punteggio osservato che rispecchi molto bene il vero costrutto latente?

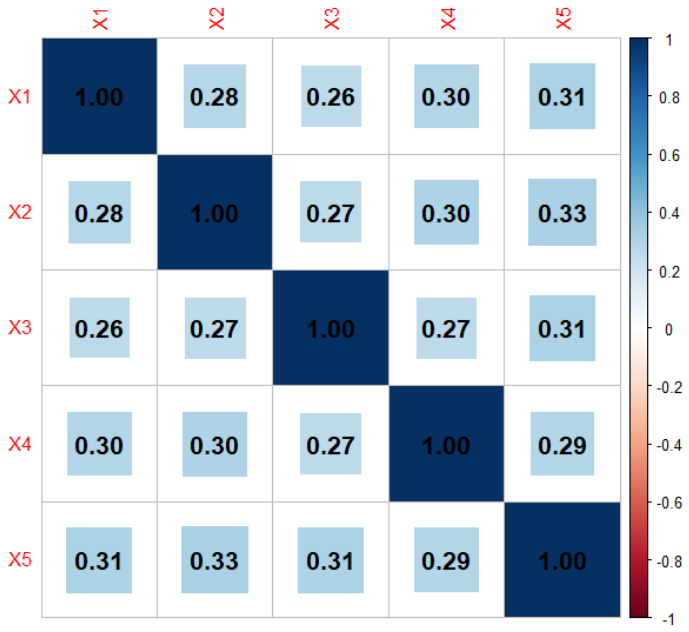
- «E» deve essere poco («s» piccolo → correlazioni medie $\bar{r}$ tra item forti)
- sommo quanti più item possibili (elevato k)

$$\alpha = \frac{k \cdot \bar{r}}{1 + (k-1) \cdot \bar{r}}$$

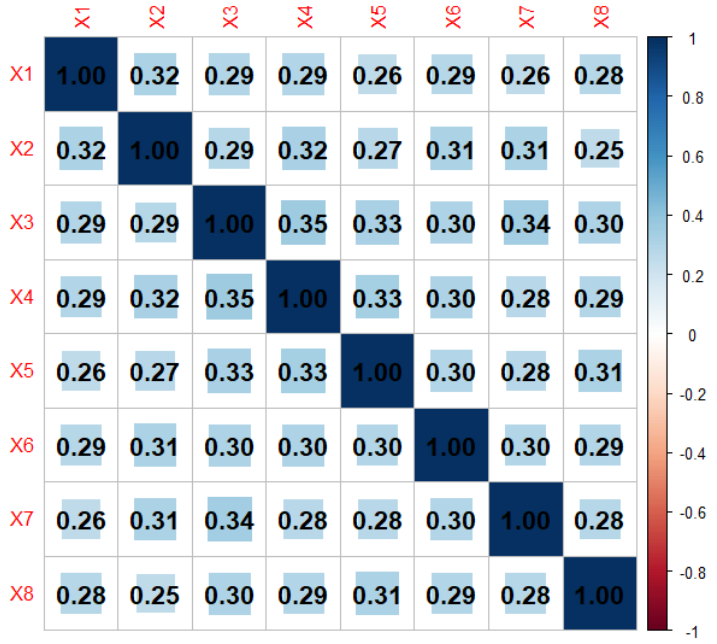
Quanta attendibilità avrò in ciascuno dei seguenti scenari?

Le figure mostrano le matrici di correlazioni tra gli elementi (item, subtest) che compongono una certa scala, e varia sia $\bar{r}$ (correlazione media) che **k** (numero di item che compongono la scala)

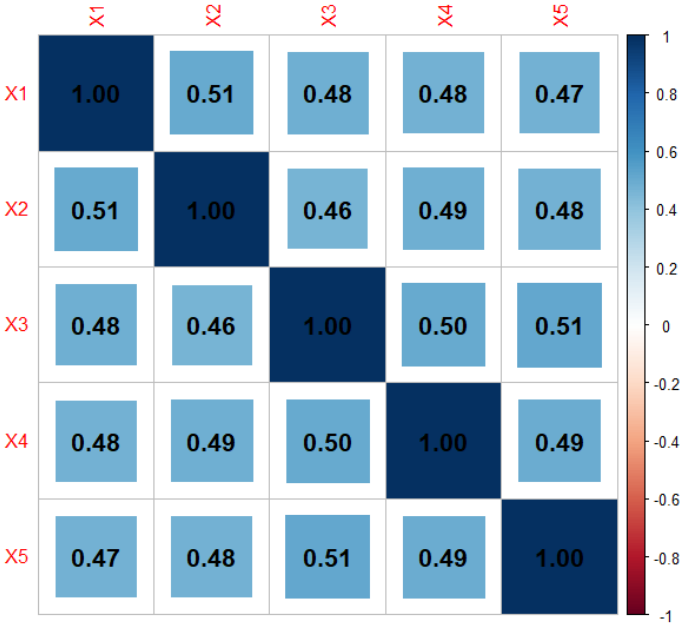
Scenario 1



Scenario 2



Scenario 3



Scenario 4

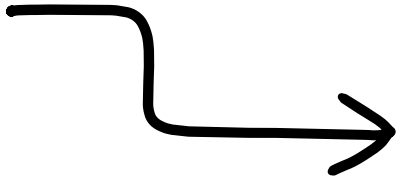


Attendibilità come **Consistenza interna**

Per questionari e test monocomponenziali il calcolo è «facile», ma per strumenti multicomponenziali come molte batteria d'intelligenza diventa più complesso

→ Per il QI totale potrebbe bastare considerare l'aggregato di tutti i subtest

→ Ma per gli indici (e, volendo, i subtest) un'interpretazione «onesta» dovrebbe essere **multilivello/gerarchica** – dunque complessa!



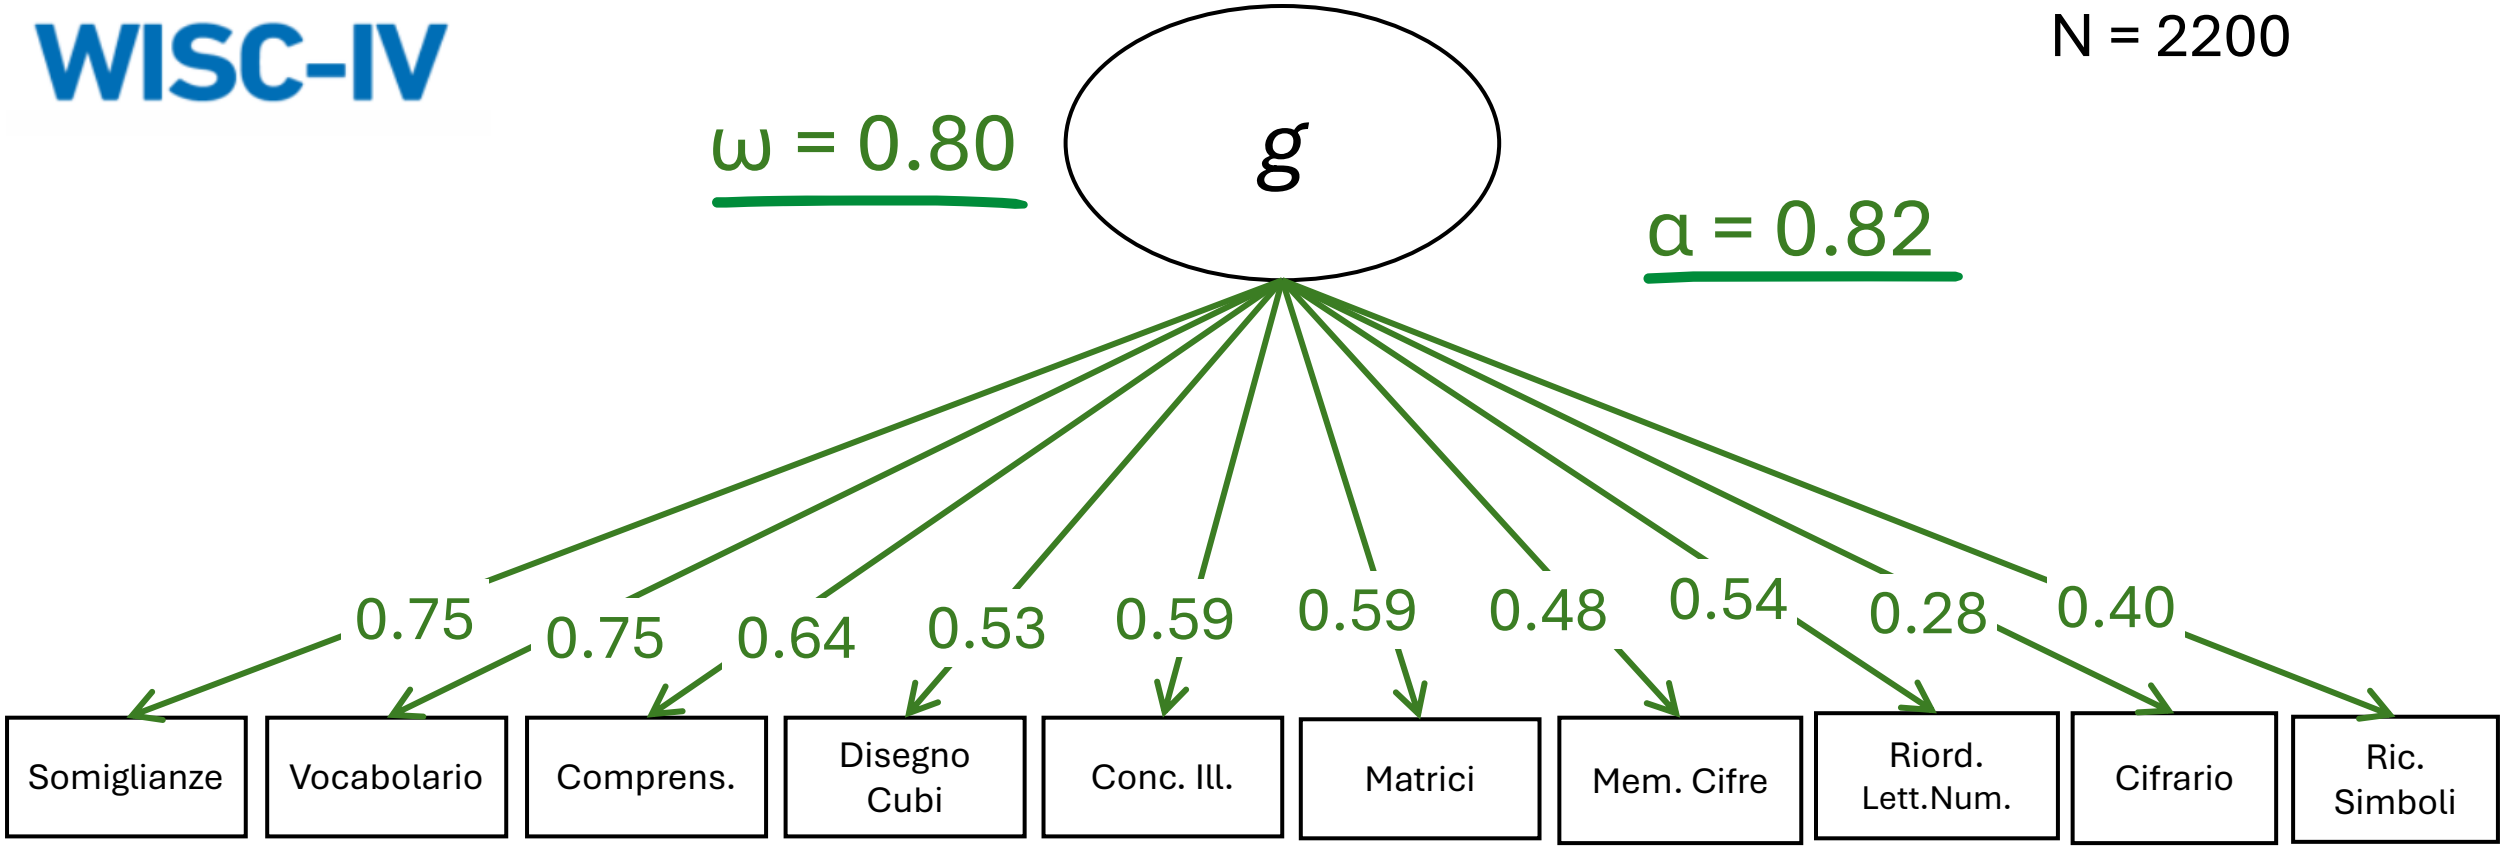
es. il punteggio totale di un **indice riflette in parte** anche il **fattore g**

quanta parte dell'indice è **specifico** solo di quel dominio al netto di g?
posso interpretare questa **parte** in modo ***attendibile***?

Consistenza interna – esempio su WISC-IV ITA

WISC-IV

N = 2200

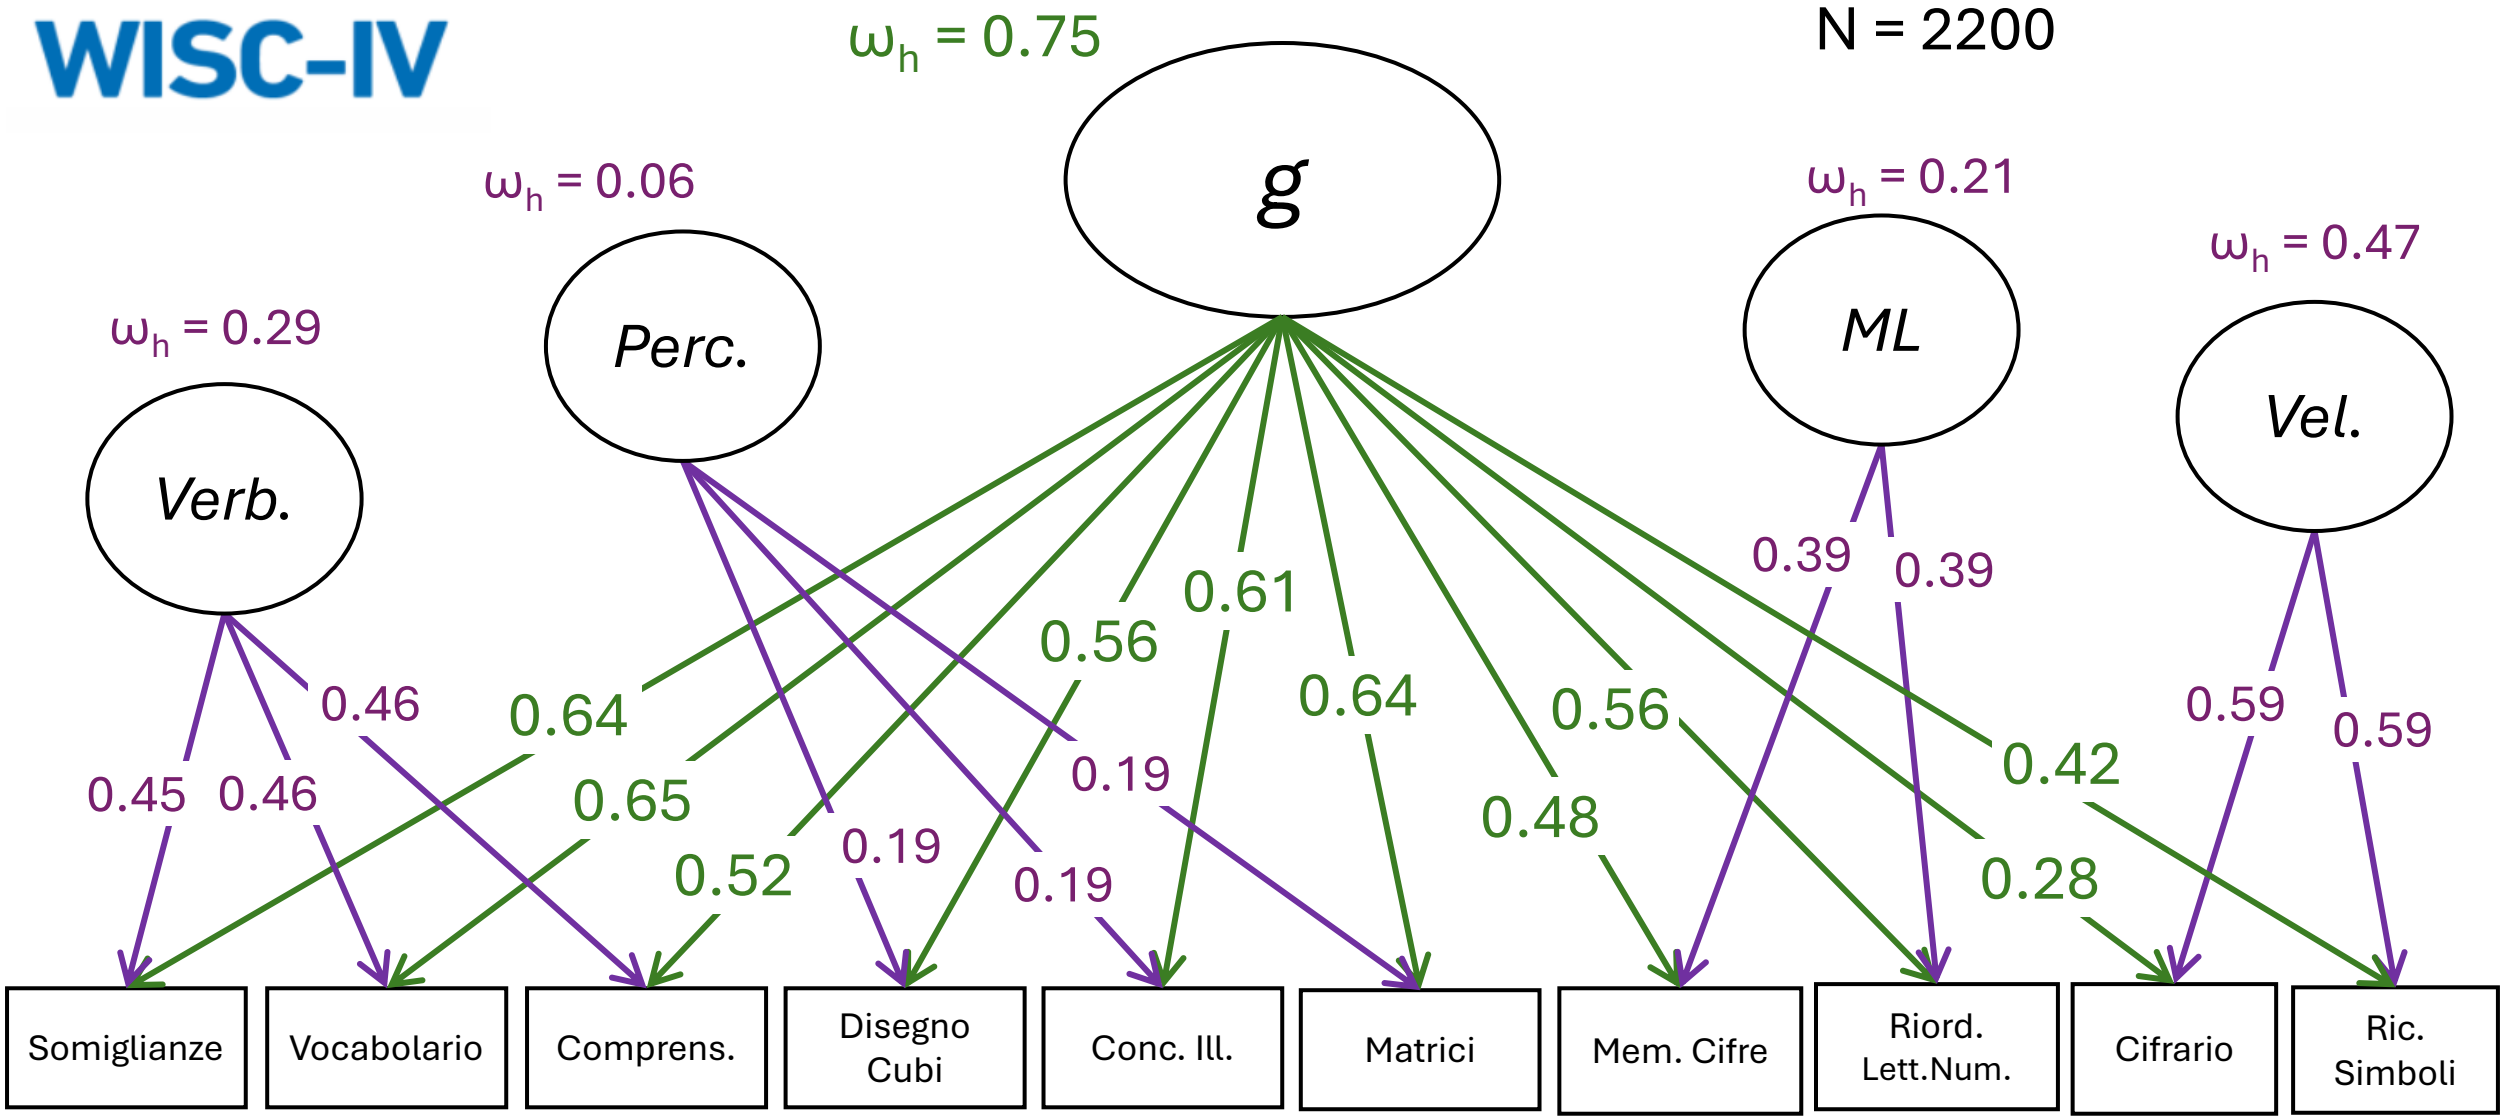


Ma … questo non è il modello «giusto»!

L'intelligenza non è strettamente «unitaria»

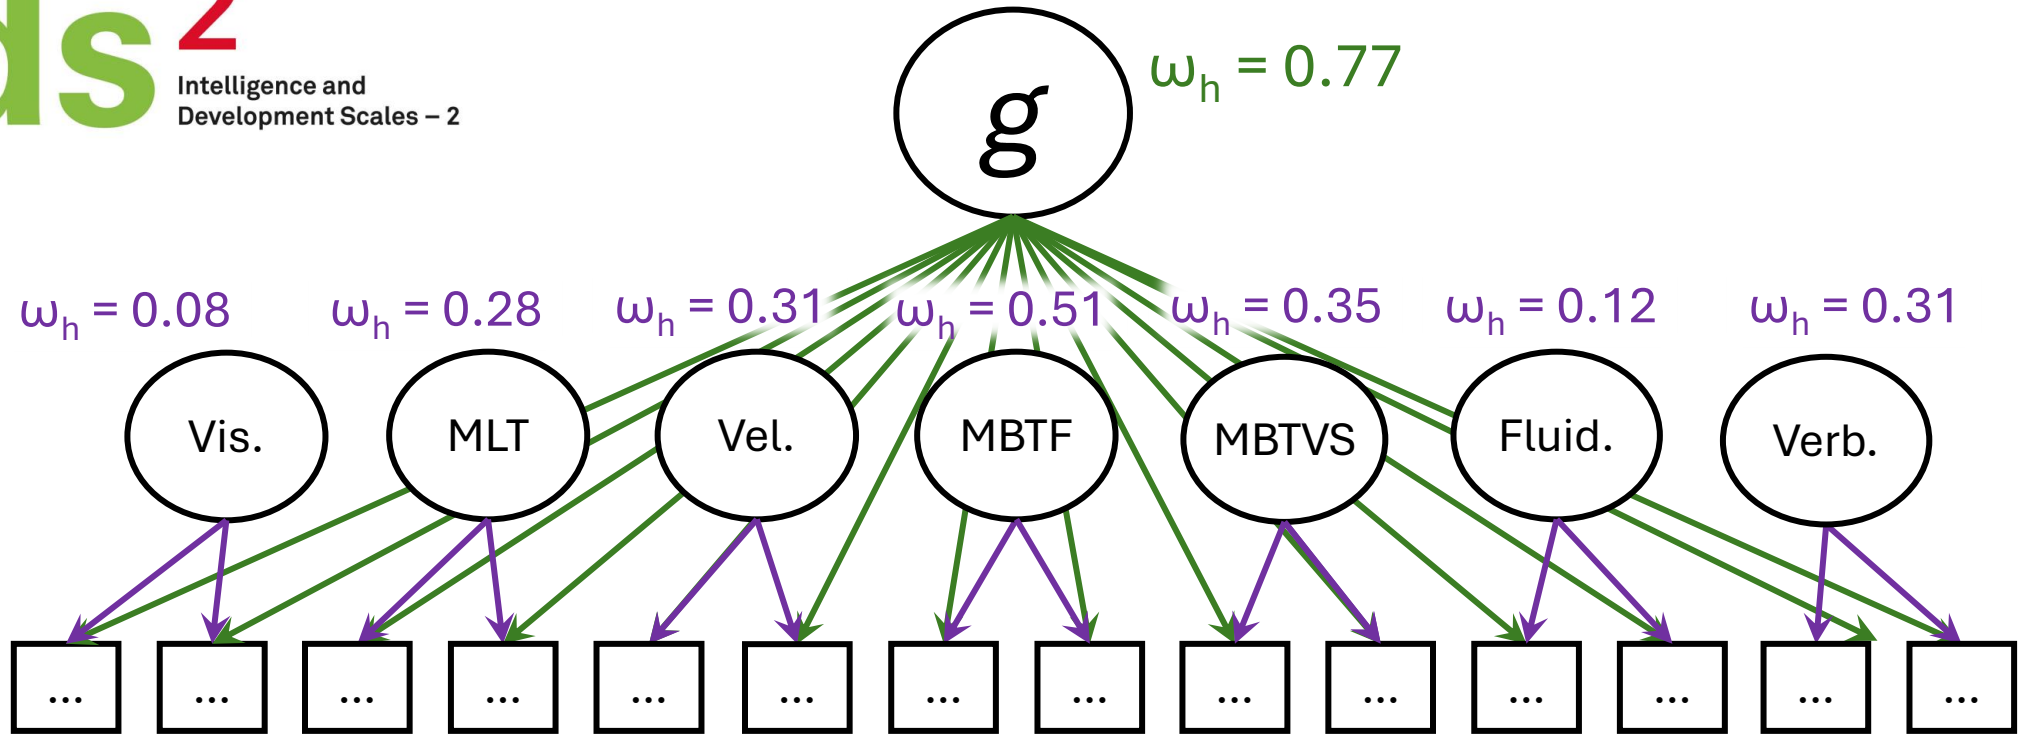
Applichiamo un modello gerarchico – *bifattoriale* per facilitare la separazione della varianza tra «g» e fattori di dominio cognitivo

Consistenza interna – esempio su WISC-IV ITA



Consistenza interna – esempio su IDS-2 ITA

N = 1281



di nuovo stesso riscontro: fattore g risulta attendibile e interpretabile (anche perché molto più «potente» con molti subtest) – fattori di dominio cognitivo non raggiungono un'attendibilità adeguata per interpretazione indipendente

Consistenza interna – indici

Diversi ricercatori concludono che sia semplicemente inappropriato interpretare qualsiasi indice di dominio cognitivo, e puntano solo al QI totale (es. Gignac & Kretzschmar, 2017; Watkins, 2006)

Un'interpretazione più equilibrata è che l'interpretazione degli indici sia possibile ma vada motivata in base ai casi, e generalmente vada riservata a casistiche cliniche per le quali si conosca il profilo atteso (Cornoldi et al., 2015; Giofrè et al., 2017; 2019; Toffalini et al., 2017, 2022)

→ L'interpretazione indipendente degli indici **è** possibile, ma va giustificata all'interno di un *assessment* clinico complessivo, corroborandola con evidenze convergenti