Psicologia dell'Intelligenza Umana

Enrico Toffalini

Indice

Introduzione 1

I Capire l'intelligenza 2

1 Perché studiare l'intelligenza 3

2 Che cosa chiamiamo intelligenza 10

II Dati, misure e punteggi 16

3 Correlazione e differenze individuali 17

4 Distribuzioni, punti z e punteggi standardizzati 26

5 Quando una misura è buona 36

III Modelli e test dell'intelligenza 44

6 Il fattore generale e la positive manifold 45

7 Abilità multiple e modelli gerarchici 52

8 Dai primi test al testing di massa 61

9 Le batterie moderne di intelligenza 69

IV Basi biologiche, ambiente e cambiamento 78

10 Geni, ambiente ed ereditabilità 79

11 Che cosa aggiunge la genetica molecolare 87

12 Cervello e intelligenza 94

13 L'effetto Flynn e i cambiamenti storici 101

14 Si può potenziare l'intelligenza? 109

V Scuola, salute e lavoro 118

15 Intelligenza, scuola e condizioni sociali 119

16 Salute e longevità 126

17 Intelligenza e lavoro 132

VI Intelligenza e condizioni del neurosviluppo 138

18 Dalle categorie alle dimensioni 139

19 Valutare l'intelligenza nel neurosviluppo 148

VII Approfondimenti: oltre g 157

20 Altre intelligenze o vecchi costrutti con un nome nuovo? 158

21 Si può spiegare la positive manifold senza un fattore generale? 162

Riferimenti bibliografici 168

Introduzione

Lo studio scientifico dell'intelligenza in Italia non gode della stessa attenzione e maturità teorica che ha raggiunto in altri paesi. Eppure, psicologhe e psicologi si trovano quotidianamente a valutare il funzionamento intellettivo di bambini, adulti, pazienti, in ogni genere di contesto, utilizzando strumenti complessi come le scale di QI e altri test cognitivi. Farlo senza un'adeguata consapevolezza dei modelli teorici, della storia, dei limiti e dei punti di forza della misurazione rischia di ridurre la valutazione a un gesto tecnico, anziché renderla un atto scientifico e interpretativo.

Cos'è l'intelligenza? Come si misura? È innata o appresa? Cosa significa il QI? Stiamo diventando più intelligenti o meno? Esistono le intelligenze multiple? Questo libro, e il progetto più ampio da cui nasce, mira a fornire gli strumenti concettuali per capire queste domande e le loro risposte, nonché a fornire una base di competenze pratiche per chi deve utilizzare i test quotidianamente.

I capitoli esplorano le teorie classiche e contemporanee sull'intelligenza, la sua storia e le sue basi biologiche, la misurazione psicometrica, la genetica delle differenze individuali, i fenomeni sociali e culturali che la influenzano e i test più utilizzati in ambito clinico, scolastico e di ricerca. Un'attenzione particolare è dedicata all'interpretazione dei punteggi, alla comprensione critica dei limiti dei test e ai temi più attuali, come la neurodiversità, la plusdotazione, il funzionamento intellettivo limite e la disabilità. L'obiettivo è promuovere una riflessione informata e critica sul modo in cui la psicologia studia, misura e comunica l'intelligenza.

Parte I

Capire l'intelligenza

1 Perché studiare l'intelligenza

L'intelligenza è uno dei primi temi affrontati dalla psicologia scientifica e, oggi, uno dei più maturi. Ha prodotto metodi che usa l'intera disciplina, ha una rete fitta di collegamenti con la genetica, le neuroscienze e lo sviluppo, e si misura ogni giorno in ambulatori, scuole, aziende e tribunali. Eppure resta uno degli argomenti su cui anche chi lavora in psicologia sa meno di quanto crede.

Capita di sentire professionisti che chiedono come interpretare un QI calcolato con l'età mentale, un metodo abbandonato da decenni. Capita di sentire chiedere quale questionario si usi per misurare l'intelligenza, come se bastasse domandare alle persone quanto si sentono brillanti. Capita perfino di sentir dire che i test di QI siano un mito pseudoscientifico. Sono tre errori diversi, ma hanno un'origine comune: si usano strumenti di cui non si conoscono le basi.

Questo capitolo spiega perché vale la pena colmare la lacuna. Le ragioni sono pratiche, teoriche e storiche. E c'è un motivo meno ovvio: capire l'intelligenza significa capire come la psicologia studia le differenze fra le persone.

1.1 Test ovunque, spesso sotto un altro nome

Le batterie di intelligenza sono fra gli strumenti più usati della professione psicologica. Raramente però si presentano con il loro nome. Si parla di «profilo cognitivo» a un genitore, di «abilità di ragionamento» in una richiesta a una scuola, di «test di problem solving» in una selezione del personale. Spesso la scelta è sensata: evita di caricare la valutazione di significati che il punteggio non ha. Ma il cambio di etichetta non cambia lo strumento.

I contesti d'uso sono molti:

- nello **sviluppo**, per distinguere traiettorie tipiche e atipiche e per valutare i disturbi del neurosviluppo;
- nella **scuola**, per comprendere difficoltà di apprendimento e bisogni educativi;

- nella **clinica**, per descrivere risorse e limiti di una persona;
- nell'**invecchiamento**, per distinguere un declino atteso da uno patologico;
- nel **lavoro**, per prevedere l'adattamento a compiti complessi;
- in ambito **forense**, per perizie su imputabilità, capacità di partecipare al processo o danno neuropsicologico, dove validità e attendibilità di una misura vanno difese davanti a un giudice.

Molte batterie classificate come «cognitive» o «neuropsicologiche» sono, nei fatti, test di intelligenza. Le scale Wechsler ne sono l'esempio più noto.

Il problema è che la formazione si concentra spesso su somministrazione e scoring. Si impara a leggere le istruzioni e a convertire i punteggi grezzi, ma non a rispondere a domande più importanti. Che cosa sta misurando davvero lo strumento? Quanto è affidabile il punteggio ottenuto? Una discrepanza fra due indici è abbastanza grande da essere interpretata? Senza queste risposte l'interpretazione diventa automatica, a volte delegata alle piattaforme di scoring. Il risultato è un numero preciso fino al decimale e opaco nel significato.

1.2 Una palestra per tutta la psicologia

La seconda ragione riguarda la ricerca. Molti metodi oggi diffusi in ogni area della psicologia sono nati o si sono sviluppati per studiare le abilità cognitive. L'analisi fattoriale è stata proposta da Spearman per spiegare le correlazioni fra prestazioni scolastiche e sensoriali (Spearman, 1904). Dalla stessa tradizione discendono l'idea di **variabile latente**, i modelli di equazioni strutturali e buona parte della teoria della misura.

Chi conosce l'intelligenza capisce quindi meglio gli strumenti con cui si analizzano personalità, psicopatologia o benessere. Il percorso inverso è più faticoso: si imparano le tecniche e poi si scopre che erano state costruite per rispondere a domande precise sulle abilità mentali.

C'è anche un debito storico. La psicologia delle differenze individuali e la psicometria si sono formate attorno ai primi test cognitivi. Concetti oggi ovvi, come il punteggio standardizzato o il confronto con un gruppo normativo, sono stati inventati per misurare l'intelligenza. Sapere da dove

vengono aiuta a capire perché funzionano in un certo modo e dove smettono di funzionare.

1.3 Due modi di fare psicologia

Le origini della psicologia scientifica si collocano di solito alla fine dell'Ottocento. In Germania Wilhelm Wundt apre a Lipsia, nel 1879, il primo laboratorio di psicologia sperimentale. L'interesse è rivolto ai processi generali della mente: percezione, memoria, attenzione, coscienza. Le differenze fra le persone sono un disturbo da contenere.

Negli stessi anni, in Gran Bretagna, la biologia evoluzionista di Darwin porta Francis Galton a una domanda diversa. Se la variabilità è la materia prima dell'evoluzione, allora le differenze individuali non sono rumore: sono l'oggetto da studiare. Galton raccoglie misure fisiche e sensoriali su migliaia di visitatori del suo laboratorio antropometrico. Karl Pearson formalizza la correlazione. Spearman propone l'analisi fattoriale.

Nasce così una distinzione che Cronbach, molti decenni dopo, descrisse come quella fra «due discipline» della psicologia scientifica (Cronbach, 1957):

Tabella 1.1: Due prospettive nello studio della mente.

	Processi generali	Differenze individuali
Domanda	Come funziona la mente in media?	Lungo quali dimensioni le persone differiscono, e con quali conseguenze?
Disegno tipico	Esperimento controllato	Studio correlazionale e longitudinale
Campione preferito	Omogeneo	Ampio e rappresentativo
Variabilità fra persone	Rumore	Oggetto di studio
Esempi	Memoria, percezione, linguaggio	Intelligenza, personalità, psicopatologia

Talvolta l'oggetto è lo stesso, ma la domanda cambia. Si prenda la memoria di lavoro. Chi studia i processi generali si chiede se una componente fonologica e una visuospaziale siano distinte perché un compito secondario interferisce con l'una e non con l'altra. Chi studia le differenze individuali si chiede se siano distinte perché alcune persone vanno meglio nell'una e altre nell'altra. Sono due evidenze diverse. Non è detto che diano la stessa risposta.

Oggi le due tradizioni si contaminano sempre di più. Un esperimento può stimare sia l'effetto medio di una manipolazione sia quanto quell'effetto varia da persona a persona. Un'illusione percettiva, un trattamento o una traiettoria di sviluppo hanno un andamento tipico e una dispersione attorno a esso. Studiare solo il primo significa perdere metà della storia.

1.4 La foresta delle differenze individuali

Le abilità cognitive sono una delle tre grandi aree in cui la psicologia descrive le differenze fra persone. Le altre due sono la personalità e la psicopatologia. In tutte e tre si è arrivati a modelli simili: molti tratti specifici, raggruppati in dimensioni più ampie, a loro volta correlate.

- Per le abilità cognitive il modello di riferimento è gerarchico, con abilità specifiche, ampie aree come intelligenza fluida e cristallizzata e, al vertice, un fattore generale.
- Per la personalità i cinque grandi fattori riassumono decine di tratti più circoscritti.
- Per la psicopatologia la proposta HiTOP organizza sintomi e sindromi in dimensioni internalizzanti, esternalizzanti e di altro tipo (Kotov et al., 2017); alcuni autori hanno ipotizzato anche un fattore generale, chiamato p per analogia con g (Caspi et al., 2014).

Queste aree condividono strumenti e problemi. Si misurano con test e punteggi; mostrano basi genetiche distribuite su moltissime varianti; hanno correlati neurobiologici; cambiano lungo lo sviluppo; interagiscono con l'esperienza. L'intelligenza è il punto in cui questi temi sono stati studiati più a lungo e con più dati. Per questo funziona bene come porta d'ingresso.

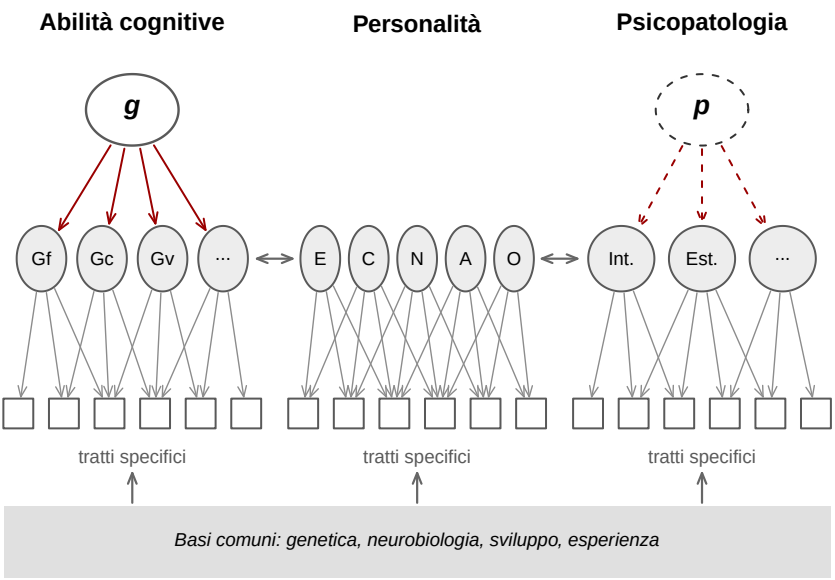


Figura 1.1: Le tre grandi aree delle differenze individuali hanno un'architettura simile: molti tratti specifici, raggruppati in dimensioni più ampie e correlate. Per le abilità cognitive al vertice c'è il fattore g; per la psicopatologia un fattore generale p è stato ipotizzato (bordo tratteggiato); per la personalità le dimensioni ampie sono i cinque grandi fattori. Schema originale.

Nella Figura 1.1 Gf e Gc indicano l'intelligenza fluida e cristallizzata, Gv l'elaborazione visiva; le lettere della personalità indicano estroversione, coscienziosità, nevroticismo, amicalità e apertura mentale; Int. ed Est. le dimensioni internalizzante ed esternalizzante.

1.5 Perché sembra più difficile di quanto sia

L'intelligenza non è un tema più complicato della memoria o del linguaggio. Eppure sembra essere compresa con più fatica. Una parte del problema sta nei preconcetti. Tutti hanno un'idea di che cosa sia l'intelligenza, e molte di queste idee contraddicono ciò che la ricerca ha accertato. Il caso non è

unico, ma qui la distanza fra intuizione comune e consensus scientifico è particolarmente ampia.

L'altra parte del problema è emotiva. Le obiezioni si somigliano: il QI serve a discriminare; non si possono ridurre le persone a numeri; siamo tutti uguali; nella vita conta l'impegno, non il QI; ognuno è un genio a modo suo. Alcune sono slogan. Altre contengono un nucleo serio, che i capitoli successivi prenderanno sul serio.

Questa resistenza non nasce dal nulla. Nella prima metà del Novecento i test di intelligenza sono stati usati per giustificare politiche eugenetiche, restrizioni all'immigrazione e sterilizzazioni forzate. Sono fatti storici, non caricature polemiche, e ne parleremo nel capitolo sulle origini dei test. Ignorarli sarebbe disonesto. Concludere che il costrutto sia per questo privo di valore sarebbe però un errore di altro tipo: confondere l'uso di uno strumento con la sua validità.

Un costrutto capace di generare polemiche così accese e abusi così gravi è, evidentemente, un costrutto potente. Lo è nel bene e nel male. Le stesse misure che sono state usate per escludere servono oggi a riconoscere una disabilità intellettiva, a individuare un bisogno educativo, a documentare un declino cognitivo, a stimare l'impatto di un'esposizione ambientale nociva. La conclusione ragionevole non è rinunciare a misurare, ma imparare a misurare bene e a interpretare con giudizio.

1.6 L'impostazione di questo libro

Il percorso che segue cerca di offrire una visione equilibrata e allineata al consenso scientifico prevalente, senza nascondere le controversie, gli errori storici e gli abusi. Quando l'evidenza è solida, lo diremo chiaramente. Quando è debole, contraddittoria o fraintesa, lo diremo con la stessa chiarezza.

Le domande sono quelle che chiunque si pone: che cos'è l'intelligenza, come si misura, se è una o molte, che cosa significa il QI, quanto contano geni e ambiente, dove si trova nel cervello, se stiamo diventando più o meno intelligenti, se si può potenziare, che cosa predice nella vita reale, come si valuta nelle condizioni del neurosviluppo. Per rispondere servirà anche un minimo di linguaggio quantitativo: correlazioni, distribuzioni, punteggi,

qualità della misura. Non è un pedaggio da pagare per arrivare ai temi interessanti. È il modo in cui quei temi diventano discutibili con argomenti invece che con opinioni.

In breve

- I test di intelligenza sono fra gli strumenti più usati in psicologia, spesso sotto altri nomi; usarli bene richiede di conoscerne le basi concettuali, non solo le procedure di scoring.
- Lo studio dell'intelligenza ha generato metodi, come l'analisi fattoriale e le variabili latenti, che servono a tutta la psicologia.
- La psicologia dei processi generali e quella delle differenze individuali pongono domande diverse anche sugli stessi fenomeni.
- La storia dei test include abusi reali. Riconoscerli non implica rinunciare a misurare, ma pretendere misure valide e interpretazioni prudenti.

Riferimenti bibliografici

2 Che cosa chiamiamo intelligenza

Una persona capisce al volo un problema difficile e poi prende una decisione disastrosa. È intelligente o no? La domanda sembra imbarazzante solo perché alla parola «intelligenza» chiediamo troppo: la rapidità del ragionamento, la saggezza delle scelte, talvolta perfino il carattere. Nessun concetto regge un incarico così ampio.

Per studiarla bisogna restringere il campo. Questo capitolo lo fa in tre passaggi: che cosa intendiamo per intelligenza, come si passa da una capacità che non si vede a prestazioni che si osservano, e che cosa indica, e non indica, il numero chiamato QI. Saltare questi passaggi non rende il numero più preciso. Lo rende più misterioso.

2.1 Una parola con troppi compiti

Nel linguaggio comune chiamiamo intelligente chi capisce una spiegazione, chi trova una soluzione ingegnosa, chi sa molte cose, chi evita una scelta avventata. Sono giudizi spesso sensati, ma non descrivono la stessa capacità. Possedere una conoscenza, acquisirla in fretta e sapere quando usarla sono tre operazioni diverse.

Si pensi a due colleghi alle prese con un nuovo gestionale. Il primo ne intuisce subito la logica e trova anche le funzioni che nessuno gli ha mostrato. Il secondo ricorda alla perfezione le procedure imparate, ma si blocca quando un aggiornamento cambia i menu. Possiamo descrivere la differenza senza decidere chi dei due sia, in assoluto, «quello intelligente». Vediamo indizi su apprendimento, memoria e capacità di ricavare una regola. Non una biografia.

Anche la buona condotta va tenuta fuori. Capire le conseguenze di un'azione non obbliga a scegliere quelle migliori per tutti, e si può ragionare in modo eccellente al servizio di uno scopo pessimo. Il giudizio sulla capacità e quello sullo scopo restano separati.

Non è pedanteria. Se la definizione includesse ogni qualità desiderabile, una buona decisione sarebbe intelligente per definizione e una cattiva sa-

rebbe stupida per definizione. Avremmo un'etichetta con cui commentare i risultati, e nessuna possibilità di spiegare come si producono.

2.2 Una definizione di lavoro

Chiameremo **intelligenza** un'abilità mentale generale che interviene nel comprendere, ragionare, apprendere e risolvere problemi. Una formulazione molto citata, firmata da Gottfredson e sottoscritta da decine di ricercatori, aggiunge la pianificazione, il pensiero astratto, la comprensione di idee complesse e l'apprendimento rapido dall'esperienza. Il suo pregio è collegare attività diverse senza ridurre l'intelligenza alla cultura scolastica (Gottfredson, 1997, p. 13).

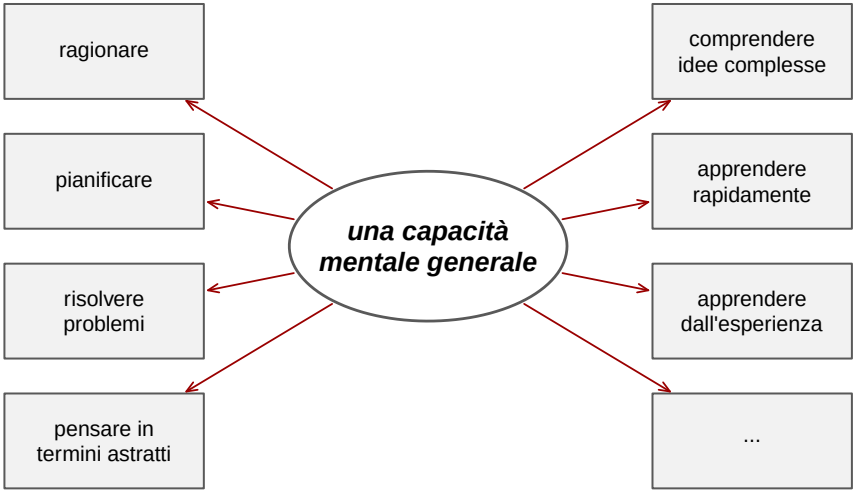


Figura 2.1: Una capacità mentale generale e alcune delle attività in cui interviene, secondo la definizione di lavoro adottata in questo libro. Elaborazione da Gottfredson (1997).

«Generale» indica l'ampiezza del campo di applicazione, non l'uniformità dei risultati. Una persona può usare la stessa capacità in compiti diversi e riuscire meglio in alcuni che in altri. Il resto del libro mostrerà che questa

non è una sottigliezza: è il cuore del dibattito fra modelli unitari e modelli multipli.

Due idee reggono la definizione. La prima è l'**adattamento**: rispondere alle richieste di una situazione quando le abitudini disponibili non bastano. Il secondo collega del gestionale è bravissimo finché il mondo resta fermo. L'intelligenza si vede soprattutto quando la risposta non è già pronta.

La seconda è la **rappresentazione mentale**: una descrizione interna degli elementi di un problema e delle loro relazioni. Chi si rappresenta la logica di un programma può prevedere dove si troverà una funzione mai vista, confrontare possibilità, scartare un'ipotesi prima di provarla. La rappresentazione non deve essere un'immagine: può essere verbale, spaziale o del tutto astratta.

Una definizione di lavoro non è una teoria. Già il rapporto dell'American Psychological Association coordinato da Neisser notava che i ricercatori riconoscono lo stesso insieme di fenomeni anche senza condividere una definizione universale (Neisser et al., 1996, p. 77). Sapere che cosa vogliamo spiegare è un inizio. Spiegarlo è un altro mestiere.

2.3 Dalla capacità alla prestazione

Una capacità non si osserva. Si osservano risposte giuste e sbagliate, tempi, strategie, esitazioni. Da queste prestazioni cerchiamo di inferire qualcosa che valga oltre il singolo episodio. Il problema della misura comincia qui.

Una singola prestazione è ambigua. Il collega che trova subito la funzione nascosta potrebbe aver capito la logica del programma, oppure aver usato per anni un software quasi identico. Un errore può rivelare una difficoltà di ragionamento o una consegna fraintesa. Una risposta isolata lascia aperte troppe spiegazioni; molte risposte diverse cominciano a chiuderne qualcuna.

Per questo le batterie di intelligenza combinano prove di natura diversa: ragionamento su relazioni, conoscenze verbali, memoria, elaborazione di informazioni visive. Variare i compiti impedisce che l'intera valutazione dipenda da una sola richiesta e dai suoi difetti particolari.

Moltiplicare le prove, però, non basta. Se le istruzioni sono ambigue in tutte, l'ambiguità si moltiplica con loro. Servono regole precise su che cosa si chiede, quali aiuti sono ammessi, quando si interrompe una prova e come si assegna il punteggio. La comparabilità fra persone va costruita, non presunta.

Resta l'obiezione dell'impegno: forse chi ottiene punteggi bassi semplicemente non ci ha provato. In una serie di studi su adulti sani, Bates e Gignac hanno offerto incentivi economici per le risposte corrette e hanno osservato miglioramenti medi piccoli (Bates & Gignac, 2022). La motivazione conta, e in una valutazione individuale va sempre osservata; ma non è la bacchetta magica che cancella le differenze di punteggio. Il risultato riguarda volontari sani e non copre ogni contesto, ma è difficile conciliarlo con l'idea che il QI misuri soprattutto la voglia di fare il test.

La distinzione da tenere ferma è questa: la prestazione è l'evidenza, l'abilità è l'inferenza.

2.4 Che cosa indica il QI

Il **quoziente di intelligenza**, o **QI**, è un punteggio. Nelle batterie moderne combina i risultati di più prove ed esprime la posizione di una persona rispetto a una popolazione di riferimento della stessa età.

Il percorso parte dal **punteggio grezzo**, per esempio il numero di risposte corrette. Da solo dice poco: dodici punti sono tanti in una prova difficile e pochi in una facile, e la stessa prestazione significa cose diverse a sette e a quindici anni. Il punteggio acquista senso solo nel confronto con le **norme**, cioè con i dati del campione su cui il test è stato tarato. «Norma» qui è un termine statistico: indica come si distribuiscono le persone, non come dovrebbero essere. Ed è un confronto legittimo solo se quella popolazione è pertinente alla persona valutata (American Educational Research Association et al., 2014, standard 5.8).

Il risultato finale viene espresso su una scala con media 100 e, di solito, deviazione standard 15 (Neisser et al., 1996, p. 78). Il capitolo sulle distribuzioni spiega come funziona. Qui basta una conseguenza: quella scala non ha uno zero naturale né un'unità di intelligenza. Un QI di 120 non

significa aver risolto il 120% dei problemi, né avere il 20% di intelligenza in più di chi ha 100.

Il QI non va confuso neppure con g, il fattore generale ricavato dalle correlazioni fra prove diverse. g appartiene a un modello delle relazioni fra misure; il QI è il risultato concreto di uno strumento. Sono strettamente legati, ma non sono la stessa cosa (Neisser et al., 1996, p. 78).

Infine, ogni riassunto perde dettagli. Due persone con lo stesso QI possono arrivarci per strade diverse. Chiedere a un totale di descrivere una persona intera significa chiedergli un lavoro per cui non è stato costruito.

2.5 Perché compiti così artificiali?

L'obiezione più comune è ragionevole. Nella vita reale i problemi sono articolati, si cercano informazioni, si chiede aiuto, spesso c'è tempo. Perché stimare una capacità generale con compiti brevi, astratti e un po' strani?

Perché un compito circoscritto permette di controllare che cosa la persona sa già e che cosa le viene chiesto. Nel caso del gestionale, il successo dipende dal ragionamento, ma anche dall'esperienza con software simili, dalle abitudini d'ufficio e dalla disponibilità di un collega paziente. Una prova delimitata separa una parte di questi ingredienti e la rende leggibile.

Il prezzo è la distanza dalla vita quotidiana, e va riconosciuto. Ma la somiglianza esteriore non decide nulla. Una simulazione molto realistica può misurare soprattutto esperienze specifiche; una prova astratta può prevedere bene l'apprendimento in situazioni nuove. «Sembra artificiale» e «sembra realistico» sono impressioni. La qualità di una misura si giudica dai dati.

2.6 Una misura va messa alla prova

Chiamare un test «test di intelligenza» non certifica che cosa misura. Altrimenti il ragionamento sarebbe circolare: è un buon test perché misura l'intelligenza, e misura l'intelligenza perché lo dice il nome sulla copertina.

L'interpretazione di un punteggio deve poter essere smentita. Se una prova presentata come misura del ragionamento dipendesse soprattutto dalla conoscenza di poche parole rare, il problema andrebbe indagato, non nascosto. Gli Standards per i test psicologici chiamano **validità** proprio questo: il grado in cui evidenze e teoria sostengono una certa interpretazione dei punteggi per un certo uso (American Educational Research Association et al., 2014, pp. 11–17). Il capitolo sulla qualità della misura mostra quali evidenze servono e come se la cavano i test di intelligenza.

Una cosa va detta subito. Prevedere bene un esito, come il rendimento scolastico, è una prova importante a favore di un test, ma non spiega perché la previsione funziona. La qualità di una misura e la spiegazione causale sono due domande diverse, e confonderle è uno degli errori più frequenti in questo campo.

L'intelligenza si può studiare anche senza una definizione che metta tutti d'accordo. Servono concetti abbastanza precisi da orientare le osservazioni e misure abbastanza controllate da poterli smentire. Il QI ha significato dentro questo rapporto fra teoria ed evidenza.

In breve

- L'intelligenza è una capacità generale di comprendere, ragionare, apprendere e risolvere problemi; non coincide con ogni qualità desiderabile.
- Le prestazioni sono l'evidenza osservabile; l'abilità è ciò che se ne inferisce, e servono molte prove diverse e regole precise per farlo.
- Il QI esprime una posizione rispetto a una popolazione di riferimento. Non è una percentuale di intelligenza e non è sinonimo del fattore *g*.
- La validità riguarda un'interpretazione dei punteggi per un uso; il nome del test non basta, e prevedere non equivale a spiegare.

Riferimenti bibliografici

Parte II

Dati, misure e punteggi

3 Correlazione e differenze individuali

Chi ha un QI più alto tende a ottenere voti scolastici migliori. Eppure tutti conoscono qualcuno brillante con una pagella mediocre e qualcuno con risultati eccellenti senza particolari doti di ragionamento. Le due osservazioni non si contraddicono. Una tendenza può essere solida e ammettere moltissime eccezioni. La correlazione è lo strumento che permette di dire quanto.

Quasi tutto ciò che sappiamo sulle differenze individuali si esprime con correlazioni: fra prove cognitive, fra fratelli, fra un punteggio e un esito scolastico o lavorativo. Conviene quindi capire bene che cosa riassume questo numero e, soprattutto, che cosa lascia fuori.

3.1 Leggere una nuvola di punti

Immaginiamo di avere due misure per ciascuna persona: per esempio un punteggio di ragionamento e un voto medio. Ogni persona diventa un punto su un piano, con la prima misura sull'asse orizzontale e la seconda su quello verticale. La domanda è semplice: se una persona sta sopra la media nella prima misura, tende a stare sopra la media anche nella seconda, sotto, oppure non c'è alcuna tendenza?

Le domande quotidiane hanno la stessa forma. Se oggi fa più caldo del solito, si vendono più gelati? Se un genitore ha un QI sopra la media, i figli tendono ad averlo sopra la media? Se si studia più della media, il voto tende a essere più alto?

Il **coefficiente di correlazione di Pearson**, indicato con r, riassume la risposta in un numero compreso fra -1 e $+1$. Il **segno** indica la direzione: positivo se le due misure tendono a salire insieme, negativo se all'aumentare dell'una l'altra tende a scendere. Il **valore assoluto** indica l'intensità: quanto i punti si dispongono vicino a una retta. A $+1$ o -1 si trovano tutti esattamente sulla retta; vicino a zero non c'è alcuna tendenza lineare.

Il coefficiente non dipende dall'unità di misura. Esprimere i voti in decimi o in trentesimi, o il ragionamento in punti grezzi o in punti QI, non cambia

r. Conta solo quanto stretta è la relazione fra le posizioni delle persone nelle due distribuzioni.

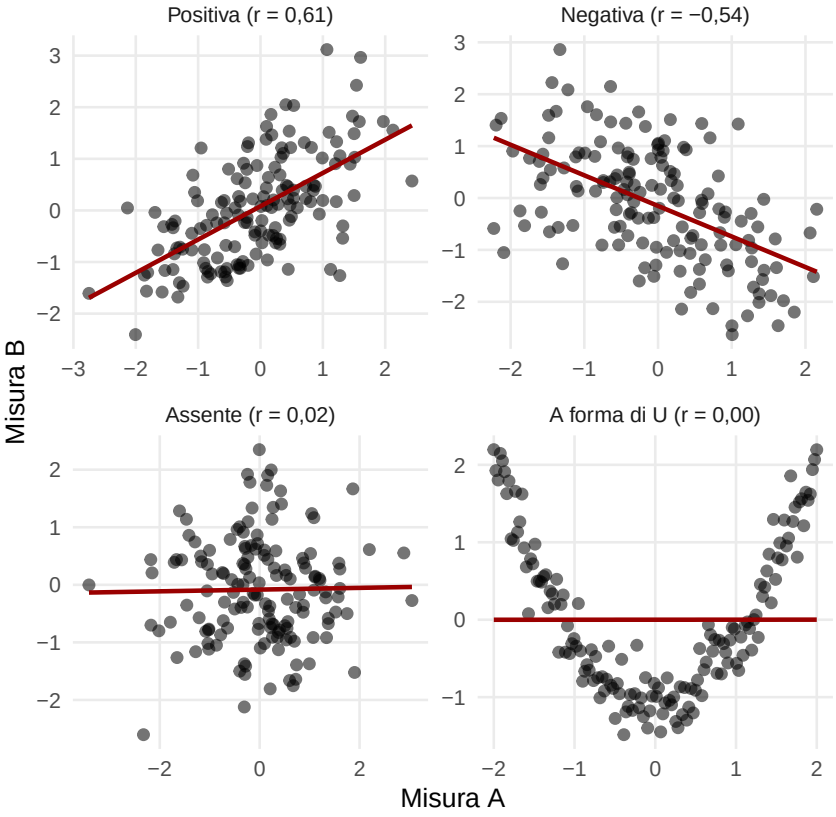


Figura 3.1: Quattro associazioni fra due misure. I primi tre pannelli mostrano dati simulati a scopo illustrativo; il quarto una relazione a U costruita. Il valore di r è calcolato sui punti disegnati.

3.2 Quanto dice un numero

Nelle sintesi della letteratura la correlazione fra QI e risultati scolastici è dell'ordine di 0,5 (Roth et al., 2015). Che cosa significa? Che la tendenza è netta, ma lontana dal determinismo. Molte persone con un punteggio cognitivo sopra la media hanno risultati scolastici nella media o sotto, e viceversa. Le eccezioni non smentiscono la correlazione: sono già incluse nel valore 0,5.

Un errore frequente è leggere r come una percentuale di persone. Un r di 0,5 non vuol dire che metà delle persone segue la regola e metà no. Descrive invece quanto, in media, la posizione in una misura si allinea alla posizione nell'altra. Il capitolo sulle distribuzioni darà a questa idea una forma precisa, attraverso i punti z.

Esistono etichette di comodo: correlazione debole, moderata, forte. Vanno usate con prudenza, perché la grandezza di un effetto dipende dal contesto. In psicologia le correlazioni pubblicate hanno di solito valori modesti: una rassegna di centinaia di meta-analisi sulle differenze individuali ha trovato un valore tipico attorno a 0,20 (Gignac & Szodorai, 2016). In questo panorama 0,5 è un'associazione notevole. Un valore di 0,8 fra due prove è eccezionale e indica spesso che stanno misurando cose molto simili, anche se non basta da solo a stabilire che misurino lo stesso costrutto.

Anche un r piccolo può contare. Un fattore che sposta di poco la probabilità di un esito, applicato a milioni di persone o cumulato per anni, può avere conseguenze consistenti (Funder & Ozer, 2019). Il giudizio sulla grandezza va quindi legato alla domanda: spiegare un meccanismo, prevedere un singolo caso o stimare un effetto su una popolazione sono obiettivi diversi.

> Punto metodologico: la «varianza spiegata»
>
> Nei modelli di regressione si parla spesso di percentuale di varianza spiegata, indicata con R^2. In una regressione lineare semplice, con un solo predittore, R^2 coincide con il quadrato di r. Con $r = 0{,}5$ si ottiene $R^2 = 0{,}25$: si dice allora che il QI «spiega» il 25% della varianza dei voti. «Spiegare» ha qui un significato statistico: indica quanto la retta riduce l'errore di previsione, non quale parte delle cause dei

voti sia stata individuata. Con più predittori, R^2 è il quadrato della correlazione fra il criterio e la loro migliore combinazione lineare.

3.3 Guardare anche la forma

Il coefficiente di Pearson misura l'associazione **lineare**. Se la relazione ha un'altra forma, r può essere ingannevole. Il caso estremo è la relazione a U del quarto pannello della Figura 3.1: i punti seguono una curva evidente, ma r è vicino a zero. Il fenomeno non dipende dal caso. Con i valori $x = -2, -1, 0, 1, 2$ e $y = x^2$, la covarianza è esattamente zero, e quindi anche r, benché y sia determinato del tutto da x. Un r nullo dice «nessuna tendenza lineare», non «nessuna relazione».

Relazioni non lineari sono comuni quando si studia lo sviluppo. Molte abilità crescono rapidamente nell'infanzia, rallentano nell'adolescenza, restano stabili e poi declinano. Una retta descrive male questa traiettoria. Curve più flessibili la descrivono meglio, al prezzo di essere meno facili da riassumere in un solo numero.

Il secondo problema sono i **casi estremi**. Un singolo punto molto lontano dagli altri può spostare r in modo sensibile, perché Pearson pesa le distanze dalla media. Un'alternativa è il coefficiente di **Spearman**, che lavora sui ranghi: ogni valore è sostituito dalla sua posizione nell'ordinamento. Il caso estremo diventa così semplicemente il primo della classifica, senza più far pesare quanto è lontano dagli altri. Spearman descrive un'associazione monotona, cioè sempre crescente o sempre decrescente, anche se non lineare. Non è però una scorciatoia automatica: un valore estremo può essere un errore di inserimento da correggere oppure il dato più interessante del campione. Prima di scegliere il coefficiente, bisogna guardare i dati (Schober et al., 2018).

3.4 Dal campione alla popolazione

Una correlazione calcolata su un campione è una stima. Se lo stesso studio fosse ripetuto su altre persone della stessa popolazione, il valore cambierebbe. Quanto cambierebbe dipende soprattutto dalla numerosità.

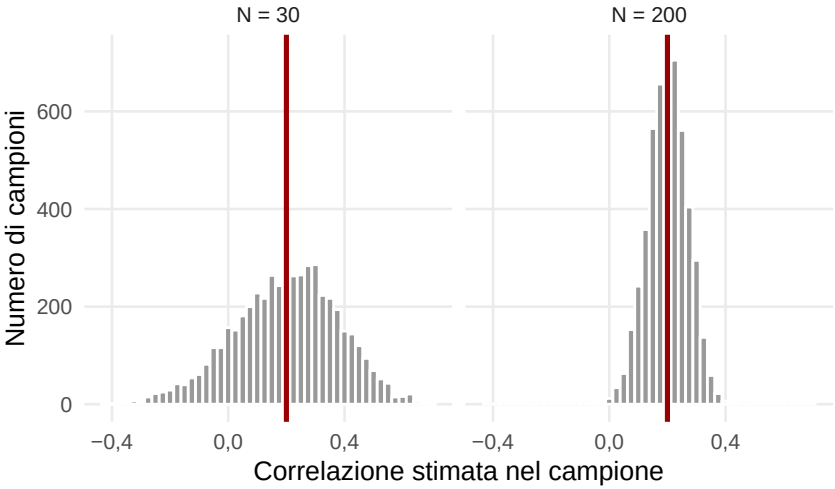


Figura 3.2: Distribuzione delle correlazioni ottenute in 5.000 campioni simulati estratti da una popolazione in cui la correlazione vera è 0,20 (linea verticale). Con 30 persone le stime spaziano da valori negativi a valori molto alti; con 200 si concentrano attorno al valore vero.

La Figura 3.2 mostra il punto con una simulazione. Nella popolazione la correlazione vera è 0,20. Con 30 persone si possono ottenere valori vicini a zero, negativi, oppure doppi del valore vero. Con 200 persone la stima è molto più stabile. Un piccolo studio che trova $r = 0{,}45$ non ha quindi scoperto un effetto grande: ha ottenuto una stima molto imprecisa.

Il **test di significatività** chiede se il valore osservato sia compatibile con una popolazione in cui la correlazione è zero. Il valore p misura questa compatibilità. Non misura la grandezza dell'effetto né la probabilità che l'ipotesi sia vera (Wasserstein & Lazar, 2016). Una correlazione di 0,20 può essere «non significativa» con 30 persone e «significativa» con 200: è cambiata la precisione, non l'effetto. Per questo conviene riportare sempre anche un intervallo di confidenza, che mostra l'ampiezza dell'incertezza.

3.5 Dall'associazione alle spiegazioni

Se due variabili correlano davvero, deve esserci un motivo. Il motivo, però, non è necessariamente che una causi l'altra. Le possibilità principali sono quattro: A causa B; B causa A; le due si influenzano a vicenda; oppure una terza variabile influenza entrambe.

L'esempio classico è quello dei gelati. Nei giorni in cui si vendono più gelati avvengono anche più annegamenti. Nessuno pensa che i gelati facciano annegare: il caldo spinge le persone sia a comprare gelati sia a fare il bagno. La temperatura è una **causa comune**. In rete si trovano raccolte di correlazioni assurde, ottenute confrontando serie temporali che crescono o calano per motivi indipendenti. Fanno sorridere, ma ricordano un fatto serio: una correlazione da sola non indica la direzione causale né esclude terze variabili (Rohrer, 2018).

Un caso meno ovvio riguarda proprio l'intelligenza. QI e anni di istruzione correlano. L'intelligenza favorisce la prosecuzione degli studi? L'istruzione aumenta le abilità cognitive? Entrambe le cose? Oppure condizioni familiari come lo status socioeconomico influenzano sia l'una sia l'altra? Le evidenze disponibili suggeriscono che più di un meccanismo sia all'opera, compreso un effetto causale dell'istruzione sui punteggi (Ritchie & Tucker-Drob, 2018). Per arrivarci non è bastata la correlazione: sono serviti disegni longitudinali ed esperimenti naturali, come i cambiamenti di legge sull'obbligo scolastico.

Anche la sequenza temporale aiuta, ma non risolve tutto. Se A precede B, B non può aver causato A; resta però possibile che una terza variabile abbia preceduto entrambe.

Due concetti aiutano a precisare le ipotesi causali (Figura 3.3). Si parla di **mediazione** quando si ipotizza che A influenzi B attraverso una variabile intermedia M. Per esempio, un consumo elevato di alcol potrebbe peggiorare il rendimento agli esami riducendo la qualità del sonno o il tempo dedicato allo studio. Un modello di mediazione può prevedere anche un percorso diretto da A a B. Va però ricordato che una mediazione stimata con dati raccolti in un unico momento non dimostra il processo nel tempo (Maxwell & Cole, 2007).

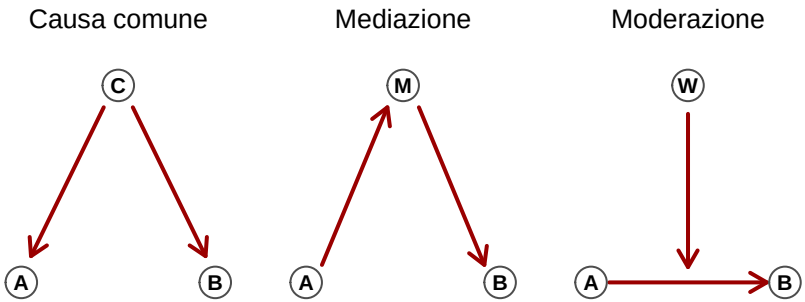


Figura 3.3: Tre schemi causali ipotetici. Le frecce rappresentano ipotesi, non conclusioni ricavabili dalle sole correlazioni.

Si parla di **moderazione** quando la relazione fra A e B cambia in funzione di una terza variabile W (Baron & Kenny, 1986). La presenza di un pubblico tende a migliorare la prestazione in compiti già automatizzati e a peggiorarla in compiti nuovi (Zajonc, 1965): il tipo di compito modera l'effetto del pubblico (Figura 3.4). Nel campo dell'intelligenza un esempio discusso riguarda lo status socioeconomico, che in alcuni studi statunitensi sembra modificare quanto le differenze genetiche si traducono in differenze di punteggio (Turkheimer et al., 2003). Ne riparleremo nel capitolo sull'ereditabilità, insieme ai limiti di questo risultato.

3.6 Quattro controlli prima di fidarsi

Una correlazione è uno dei risultati più semplici della ricerca e uno dei più facili da interpretare male. Prima di trarne conclusioni conviene controllare quattro cose: il segno, che dice la direzione; l'intensità, da leggere nel contesto della domanda; la forma dei dati, che può rendere il coefficiente fuorviante; il disegno dello studio, che decide quali spiegazioni restano in gioco. Saltare l'ultimo passaggio è l'errore più comune. Ed è quello che produce i titoli di giornale peggiori.

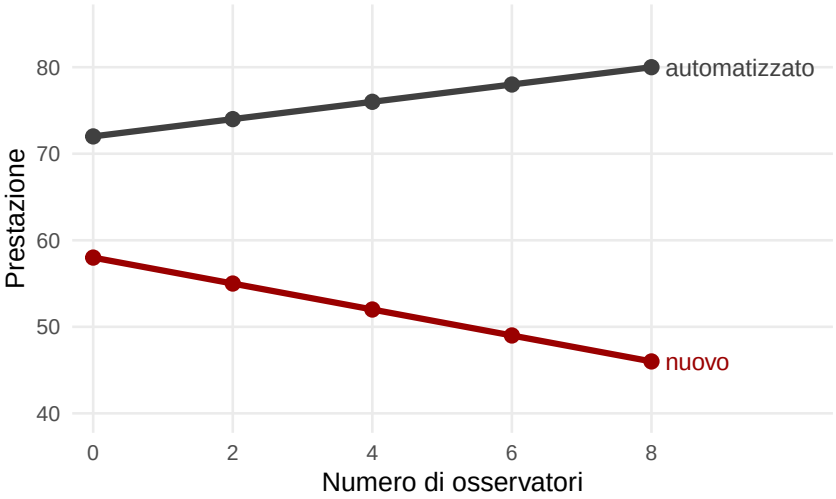


Figura 3.4: Un esempio di moderazione. Al crescere del numero di osservatori la prestazione migliora in un compito già automatizzato e peggiora in un compito nuovo: la relazione fra pubblico e prestazione dipende dal tipo di compito. Valori illustrativi.

In breve

- La correlazione di Pearson riassume direzione e intensità dell'associazione lineare fra due misure, da -1 a $+1$, indipendentemente dalle unità di misura.
- Non indica una percentuale di persone che segue una regola; in psicologia valori attorno a 0,2 sono tipici e 0,5 è un'associazione notevole.
- Un r nullo esclude solo una tendenza lineare: forme curve e casi estremi vanno cercati guardando i dati.
- Con campioni piccoli la stima è molto imprecisa; il valore p non misura né la grandezza dell'effetto né la probabilità che un'ipotesi sia vera.
- Correlazione non significa causalità: cause comuni, direzione inversa e influenze reciproche vanno valutate con disegni

> adeguati.

Riferimenti bibliografici

4 Distribuzioni, punti z e punteggi standardizzati

Un QI di 130 non indica una quantità di intelligenza. Indica una posizione: due deviazioni standard sopra la media della popolazione di riferimento, un livello raggiunto o superato da circa due persone su cento. Tutta la misura psicologica funziona così. Non avendo un metro naturale per le capacità mentali, usa come unità la variabilità fra le persone.

Questo capitolo spiega come. Parte dalla curva gaussiana, il modello di distribuzione su cui poggia gran parte della psicometria, e arriva alle scale che si incontrano nei referti: punti z, QI, punteggi ponderati, punti T, percentili. Poi mostra dove il modello è una buona approssimazione e dove è una scelta teorica che conviene riconoscere come tale.

4.1 Una curva che si trova ovunque

Molte caratteristiche fisiche e biologiche si distribuiscono in modo simile: la statura degli adulti, il peso alla nascita, la pressione sanguigna a riposo, le dimensioni di foglie e organi, gli errori nelle misure ripetute di una stessa grandezza. La maggior parte dei casi si concentra attorno a un valore centrale; allontanandosi in entrambe le direzioni i casi diventano sempre più rari. Il grafico ha la forma di una campana.

Questa forma è la **distribuzione gaussiana**, o normale. Ha tre proprietà importanti:

- è **simmetrica** attorno alla media;
- è descritta completamente da due parametri, la **media** ( ) e la **deviazione standard** ( ), che misura la dispersione dei valori attorno alla media;
- esistono corrispondenze fisse fra distanza dalla media, espressa in deviazioni standard, e proporzione di casi.

Circa il 68% dei casi cade entro una deviazione standard dalla media, circa il 95% entro due, quasi tutti entro tre. Oltre due deviazioni standard sopra la media si trova circa il 2,3% dei casi; lo stesso vale sotto. Queste proporzioni valgono per qualunque gaussiana, qualunque siano media e unità di misura.

4.2 Da dove nasce la campana

Perché tante grandezze diverse assumono la stessa forma? La risposta è un risultato della teoria della probabilità, il **teorema del limite centrale**: la somma di molti fattori indipendenti, ciascuno con un piccolo effetto, tende a distribuirsi in modo gaussiano, quasi indipendentemente da come sono distribuiti i singoli fattori.

Un'immagine utile è la passeggiata di una persona ubriaca che cerca di seguire una linea retta. A ogni passo barcolla un po' a destra o un po' a sinistra, a caso. Dopo mille passi dove si troverà? Probabilmente non lontano dalla linea, perché molte deviazioni si compensano. Talvolta, per una serie di sbandate nella stessa direzione, sarà parecchio distante. Se ripetessimo l'esperimento con migliaia di passeggiate, le posizioni finali formerebbero una campana. Lo stesso principio è reso visibile dalla tavola di Galton, in cui palline che rimbalzano a caso su file di chiodi si accumulano in una distribuzione a campana. La Figura 4.1 mostra il fenomeno con una simulazione.

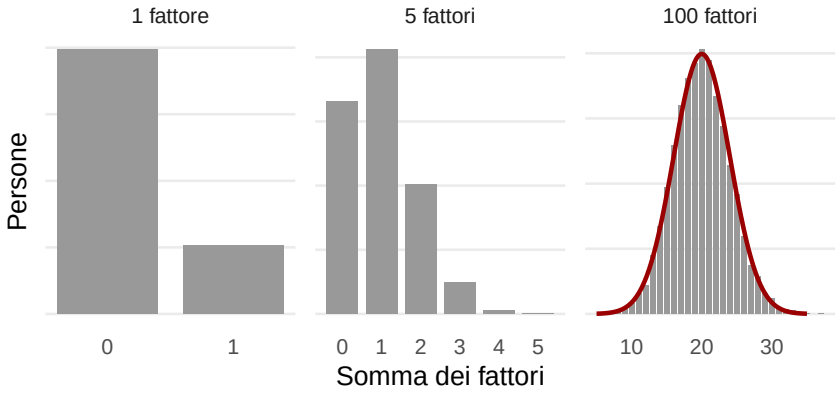


Figura 4.1: Il teorema del limite centrale in una simulazione. Ogni persona riceve un certo numero di fattori indipendenti, ciascuno di effetto asimmetrico (vale 1 con probabilità 0,2, altrimenti 0). Un fattore solo produce una distribuzione per nulla gaussiana; la somma di molti fattori si avvicina alla campana (curva rossa). Dati simulati su 10.000 persone.

Per l'intelligenza l'ipotesi additiva non è solo un'analogia. Le differenze genetiche associate alle abilità cognitive dipendono da migliaia di varianti, ciascuna con un effetto minuscolo (Davies et al., 2018; Savage et al., 2018). A queste si aggiungono innumerevoli influenze ambientali, educative, motivazionali e situazionali, compresa un po' di casualità nelle risposte a un test. Le abilità cognitive sono quindi **poligeniche**, perché molti geni influiscono sullo stesso tratto, e i loro effetti sono in larga parte condivisi tra abilità diverse (Kovas & Plomin, 2006). Un risultato di tanti piccoli contributi sommati è esattamente il tipo di processo che genera una gaussiana.

Vale la pena notare l'ordine storico. La scelta di modellare le abilità come gaussiane è nata molto prima che se ne conoscessero le basi genetiche. Sembrava naturale. Le evidenze successive l'hanno resa più plausibile, ma resta in parte una scelta teorica, come vedremo.

4.3 La variabilità come unità di misura

La statura si misura in centimetri, e un centimetro vale lo stesso ovunque. Le abilità mentali sono invece **variabili latenti**: non si vedono e non hanno un'unità naturale. Dieci risposte corrette in una prova non sono confrontabili con dieci risposte corrette in un'altra, perché dipendono dal numero e dalla difficoltà degli item.

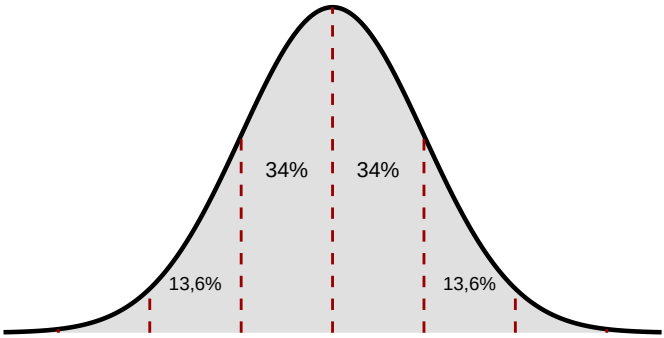
La soluzione è esprimere ogni punteggio come distanza dalla media della popolazione di riferimento, usando la deviazione standard come unità. Questa trasformazione si chiama **standardizzazione** e produce i **punti *z***:

$$z = \frac{x - \mu}{\sigma}$$

Un punto z di $+1$ indica un punteggio una deviazione standard sopra la media; -2 due deviazioni standard sotto. Lo zero è la media. La metrica non dice più «quanto» in senso assoluto, ma «quanto distante dagli altri».

Quasi tutti i punteggi usati nei test psicologici sono punti z riscalati, cioè moltiplicati per una costante e spostati per evitare decimali e numeri negativi (Figura 4.2):

- **QI e indici compositi** delle batterie di intelligenza: media 100, deviazione standard 15. Un QI di 115 corrisponde a $z = +1$.
- **Punteggi ponderati** dei singoli subtest: media 10, deviazione standard 3.
- **Punti T**, comuni nei questionari clinici: media 50, deviazione standard 10.
- **Percentili**: la percentuale di persone della popolazione di riferimento con un punteggio inferiore o uguale.



Punti z	−3	−2	−1	0	+1	+2	+3
QI e indici	55	70	85	100	115	130	145
Ponderati	1	4	7	10	13	16	19
Punti T	20	30	40	50	60	70	80
Percentili	0,1	2	16	50	84	98	99,9

Figura 4.2: La curva gaussiana e le principali scale di punteggio. Ogni riga riporta lo stesso punto della distribuzione espresso in una metrica diversa.

I percentili sono molto usati in clinica perché sono intuitivi. Hanno però un limite: non sono una scala a intervalli uguali. Al centro della distribuzione una piccola differenza di abilità sposta molti percentili; nelle code una grande differenza ne sposta pochi. Passare dal 50° all'84° percentile richiede una deviazione standard; passare dall'84° al 98° ne richiede un'al-

tra. Per questo non ha senso fare la media dei percentili, e nella ricerca si preferiscono i punti z.

Questa metrica permette anche di rendere preciso un concetto del capitolo precedente. Se la relazione fra due misure è lineare, il valore atteso di una persona nella seconda misura, espresso in punti z, è r volte il suo punto z nella prima:

$$\widehat{z_Y} = r\, z_X$$

Con $r = 0{,}5$, chi si trova a $z = +1$ nel QI ha come previsione $z = +0{,}5$ nei risultati scolastici. La previsione si avvicina alla media: è il fenomeno della **regressione verso la media**, che si presenta ogni volta che due misure non sono perfettamente correlate.

4.4 Essere rari

Definire i punteggi come distanze dalla media ha una conseguenza importante: la rarità statistica diventa, di per sé, un'informazione potenzialmente rilevante.

La disabilità intellettiva non è definita da un livello di funzionamento basso in assoluto, ma basso rispetto a quello della popolazione, insieme a difficoltà nel comportamento adattivo. Una società organizza scuole, lavori e servizi attorno a ciò che la maggior parte delle persone riesce a fare. Chi si trova molto sotto quella soglia incontra ostacoli concreti. Lo stesso vale per la dislessia: la scuola è costruita attorno a un ritmo medio di apprendimento della lettura, e chi ne è molto distante resta indietro. E per l'ADHD: livelli di attenzione o di impulsività diventano problematici soprattutto quando divergono da ciò che il contesto richiede.

Il ragionamento vale anche all'altro estremo. Un'abilità molto superiore alla media è rara, e la rarità può comportare un disallineamento con il contesto: un programma scolastico troppo lento, interessi poco condivisi con i coetanei. Essere statisticamente insoliti non è una diagnosi. È però una ragione per guardare meglio.

Punto metodologico: il d di Cohen

La stessa logica dei punti z serve a misurare la differenza fra due gruppi o due condizioni. Il **d di Cohen** è la differenza fra due medie divisa per la deviazione standard:

$$d = \frac{M_1 - M_2}{DS}$$

Un d di 0,5 indica che le due medie distano mezza deviazione standard. Le soglie tradizionali definiscono «piccolo» un d di 0,2, «medio» 0,5 e «grande» 0,8. Sono convenzioni proposte in assenza di dati migliori. Le revisioni degli effetti replicati in psicologia suggeriscono che effetti veri attorno a 0,3–0,4 siano già consistenti e che le soglie andrebbero abbassate (Funder & Ozer, 2019). Come per la correlazione, la grandezza va giudicata nel contesto.

4.5 Quando i dati non sono gaussiani

Fin qui il modello. I dati osservati, però, spesso non hanno la forma di una campana, e non per ragioni profonde. Dipende dallo strumento di misura. Un test con pochi item facili produce molti punteggi massimi; uno con item difficili produce molti zeri. I tempi di risposta non possono scendere sotto lo zero e hanno una lunga coda di risposte lente. Le risposte su scala Likert sono poche categorie ordinate. Nei test cognitivi è frequente osservare distribuzioni dei punteggi grezzi asimmetriche, con un accumulo vicino al punteggio massimo.

Chi analizza i dati ha diverse strade. Può ignorare il problema e assumere comunque la normalità, sperando che non faccia danni: è la scelta più frequente, spesso per mancanza di alternative conosciute. Può usare test non parametrici, che però limitano le analisi possibili. Può usare modelli statistici che descrivono correttamente la distribuzione della risposta osservata, come i modelli lineari generalizzati. Oppure, quando si costruisce un test, può intervenire direttamente sulla scala dei punteggi.

Le procedure sono due (Figura 4.3). La **trasformazione lineare** in punti z sottrae la media e divide per la deviazione standard. È semplice e molto

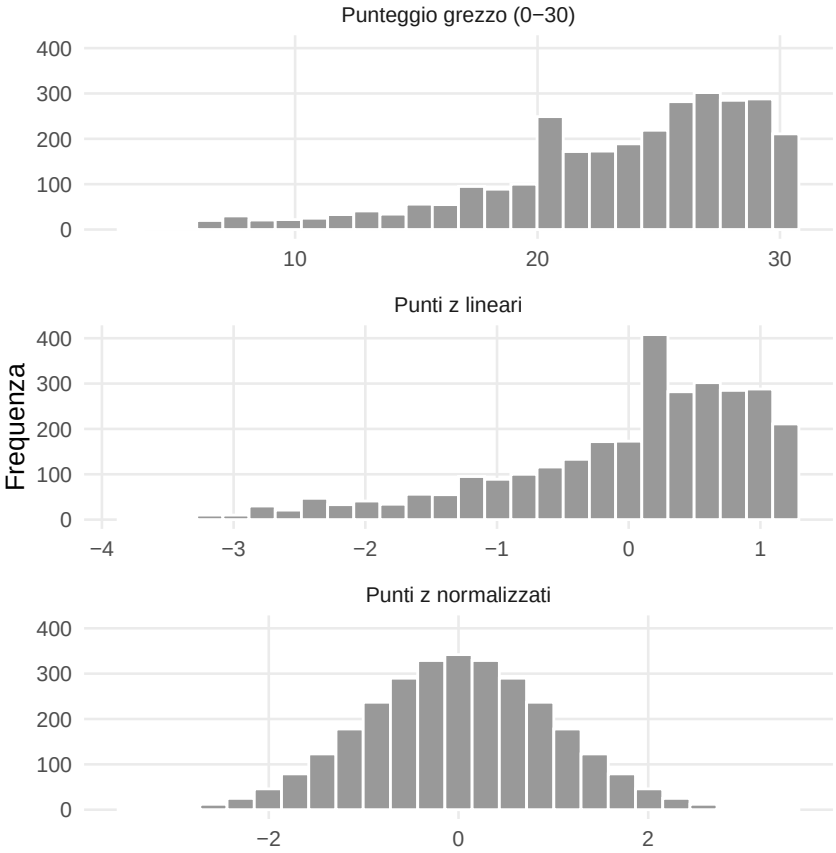


Figura 4.3: Punteggi grezzi simulati di una prova con effetto tetto (primo pannello) e due modi di trasformarli. La trasformazione lineare in punti z conserva l'asimmetria; la normalizzazione rimappa i punteggi sulla gaussiana attraverso i percentili. Per semplicità, i punteggi a pari merito sono qui distribuiti fra percentili adiacenti.

usata, ma conserva la forma originale: se i punteggi grezzi sono asimmetrici, lo sono anche i punti z, e le corrispondenze fra z e percentili non valgono più. La **normalizzazione** assegna invece a ogni punteggio grezzo il punto z corrispondente al suo percentile nella gaussiana. Il risultato è una distribuzione a campana per costruzione.

La normalizzazione è la procedura tipica delle tabelle normative dei test di intelligenza. Ogni tabella di conversione da punteggio grezzo a ponderato è, in sostanza, una normalizzazione calcolata separatamente per ogni fascia d'età: un certo numero di risposte corrette viene tradotto nel ponderato corrispondente alla stessa posizione nella distribuzione dei coetanei. In fondo a una tabella del genere c'è un'ipotesi esplicita: l'abilità latente è distribuita in modo gaussiano, mentre la forma irregolare dei punteggi grezzi riflette le caratteristiche dello strumento.

4.6 Che tipo di scala?

Le scale di misura si distinguono per le operazioni che consentono.

Tabella 4.1: Scale di misura e operazioni consentite.

Scala	Che cosa si può dire	Esempi
Categoriale	Uguale o diverso	Diagnosi sì/no; gruppo sperimentale o di controllo
Ordinale	Maggiore o minore	Risposta a un item Likert
A intervalli	Distanze uguali; zero arbitrario	Temperatura in gradi Celsius; punti z ben costruiti
A rapporti	Anche «il doppio» e «la metà»; zero assoluto	Tempi; numero di errori; temperatura in kelvin

Il percorso tipico della misura psicologica è curioso. Si parte spesso da dati ordinali, come le risposte agli item di un questionario, o da dati a rapporti,

come il numero di risposte corrette. Poi si convertono in punti z, che sono una scala a intervalli. Il motivo è sempre lo stesso: ciò che interessa è una variabile latente, il cui zero è ignoto. Ecco perché non ha senso dire che una persona con QI 140 è «il doppio più intelligente» di una con QI 70. Lo zero della scala non corrisponde all'assenza di intelligenza.

4.7 Oltre la gaussiana

Non tutte le distribuzioni nascono dalla somma di piccoli effetti. Due eccezioni sono rilevanti.

La prima è la **mistura**. Il peso alla nascita è approssimativamente gaussiano, ma con un eccesso di neonati sottopeso dovuto a condizioni patologiche che agiscono come una popolazione a sé. L'intelligenza nella popolazione generale mostra un fenomeno simile: la coda inferiore contiene più casi del previsto, perché sindromi genetiche, mutazioni rare e danni neurologici precoci producono effetti molto grandi, che non si sommano ai piccoli contributi ordinari ma li sovrastano.

La seconda è la distribuzione **log-normale**, prodotta da fattori che si moltiplicano anziché sommarsi. Si pensi a un esito sociale come il reddito: se istruzione, salute, opportunità e abilità interagiscono in modo moltiplicativo, basta che uno manchi quasi del tutto per azzerare il risultato, mentre una combinazione favorevole di tutti produce valori estremi. Da qui code molto lunghe e la concentrazione di ricchezza osservata in molte società. Questo modello è più adatto agli esiti sociali che alle caratteristiche psicologiche di base.

Come sappiamo che l'intelligenza è il prodotto di effetti additivi e non moltiplicativi? In realtà non lo sappiamo con certezza. Le distribuzioni approssimativamente simmetriche dei punteggi grezzi sono un indizio debole, perché gli item vengono selezionati proprio per ottenere quella simmetria. Per alcune abilità, come lettura e matematica, sono stati ipotizzati meccanismi cumulativi, in cui chi parte avvantaggiato accumula vantaggi ulteriori. Qualcosa di simile è stato proposto anche per l'intelligenza, attraverso il legame con la scolarizzazione. La gaussiana resta il modello di riferimento: utile, plausibile, ma non un fatto di natura.

In breve

- La gaussiana descrive bene grandezze prodotte dalla somma di molti piccoli effetti; le abilità cognitive, fortemente poligeniche, sono un caso plausibile.
- Non avendo un'unità naturale, la misura psicologica usa la deviazione standard come unità: QI, punteggi ponderati e punti T sono punti z riscalati.
- I percentili sono intuitivi ma non hanno intervalli uguali; la rarità statistica è un indizio da approfondire, non una diagnosi.
- I punteggi grezzi spesso non sono gaussiani per ragioni legate allo strumento; la normalizzazione delle tabelle normative assume che lo sia l'abilità latente.
- Lo zero della scala del QI è arbitrario: rapporti come «il doppio» non hanno senso.

Riferimenti bibliografici

5 Quando una misura è buona

Una bilancia da cucina che sbaglia di quindici grammi è inutile per dosare il lievito. Una bilancia pesapersone che sbaglia di tre chili è inutile per seguire una dieta. Entrambe misurano il peso, e nessuno lo mette in dubbio. Eppure nessuno le userebbe per quegli scopi. Misurare la cosa giusta non basta: serve misurarla abbastanza bene per l'uso che se ne fa. In psicologia lo stesso ragionamento vale per ogni test, con una complicazione: ciò che vogliamo misurare non si vede.

Le abilità cognitive sono variabili latenti. Le stimiamo a partire da risposte a compiti, e il punteggio che ne ricaviamo è il risultato di una catena di inferenze. Come facciamo a sapere che quel numero va bene? La psicometria ha sviluppato una serie di criteri. Questo capitolo li presenta e li applica ai test di intelligenza, che nel panorama della misura psicologica hanno indici di qualità fra i più alti. Proprio per questo è utile vedere dove anche loro incontrano dei limiti.

5.1 Quattro domande su un test

I criteri principali possono essere riassunti in quattro domande.

- **Validità.** Il test misura davvero ciò che dovrebbe misurare, e permette le interpretazioni e le previsioni per cui viene usato?
- **Attendibilità**, o affidabilità. Il punteggio è preciso e stabile? Se ripetessi la misura, otterrei un risultato simile?
- **Sensibilità.** Lo strumento distingue bene i diversi livelli di abilità? Se è usato a scopo diagnostico, separa bene chi ha una condizione da chi non ce l'ha?
- **Robustezza.** Il test resta valido e attendibile anche in condizioni non ideali: una popolazione diversa da quella di riferimento, una condizione del neurosviluppo, una somministrazione non standard, una ripetizione ravvicinata?

Le batterie di intelligenza ben costruite superano bene le prime tre prove. La quarta dipende dalla situazione: nessun test è robusto in ogni circostanza, ma esistono contromisure note. Vediamole una per una.

5.2 Validità: che cosa misura il test?

Nella formulazione moderna la validità non è una proprietà del test, ma del sostegno che evidenze e teoria offrono a una specifica interpretazione dei punteggi per un certo uso (American Educational Research Association et al., 2014). Si accumula attraverso diversi tipi di evidenza.

La **validità di contenuto** chiede se le prove coprono in modo appropriato il dominio da misurare. Per l'intelligenza la questione ha una storia curiosa. Spearman osservò che quasi qualunque compito cognitivo, purché impegnativo, fornisce informazioni sul fattore generale. Chiamò questo fenomeno **indifferenza dell'indicatore** (Spearman, 1927). Costruire un test che misuri il fattore generale è quindi, in un certo senso, facile: basta combinare prove abbastanza diverse e bilanciarle in modo sensato (Warne, 2020). Le batterie moderne preferiscono comunque una base teorica esplicita, di solito il modello gerarchico che vedremo nel capitolo sui modelli dell'intelligenza.

La **validità strutturale** chiede se le correlazioni fra item, subtest e indici seguono un modello teorico plausibile. Si verifica con l'analisi fattoriale confermativa, valutando quanto il modello si adatta ai dati.

La **validità convergente** chiede se il test correla con altri test dello stesso costrutto. Per l'intelligenza è eccellente: i QI ottenuti con strumenti diversi correlano in genere almeno 0,70, spesso molto di più.

La **validità predittiva** chiede se il punteggio prevede esiti che, in base alla teoria, dovrebbe prevedere: rendimento scolastico, formazione e prestazione lavorativa, salute. È il punto di forza dei test di intelligenza, e vi dedicheremo un'intera parte del libro.

La **validità discriminante** chiede se il test non misuri anche cose che non dovrebbe misurare. Per l'intelligenza è un criterio delicato: un'abilità generale ha molte ragioni teoriche per correlare con molte altre variabili, e una correlazione con lo status socioeconomico, per esempio, non è di per sé un segno di contaminazione.

Infine l'**invarianza di misura** chiede se il punteggio si interpreta allo stesso modo in gruppi diversi. Possiamo leggere il QI totale di un bambino con ADHD o con autismo come quello di un bambino a sviluppo tipico? E quello di un bambino cresciuto in un'altra lingua? Non è una proprietà fissa del

test, ma della combinazione fra test, gruppo e interpretazione. Torneremo su questo punto nel capitolo sulla valutazione nel neurosviluppo.

5.3 Attendibilità come stabilità

Un modo diretto di valutare la precisione è somministrare lo stesso test due volte e correlare i punteggi. È l'**attendibilità test-retest**. Le differenze fra le due misure possono avere due origini: un errore casuale, legato a oscillazioni dell'attenzione, all'ora del giorno o alla stanchezza; oppure un cambiamento reale del funzionamento. Per il QI i cambiamenti reali a breve termine sono modesti. Esiste anche un effetto pratica, perché la seconda volta le prove sono meno nuove, ma è abbastanza prevedibile da poter essere considerato. In genere una stabilità sotto 0,70 si considera problematica, se si possono escludere cambiamenti reali.

Nei manuali tecnici delle batterie per adulti il QI totale, risomministrato dopo poche settimane, ha correlazioni test-retest attorno a 0,95. Sembra quasi perfetto. Ma che cosa significa per un singolo caso? La Figura 5.1 lo mostra con una simulazione. Anche con una stabilità di 0,96 la differenza tipica fra due somministrazioni è di circa quattro punti, e in un caso su venti supera gli otto. Con una stabilità di 0,70 la differenza tipica sale a circa dodici punti e in un caso su venti supera i venti.

In età evolutiva e su intervalli lunghi la stabilità è inferiore. In uno studio su 344 studenti valutati due volte con la WISC-IV a quasi tre anni di distanza, la stabilità del QI totale era 0,82, quella degli indici fra 0,65 e 0,76. Un quarto degli studenti aveva QI totali che differivano di dieci punti o più (Watkins & Smith, 2013). Una parte della variazione è certamente reale: i bambini cambiano, e una valutazione può dover essere aggiornata. Ma la conclusione pratica non cambia: un singolo punteggio, soprattutto di un indice, non è una fotografia definitiva.

Nel lungo periodo, però, la stabilità dell'ordinamento fra le persone è notevole. Nella coorte scozzese testata a 11 anni nel 1932 e ritestata quasi settant'anni dopo, la correlazione fra i punteggi alle due età era dell'ordine di 0,6–0,7 (Deary et al., 2000, 2004). Poche caratteristiche psicologiche mostrano una continuità simile lungo l'intera vita adulta.

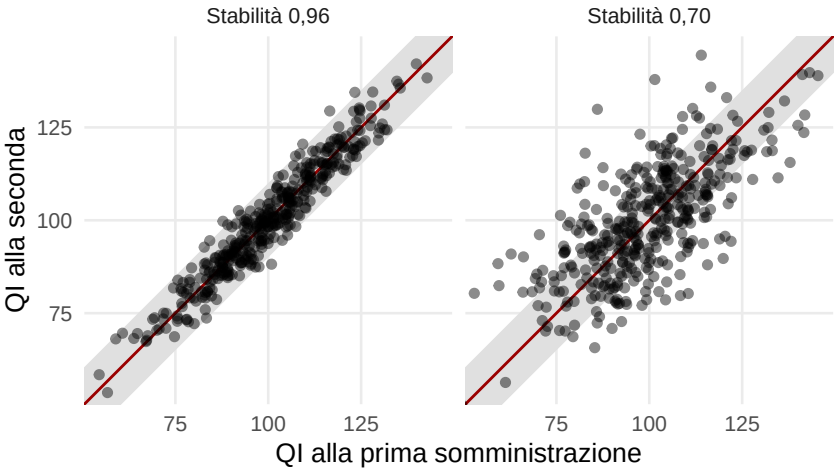


Figura 5.1: Punteggi di QI simulati in due somministrazioni dello stesso test, con stabilità test-retest di 0,96 e di 0,70. La linea diagonale indica punteggi identici; la fascia grigia comprende le differenze entro ±10 punti.

5.4 Attendibilità come consistenza interna

Il secondo modo di stimare l'attendibilità non richiede due somministrazioni. Guarda alla coerenza fra le parti di un test: quanto gli item, o i subtest, misurano la stessa cosa.

Il ragionamento parte dalla **teoria classica dei test**. Il punteggio osservato X è la somma di un punteggio vero T, che rappresenta il costrutto latente, e di un errore E:

$$X = T + E$$

L'attendibilità è la quota della varianza di X dovuta a T. Come si stima, se T non si vede? Sotto certe assunzioni, la si ricava dalla forza delle correlazioni fra gli elementi e dal loro numero. Correlazioni medie più alte indicano che ogni elemento contiene meno errore; più elementi permettono

agli errori casuali di compensarsi. Un punteggio molto attendibile si ottiene quindi con elementi fortemente correlati, oppure con molti elementi.

L'indice più noto è l'**alfa di Cronbach** ( ). Assume che tutti gli elementi rappresentino il costrutto nella stessa misura, un'ipotesi spesso irrealistica. Oggi si preferiscono indici basati su un modello fattoriale, come l'**omega di McDonald** ( ) (McNeish, 2018). Anche qui si cita spesso una soglia minima di 0,70.

Che cosa significa un'attendibilità di 0,70? Che il punteggio osservato condivide il 70% della varianza con il punteggio vero. La correlazione fra i due è quindi la radice quadrata: circa 0,84. Le batterie di intelligenza raggiungono per il QI totale valori superiori a 0,95. Per gli indici di dominio si scende di solito fra 0,80 e 0,90, per i singoli subtest a volte sotto.

Dall'attendibilità si ricava l'**errore standard di misura**, cioè la deviazione standard degli errori attorno al punteggio vero. Sulla scala del QI vale $15 \times \sqrt{(1 - \text{attendibilità})}$. Con un'attendibilità di 0,97 è di circa 2,6 punti; con 0,85 sale a quasi 6. Per questo un referto serio riporta il punteggio con un intervallo di confidenza, non come un numero esatto.

5.5 Il problema degli indici

Fin qui il quadro è rassicurante. Il problema nasce quando dal QI totale si passa agli indici: comprensione verbale, ragionamento visuo-percettivo, memoria di lavoro, velocità di elaborazione e così via. Nella pratica clinica si interpretano spesso profili e discrepanze fra indici. Sono abbastanza attendibili per farlo?

L'attendibilità di un indice, calcolata come se fosse una scala a sé, è buona. Ma un indice di memoria di lavoro riflette in buona parte il fattore generale, perché tutte le abilità cognitive sono correlate. La domanda giusta è un'altra: quanta parte del punteggio di un indice è specifica di quel dominio, al netto del fattore generale? E questa parte è attendibile?

Per rispondere si usano modelli gerarchici o **bifattoriali**, che separano la varianza comune a tutte le prove da quella propria di ciascun dominio. Da essi si ricava l'**omega gerarchico** ($_{\text{h}}$), che stima quanta varianza del punteggio è dovuta a un solo fattore (Rodriguez et al., 2016) (Figura 5.2). I risultati sui campioni normativi delle principali batterie sono convergenti.

Il fattore generale ha un omega gerarchico elevato, attorno a 0,75–0,80. I domini specifici, al netto di *g*, scendono spesso sotto 0,30 e talvolta vicino a zero (Gignac & Kretzschmar, 2017; Watkins, 2006). Le rianalisi delle edizioni più recenti, come la WISC-V, mostrano lo stesso schema (Canivez et al., 2017), e così i dati normativi italiani. Nel campione di taratura italiano della WISC-IV i fattori di dominio contribuiscono in misura trascurabile, al netto del fattore generale (Kush & Canivez, 2019); lo stesso modello è stato applicato anche al confronto con ampi campioni di bambini con disturbi dell'apprendimento (Giofrè et al., 2019). Nel campione di taratura italiano dell'IDS-2, su 1.281 bambini e ragazzi, il fattore generale ha un omega gerarchico di 0,77, mentre quello dei fattori specifici varia fra 0,08 e 0,51 (Toffalini & Cornoldi, 2026). In tutti questi casi il fattore generale risulta attendibile e interpretabile, i fattori di dominio quasi mai abbastanza da essere letti da soli.

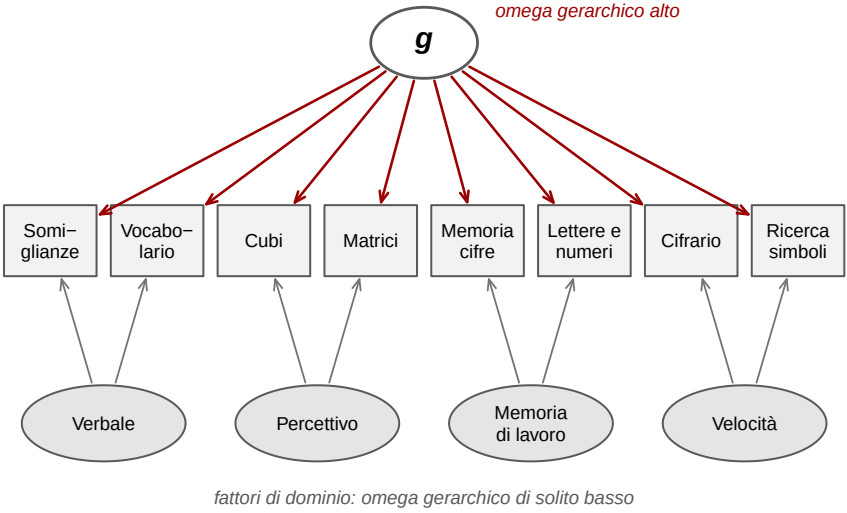


Figura 5.2: Un modello bifattoriale per una batteria con quattro domini. Ogni subtest dipende dal fattore generale g (frecce rosse) e da un fattore di dominio (frecce grigie); i fattori di dominio catturano solo ciò che resta al netto di g. Con i dati delle batterie reali l'omega gerarchico di g è alto, quello dei domini di solito basso. Schema originale.

Le conclusioni tratte da questi dati sono di due tipi. Alcuni ricercatori sostengono che sia semplicemente inappropriato interpretare gli indici di dominio e che ci si debba limitare al QI totale (Gignac & Kretzschmar, 2017; Watkins, 2006). Una posizione più equilibrata ammette l'interpretazione degli indici, ma solo se motivata dal caso specifico e sostenuta da evidenze convergenti: per esempio quando si valuta una condizione per cui un certo profilo è atteso sulla base della letteratura (Giofrè et al., 2017; Toffalini et al., 2017). In entrambi i casi la lettura disinvolta di ogni discrepanza fra indici, senza tener conto dell'errore di misura, non regge.

5.6 Sensibilità e robustezza

Un test sensibile distingue bene i livelli di abilità in tutto l'intervallo che interessa. Le batterie di intelligenza coprono per progetto un ampio intervallo, di solito da QI attorno a 40 fino a 160. Gli effetti tetto, in cui molte persone raggiungono il punteggio massimo, sono rari e gestiti con versioni diverse dello stesso strumento: forme per bambini, forme avanzate per adulti con abilità elevate, prove non verbali per chi ha difficoltà linguistiche marcate.

La robustezza è più difficile da garantire. Una persona con una disabilità motoria non può essere valutata con prove a tempo che richiedono manipolazione; una persona con ADHD può essere penalizzata in modo sproporzionato dalle prove di memoria di lavoro e velocità; una persona che non padroneggia la lingua italiana sarà svantaggiata nelle prove verbali. Per questi casi esistono contromisure: indici che escludono le componenti più problematiche, come l'indice di abilità generale al posto del QI totale; batterie non verbali; sostituzioni di subtest e procedure di stima parziale previste dai manuali. Le contromisure funzionano se si sa quando servono. Usarle richiede di conoscere la persona, non solo lo strumento.

5.7 Una misura buona, non infallibile

I test di intelligenza ben costruiti sono fra gli strumenti più validi e attendibili della psicologia. Questo giustifica la fiducia nel QI totale come stima del funzionamento cognitivo generale. Non giustifica la fiducia indiscriminata

in ogni numero che compare in un referto. Il QI ha un margine di errore che va dichiarato. Gli indici di dominio portano un'informazione specifica modesta e vanno interpretati con argomenti. La robustezza dipende da chi è la persona valutata.

In breve

- La qualità di un test si giudica per validità, attendibilità, sensibilità e robustezza; la validità riguarda un'interpretazione per un uso, non il test in sé.
- Le batterie di intelligenza hanno validità convergente e predittiva elevate e una stabilità notevole anche su decenni.
- Anche un'attendibilità di 0,95 lascia differenze di alcuni punti fra due somministrazioni; i punteggi vanno riportati con un intervallo di confidenza.
- Gli indici di dominio, al netto del fattore generale, sono poco attendibili: la loro interpretazione va motivata e corroborata.

Riferimenti bibliografici

Parte III

Modelli e test dell'intelligenza

6 Il fattore generale e la positive manifold

Chi va bene in un test cognitivo tende ad andare bene anche negli altri. Non in tutti allo stesso modo, non sempre, ma con una regolarità che più di un secolo di ricerca non è riuscito a smentire. Vocabolario e rotazione mentale, memoria di cifre e ragionamento con le matrici, aritmetica e velocità nel confrontare simboli: compiti che non si assomigliano in nulla producono punteggi correlati positivamente. Questo fatto ha un nome, **positive manifold**, ed è il punto di partenza obbligato di ogni teoria dell'intelligenza.

La domanda è se l'intelligenza sia una cosa sola o molte. Assomiglia alla personalità, che si descrive con diverse dimensioni distinte? Oppure tutto tende a convergere su un'unica dimensione? E il QI riflette qualcosa di reale, con basi biologiche, o è solo la somma di abilità diverse a cui si è dato un nome solo? Lo studio dell'intelligenza ha oscillato a lungo fra un approccio **unitario** e uno **multiplo**. Questo capitolo presenta il primo, nella forma che gli diede Charles Spearman. Il prossimo presenta le alternative e la sintesi gerarchica oggi prevalente.

6.1 Perché le prestazioni correlano?

Il capitolo sulla correlazione ha elencato le spiegazioni possibili di un'associazione: A causa B, B causa A, le due si influenzano a vicenda, oppure una terza variabile influenza entrambe. Applichiamole a due prove cognitive. Che il vocabolario causi direttamente la capacità di ruotare mentalmente una figura è implausibile, almeno nel presente di un adulto. Che accada il contrario, altrettanto. Resta l'ipotesi più semplice: una causa comune. Un'influenza reciproca accumulata durante lo sviluppo non è esclusa, ed è la base delle alternative discusse negli approfondimenti finali; ma richiede una storia più lunga da raccontare.

Nel 1904 Spearman pubblicò un'analisi delle correlazioni fra misure molto eterogenee, raccolte su bambini delle scuole: voti in varie materie, discriminazioni sensoriali, giudizi degli insegnanti. Notò che tutte le correlazioni erano positive e che il loro schema poteva essere spiegato da un unico fattore sottostante, comune a tutte le misure, più una componente specifica

di ciascuna (Spearman, 1904). Chiamò il primo **fattore generale**, o g; le seconde fattori specifici, o s.

Gli indicatori usati da Spearman erano rudimentali. Pochi anni dopo Binet e Simon avrebbero costruito le prime batterie di prove cognitive simili a quelle moderne. Ma l'idea era già completa: le prestazioni osservate sono indizi di una capacità comune che non si osserva direttamente.

6.2 Un fattore latente, spiegato con lo sport

L'idea di fattore latente è più intuitiva di quanto sembri. Prendiamo un esempio che con l'intelligenza non ha nulla a che fare. Misuriamo in un ampio gruppo di persone il tempo per nuotare una vasca, il tempo per percorrere dieci chilometri in bicicletta, la lunghezza di un salto, la precisione nei tiri liberi a basket. Nella popolazione generale queste prestazioni saranno correlate. Chi nuota velocemente tende anche a pedalare velocemente e a saltare lontano.

Perché? Non perché il nuoto migliori il salto. Esistono caratteristiche comuni che favoriscono tutte queste attività: forza muscolare, coordinazione, composizione corporea, flessibilità, età. Possiamo chiamarle insieme «atleticità». Ogni prova dipende inoltre da componenti specifiche, come l'allenamento in quella disciplina o la statura per il basket. Un modello con un fattore generale e tanti fattori specifici spiega le correlazioni in modo parsimonioso. Fra atleti olimpici, molto selezionati e specializzati, le correlazioni potrebbero quasi sparire; nella popolazione generale sono forti. La Figura 6.1 traduce l'esempio in un modello.

Lo stesso schema vale per la personalità. Le risposte ad affermazioni come «mi piace conoscere persone nuove», «mi riesce facile iniziare una conversazione con uno sconosciuto», «mi piace essere al centro dell'attenzione» sono correlate. Il fattore comune si chiama estroversione. Nessuno lo osserva direttamente; lo si inferisce dalle correlazioni e lo si usa perché spiega e prevede.

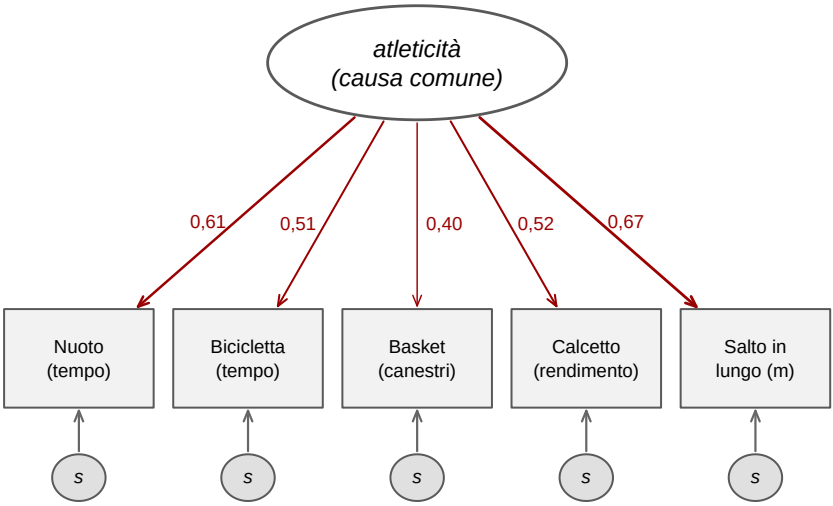


Figura 6.1: Un fattore latente fuori dalla psicologia. L'atleticità, causa comune non osservata, spiega perché prestazioni sportive diverse sono correlate; ogni prova dipende anche da una componente specifica s (allenamento nella disciplina, statura, tecnica). I pesi sono inventati a scopo illustrativo. Schema originale.

6.3 Che cos'è, e che cosa non è, *g*

La teoria di Spearman è il primo caso storico di definizione di un fattore latente in psicologia. Oggi i fattori latenti si usano ovunque, dalla psicometria all'economia alla biostatistica. Conviene quindi chiarire bene che cosa si intende.

g si chiama **latente** perché non si osserva direttamente. Nessuno dei punteggi ottenuti nei test è la cosa che interessa; tutti servono solo da misure indirette. Nell'esempio sportivo si potrebbe in teoria misurare la forza o la coordinazione. Nel caso dell'intelligenza, in pratica, no.

g non è necessariamente una cosa sola. Anzi, si ipotizza che sia l'aggregato di moltissimi fattori: varianti genetiche, caratteristiche del cervello, esperienze, condizioni di sviluppo. Lo si tratta come unitario perché questi fattori, nei dati comportamentali, non si lasciano separare: agiscono tutti

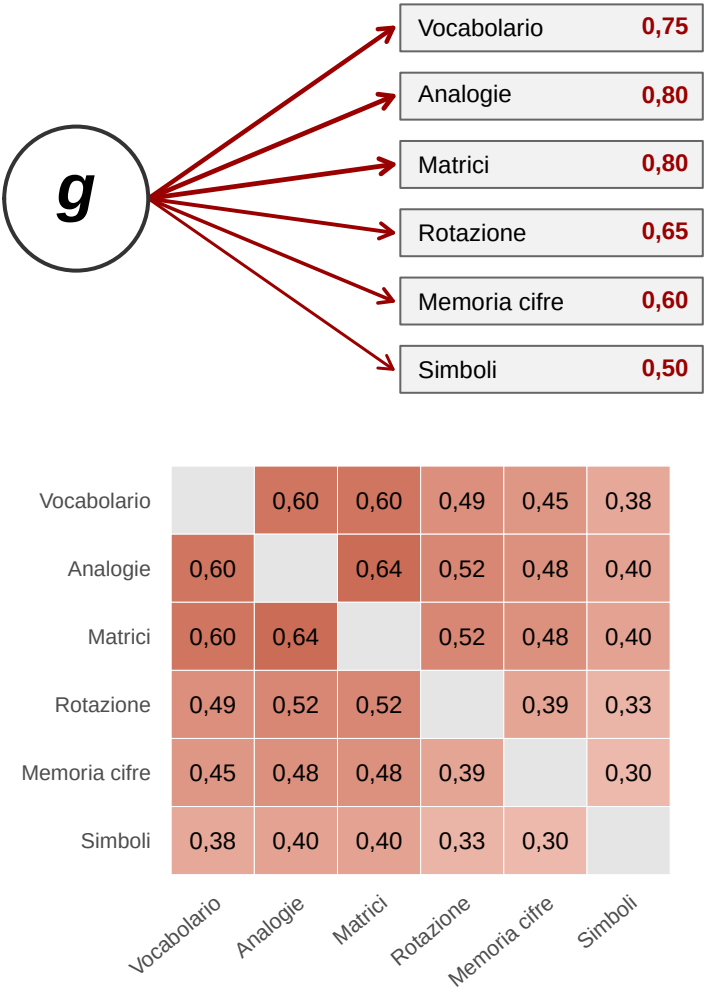


Figura 6.2: Un modello a un fattore. Nel primo pannello, il fattore g e i pesi fattoriali di sei prove ipotetiche, indicati accanto a ciascuna prova. Nel secondo, le correlazioni fra le prove implicate dal modello, pari al prodotto dei rispettivi pesi: tutte positive, più alte fra le prove più legate a g. I valori sono illustrativi.

nella stessa direzione su tutte le prove. Il «fattore» è un riassunto statistico di cause comuni, non un organo o una sostanza.

Infine, g è utile perché è una spiegazione parsimoniosa e perché prevede cose rilevanti. Vale finché ha questa validità predittiva. Se domani un modello con più dimensioni spiegasse meglio le correlazioni fra prove e gli esiti nella vita reale, g andrebbe rivisto.

6.4 «Se non vedo, non credo»

A molti l'idea di lavorare con qualcosa che non si vede sembra sospetta. È una diffidenza rispettabile, condivisa da tradizioni importanti: il comportamentismo radicale, l'operazionalismo, alcune teorie moderne che spiegano le correlazioni fra abilità senza ricorrere a un fattore comune, di cui si parla negli approfondimenti finali.

Concentrarsi su ciò che si osserva è giusto. Ma spesso la spiegazione dei fenomeni impone di postulare qualcosa che non si osserva. Il comportamentismo radicale entrò in crisi proprio di fronte a fenomeni come l'apprendimento latente e l'acquisizione del linguaggio, che richiedevano di ipotizzare rappresentazioni interne; da quella crisi nacquero le scienze cognitive. Fuori dalla psicologia, la cosmologia attribuisce gran parte della massa dell'universo a una «materia oscura» mai osservata direttamente, ma necessaria per spiegare la dinamica delle galassie. Il paragone con g è naturale: qualcosa che deve esserci per dare conto dei dati, anche se non si riesce ancora a osservarlo direttamente.

L'analogia ha un limite a favore di g. Per l'intelligenza si conoscono già alcune componenti: varianti genetiche comuni e caratteristiche del cervello associate al fattore generale. Spiegano però una quota ancora piccola delle differenze. Ne parleremo nei capitoli sulla genetica e sul cervello.

6.5 Quanto è solido il fattore generale

Che il fattore generale sia un risultato robusto lo mostrano due tipi di evidenza. Il primo è la sua ubiquità. Nella più ampia rianalisi mai condotta

delle correlazioni fra test cognitivi, Carroll esaminò oltre quattrocento insiemi di dati raccolti in decenni di ricerca: la positive manifold e un fattore generale emergevano in modo sistematico (Carroll, 1993).

Il secondo è la sua indipendenza dalle prove usate per stimarlo. Se g fosse solo il fattore comune di una batteria particolare, batterie diverse dovrebbero produrre g diversi. In uno studio su adulti che avevano svolto tre batterie complete e diverse fra loro, i fattori generali stimati separatamente correlavano fra loro quasi perfettamente (Johnson et al., 2004). È la versione moderna dell'«indifferenza dell'indicatore» di Spearman: purché le prove siano abbastanza numerose e varie, il fattore generale che se ne ricava è sostanzialmente lo stesso.

Per questo g, pur con una parte di nebulosità teorica, resta una nozione centrale e largamente accettata nella ricerca sull'intelligenza (Deary, 2012a; Gottfredson, 1997). Oggi viene inserito in un quadro gerarchico, meno rigido dell'unitarismo originario, ma non è stato abbandonato.

6.6 I limiti della teoria unitaria

La teoria unitaria classica ha però tre limiti seri, che le teorie successive hanno cercato di superare.

Il primo è l'assenza di una teoria psicologica. Il fattore generale descrive che le prestazioni covariano, ma non dice quale processo mentale le accomuni. Velocità di elaborazione? Memoria di lavoro? Controllo dell'attenzione? Efficienza delle connessioni cerebrali? In senso minimo g indica solo «cause comuni». Per questo è stato sospettato di essere un epifenomeno statistico reificato, cioè un'astrazione trattata come se fosse una cosa. Il sospetto non tocca l'utilità pratica del QI, che nessuno contesta seriamente, ma il suo statuto teorico.

Il secondo è la dipendenza dalla scelta delle prove. Il fattore comune di una batteria è il fattore comune delle prove che contiene. Le prime scale storiche erano piene di prove verbali, e il loro fattore generale era sbilanciato di conseguenza. Il risultato sull'equivalenza dei g stimati da batterie diverse attenua il problema, ma solo per batterie ampie e ben bilanciate.

Il terzo è la sottovalutazione dei fattori specifici. Se tutto ciò che conta è g, le differenze fra le abilità di una persona diventano rumore. Ma un punto

di forza nelle abilità visuospaziali o una debolezza selettiva nel linguaggio possono essere rilevanti per capire un caso clinico o una scelta di studi. L'esistenza di un fattore generale non implica che non esista nient'altro.

Questi limiti non sono stati ignorati. Hanno alimentato un secolo di teorie alternative, con fortune molto diverse. Alcune hanno lasciato contributi duraturi; altre hanno avuto più successo nelle scuole che nei dati. Il prossimo capitolo le esamina e mostra come la ricerca sia arrivata a una sintesi.

In breve

- Prestazioni cognitive molto diverse sono sempre correlate positivamente: è la positive manifold.
- Spearman la spiegò con un fattore generale comune, g, più fattori specifici di ciascuna prova: il primo modello a variabile latente della psicologia.
- g non è un oggetto unico nel cervello, ma il riassunto di molte cause comuni che agiscono nella stessa direzione su tutte le prove.
- Il fattore generale è robusto: emerge in centinaia di insiemi di dati ed è quasi identico se stimato da batterie diverse.
- La teoria unitaria classica manca però di una spiegazione psicologica, dipende dalle prove scelte e trascura le abilità specifiche.

Riferimenti bibliografici

7 Abilità multiple e modelli gerarchici

Nessuno ha mai seriamente negato la positive manifold. Ciò che molti hanno negato è che la spiegazione migliore sia un fattore generale. Le prove correlano, sostengono, perché si sovrappongono: ruotare mentalmente una figura richiede anche memoria di lavoro, che a sua volta richiede velocità di elaborazione. Oppure perché l'intelligenza misurata dai test è solo una fra molte intelligenze. Oppure, in alcune teorie recenti, perché le abilità si sostengono a vicenda durante lo sviluppo.

Questo capitolo segue la storia delle alternative al fattore unico. Non è un catalogo: ogni teoria va giudicata per ciò che ha spiegato e per l'evidenza che la sostiene. Alcune hanno fallito in modo utile, altre hanno avuto più fortuna nelle aule che nei dati. Il punto d'arrivo è il modello gerarchico, oggi la sintesi più accreditata. Una sintesi che però non ha chiuso del tutto il contrasto di fondo: conta di più l'abilità generale o le abilità specifiche?

7.1 Thurstone e le abilità mentali primarie

Negli anni Trenta Louis Thurstone osservò che molti test dell'epoca erano impuri. Voti scolastici, problemi aritmetici, memoria di parole, completamento di sequenze numeriche: ciascuno mescolava diverse competenze mentali. Forse, pensò, g era un'illusione. I test sembravano diversi, ma chiamavano in causa sempre le stesse capacità di base, e per questo correlavano.

Nel 1938 propose una teoria radicalmente multicomponenziale. Il comportamento intelligente dipenderebbe da un insieme di **abilità mentali primarie**, teoricamente indipendenti (Thurstone, 1938). Fra queste c'erano la comprensione verbale, la fluenza verbale, il ragionamento induttivo, il calcolo numerico, la visualizzazione spaziale, la memoria e la velocità percettiva. Se si fossero costruiti test puri di ciascuna abilità, questi non sarebbero stati correlati.

Thurstone costruì quei test e affinò le tecniche dell'analisi fattoriale per analizzarli. Il risultato fu un fallimento utile: le abilità primarie risultavano correlate fra loro. Thurstone stesso finì per ammettere un fattore generale

di ordine superiore. La sua teoria non è più attuale, ma ha lasciato due eredità: test di abilità specifiche ancora usati nella ricerca e l'idea che fra il fattore generale e le singole prove esista un livello intermedio.

7.2 Sternberg e Gardner: allargare il concetto

Una seconda famiglia di teorie non contesta tanto la struttura statistica quanto l'ampiezza del concetto. Robert Sternberg ha proposto una **teoria triarchica** con tre forme di pensiero intelligente (Sternberg, 1985). L'intelligenza analitica corrisponde grosso modo a ciò che misurano i test. L'intelligenza pratica è la capacità di adattarsi alle richieste quotidiane usando al momento giusto ciò che si è appreso. L'intelligenza creativa è la capacità di trovare soluzioni nuove.

L'enfasi sul comportamento nei contesti reali è condivisibile. Il problema è la misura. L'intelligenza analitica si misura bene ed è un ottimo predittore degli apprendimenti e un buon predittore del successo lavorativo. Le misure di intelligenza pratica e creativa si sono rivelate più difficili da costruire e, quando funzionano, correlano con l'abilità generale più di quanto la teoria preveda.

Howard Gardner ha proposto le **intelligenze multiple**: linguistica, logico-matematica, spaziale, musicale, corporeo-cinestesica, interpersonale, intrapersonale, a cui ne ha poi aggiunte altre (Gardner, 1983). I criteri per riconoscere un'intelligenza erano ambiziosi: basi neurobiologiche localizzabili, operazioni cognitive dedicate, una storia evolutiva plausibile, uno sviluppo descrivibile, l'esistenza di talenti o deficit selettivi. Ogni persona avrebbe una combinazione unica di intelligenze.

La teoria è molto popolare in ambito educativo. Il suo sostegno empirico è scarso. Gardner non ha sviluppato misure standardizzate delle sue intelligenze, e quando altri ricercatori le hanno costruite hanno trovato che le prove delle intelligenze più «cognitive» correlano fra loro e con g, mentre quelle musicale e corporea dipendono in parte da abilità non cognitive (Visser et al., 2006; Waterhouse, 2006). Le intelligenze multiple, poi, non hanno tutte la stessa importanza. Una scarsa abilità musicale o corporeo-cinestesica pesa poco nella vita quotidiana; una scarsa abilità logico-matematica è spesso parte di una disabilità intellettiva. Chiamare tutto «intelligenza» rende l'etichetta più inclusiva e meno informativa.

C'è poi un problema di numero. Joy Guilford arrivò a ipotizzare oltre cento abilità distinte, poi quasi duecento (Guilford, 1967). Come ha osservato Alan Kaufman, se un'abilità sola era troppo poco, centoventi sono troppe (Kaufman, 2009).

7.3 Intelligenza fluida e cristallizzata

Una distinzione proposta da Raymond Cattell ha avuto invece un successo duraturo, perché poggia su dati solidi (Cattell, 1963).

L'**intelligenza fluida** (Gf) è la capacità di ragionare su problemi nuovi, indipendentemente dall'istruzione, ricavando regolarità da stimoli mai visti. Si misura preferibilmente con prove non verbali, come le matrici. L'**intelligenza cristallizzata** (Gc) è l'insieme delle conoscenze e delle strategie acquisite, insieme alla capacità di usarle quando servono. Dipende molto dall'istruzione e si misura soprattutto con prove verbali, come il vocabolario o le domande di cultura generale.

Le due forme sono fortemente correlate. Si distinguono soprattutto per il modo in cui cambiano nel corso della vita (Figura 7.1). L'intelligenza fluida cresce rapidamente durante lo sviluppo, raggiunge il massimo nella giovane età adulta e poi declina insieme alle abilità neurocognitive generali. L'intelligenza cristallizzata continua a crescere a lungo e può aumentare anche in età avanzata, finché si accumulano esperienze (McArdle et al., 2002).

Le due forme interagiscono. Si consideri questo problema: $X + Y = 200$, $X + Z = 240$, $Z + Y = 110$. Chi non ha mai visto un sistema di equazioni può arrivare alla soluzione ragionando per tentativi, con un notevole impegno di intelligenza fluida. Chi conosce il metodo lo risolve in pochi passaggi. Le conoscenze cristallizzate rendono facili problemi che la sola intelligenza fluida affronterebbe con fatica. Secondo la **teoria dell'investimento** di Cattell, l'intelligenza fluida emerge per prima e fornisce la capacità con cui, nel tempo, si costruisce quella cristallizzata.

Cattell non pensava davvero a due intelligenze separate: era sostanzialmente un unitarista, e considerava Gf e Gc due modi in cui la stessa capacità si esprime. La sua distinzione ha però aperto la strada al passaggio dall'unitarismo iniziale al modello gerarchico.

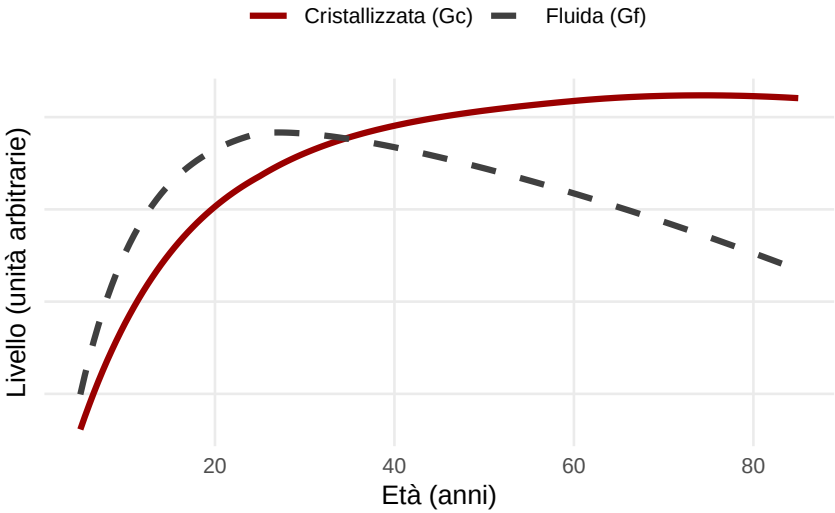


Figura 7.1: Andamento schematico dell'intelligenza fluida e cristallizzata nel corso della vita, costruito a scopo illustrativo sulla base delle tendenze descritte negli studi longitudinali; non rappresenta dati osservati.

7.4 La sintesi gerarchica

Il fallimento di Thurstone conteneva un'informazione preziosa. Prove del tutto diverse continuano a correlare, ma prove che coinvolgono materiale o processi simili correlano di più: verbale con verbale, spaziale con spaziale, memoria con memoria. Lo schema richiede almeno tre livelli: un fattore generale; fattori di dominio, che raggruppano prove simili; componenti specifiche di ogni prova.

Riprendiamo l'esempio sportivo del capitolo precedente. Oltre all'atleticità generale esistono capacità intermedie comuni a gruppi di discipline: la velocità per nuoto e ciclismo, il gioco di squadra per basket e calcetto. E restano componenti proprie di ciascuna disciplina. Un modello a più livelli è un compromesso fra teorie unitarie e multiple: il fattore generale coesiste con fattori più specifici, e solo l'insieme descrive in modo completo le differenze individuali.

Una delle prime formulazioni gerarchiche si deve a Philip Vernon, che sotto *g* collocava due grandi gruppi di abilità, verbali-educative e spaziali-pratiche-meccaniche (Vernon, 1950). La formulazione oggi più citata è il modello **Cattell-Horn-Carroll** (CHC). La sua storia combina tre contributi. Cattell introdusse la distinzione fra fluida e cristallizzata. John Horn, rifiutando il fattore generale, mostrò che con l'analisi fattoriale si potevano distinguere diversi altri domini. John Carroll, dopo aver rianalizzato centinaia di insiemi di dati, propose una sintesi a tre strati (Carroll, 1993). In seguito i modelli di Cattell-Horn e di Carroll sono stati integrati e ampliati (McGrew, 2009).

Oggi «intelligenza gerarchica» è quasi sinonimo di CHC, e le batterie moderne sono costruite o riviste per riflettere questo modello. Due precisazioni sono però doverose. Non tutti i fattori hanno la stessa importanza: intelligenza fluida e cristallizzata sono centrali, altri domini, come la conoscenza quantitativa o la lettura e scrittura, sono più periferici o dipendono molto dal contesto. E il CHC è più una tassonomia delle abilità distinguibili che una teoria di come funzionano.

7.5 Leggere una prestazione su più livelli

Che cosa significa, concretamente, che l'intelligenza è gerarchica? Che la prestazione a una prova va letta su diversi livelli contemporaneamente.

Prendiamo il punteggio di una persona in una prova di vocabolario. Riflette in parte il fattore generale; in parte l'abilità verbale, comune alle prove linguistiche; in parte la conoscenza specifica delle parole presenti nella prova. Il resto è errore: casualità, numero limitato di item, effetti transitori come una notte dormita male. Componente specifica ed errore, insieme, possono pesare per il 30–40% della varianza dei singoli subtest; l'errore da solo, con attendibilità tipiche fra 0,80 e 0,90, ne rappresenta il 10–20%. Lo stesso vale per una prova di rotazione mentale, con il dominio visuospaziale al posto di quello verbale.

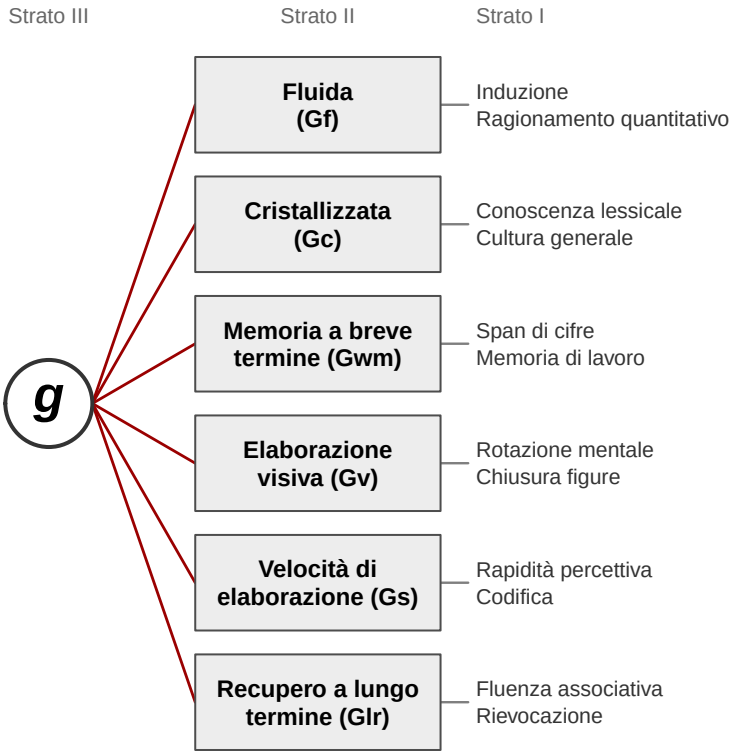


Figura 7.2: Struttura semplificata del modello CHC, con il fattore generale (strato III), alcune abilità ampie (strato II) ed esempi di abilità ristrette (strato I). Schema originale, non esaustivo.

7.6 La prevalenza di *g*

In teoria c'è ampio accordo sul modello gerarchico. In pratica, la ricerca mostra che i diversi livelli non pesano allo stesso modo.

Nelle batterie multicomponenziali il fattore generale spiega da solo la maggior parte della varianza comune ai subtest: nell'analisi della WISC-IV statunitense più di due terzi (Watkins, 2006). I fattori di dominio, al netto di *g*, ne spiegano poca e sono poco attendibili, come si è visto nel capitolo sulla qualità della misura (Gignac & Kretzschmar, 2017). È inoltre il fattore generale a spiegare con regolarità gli esiti della vita reale: risultati scolastici, prestazione lavorativa, salute e longevità. Ed è la componente più chiaramente ereditabile.

Questo vale per la popolazione nel suo insieme. Può non valere per individui con discrepanze molto ampie fra abilità, o in gruppi con condizioni del neurosviluppo, dove i profili di abilità sono informativi (Giofrè et al., 2017). Nella pratica clinica la gerarchia non è un dettaglio accademico: decide quanto peso dare al totale e quanto ai singoli indici.

Punto metodologico: dimenticare la causa comune

Ignorare il fattore generale può produrre conclusioni sbagliate. Supponiamo di voler capire quali abilità prevedono il successo scolastico e di inserire in un modello vocabolario, memoria di lavoro e velocità come predittori separati. Ciascuna sembrerà legata al successo, e si sarà tentati di concludere che tutte contano. Ma se le tre abilità correlano col successo soprattutto perché condividono *g*, il modello attribuisce a ciascuna un effetto che appartiene al fattore comune. Un modello che include il fattore generale riduce, o elimina, molti di questi effetti specifici apparenti. Lo stesso errore compare spesso in psicologia della personalità e sociale, ogni volta che si trascura la possibilità di cause comuni a più misure.

7.7 Una sintesi ragionevole

Si può quindi rispondere alla domanda iniziale con una sintesi.

Che cos'è *g*? È l'insieme delle cause comuni, in buona parte ancora ignote, che fanno sì che una persona vada meglio o peggio in molte abilità cognitive diverse. Si riassume come abilità mentale generale. Moltissimi fattori genetici, ambientali e di esperienza producono un assetto neurobiologico più o meno favorevole alla prestazione cognitiva; statisticamente, il risultato si lascia riassumere da un singolo fattore. Ma *g* non è, ontologicamente, una cosa sola.

Come si misura? Con il QI, che aggrega le prestazioni in molte prove di tipo diverso.

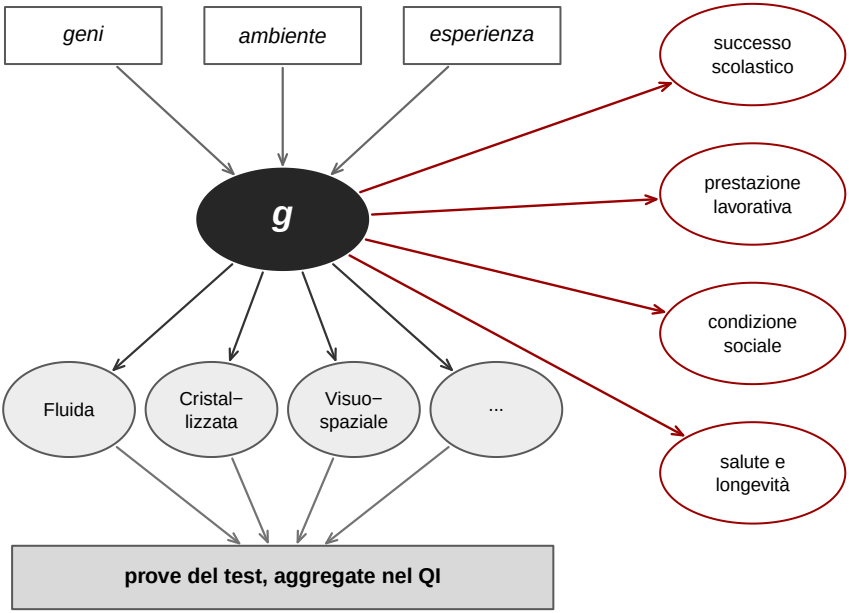


Figura 7.3: Una sintesi del capitolo. Molte cause genetiche, ambientali e di esperienza producono le differenze riassunte da g; g sostiene le abilità ampie, che si osservano attraverso le prove di un test e si aggregano nel QI; lo stesso g prevede esiti rilevanti della vita reale. Schema originale.

Perché è importante? Perché si misura in modo affidabile, stabile e relativamente rapido, e prevede molti esiti rilevanti della vita reale, spesso rendendo superfluo l'approfondimento di questo o quel dominio specifico.

Spesso, non sempre. Le abilità specifiche esistono, e in alcuni casi fanno la differenza. Ma chi vuole interpretarle deve prima fare i conti con il fattore generale.

In breve

- Le teorie multiple hanno cercato di spiegare la positive manifold senza un fattore generale; Thurstone fallì in modo produttivo, mentre le intelligenze multiple di Gardner hanno scarso sostegno empirico.
- Intelligenza fluida e cristallizzata sono fortemente correlate, ma seguono traiettorie diverse nel corso della vita.
- Il modello gerarchico CHC combina un fattore generale, abilità ampie e abilità ristrette: è oggi la tassonomia di riferimento.
- Nei dati il fattore generale prevale: spiega gran parte della varianza comune e degli esiti reali, mentre i fattori di dominio al netto di g sono deboli.

Riferimenti bibliografici

8 Dai primi test al testing di massa

L'intelligenza è il primo costrutto psicologico per cui sono stati costruiti test, e la storia di quei test coincide in gran parte con la nascita della psicometria. Punteggi standardizzati, campioni normativi, somministrazioni collettive, risposte a scelta multipla: sono state inventate qui e poi estese a personalità, psicopatologia, apprendimento.

È una storia di innovazioni notevoli e di errori gravi. Alcuni errori erano tecnici, e sono stati corretti. Altri erano morali e politici, e hanno lasciato un'ombra che dura ancora. Questo capitolo segue le tappe principali fino alla Prima guerra mondiale e agli anni immediatamente successivi. Il prossimo riprende il filo dalle scale moderne.

8.1 Galton: un fallimento istruttivo

Negli anni Ottanta dell'Ottocento Francis Galton, cugino di Charles Darwin, aprì a Londra un laboratorio antropometrico. Per una piccola somma i visitatori potevano farsi misurare: diametro della testa, acutezza visiva e uditiva, capacità di discriminare pesi, tempi di reazione, forza della presa, capacità polmonare. Galton era convinto che l'intelligenza fosse in larga parte ereditaria e che si manifestasse nell'efficienza del sistema nervoso, quindi in capacità sensoriali e motorie elementari (Galton, 1869).

Il progetto aveva elementi davvero innovativi. Era il primo tentativo di misurare quantitativamente le differenze intellettive. Combinava una teoria, quella evoluzionista, con tecniche di misura. E cercava una forma di validità: voleva verificare se chi stava sopra la media nelle misure stava sopra la media anche nel successo nella vita.

Non funzionò. Le misure sensoriali e motorie correlavano poco fra loro e quasi nulla con indicatori di successo. Negli Stati Uniti James McKeen Cattell riprese l'approccio con i suoi «test mentali», e un'analisi condotta nel 1901 su studenti universitari mostrò che i punteggi non correlavano con i voti (Wissler, 1901). L'idea che l'intelligenza fosse una questione di sensi acuti e riflessi pronti fu abbandonata.

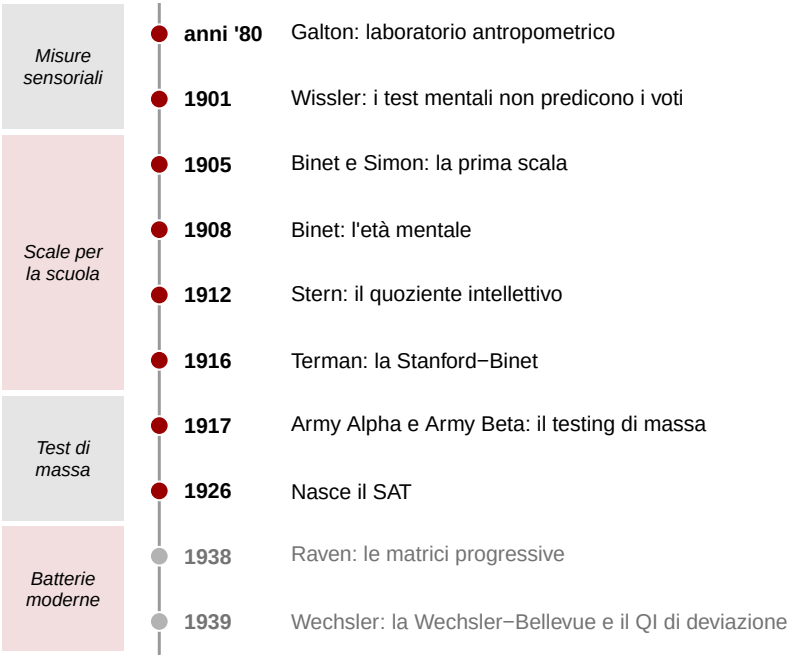


Figura 8.1: Le tappe principali della storia dei test di intelligenza. Le date in nero sono discusse in questo capitolo, quelle in grigio nel successivo. Schema originale.

C'è poi l'altro lato. Galton coniò il termine «eugenetica» e ne fu un convinto sostenitore, con posizioni apertamente razziste. Erano idee molto diffuse nell'élite scientifica del tempo. Questo spiega il contesto, non lo giustifica.

8.2 Binet: misurare per proteggere

La svolta arrivò da un problema pratico. In Francia l'istruzione primaria era diventata gratuita e obbligatoria per tutti. Nel 1904 il governo istituì una commissione per individuare i bambini che non riuscivano a trarre profitto dall'insegnamento ordinario e avevano bisogno di un sostegno par-

ticolare. Alfred Binet, psicologo e membro di una società per lo studio psicologico dell'infanzia, si dedicò alla questione.

L'obiettivo era stabilire se un bambino potesse essere inserito con profitto nella classe della sua età. Con Théodore Simon, Binet costruì una scala presentata per la prima volta nel 1905, anche a un congresso internazionale a Roma (Binet & Simon, 1904). Conteneva una trentina di prove, per lo più verbali: nominare oggetti o parti del corpo, ripetere frasi o cifre, definire parole astratte, trovare la parola mancante in una frase, copiare una figura, ordinare oggetti di peso diverso.

La differenza rispetto a Galton era netta. Binet non misurava processi elementari, ma capacità complesse come comprensione, giudizio e ragionamento, le stesse che servono a scuola. E insisteva su un punto che resta attuale: nessuna prova isolata può valutare l'intelligenza, ma solo l'insieme. Un bambino può avere una difficoltà specifica a trovare le rime o a usare le forbici senza che questo dica molto delle sue capacità generali.

Molti tipi di prova introdotti da Binet sono ancora in uso, in forme simili, nelle batterie moderne. Altri aspetti del suo pensiero sono meno noti. Binet credeva che le capacità intellettive potessero essere migliorate con esercizi appropriati, una sorta di «ortopedia mentale». Non considerava l'intelligenza una dotazione fissa. E pensava che il ragionamento del bambino seguisse processi diversi da quelli dell'adulto, anticipando un tema che Jean Piaget avrebbe sviluppato. Soprattutto, concepiva la valutazione come strumento di tutela: serviva a dare aiuto a chi ne aveva bisogno, non a escludere.

8.3 L'età mentale e il primo quoziente

Nella prima versione le prove venivano presentate in ordine di difficoltà crescente e il bambino veniva classificato in categorie qualitative, con etichette mediche dell'epoca oggi giustamente abbandonate. Nella revisione del 1908 Binet introdusse un'idea più elegante: l'**età mentale**. Se un bambino superava le prove che la maggior parte dei bambini di otto anni supera, la sua età mentale era otto anni, qualunque fosse la sua età anagrafica.

Nel 1912 William Stern propose di dividere l'età mentale per l'età cronologica (W. Stern, 1912). Lewis Terman moltiplicò il rapporto per cento e

lo adottò nella sua versione statunitense della scala. Nacque così il primo **quoziente di intelligenza**:

$$\text{QI di rapporto} = \frac{\text{età mentale}}{\text{età cronologica}} \times 100$$

Un bambino di 4 anni con le prestazioni tipiche dei 6 avrebbe un QI di 150; uno di 6 anni con le prestazioni tipiche dei 4 avrebbe un QI di 67.

Il nome «quoziente» viene da qui. Ma questa formula non si usa più da decenni, e il QI moderno ha un significato e un calcolo completamente diversi. Il QI di rapporto aveva difetti seri.

- **La metrica è disuguale.** Un anno di differenza pesa molto di più a 4 anni che a 11. Lo stesso scarto in età mentale non corrisponde allo stesso scarto in capacità.
- **Lo sviluppo non è lineare.** Le prestazioni nei test crescono rapidamente nell'infanzia e si appiattiscono nella tarda adolescenza. Per mantenere un QI di 150, un ragazzo di 15 anni dovrebbe avere un'età mentale di 22 anni e mezzo, un concetto privo di senso. Per gli adulti la formula non funziona.
- **Il concetto è troppo globale.** L'età mentale evoca una maturazione complessiva della persona. Dire che un adulto con sindrome di Down «ha un'età mentale di sei anni» confonde la prestazione in alcuni test con l'esperienza, gli interessi e l'autonomia di un adulto.

Oggi anche le scale per i primi anni di vita usano punteggi di deviazione dalla media dei coetanei, che vedremo nel prossimo capitolo.

> Attenzione clinica: età equivalente non è età mentale
>
> Il concetto di **età equivalente** è difendibile, con cautela, quando si riferisce alla prestazione in un test e non alla persona. Nella disabilità intellettiva moderata o grave i punteggi standardizzati arrivano spesso al limite inferiore della scala: tutti i risultati si schiacciano sul minimo, e il profilo di punti di forza e debolezza si perde. Confrontare una persona con una popolazione di riferimento da cui è molto distante ha inoltre poco senso teorico. In questi casi dire che la prestazione in un certo subtest corrisponde a quella tipica di una certa

età può aiutare la descrizione e la comunicazione, soprattutto per singole aree di funzionamento. Calcolare un QI di rapporto, invece, non ha giustificazione in nessun caso.

8.4 Terman e il lato oscuro

Lewis Terman portò la scala di Binet all'Università di Stanford, la adattò, la standardizzò su un campione statunitense e la pubblicò nel 1916 come Stanford-Binet (Terman, 1916). Il test ebbe un successo enorme e fu rieditato più volte, fino alla quinta edizione del 2003.

Terman, però, ne sostenne l'uso a fini eugenetici. Nello stesso volume del 1916 attribuiva a cause razziali i punteggi bassi di bambini di origine messicana, afroamericana e di altri gruppi, ne raccomandava la separazione in classi speciali e presentava la loro presunta fertilità elevata come un problema eugenetico. Fu membro di organizzazioni che promuovevano la sterilizzazione obbligatoria delle persone con basso livello intellettivo, praticata in molti stati statunitensi nei primi decenni del Novecento e avallata dalla Corte Suprema nel 1927.

Lo strumento di Binet, pensato per proteggere, veniva così usato per classificare e discriminare. Il contrasto illustra un punto generale: la validità di un test non dice nulla sulla legittimità dell'uso che se ne fa. E le premesse ideologiche di chi interpreta i punteggi pesano almeno quanto la qualità dello strumento.

La Stanford-Binet aveva anche limiti tecnici. Era nata per l'età evolutiva e restava legata all'età mentale, inadatta agli adulti. Era orientata a individuare deficit e distingueva male i livelli alti. E poggiava molto su prove verbali, che penalizzavano chi aveva avuto poca istruzione o non padroneggiava la lingua.

8.5 La guerra e il testing di massa

Nel 1917 gli Stati Uniti entrarono nella Prima guerra mondiale. L'esercito doveva assegnare rapidamente ruoli a oltre un milione e mezzo di reclute.

Un test individuale come la Stanford-Binet richiedeva troppo tempo. Molte reclute erano analfabete o non parlavano inglese. E serviva una scala adatta agli adulti.

Robert Yerkes, allora presidente dell'American Psychological Association, riunì un gruppo di psicologi, fra cui Terman, per costruire test collettivi a carta e matita (Yerkes, 1921). Nacquero così due strumenti:

- l'**Army Alpha**, per chi sapeva leggere e scrivere in inglese, con prove di vocabolario, serie numeriche, comprensione di istruzioni verbali, analogie;
- l'**Army Beta**, per analfabeti e non anglofoni, con istruzioni mimate a gesti e prove non verbali: labirinti, completamento di figure, cifrari, sequenze di simboli.

I punteggi venivano convertiti in fasce, dalla A, «molto superiore», alla E, corrispondenti grosso modo a percentuali fisse della distribuzione. Le fasce orientavano l'assegnazione: ufficiali dalle prime, ruoli semplici o esonero dalle ultime. Era un sistema rudimentale di punteggi basati sulla posizione relativa, il primo passo verso i punteggi di deviazione.

Le innovazioni furono notevoli: somministrazione collettiva, risposte a scelta multipla, scoring rapido, standardizzazione su numeri enormi, una prova non verbale per non sottovalutare chi non conosceva la lingua. Molte di queste soluzioni sono ancora alla base della valutazione su larga scala.

I limiti furono altrettanto evidenti. Anche maneggiare un modulo a carta e matita richiede familiarità con la scuola. Le condizioni di somministrazione erano spesso caotiche, e reclute che avrebbero dovuto svolgere il Beta finivano per svolgere l'Alpha. Alcune prove dell'Alpha erano domande di cultura generale statunitense, che misuravano soprattutto quanto a lungo si era vissuti nel paese.

8.6 Dai test ai pregiudizi

I dati dell'esercito furono poi usati per sostenere tesi sulla superiorità di alcuni gruppi nazionali. Nel 1923 lo psicologo Carl Brigham pubblicò un'analisi che classificava gli immigrati per paese d'origine, trovando punteggi più bassi fra quelli provenienti dall'Europa meridionale e orientale, italiani

compresi (Brigham, 1923). I suoi stessi dati mostravano che il punteggio cresceva con gli anni di residenza negli Stati Uniti, un indizio evidente del peso della lingua e dell'esposizione culturale; Brigham lo interpretò invece come segno di un peggioramento delle ondate migratorie più recenti. Pochi anni dopo ritrattò pubblicamente quelle conclusioni (Brigham, 1930).

Nel 1924 il Congresso statunitense approvò una legge che limitava drasticamente l'immigrazione da quei paesi. Il ruolo dei test in quella decisione viene spesso esagerato: un'analisi dei dibattiti parlamentari ha mostrato che i risultati dei test furono citati raramente e che le motivazioni principali erano di altro tipo (Snyderman & Herrnstein, 1983). Ma il clima intellettuale in cui i test venivano interpretati era quello. E alcuni dei loro promotori lo alimentarono attivamente.

Brigham, intanto, aveva adattato l'esperienza dell'esercito a un uso civile. Nel 1926 nacque lo **Scholastic Aptitude Test** (SAT), concepito per una selezione universitaria che premiasse il merito anziché la famiglia d'origine. Le sue caratteristiche, cioè scelta multipla, somministrazione collettiva, standardizzazione su campioni ampi, sono state ereditate dalle grandi indagini educative contemporanee, come PISA e INVALSI. Queste ultime non valutano singoli individui, ma sistemi scolastici, e sono più legate ai programmi; i loro punteggi, tuttavia, sono dominati da un fattore generale molto simile a quello dei test cognitivi (Pokropek et al., 2022).

8.7 Che cosa resta

La prima stagione dei test lascia un'eredità doppia. Da un lato un insieme di soluzioni tecniche che hanno funzionato: prove complesse anziché elementari, aggregazione di molte prove, confronto con un gruppo di riferimento, versioni non verbali, somministrazione standardizzata. Dall'altro una serie di errori: un quoziente costruito su una metrica inadeguata, prove contaminate dalla lingua e dalla scolarità, interpretazioni razziali di differenze che riflettevano soprattutto esperienze diverse.

Chi oggi diffida dei test di intelligenza ha spesso in mente questa storia. Fa bene a ricordarla. Il passo successivo è chiedersi quali di questi errori siano stati corretti e quali richiedano ancora vigilanza. Il prossimo capitolo comincia da qui.

In breve

- Il tentativo di Galton di misurare l'intelligenza con capacità sensoriali e motorie fallì: le misure non prevedevano il successo scolastico o professionale.
- Binet costruì la prima scala efficace usando prove complesse e aggregandole, con lo scopo di individuare i bambini bisognosi di sostegno.
- Il QI di rapporto di Stern e Terman aveva difetti gravi e non si usa più; l'età equivalente di singole prestazioni resta utile solo in casi specifici.
- I test di massa dell'esercito statunitense introdussero innovazioni durature ma furono interpretati, con Terman e Brigham, in chiave eugenetica e razziale.

Riferimenti bibliografici

9 Le batterie moderne di intelligenza

Il QI che si legge oggi in un referto non ha quasi nulla in comune con il quoziente di Stern. Non è un rapporto fra età, non si basa su un'età mentale, e vale allo stesso modo a 8 e a 80 anni. È il risultato di una seconda rivoluzione nella storia dei test, iniziata alla fine degli anni Trenta in un ospedale psichiatrico di New York.

Questo capitolo descrive come sono costruite le batterie moderne, che cosa significano i loro punteggi e quali sono gli strumenti più diffusi. Non riproduce item di test commerciali: quando servono esempi, sono costruiti ad hoc per illustrare il tipo di prova, non equivalenti a item reali.

9.1 Un piccolo glossario

Il linguaggio dei test usa alcuni termini con un significato preciso.

- **Batteria.** Strumento completo per valutare un'area del funzionamento, come l'intelligenza, articolato in molte componenti. Per tradizione si parla spesso di «scale».
- **Item.** Il singolo problema all'interno di una prova. La risposta può essere giusta o sbagliata, oppure valutata su pochi livelli di accuratezza.
- **Subtest.** Una prova che misura una particolare abilità, di solito composta da una sequenza di item di difficoltà crescente. Esempi tipici sono un subtest di vocabolario o uno di costruzioni con cubi.
- **Indice.** Un punteggio che stima un costrutto latente aggregando più subtest, espresso su una metrica standardizzata. Il QI totale è un indice; lo sono anche gli indici di dominio, come comprensione verbale o memoria di lavoro.

9.2 Wechsler e il QI di deviazione

David Wechsler aveva lavorato da giovane alla somministrazione dei test dell'esercito statunitense. Negli anni Trenta era psicologo clinico al Bellevue

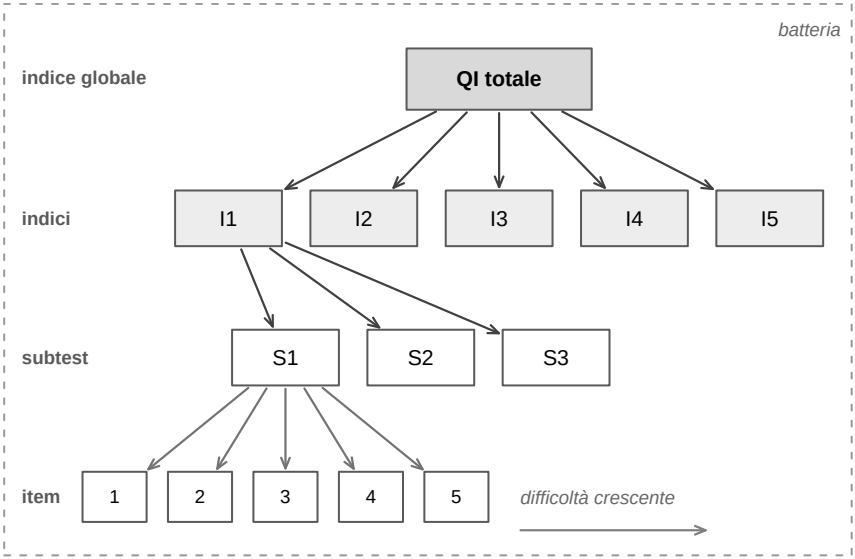


Figura 9.1: I livelli di una batteria di intelligenza. Il QI totale aggrega gli indici, ogni indice aggrega alcuni subtest, ogni subtest è una sequenza di item di difficoltà crescente. Per leggibilità sono sviluppati per esteso solo un indice e un subtest. Schema originale.

Hospital di New York, dove doveva valutare adulti molto diversi per età, storia e sintomi: per stabilirne l'autonomia, la capacità di lavorare o di testimoniare, il bisogno di tutela, le possibilità di recupero. La Stanford-Binet non era adatta. Nel 1939 Wechsler pubblicò la Wechsler-Bellevue, la prima vera batteria clinica per adulti (Wechsler, 1939). Il campione di standardizzazione, circa 1.700 persone, era poco rappresentativo: per lo più newyorkesi, bianchi e con istruzione superiore alla media. Ma l'impianto era nuovo.

Le innovazioni erano due. La prima era l'equilibrio fra prove **verbali** e prove **di performance**, cioè non verbali, un'idea che riprendeva la distinzione fra Army Alpha e Army Beta. La batteria forniva un QI verbale, un QI di performance e un QI totale. Questa struttura è rimasta sostanzialmente invariata fino agli anni Novanta.

La seconda, più importante, era il **QI di deviazione**. Invece di confron-

tare età mentale e cronologica, Wechsler confrontava la prestazione di una persona con quella dei coetanei del campione normativo, e la esprimeva come distanza dalla loro media su una scala con media 100 e deviazione standard 15. È esattamente la logica dei punti z vista nel capitolo sulle distribuzioni. Il QI di deviazione funziona a ogni età e ha lo stesso significato in qualunque punto della vita: 115 indica sempre una deviazione standard sopra la media dei coetanei. Questa metrica è diventata universale ed è usata ancora oggi per quasi tutti i test psicologici.

Wechsler aveva un'ispirazione pragmatica e in fondo unitarista. Voleva anzitutto misurare bene il QI totale. Considerava i subtest misure diverse della stessa intelligenza, non misure di intelligenze diverse, e la divisione fra parte verbale e di performance solo uno dei modi possibili di raggrupparli (Wechsler, 1958). Gli bastava che la batteria funzionasse.

9.3 Dagli indici di Wechsler al CHC

Le scale Wechsler si sono moltiplicate e sono state riviste più volte: la WAIS per adulti, la WISC per l'età scolare, la WPPSI per l'età prescolare. WISC e WAIS sono oggi alla quinta edizione, la WPPSI alla quarta; le edizioni disponibili in Italia possono essere precedenti. Restano le batterie più usate al mondo per la valutazione cognitiva globale.

Nel tempo la struttura si è articolata. La distinzione fra QI verbale e QI di performance è stata sostituita, nelle edizioni degli anni Duemila, da quattro indici di ispirazione cognitiva e neuropsicologica: comprensione verbale, ragionamento percettivo, memoria di lavoro, velocità di elaborazione. Le quinte edizioni hanno separato il ragionamento percettivo in un indice visuospaziale e uno di ragionamento fluido, con un riferimento più esplicito al modello CHC. La Figura 9.2 riassume il passaggio.

Le convenzioni metriche sono ormai universali: i subtest hanno punteggi ponderati con media 10 e deviazione standard 3; gli indici, compreso il QI totale, media 100 e deviazione standard 15.

La struttura di una batteria come la WISC-V è dunque gerarchica: un QI totale, cinque indici primari, una decina di subtest principali e altri subtest supplementari. I principali tipi di prova sono questi.

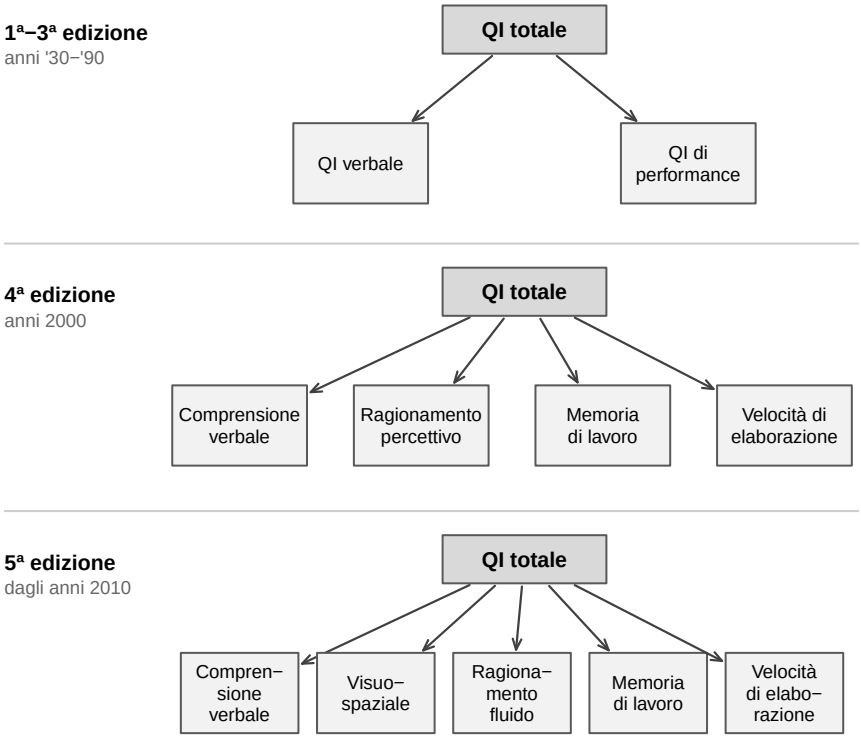


Figura 9.2: Come è cambiata la struttura delle scale Wechsler: dal QI verbale e di performance delle prime tre edizioni ai quattro indici della quarta, ai cinque indici primari della quinta, più vicini al modello CHC. Schema originale.

Tabella 9.1: Indici primari di una batteria di tipo Wechsler per l'età evolutiva e relativi tipi di prova.

Indice	Che cosa valuta	Tipo di prova
Comprensione verbale	Conoscenza delle parole, dei concetti e del mondo	Spiegare che cosa hanno in comune due concetti; definire parole

Indice	Che cosa valuta	Tipo di prova
Visuospaziale	Analisi di dettagli visivi e relazioni spaziali	Riprodurre un modello con cubi colorati; scegliere i pezzi che compongono una figura
Ragionamento fluido	Ragionamento induttivo e deduttivo, astrazione di regole	Completare matrici di figure; trovare ciò che bilancia una serie di pesi
Memoria di lavoro	Mantenere e manipolare informazioni verbali o visive	Ripetere sequenze di cifre in avanti, all'indietro o riordinate; riconoscere immagini viste
Velocità di elaborazione	Rapidità ed efficienza in compiti semplici	Associare simboli a cifre; cercare simboli bersaglio

Un esempio originale chiarisce il tipo di richiesta senza riprodurre item reali. In una prova di somiglianze si potrebbe chiedere in che cosa si assomigliano una bussola e un orologio: entrambi sono strumenti che servono a orientarsi, uno nello spazio e l'altro nel tempo. La risposta richiede di trovare la categoria astratta che li accomuna, non di descriverli.

La struttura a cinque fattori delle scale Wechsler più recenti è stata contestata. Alcune rianalisi dei dati normativi trovano che quattro fattori di dominio, più un fattore generale molto forte, descrivano i dati altrettanto bene, e che la varianza specifica di molti indici sia modesta (Canivez et al., 2017). È lo stesso problema discusso nel capitolo sulla qualità della misura: i domini esistono, ma al netto di g pesano poco.

9.4 Leggere un profilo

Una batteria multicomponenziale restituisce molti numeri. La tentazione è leggerli tutti: un indice verbale di 112 e uno visuospaziale di 96 sembrano

raccontare una storia. A volte la raccontano. Spesso, però, raccontano anche l'errore di misura.

Il QI totale è la stima più attendibile e stabile. Gli indici di dominio seguono in gran parte il fattore generale e, considerati da soli, sono meno attendibili: se si ripetesse la valutazione, la differenza fra due indici potrebbe ridursi o addirittura invertirsi. I singoli subtest, ancora meno affidabili, non vanno interpretati isolatamente. Il capitolo sulla qualità della misura ha mostrato perché.

Questo non significa che i profili siano inutili. Possono essere informativi quando la discrepanza è ampia, quando è coerente con altre informazioni sul caso e quando esiste un profilo atteso documentato per una certa condizione. In queste circostanze, per esempio, si può preferire un indice di abilità generale che escluda memoria di lavoro e velocità, se queste componenti sono compromesse per ragioni specifiche e rischiano di sottostimare il ragionamento. Ne riparleremo nel capitolo sulla valutazione nel neurosviluppo.

9.5 Le matrici di Raven e i test monocomponenziali

Accanto alle grandi batterie esiste una tradizione diversa, di origine britannica. John Raven, allievo di Spearman, voleva un test di ragionamento complesso per la ricerca, che non dipendesse da competenze verbali. Nel 1938 pubblicò le **Standard Progressive Matrices**: una serie di matrici di figure in cui manca un elemento, da scegliere fra diverse alternative in base a una regola da scoprire (Raven, 2000).

Durante la Seconda guerra mondiale l'esercito britannico le usò per lo screening di massa, grazie alla facilità di somministrazione collettiva, con scopi simili a quelli dei test statunitensi della guerra precedente. Seguirono una versione a colori per bambini, anziani e persone con difficoltà cognitive, nel 1947, e una versione avanzata per livelli di abilità elevati, nel 1962. Le matrici sono oggi considerate una misura tipica di intelligenza fluida e uno dei migliori singoli indicatori di *g*.

Test come le matrici di Raven o il Culture Fair Test di Cattell sono **monocomponenziali**: forniscono una sola stima del livello generale. Sono rapidi,

spesso somministrabili in gruppo, e utili per la ricerca e lo screening. Furono presentati a lungo come «liberi dalla cultura». Nessun test lo è davvero: il formato a scelta multipla, la familiarità con figure astratte e con la logica delle prove scolastiche contano. Il capitolo sull'effetto Flynn mostrerà che proprio le matrici sono fra le prove più sensibili ai cambiamenti storici. Meglio parlare di test **ridotti nella componente culturale**.

9.6 Test equi?

L'accusa più antica ai test di intelligenza è che siano ingiusti verso alcuni gruppi. La storia raccontata nel capitolo precedente le dà più di una ragione. Ma la domanda va posta nei termini giusti. Nel linguaggio della psicometria un test è **distorto** (*biased*) quando lo stesso punteggio non ha lo stesso significato in gruppi diversi: perché a parità di abilità un gruppo ottiene punteggi più bassi in alcune prove, cioè manca l'invarianza di misura, oppure perché il punteggio prevede gli esiti in modo diverso nei due gruppi (Meredith, 1993). Una differenza fra le medie, da sola, non è prova di distorsione. Un termometro che segna temperature diverse a Palermo e a Bolzano non è per questo un termometro sbagliato.

Per gruppi che condividono lingua e scolarizzazione, le batterie moderne superano in genere queste verifiche: la struttura dei punteggi è la stessa e la loro capacità predittiva è simile (Warne, 2020). I problemi seri nascono quando lingua, scolarità e familiarità con le prove differiscono, cioè proprio nelle condizioni in cui fallirono i test dell'esercito statunitense. Le differenze medie fra gruppi definiti per etnia o nazionalità sollevano, oltre a queste, domande sulle cause a cui l'ereditabilità stimata dentro ciascun gruppo non può rispondere da sola; il caso del divario Nord-Sud discusso nel capitolo sulla scuola mostra quanto fragili possano essere i dati su cui si costruiscono certe conclusioni.

Il caso dei sessi è istruttivo. Nell'abilità generale le differenze medie fra maschi e femmine sono trascurabili; ne esistono alcune in abilità specifiche, come un vantaggio maschile nella rotazione mentale e uno femminile in alcune prove verbali e di velocità (Halpern et al., 2007). Va però ricordato che le batterie vengono costruite scartando gli item che funzionano in modo diverso nei due sessi, sicché l'uguaglianza dei totali è in parte una scelta di costruzione. Più solido è un altro risultato. Nell'intera coorte scozzese

testata nel 1932, quasi tutti i bambini di undici anni, le medie erano praticamente uguali, ma la variabilità era maggiore fra i maschi, più numerosi in entrambe le code (Johnson et al., 2008).

Una spiegazione molto popolare delle differenze fra gruppi è la **minaccia dello stereotipo**: chi appartiene a un gruppo descritto come meno capace renderebbe peggio quando lo stereotipo viene evocato, per ansia o distrazione. L'idea è plausibile e ha avuto un enorme successo. Le evidenze sono più deboli della reputazione. Per le ragazze in matematica, una meta-analisi ha trovato un effetto piccolo, con segni di pubblicazione selettiva (Flore & Wicherts, 2015); e gli effetti si riducono ancora negli studi che riproducono le condizioni di una valutazione reale (Shewach et al., 2019). È una traiettoria che il capitolo sul potenziamento cognitivo mostrerà più volte: un risultato elegante, studi piccoli, una letteratura che si ridimensiona quando arrivano i campioni grandi.

9.7 Il panorama italiano e le tendenze recenti

Oltre alle scale Wechsler, in Italia sono disponibili diversi strumenti. Alcune batterie multicomponenziali, come la IDS-2, sono costruite esplicitamente sul modello CHC e coprono anche aree diverse dall'intelligenza in senso stretto, come funzioni esecutive e competenze scolastiche. Esistono batterie brevi, con pochi subtest, che stimano in modo rapido e robusto il QI totale; strumenti interamente non verbali, anche nelle istruzioni, utili per chi ha difficoltà linguistiche o per alcune condizioni del neurosviluppo; test monocomponenziali di ragionamento fluido per l'età evolutiva o per la selezione del personale. Un elenco ragionato, con caratteristiche e limiti di ciascuno, è nella sezione del sito dedicata alla professione.

Due tendenze stanno cambiando il settore. La prima è la diffusione di modelli psicometrici più avanzati della teoria classica, come la **teoria della risposta all'item**, che stima l'abilità tenendo conto delle caratteristiche di ciascun item. Su questa base si costruiscono **test adattivi computerizzati**, che scelgono l'item successivo in funzione delle risposte già date e raggiungono una stima precisa con meno domande. La seconda è il passaggio allo scoring tramite piattaforme online. È comodo, ma crea un problema nuovo: quando le tabelle normative non sono pubblicate, il professionista non può verificare come il punteggio grezzo sia stato trasformato (Frinco et

al., 2024; Zanon & Priftis, 2025). Un numero ottenuto da una procedura opaca è difficile da difendere, in clinica come in tribunale.

9.8 Uno strumento, non un oracolo

Le batterie moderne sono il risultato di un secolo di correzioni. La metrica di deviazione ha eliminato i difetti del QI di rapporto. La struttura gerarchica permette di stimare sia il livello generale sia i domini. La standardizzazione su campioni ampi rende i confronti più equi. Restano però limiti che nessuna revisione elimina del tutto: l'errore di misura, la debolezza degli indici specifici, la dipendenza dalla lingua e dalla scolarità, la necessità di norme aggiornate e trasparenti. Una batteria ben usata fornisce una stima solida; che cosa quella stima significhi per la persona valutata non lo dice il manuale.

In breve

- Wechsler introdusse il QI di deviazione, con media 100 e deviazione standard 15 rispetto ai coetanei: una metrica valida a ogni età e oggi universale.
- Le batterie moderne sono gerarchiche: QI totale, indici di dominio, subtest e item; le edizioni recenti si richiamano esplicitamente al modello CHC.
- Il QI totale è la stima più solida; le discrepanze fra indici vanno interpretate solo se ampie e coerenti con altre evidenze.
- Un test è distorto quando lo stesso punteggio non ha lo stesso significato in gruppi diversi, non quando le medie differiscono; la minaccia dello stereotipo spiega poco delle differenze osservate.
- Nessun test è libero dalla cultura; norme trasparenti e aggiornate sono una condizione per un uso professionale difendibile.

Riferimenti bibliografici

Parte IV

Basi biologiche, ambiente e cambiamento

10 Geni, ambiente ed ereditabilità

«Intelligenti si nasce o si diventa?» La domanda sembra legittima. In realtà è mal posta, e capire perché è il primo passo per orientarsi in uno dei temi più fraintesi della psicologia.

Abbiamo un'intelligenza umana perché abbiamo un genoma umano. Con il genoma di uno scimpanzé, di un'ape o di un delfino avremmo un'intelligenza completamente diversa. In questo senso l'intelligenza ha ovviamente **basi genetiche**. Ma di solito la domanda è un'altra: quanta parte delle differenze di QI fra le persone che ci circondano riflette differenze genetiche fra loro? Questa è una domanda sull'**ereditabilità**. Riguarda la piccola frazione del genoma che varia da persona a persona, e ha una risposta precisa solo se si precisa anche la popolazione a cui si riferisce.

10.1 Basi genetiche ed ereditabilità

Una caratteristica ha **basi genetiche** quando dipende da meccanismi biologici codificati nel genoma. Può essere identica in tutti gli individui di una specie: abbiamo cinque dita per mano, i cani scodinzolano. L'**ereditabilità**, invece, riguarda le differenze: indica quanto la variazione di una caratteristica fra gli individui di una popolazione riflette variazioni genetiche fra loro. I figli di persone alte tendono a essere più alti della media; i pulcini di galline che crescono in fretta tendono a crescere in fretta.

Una caratteristica con basi genetiche chiarissime può avere ereditabilità quasi nulla, se tutti condividono le stesse varianti. E una caratteristica fortemente ereditabile può essere molto influenzata dall'ambiente. Un esempio efficace è quello dei fenicotteri (Serpico, 2022). Il loro colore rosa ha una base genetica? Sì, ma si manifesta solo se si nutrono di crostacei ricchi di carotenoidi. Sono rosa per effetto dell'alimentazione, allora? Sì, ma solo perché la loro genetica organizza il metabolismo e il deposito di quei pigmenti nelle piume. Un gabbiano può mangiare gli stessi crostacei e non diventerà mai rosa. Geni e ambiente non si sommano come ingredienti separati: agiscono insieme.

L'ereditabilità, indicata con h^2, è una proporzione di varianza:

$$h^2 = \frac{\text{varianza dovuta a differenze genetiche}}{\text{varianza totale del tratto}}$$

L'ambiente compare nella formula, al denominatore. Se in una popolazione le condizioni ambientali sono molto diverse da persona a persona, la varianza totale cresce e l'ereditabilità scende. Se sono simili, l'ereditabilità sale. L'ereditabilità non è una proprietà del tratto in assoluto, ma del tratto in una popolazione con una certa distribuzione di geni e di ambienti.

10.2 Come si stima: famiglie, adozioni, gemelli

Il fatto che figli di genitori intelligenti tendano a essere intelligenti non basta a stimare l'ereditabilità. Genitori e figli condividono metà della variabilità genetica, ma anche la casa, il reddito, i libri, la lingua, la scuola. La somiglianza potrebbe dipendere da entrambi.

Per separare le due fonti bisogna confrontare coppie di persone che condividono l'ambiente in misura simile ma la genetica in misura diversa, o viceversa. È la logica degli studi su famiglie, adozioni e soprattutto gemelli (Figura 10.1). Le correlazioni fra i QI seguono con regolarità il grado di somiglianza genetica. I gemelli monozigoti cresciuti insieme correlano attorno a 0,86, i dizigoti attorno a 0,60, i fratelli non gemelli attorno a 0,47. I gemelli monozigoti cresciuti separati restano molto simili, mentre i figli adottivi somigliano poco ai genitori adottivi (Plomin et al., 2001).

Una precisazione sulle percentuali. Dire che i gemelli dizigoti condividono il 50% non significa che condividano metà del genoma: tutti gli esseri umani ne condividono quasi la totalità. Significa che condividono, in media, metà delle varianti che differiscono nella popolazione.

Il confronto più informativo è quello fra gemelli monozigoti e dizigoti cresciuti insieme. Hanno la stessa età, crescono nella stessa famiglia, ma condividono rispettivamente tutta e metà della variabilità genetica. Se i monozigoti si somigliano più dei dizigoti, la differenza va attribuita ai geni. Oggi si usano modelli di equazioni strutturali, ma la logica è riassunta dalle formule di Falconer:

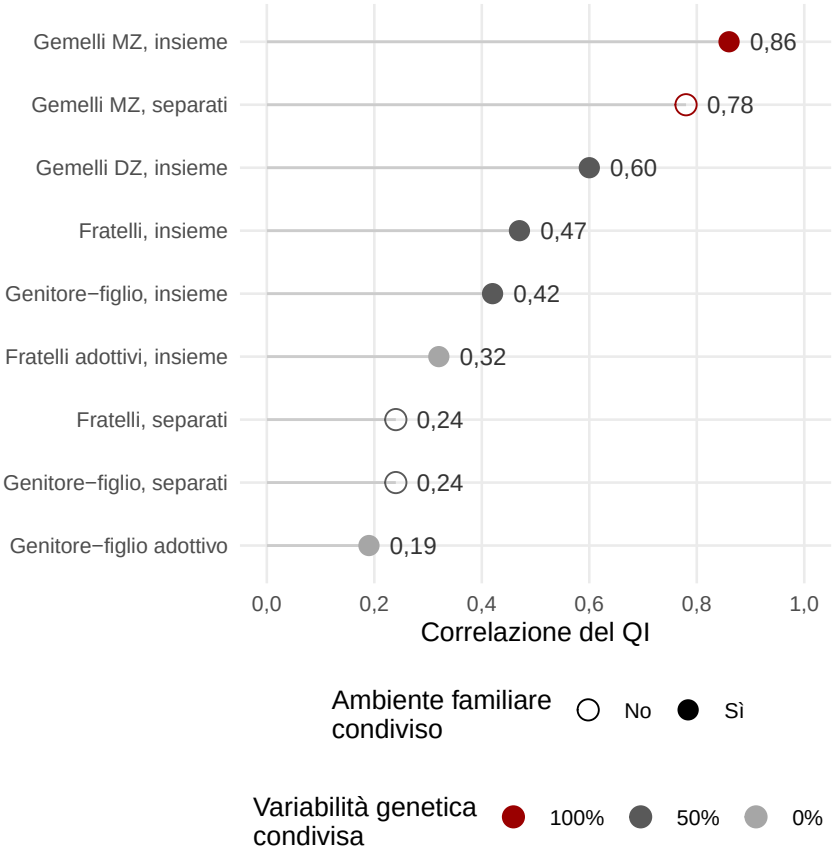


Figura 10.1: Correlazioni del QI fra persone con diversi gradi di parentela e di ambiente condiviso. Valori medi da sintesi della letteratura su famiglie, adozioni e gemelli; elaborazione da Plomin et al. (2001).

- ereditabilità: $h^2 = 2 \times (r_{\text{MZ}} - r_{\text{DZ}}) = 2 \times (0{,}86 - 0{,}60) \quad 0{,}52$;
- ambiente condiviso: $c^2 = 2 \times r_{\text{DZ}} - r_{\text{MZ}} = 1{,}20 - 0{,}86 \quad 0{,}34$;
- ambiente non condiviso ed errore di misura: $e^2 = 1 - r_{\text{MZ}} \quad 0{,}14$.

L'**ambiente condiviso** comprende tutto ciò che rende simili i membri di una famiglia: reddito, quartiere, stile educativo, libri in casa. L'**ambiente non condiviso** comprende ciò che li rende diversi: amicizie, insegnanti, malattie, eventi casuali. Con questi dati, che mescolano età diverse, circa metà delle differenze di QI è attribuibile a differenze genetiche.

10.3 L'ereditabilità cresce con l'età

Il dato più sorprendente è che l'ereditabilità del QI non è fissa. In un grande studio su gemelli di diversi paesi è risultata circa 0,41 nell'infanzia, 0,55 nella prima adolescenza e 0,66 nella tarda adolescenza (Haworth et al., 2010). Nell'età adulta le stime arrivano spesso a 0,7–0,8, mentre l'effetto dell'ambiente condiviso si riduce fin quasi a scomparire (Plomin & Deary, 2015).

Ci si aspetterebbe il contrario: con gli anni si accumulano esperienze, e l'ambiente dovrebbe pesare di più. Perché accade? Sono state proposte diverse spiegazioni.

- **Nuovi geni che entrano in gioco?** Sembra di no. Le influenze genetiche sul QI sono in larga parte le stesse alle diverse età; ciò che cambia è il loro peso (Briley & Tucker-Drob, 2013; Plomin & Deary, 2015).
- **Correlazione gene-ambiente.** È l'ipotesi più accreditata. Piccole differenze iniziali vengono amplificate perché bambini diversi suscitano risposte diverse da genitori e insegnanti e, crescendo, scelgono attivamente ambienti in linea con le proprie inclinazioni.
- **Riduzione dell'ambiente condiviso.** Crescendo si condivide sempre meno con la famiglia d'origine.
- **Stabilizzazione del QI.** Nell'infanzia i punteggi oscillano di più, per i diversi ritmi di maturazione cerebrale; poi si stabilizzano.

Un esempio chiarisce il meccanismo della correlazione gene-ambiente. Due bambini partono quasi uguali: uno esattamente nella media, l'altro un po' sopra. Il secondo ottiene voti leggermente migliori e preferisce attività un

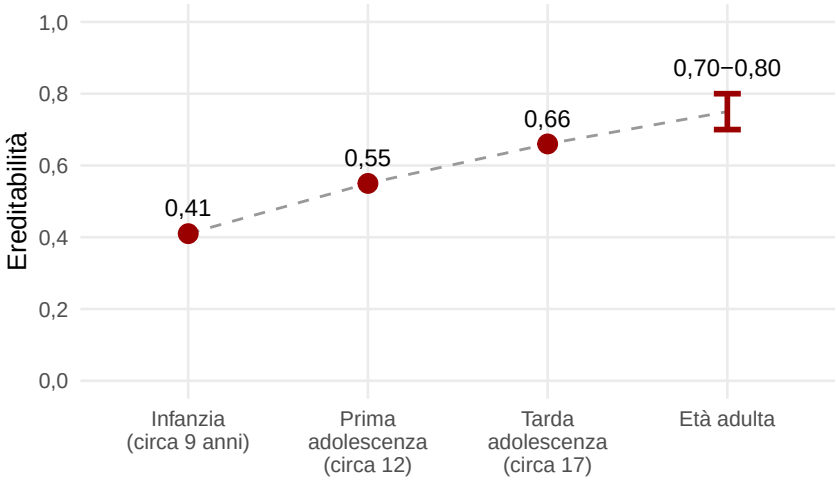


Figura 10.2: Ereditabilità del QI a età diverse. Valori da Haworth et al. (2010) per infanzia e adolescenza; per l'età adulta l'intervallo indica le stime tipiche riportate da Plomin e Deary (2015).

po' più impegnative. Nell'adolescenza sceglie una scuola più esigente, riceve più attenzione da qualche insegnante, frequenta amici con interessi simili. Da adulto sceglie un'università selettiva e un lavoro intellettualmente stimolante. Il primo fa scelte tipiche e arriva dove era partito. Il secondo, partito un po' sopra la media, arriva molto sopra. L'effetto genetico iniziale è stato amplificato dall'ambiente, e l'analisi lo attribuirà ai geni. La Figura 10.3 rappresenta l'esempio.

10.4 Che cosa l'ereditabilità non dice

Un'ereditabilità di 0,6–0,8 negli adulti suscita tre domande ricorrenti.

Significa che l'intelligenza è decisa dai geni e che impegno, istruzione e cambiamenti sociali sono inutili? No. L'ereditabilità descrive l'origine delle differenze fra individui in una popolazione, in un certo momento storico. Non dice nulla sul livello medio, né su che cosa accadrebbe

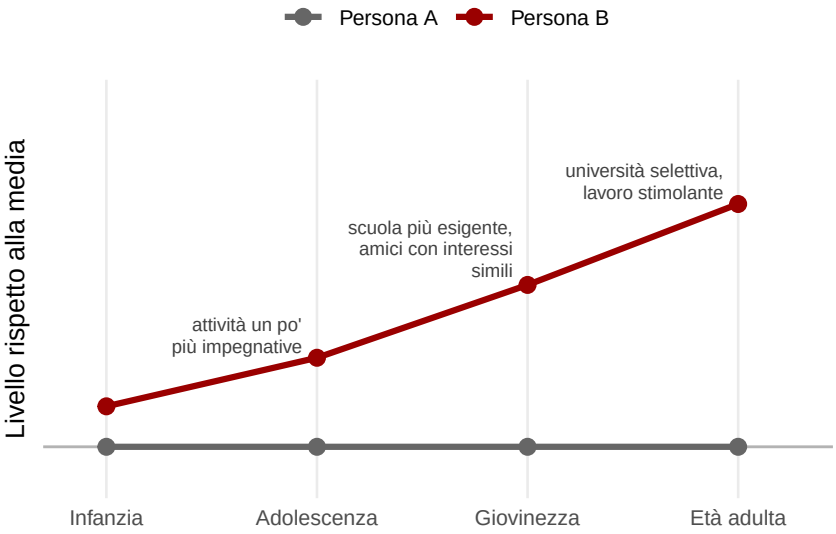


Figura 10.3: Un esempio di correlazione gene-ambiente. Una piccola differenza iniziale orienta scelte e ambienti che a loro volta la amplificano: alla fine la differenza è grande, e l'analisi la attribuisce in buona parte ai geni. Andamento puramente illustrativo. Schema originale.

cambiando l'ambiente di tutti. L'ambiente può avere effetti enormi sull'intelligenza dell'intera società, come mostra il capitolo sull'effetto Flynn, senza che l'ereditabilità cambi. E il restante 20–40% della varianza non è poco.

Il dato è definitivo? Non può esserlo per principio. L'ereditabilità esprime il peso dei geni in rapporto all'ambiente. Se le condizioni di vita diventassero più diverse da persona a persona, l'ereditabilità diminuirebbe; se diventassero più uniformi, aumenterebbe.

È meglio vivere in un mondo in cui l'ereditabilità dell'intelligenza è alta o bassa? Istintivamente si preferisce la seconda. Ma conviene pensarci. Un mondo con bassa ereditabilità è probabilmente un mondo di estremi, in cui alcuni crescono in condizioni molto avvantaggiate e altri in condizioni molto svantaggiate, e le differenze ambientali sono così grandi

da schiacciare quelle genetiche. Un'ereditabilità alta è, almeno in parte, il segno che le opportunità di base sono distribuite in modo relativamente uniforme.

10.5 Quando l'ambiente è povero

Non solo un ambiente disuguale abbassa l'ereditabilità. Anche un ambiente mediamente povero sembra farlo. In uno studio su gemelli statunitensi valutati a 7 anni, l'ereditabilità del QI era attorno al 10% nelle famiglie con lo status socioeconomico più basso e molto alta in quelle con lo status più alto (Turkheimer et al., 2003). In un ambiente svantaggiato il potenziale genetico ha poco margine per esprimersi, e piccole differenze di opportunità, come una famiglia stimolante o trascurante, fanno una grande differenza. In un ambiente benestante le opportunità di base sono comunque sufficienti e le differenze genetiche emergono.

Il risultato, però, non è universale. Una meta-analisi ha trovato questa moderazione negli Stati Uniti ma non in Europa occidentale e in Australia, dove l'ereditabilità non varia in modo apprezzabile con lo status socioeconomico (Tucker-Drob & Bates, 2016). Una spiegazione plausibile è che un accesso più universale a cure mediche, istruzione di qualità e sostegno al reddito renda anche le condizioni più povere non così povere, almeno per lo sviluppo cognitivo. È un'ipotesi, non un risultato dimostrato; ma è un'ipotesi con implicazioni politiche evidenti.

10.6 I limiti degli studi sui gemelli

Gli studi sui gemelli stimano quanta variabilità di un tratto riflette variabilità genetica, non quali geni siano coinvolti. E poggiano su alcune assunzioni discutibili.

La prima è che gemelli monozigoti e dizigoti condividano l'ambiente nella stessa misura. Forse i monozigoti vengono trattati in modo più simile, perché si somigliano di più. In tal caso una parte della loro somiglianza maggiore sarebbe ambientale e l'ereditabilità risulterebbe sovrastimata.

La seconda è che i dizigoti condividano esattamente metà della variabilità genetica. Questo è vero se gli individui si accoppiano a caso. Ma le persone tendono a scegliere partner simili, e l'intelligenza è uno dei tratti per cui questo accade di più: la correlazione fra i QI dei coniugi è attorno a 0,4 (Plomin & Deary, 2015). Se i dizigoti condividono più del 50%, l'ereditabilità risulta sottostimata. Viceversa, se contano interazioni fra geni o effetti di dominanza, i dizigoti condividono meno del 50% delle combinazioni rilevanti, e l'ereditabilità risulta sovrastimata.

Questi errori vanno in direzioni opposte e la loro entità è discussa. Il quadro generale, però, è sostenuto anche da disegni diversi, come gli studi sulle adozioni e sui gemelli cresciuti separati. Il prossimo capitolo mostra che cosa aggiungono i metodi della genetica molecolare, e perché le loro stime non coincidono con quelle dei gemelli.

In breve

- Basi genetiche ed ereditabilità sono concetti diversi: la seconda riguarda le differenze fra individui in una popolazione specifica.
- Studi su famiglie, adozioni e gemelli indicano che le differenze genetiche spiegano circa metà della varianza del QI considerando tutte le età.
- L'ereditabilità cresce con l'età, fino a 0,7–0,8 negli adulti, probabilmente perché le differenze genetiche iniziali vengono amplificate dall'ambiente.
- Un'ereditabilità alta non implica immutabilità e non permette, da sola, di trarre conclusioni sulle differenze medie fra epoche o gruppi; dipende dalla distribuzione degli ambienti.
- La moderazione da parte dello status socioeconomico è stata osservata negli Stati Uniti ma non in Europa occidentale e Australia.

Riferimenti bibliografici

11 Che cosa aggiunge la genetica molecolare

Per decenni il «gene dell'intelligenza» è stato cercato come si cerca una chiave smarrita: con la convinzione che da qualche parte ci fosse. Non c'è. Non esiste un gene dell'intelligenza, così come non esiste un gene della statura o della depressione. Esistono migliaia di varianti, ciascuna con un effetto minuscolo. Arrivare a questa conclusione è stato uno dei risultati più importanti della genetica degli ultimi vent'anni.

Gli studi sui gemelli dicono quanta variabilità di un tratto è associata a variabilità genetica. Non dicono quali geni siano coinvolti né come agiscano. Con il sequenziamento del genoma umano è diventato possibile cercare direttamente nel DNA. Questo capitolo spiega che cosa si è trovato, e perché i risultati hanno sollevato problemi nuovi invece di chiudere quelli vecchi.

11.1 Dal DNA alle varianti

Il DNA è una lunga sequenza di nucleotidi, che differiscono per una base azotata: adenina, timina, guanina o citosina. Un gene è un tratto di questa sequenza, lungo spesso migliaia di nucleotidi. Il genoma umano contiene circa ventimila geni che codificano proteine, e quasi tutti esistono nella popolazione in versioni leggermente diverse, chiamate **alleli**. Poiché ogni cromosoma è presente in due copie, una ereditata da ciascun genitore, ogni persona porta due alleli per ogni gene.

La forma di variazione più semplice e più studiata è il **polimorfismo a singolo nucleotide** (SNP): in una certa posizione del genoma, alcune persone hanno una base e altre un'altra. Il genoma umano contiene milioni di SNP comuni.

Gli **studi di associazione sull'intero genoma** (GWAS) si pongono una domanda semplice per ciascuno di questi SNP: chi porta una certa variante ha, in media, un QI più alto, più basso o uguale? Di solito si assume che gli effetti siano additivi: portare due copie della variante ha il doppio dell'effetto di portarne una.

11.2 Aghi in un pagliaio

Il problema è statistico. Gli SNP sono milioni, e i tratti come l'intelligenza sono **estremamente poligenici**: migliaia, forse decine di migliaia di varianti contribuiscono, ciascuna con un effetto piccolissimo. Per un tratto comportamentale tipico è raro che una singola variante comune spieghi più di una frazione infinitesimale della varianza. È stata proposta come una vera e propria «quarta legge» della genetica del comportamento (Chabris et al., 2015).

Per distinguere effetti così piccoli dal rumore servono campioni giganteschi. Uno dei GWAS di riferimento sull'intelligenza ha analizzato i dati di quasi 270.000 persone e ha identificato poco più di duecento regioni del genoma associate in modo statisticamente affidabile ai punteggi (Savage et al., 2018). Un altro, su circa 300.000 persone, ha ottenuto risultati simili (Davies et al., 2018). Le regioni identificate sono molte meno delle varianti realmente coinvolte: molte non superano le soglie di significatività, che per tenere conto dei milioni di confronti sono molto severe. E una regione può contenere molti SNP correlati fra loro, che contano come un solo segnale.

11.3 Il punteggio poligenico

Sommando gli effetti stimati in un GWAS sulle varianti presenti nel genoma di una persona si ottiene un **punteggio poligenico** (PGS): una stima della sua predisposizione genetica per un tratto. È un numero che si può calcolare alla nascita, o prima.

Quanto prevede? Poco, per ora. Un punteggio poligenico dell'intelligenza spiega in campioni indipendenti alcuni punti percentuali della varianza dei test cognitivi. Un punteggio costruito sui GWAS degli anni di istruzione, che dispongono di campioni ancora più grandi, arriva attorno al 7–10% (Lee et al., 2018; Plomin & von Stumm, 2018). È un risultato scientificamente notevole: una misura biologica, presente dal concepimento, prevede una differenza psicologica. Ma è troppo poco per qualsiasi conclusione affidabile sul singolo individuo. Due persone con lo stesso punteggio poligenico possono avere QI molto diversi. Le aziende che offrono previsioni genetiche sull'intelligenza dei figli vendono una precisione che non esiste.

11.4 L'ereditabilità mancante

Invece di cercare le varianti una per una, si può chiedere se la somiglianza genetica complessiva fra persone non imparentate, calcolata su tutti gli SNP comuni, si accompagni a una maggiore somiglianza nei punteggi. È l'idea della **analisi del tratto complesso sull'intero genoma** (GCTA). Fornisce un'ereditabilità stimata direttamente dal DNA, chiamata ereditabilità SNP (Davies et al., 2011).

Qui nasce un problema. Per l'intelligenza l'ereditabilità SNP si colloca attorno al 20–30% (Plomin & von Stumm, 2018). Gli studi sui gemelli, negli adulti, indicano il 60–80%. Dov'è finito il resto? È il problema dell'**ereditabilità mancante**, che riguarda quasi tutti i tratti complessi (Manolio et al., 2009).

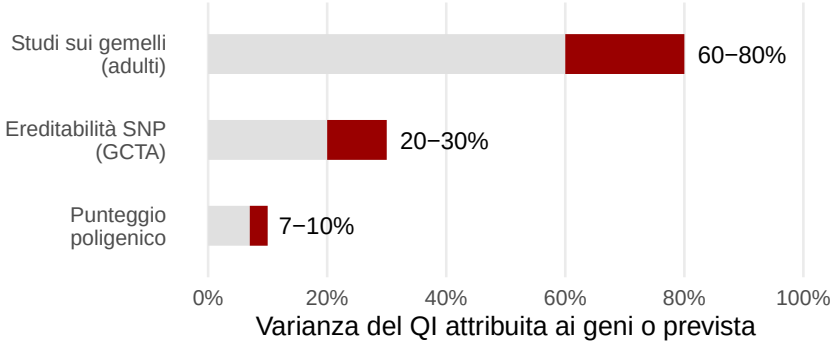


Figura 11.1: L'ereditabilità mancante. Quota di varianza del QI attribuita alle differenze genetiche dagli studi sui gemelli (adulti) e dall'analisi di tutti gli SNP comuni, e quota prevista oggi da un punteggio poligenico costruito sui GWAS degli anni di istruzione. Intervalli indicativi dalle fonti citate nel testo.

Le spiegazioni proposte sono diverse e non si escludono.

- **Varianti rare.** Gli studi molecolari analizzano soprattutto SNP comuni, presenti in più dell'1% della popolazione. Le varianti rare sono moltissime e potrebbero spiegare una parte importante della variabilità. È un'ipotesi abbastanza accreditata.

- **Effetti non additivi.** I GWAS stimano effetti additivi. Ma possono esistere interazioni fra geni, effetti di dominanza, interazioni fra geni e ambiente. Sono effetti genetici reali, che si manifestano nei gemelli monozigoti, identici per l'intero genoma, ma non in due sconosciuti che condividono un singolo allele.
- **Sovrastima negli studi sui gemelli.** Se i gemelli monozigoti condividono più ambiente dei dizigoti, una parte della loro somiglianza è stata attribuita ai geni per errore.
- **Limiti dei dati.** Gli SNP genotipizzati catturano solo in parte le varianti causali, e la qualità imperfetta delle misure cognitive usate nei grandi campioni abbassa le stime. La potenza conta soprattutto per i punteggi poligenici: campioni più grandi stimano meglio i singoli effetti e producono previsioni migliori.

Un risultato recente complica ulteriormente il quadro. Confrontando fratelli all'interno della stessa famiglia, che hanno ereditato varianti diverse ma condividono l'ambiente familiare, le associazioni genetiche con le abilità cognitive e con l'istruzione risultano sensibilmente più deboli che nel confronto fra famiglie diverse (Howe et al., 2022). Una parte di ciò che un GWAS attribuisce ai geni di una persona riflette quindi altro: l'ambiente creato dai genitori, che dipende in parte dai loro geni; la tendenza a scegliere partner simili; differenze di ascendenza correlate con condizioni sociali. È un richiamo alla cautela, non una smentita del ruolo dei geni.

11.5 Geni e ambiente insieme

Noi semplifichiamo: geni più ambiente uguale tratto. La realtà è più intricata. Due esempi estremi, fuori dall'intelligenza in senso stretto, aiutano a capire.

La **fenilchetonuria** è una condizione genetica recessiva. Chi eredita due copie alterate del gene che codifica un enzima non riesce a metabolizzare la fenilalanina, un aminoacido presente in molti alimenti. La sostanza si accumula e danneggia il cervello, causando una disabilità intellettiva grave. Ma la causa diretta è l'accumulo dovuto alla dieta. Se la condizione viene individuata alla nascita, come accade con lo screening neonatale, e si segue una dieta povera di fenilalanina, la disabilità non si sviluppa (Blau et al.,

2010). Una condizione interamente genetica nella causa ha una soluzione interamente ambientale nel trattamento.

Un esempio più sfumato riguarda alcune varianti del gene FTO, fra le più associate al peso corporeo. Il loro effetto si riduce sensibilmente nelle persone fisicamente attive (Kilpeläinen et al., 2011). La variante aumenta il rischio, ma il rischio si esprime in misura diversa a seconda dello stile di vita.

Per l'intelligenza, l'interazione con lo status socioeconomico vista nel capitolo precedente è un caso dello stesso tipo. Fra geni e punteggi ci sono lo sviluppo prenatale, la salute, il reddito familiare, lo stile educativo, i coetanei, la scuola, l'organizzazione progressiva del sistema nervoso. Ciascun passaggio può modulare gli effetti degli altri.

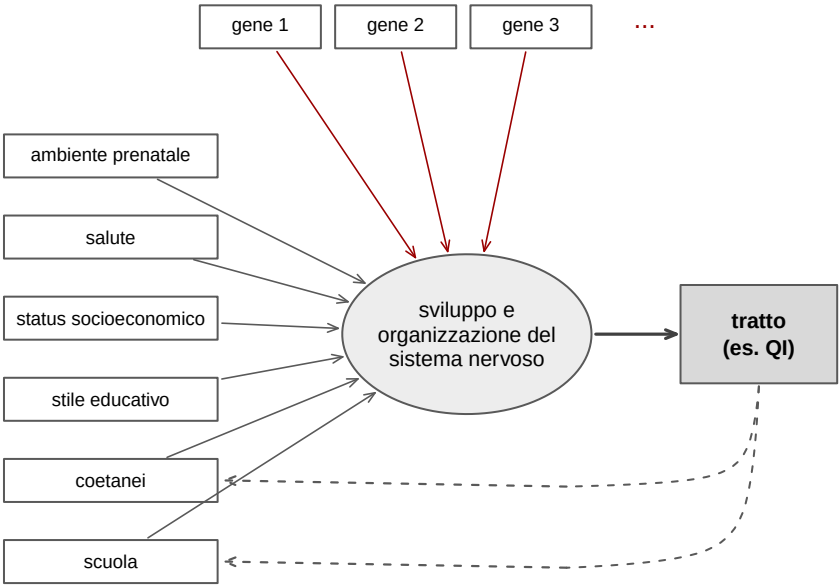


Figura 11.2: Geni e ambiente non si sommano semplicemente: agiscono insieme lungo lo sviluppo, attraverso l'organizzazione progressiva del sistema nervoso, e il tratto che ne risulta modifica a sua volta l'ambiente in cui la persona vive (frecce tratteggiate). Schema originale, ispirato a Turkheimer (2000).

11.6 Pleiotropia: gli stessi geni, molti tratti

Le varianti associate all'intelligenza non sono solo numerosissime: tendono a ricorrere in tratti diversi. È la **pleiotropia**, cioè la capacità dello stesso gene di influenzare più caratteristiche.

Questo spiega in parte la positive manifold. Le basi genetiche di abilità cognitive diverse si sovrappongono in larga misura: le stesse varianti contribuiscono alla memoria, al linguaggio, al ragionamento. Si parla per questo di **geni generalisti** (Kovas & Plomin, 2006). Gli stessi geni influenzano lo sviluppo di molte aree cerebrali, e ogni area partecipa a molti processi cognitivi. Le cause comuni ipotizzate da Spearman hanno, almeno in parte, una base genetica.

La sovrapposizione si estende oltre la cognizione. Le varianti associate all'intelligenza sono fortemente associate anche agli anni di istruzione e, in misura minore, a molte condizioni psichiatriche e neurologiche. Con alcune la correlazione genetica è negativa, come per ADHD e malattia di Alzheimer; con altre, come l'autismo, è debolmente positiva (Savage et al., 2018). Una correlazione genetica indica che gli stessi fattori genetici contribuiscono alle differenze in entrambi i tratti. Non indica che un tratto causi l'altro.

Per approfondire: la correlazione genetica nei gemelli

Anche gli studi sui gemelli permettono di stimare quanto due tratti abbiano basi genetiche comuni. Si usano le **correlazioni incrociate**: il punteggio di un gemello in lettura con il punteggio dell'altro gemello in matematica. Se questa correlazione è più alta nei monozigoti che nei dizigoti, una parte di ciò che lega lettura e matematica è genetica. La correlazione genetica r_{G} si ottiene rapportando la covarianza genetica fra i due tratti, stimata come $2 \times (r_{\mathrm{MZ,incrociata}} - r_{\mathrm{DZ,incrociata}})$, alla radice del prodotto delle due ereditabilità.

11.7 Le leggi della genetica del comportamento

Nel 2000 Eric Turkheimer riassunse in tre «leggi» ciò che gli studi su gemelli e famiglie avevano stabilito (Turkheimer, 2000):

1. ogni tratto comportamentale umano è in parte ereditabile;
2. l'effetto dell'ambiente condiviso in famiglia è di solito minore di quello dei geni;
3. una parte cospicua della variabilità resta attribuibile all'ambiente non condiviso, a eventi casuali e all'errore di misura.

La terza legge implica che non sarà mai possibile prevedere completamente il comportamento a partire da geni e ambiente familiare. La genetica molecolare ha poi aggiunto la quarta: ogni tratto dipende da moltissime varianti di effetto minuscolo (Chabris et al., 2015).

Queste leggi chiudono una vecchia polemica e ne aprono di nuove. Che i geni contino non è più in discussione. In discussione sono i meccanismi: come migliaia di varianti producano differenze nel cervello, come queste si traducano in differenze nelle prestazioni, e come l'ambiente amplifichi, attenui o indirizzi il processo. Le risposte richiedono di unire genetica, neuroscienze e psicologia dello sviluppo. Il prossimo capitolo affronta il secondo anello della catena: il cervello.

In breve

- Non esiste un gene dell'intelligenza: migliaia di varianti contribuiscono, ciascuna con un effetto minuscolo.
- I GWAS su centinaia di migliaia di persone hanno identificato circa duecento regioni del genoma associate all'intelligenza.
- I punteggi poligenici prevedono oggi una quota modesta della varianza, utile per la ricerca ma non per previsioni individuali.
- L'ereditabilità stimata dal DNA è molto inferiore a quella dei gemelli; varianti rare, effetti non additivi e limiti dei disegni sono le spiegazioni discusse.
- Le stesse varianti influenzano molte abilità e molti tratti: la pleiotropia fornisce una base genetica alla positive manifold.

Riferimenti bibliografici

12 Cervello e intelligenza

Dove si trova l'intelligenza nel cervello? La domanda è naturale e quasi del tutto sbagliata. Quando una persona risolve un problema di ragionamento si attivano molte aree, comprese quelle visive che elaborano le figure. Ma questo dice come funziona il cervello in generale, non perché alcune persone risolvano il problema meglio di altre. Le aree visive, per esempio, si attivano in tutti, e non distinguono chi va bene da chi va male.

La domanda che interessa lo studio delle differenze individuali è un'altra: quali caratteristiche del cervello, nella struttura, nelle connessioni, nel modo di attivarsi, distinguono persone con QI diverso? Le neuroscienze hanno accumulato evidenze che il fattore generale è legato all'anatomia e al funzionamento cerebrale. Ma questo campo è anche uno dei migliori esempi di come la ricerca possa illudersi, e poi correggersi. Per questo il capitolo parte dalle cautele.

12.1 Strumenti per guardare dentro la testa

La maggior parte degli studi usa la risonanza magnetica, in tre forme principali.

- La **risonanza strutturale** fornisce un'immagine tridimensionale statica del cervello: volumi di sostanza grigia, bianca e liquido, spessore della corteccia nelle diverse aree, superfici e circonvoluzioni.
- La **risonanza funzionale** (fMRI) misura le variazioni del flusso di sangue ossigenato nelle diverse regioni. Permette di stimare quanto un'area si attiva durante un compito e quali aree si attivano insieme, a riposo o durante un compito. Da questi pattern si ricavano le reti di **connettività funzionale**.
- La **risonanza di diffusione** misura come si muovono le molecole d'acqua nei tessuti. Nei fasci di fibre nervose l'acqua si muove soprattutto lungo la direzione delle fibre. Un indice come l'**anisotropia frazionaria** misura questa coerenza ed è usato come indicatore dell'integrità della sostanza bianca. Modelli più recenti stimano anche la densità e l'orientamento delle ramificazioni dei neuroni nella corteccia.

12.2 Perché tanti risultati non hanno retto

I dati di neuroimmagine sono molto rumorosi. Per molto tempo sono stati raccolti su campioni piccoli. Fra gli studi di risonanza funzionale più citati fino al 2012, la numerosità mediana era di circa dodici partecipanti; nel 2017–2018 era salita a poco più di venti (Szucs & Ioannidis, 2020). Già nel 2013 si stimava che la potenza statistica tipica degli studi di neuroscienze fosse fra l'8 e il 31% (Button et al., 2013). Con potenze così basse, gli effetti veri spesso non vengono rilevati, e quelli che risultano significativi sono sistematicamente sovrastimati. Aggiungendo la pubblicazione selettiva dei risultati positivi e la mancata correzione per i molti confronti, si ottiene una letteratura piena di scoperte che non si replicano.

Un caso esemplare. Nel 2009 uno studio su 19 persone trovò che un indice globale di efficienza delle reti cerebrali a riposo correlava con il QI attorno a $-0{,}5$ (van den Heuvel et al., 2009). Sembrava rivoluzionario. Studi successivi su migliaia di partecipanti non hanno confermato un effetto di quella grandezza per gli indici globali di efficienza; quando emergono associazioni con la connettività, sono distribuite su molte reti e di entità modesta. Oggi sappiamo che associazioni affidabili fra misure cerebrali e caratteristiche psicologiche richiedono in genere migliaia di partecipanti, perché gli effetti reali sono piccoli (Marek et al., 2022).

Il secondo problema è l'**overfitting**. I dati di neuroimmagine contengono moltissime informazioni per ogni persona: migliaia di regioni, milioni di voxel. Se si usano tutte per prevedere il QI di poche centinaia di persone, un algoritmo abbastanza flessibile trova sempre una combinazione che «indovina» il QI di ciascuna. Ma ha imparato le particolarità di quel campione, non una regola generale. La Figura 12.1 mostra il fenomeno con una simulazione.

La soluzione è verificare il modello su dati non usati per costruirlo, la **validazione incrociata**. Ma anche questa può ingannare, se i dati di stima e di verifica non sono davvero indipendenti: per esempio quando provengono dagli stessi centri o dalle stesse famiglie. Nel 2019 una competizione internazionale chiese a decine di gruppi di ricerca di prevedere l'intelligenza fluida di migliaia di ragazzi a partire dalla risonanza strutturale, escludendo il volume totale del cervello (Pohl et al., 2019). Molti usarono reti neurali

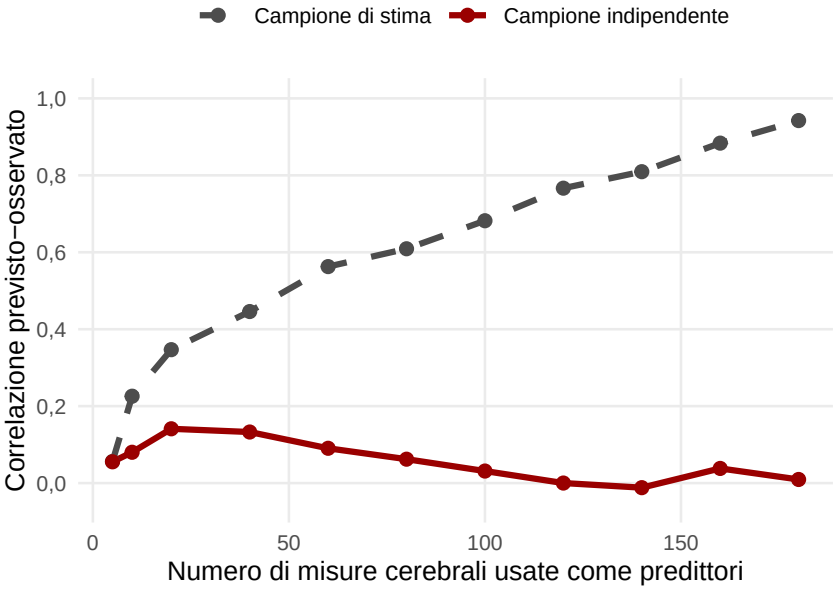


Figura 12.1: Simulazione dell'overfitting. Si prevede un punteggio da un numero crescente di misure cerebrali, ciascuna con un legame debolissimo con il punteggio, in un campione di 200 persone. La correlazione fra punteggi previsti e osservati cresce nel campione usato per stimare il modello, ma resta bassa e poi crolla in un campione indipendente.

profonde alimentate con le immagini grezze. Sul campione di verifica tenuto nascosto, le previsioni furono quasi nulle per tutti i partecipanti alla gara. Studi precedenti più piccoli avevano dichiarato capacità predittive molto superiori.

La lezione generale vale per tutto il capitolo: un singolo studio non è mai definitivo. Conviene fidarsi dei risultati replicati da gruppi indipendenti su campioni ampi. La buona notizia è che oggi questi campioni esistono, grazie a grandi consorzi internazionali.

12.3 Che cosa sappiamo davvero

12.3.1 Il volume cerebrale

Il risultato più solido è anche il più semplice: le persone con un cervello più grande tendono ad avere un QI più alto. In passato si citavano correlazioni fino a 0,40; le meta-analisi recenti e i grandi campioni le collocano attorno a 0,20–0,30 (Cox et al., 2019; Pietschnig et al., 2015). L'associazione sembra legata soprattutto alla superficie totale e allo spessore della corteccia, più che a singole aree particolari.

È un effetto sicuro ma modesto. Con una correlazione di 0,25 il volume del cervello non permette di prevedere il QI di una persona: individui con lo stesso volume si distribuiscono su quasi tutta la scala. Un cervello più grande è un vantaggio statistico, non una garanzia.

C'è poi un'anomalia istruttiva. I cervelli maschili sono in media circa il 10% più grandi di quelli femminili, una differenza superiore a una deviazione standard (Ritchie et al., 2018). Con la correlazione appena vista ci si aspetterebbe un vantaggio maschile di qualche punto di QI. Le differenze medie fra i sessi nell'abilità generale, invece, sono trascurabili (Halpern et al., 2007). Il dato non smentisce la correlazione fra volume e QI dentro ciascun sesso; suggerisce che, fra gruppi con cervelli organizzati in modo diverso, conti anche come il tessuto è distribuito e connesso, non solo quanto ce n'è.

12.3.2 Il cablaggio: la sostanza bianca

Non conta solo quanto tessuto c'è, ma come è connesso. La sostanza bianca è fatta dai fasci di assoni che collegano regioni distanti. La sua integrità, stimata con l'anisotropia frazionaria, correla con il fattore generale con valori attorno a 0,2 (Penke et al., 2012). L'associazione è più marcata in alcuni fasci: quelli che collegano lobi frontali e parietali e il corpo calloso, che collega i due emisferi. Il deterioramento della sostanza bianca nell'invecchiamento si accompagna al declino cognitivo, in particolare della velocità di elaborazione.

12.3.3 Reti efficienti

Uno studio su qualche centinaio di persone ha stimato la densità e l'organizzazione delle ramificazioni neuronali nella corteccia. Le persone con punteggi più alti avevano ramificazioni meno dense e più ordinate (Genç et al., 2018). Un'interpretazione è che lo sviluppo produca prima molte connessioni e poi ne elimini una parte, attraverso il processo di potatura sinaptica; un buon funzionamento cognitivo sarebbe associato a reti meno ridondanti e più efficienti. È un'ipotesi suggestiva, che richiede ulteriori conferme.

12.3.4 Attivazione efficiente

Alla fine degli anni Ottanta Richard Haier misurò il consumo di glucosio del cervello con la tomografia a emissione di positroni, mentre i partecipanti risolvevano le matrici di Raven. Chi otteneva punteggi più alti mostrava un metabolismo cerebrale **più basso**, non più alto (Haier et al., 1988). In un altro studio, persone che si allenavano per settimane a un videogioco mostravano un'attività corticale ridotta man mano che diventavano esperte (Haier et al., 1992). Nacque l'ipotesi dell'**efficienza neurale**: un cervello più capace ottiene lo stesso risultato con meno dispendio (Neubauer & Fink, 2009).

L'ipotesi nella forma originale ha dato risultati incoerenti: l'efficienza emerge soprattutto in compiti di difficoltà moderata e in alcune regioni, e non sempre nella stessa direzione (Neubauer & Fink, 2009). Lo stesso Haier la considera ancora utile, a patto di definirla e misurarla meglio (Haier, 2017). È sopravvissuta, infatti, in forme più specifiche. Le persone con QI più alto sembrano disattivare di più la rete cerebrale attiva a riposo, mentre attivano di più le aree richieste dal compito (Basten et al., 2013). E le loro reti di connettività funzionale cambiano meno quando passano dal riposo a compiti diversi, come se fossero già predisposte al lavoro cognitivo; il risultato è stato replicato in campioni indipendenti (Thiele et al., 2022).

12.4 Una teoria di sintesi: P-FIT

Il quadro teorico più citato è la **teoria dell'integrazione parieto-frontale** (P-FIT), proposta da Jung e Haier sulla base di decine di studi di neuroimmagine (Jung & Haier, 2007). Secondo la teoria, le aree parietali integrano e astraggono informazioni sensoriali di diverso tipo, quelle frontali pianificano e decidono, e la qualità dell'intelligenza dipende soprattutto dalla comunicazione fra queste regioni, quindi dall'integrità dei fasci che le collegano.

Una meta-analisi successiva ha confermato in larga parte il ruolo delle regioni fronto-parietali, aggiungendo altre aree (Basten et al., 2015). La tendenza attuale è vedere l'intelligenza sempre meno legata a singole regioni e sempre più distribuita su molte reti (Deary et al., 2022). Il P-FIT funziona oggi più come un'impalcatura che come una teoria con previsioni precise. Va notato anche che riguarda soprattutto il fattore generale: mancano evidenze robuste e replicate sui correlati cerebrali delle abilità specifiche, al netto di *g*.

12.5 Che cosa resta

Le caratteristiche del cervello associate in modo replicabile a un fattore generale più alto sono quindi globali: un volume maggiore, una sostanza bianca più integra, specialmente nelle connessioni fronto-parietali e fra emisferi, reti più efficienti, un'attivazione più mirata durante i compiti. Tutte hanno effetti modesti. Nessuna, da sola o in combinazione, permette oggi di prevedere in modo adeguato il QI di un individuo. E molte sono probabilmente correlate fra loro, sicché i loro contributi non si sommano semplicemente.

Il bilancio è meno spettacolare di quanto molti titoli abbiano promesso. È però più solido. Il fattore generale ha correlati biologici reali, così come ha basi genetiche reali. Ma la distanza fra le varianti genetiche, le caratteristiche cerebrali e le prestazioni nei test resta in gran parte da esplorare.

In breve

- La domanda utile non è dove si attiva il cervello durante un test, ma quali sue caratteristiche distinguono persone con QI diverso.
- Molti risultati iniziali, ottenuti su campioni piccoli o con modelli sovradattati, non sono stati replicati; servono campioni di migliaia di persone.
- Il volume cerebrale correla con il QI attorno a 0,2–0,3; integrità della sostanza bianca ed efficienza delle reti mostrano associazioni simili o minori.
- La teoria P-FIT sottolinea l'integrazione fra regioni parietali e frontali, ma il quadro attuale è sempre più distribuito; nessun indicatore prevede il QI individuale.

Riferimenti bibliografici

13 L'effetto Flynn e i cambiamenti storici

Le differenze di QI fra adulti sono in gran parte ereditabili. Già Galton ne era convinto, e gli studi sui gemelli lo hanno confermato. Ne segue che la capacità intellettiva è fissata nei geni? No. L'ereditabilità descrive le differenze in una certa società, in un certo momento storico. Ma la società e il momento storico possono cambiare. E possono cambiare moltissimo.

Il caso più spettacolare è quello che oggi porta il nome di James Flynn. Interessato al dibattito sulle differenze di QI fra gruppi, Flynn si accorse di un fatto che quasi tutti avevano trascurato: ogni volta che un test veniva ritarato su un nuovo campione, le persone ottenevano punteggi grezzi medi più alti di quelle della taratura precedente (Flynn, 1984). Il ritmo corrispondeva a circa tre punti di QI per decennio. In un secolo, trenta punti: due deviazioni standard.

13.1 Una crescita in tutto il mondo

Flynn mostrò che il fenomeno non era limitato agli Stati Uniti: lo stesso accadeva in molti paesi industrializzati, talvolta a ritmi ancora più elevati (Flynn, 1987). Una meta-analisi successiva, con dati raccolti fra il 1909 e il 2013 in decine di paesi, ha stimato un aumento medio globale di circa quattro punti di QI per decennio, con grandi differenze fra paesi ed epoche (Pietschnig & Voracek, 2015).

Che cosa significa, in concreto? Se valutassimo la popolazione di oggi con le norme di inizio Novecento, il QI medio sarebbe attorno a 130 (Figura 13.1). Viceversa, valutata con le norme di oggi, la persona media di inizio Novecento otterrebbe un punteggio attorno a 70, al confine con la disabilità intellettiva.

Il secondo numero fa capire perché la scoperta fu così sconvolgente. I nostri bisnonni non erano, in maggioranza, persone con una disabilità intellettiva. Lavoravano, gestivano famiglie e aziende, combattevano guerre, scrivevano libri. Eppure, per buona parte del Novecento, molti intellettuali dubitavano che le masse fossero capaci di svolgere ruoli cognitivamente complessi,

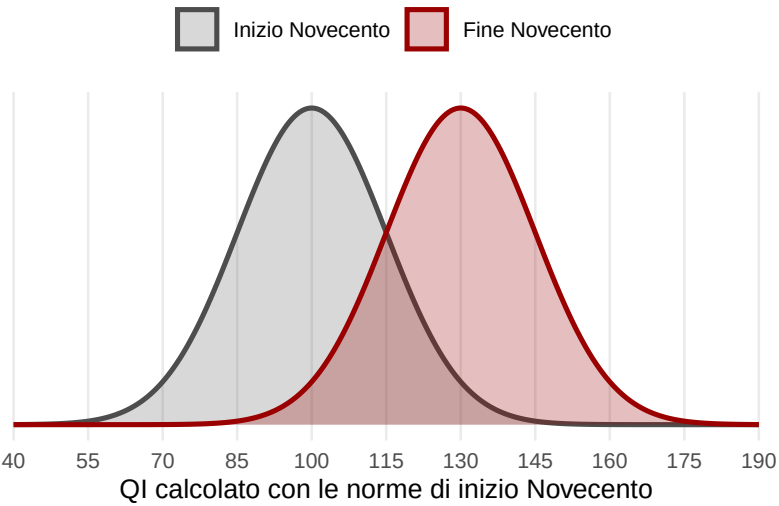


Figura 13.1: Illustrazione della grandezza dell'effetto Flynn. Le due curve rappresentano la distribuzione dei punteggi di una popolazione di inizio Novecento e di una di fine Novecento, entrambe espresse con le norme della prima. Il valore di 30 punti è un ordine di grandezza, non una stima per un paese specifico.

e sostenevano l'istruzione di massa con scarsa convinzione (Flynn, 2020). L'effetto Flynn è anche la smentita di quel pessimismo.

13.2 Perché i punteggi sono cresciuti

La prima cosa da escludere è la genetica. La composizione genetica di una popolazione non cambia in modo apprezzabile in pochi decenni: l'effetto Flynn non è evoluzione. Le cause vanno cercate nell'ambiente, e conviene distinguerne tre famiglie.

La prima è l'**ambiente materiale**: alimentazione più ricca e varia, minori carenze nutrizionali, come quella di iodio, ridotta dall'introduzione del sale iodato; meno malattie infettive, grazie a igiene, vaccini e antibiotici; minore esposizione a neurotossine come il piombo. Questi fattori sono stati probabilmente decisivi nella prima metà del secolo, e rilevanti più a lungo

per il piombo, eliminato da benzine e vernici solo negli ultimi decenni del Novecento.

La seconda è l'**ambiente sociale e culturale**: più anni di scuola per tutti, esposizione quotidiana a libri, giornali, radio e televisione, lavori sempre più cognitivamente impegnativi, famiglie più piccole, una vita quotidiana più complessa, varia e imprevedibile. Questi fattori sono rimasti attivi per tutto il secolo.

La terza sono i **bias di misura**: la crescente familiarità con il formato dei test, la pratica con prove simili. Questi aumentano i punteggi senza aumentare le capacità.

Flynn propose un'interpretazione suggestiva di come l'ambiente culturale abbia agito: cambiando le **abitudini mentali** (Flynn, 2020). Una persona di inizio Novecento, alla domanda su che cosa abbiano in comune un cane e un coniglio, poteva rispondere che il cane serve a cacciare il coniglio. Oggi si risponde che sono mammiferi. Davanti a un sillogismo con una premessa ipotetica, come «in questa regione non ci sono cammelli; questa città è in quella regione; ci sono cammelli in questa città?», la risposta poteva essere «non lo so, non ci sono mai stato». Il mondo di allora era ancorato all'utilità concreta delle cose. Il mondo di oggi abitua a classificare, astrarre, ragionare su ipotesi. Non a caso gli aumenti maggiori si osservano nelle prove come le matrici di Raven, che richiedono ragionamento ipotetico su stimoli astratti. Prove di intelligenza cristallizzata, come il vocabolario, sono cresciute di meno, nonostante l'enorme aumento della scolarità. L'effetto sembra riflettere più un cambiamento nel modo di ragionare che un effetto diretto dell'istruzione formale.

Nessuna spiegazione singola regge da sola. L'istruzione spiega male perché i guadagni siano maggiori nell'intelligenza fluida. La tecnologia non spiega perché la crescita sia iniziata prima della sua diffusione di massa, né perché si osservi anche in contesti rurali poco tecnologici. La familiarità con i test non spiega perché i guadagni siano cominciati prima che i test si diffondessero. L'alimentazione e la salute prevederebbero guadagni maggiori nei bambini, mentre spesso sono maggiori negli adulti (Pietschnig & Voracek, 2015). Il quadro più plausibile è quello di molti fattori che agiscono insieme e si rinforzano a vicenda, con pesi diversi in epoche e paesi diversi.

> **Attenzione clinica: le norme invecchiano**
>
> L'effetto Flynn ha conseguenze pratiche immediate. Se una persona viene valutata con un test tarato vent'anni prima, viene confrontata con una popolazione che nel frattempo è cambiata. Durante il Novecento questo portava a **sovrastimare** il QI: un punteggio di 108 poteva corrispondere a 100 rispetto ai coetanei attuali, uno di 76 a 68. Nel secondo caso la differenza può decidere una diagnosi di disabilità intellettiva. Per questo è essenziale usare test con tarature recenti. Oggi che l'effetto si è attenuato o invertito in molti paesi, il problema non scompare: i profili medi delle diverse abilità possono essere cambiati in direzioni diverse.

L'effetto ha conseguenze anche per la ricerca. Negli studi trasversali sul declino cognitivo, gli anziani possono sembrare molto compromessi rispetto ai giovani in parte perché appartengono a coorti che hanno sempre avuto punteggi più bassi. L'effetto Flynn è anche un effetto di coorte.

13.3 Che cosa è aumentato davvero?

Il QI è un indicatore osservato di qualcosa che non si osserva. Se il QI medio aumenta, aumenta anche l'intelligenza? Non è scontato.

Il primo dubbio è quello dei bisnonni: un aumento di due deviazioni standard nella capacità reale è difficile da credere. Il secondo riguarda la genetica: se le differenze di intelligenza sono fortemente ereditabili e i geni non sono cambiati, può l'intelligenza essere cambiata? Sì, se si ricorda che l'espressione di una base genetica dipende dall'ambiente, come il rosa dei fenicotteri del capitolo sull'ereditabilità. No, se per intelligenza si intende solo il potenziale genetico.

Il terzo dubbio è il più serio. Gli aumenti sono molto disomogenei fra le prove: fortissimi nelle matrici e nelle prove di velocità, minori nel vocabolario, modesti nel ragionamento aritmetico. E le prove che meglio rappresentano il fattore generale non sono sempre quelle cresciute di più. Le analisi psicometriche mostrano che i guadagni fra coorti non rispettano l'invarianza di misura: le differenze fra generazioni non hanno la stessa struttura delle differenze fra individui della stessa generazione (Wicherts et al., 2004).

Una lettura rigorosamente psicometrica suggerisce quindi che siano aumentate soprattutto abilità specifiche, più che *g* (te Nijenhuis & van der Flier, 2013).

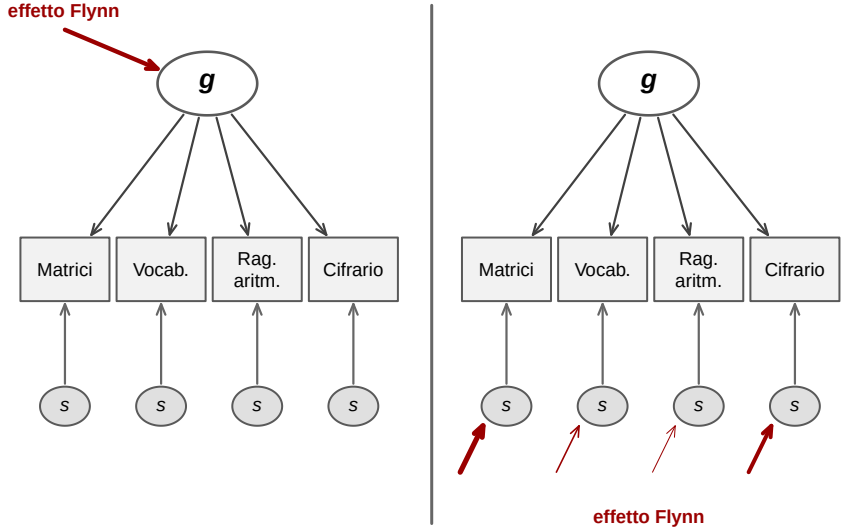


Figura 13.2: Due letture dell'effetto Flynn. Nel primo pannello l'ambiente agisce sul fattore generale, e i guadagni si trasmettono a tutte le prove in proporzione al loro legame con g. Nel secondo l'ambiente agisce sulle componenti specifiche s, con intensità diversa da prova a prova (frecce di spessore diverso). Schema originale.

Flynn arrivò a una posizione più sfumata. Se tutti i punteggi crescono, almeno un po', qualcosa dell'intelligenza deve essere cresciuto davvero. Non siamo diventati tutti geni, ma in molte abilità importanti la persona media raggiunge oggi livelli che a inizio Novecento sembravano impensabili. E anche se l'aumento non riguardasse *g*, mostrerebbe un'enorme plasticità delle capacità cognitive umane in risposta all'ambiente: un risultato forse più importante di *g* stesso. Una sintesi ragionevole è che i miglioramenti dell'ambiente materiale abbiano prodotto un aumento reale della capacità generale, soprattutto fino alla metà del secolo; che quelli dell'ambiente culturale abbiano prodotto un misto di capacità generale e abilità specifiche; e che i bias di misura abbiano aumentato solo i punteggi.

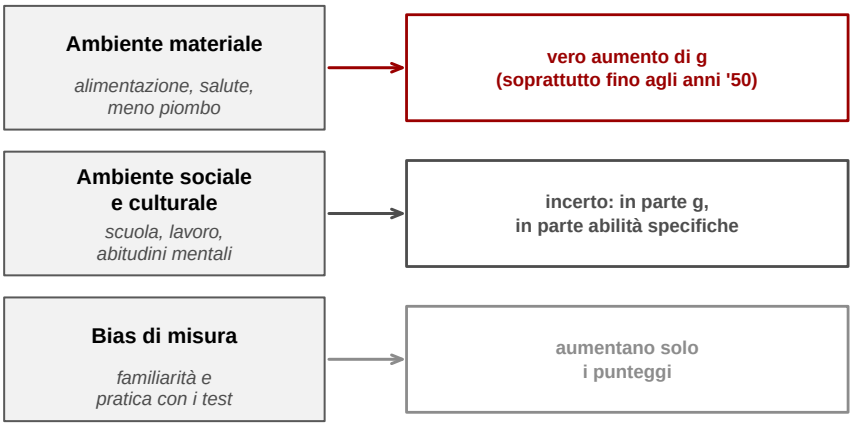


Figura 13.3: Le tre famiglie di cause dell'effetto Flynn e ciò che, secondo una sintesi ragionevole, ciascuna ha prodotto. Schema originale.

13.4 La fine, e l'inversione

L'effetto Flynn non è finito ovunque. Nella maggior parte del mondo, dove salute, nutrizione e scolarizzazione stanno ancora migliorando, i punteggi continuano a crescere (Pietschnig & Voracek, 2015). Nei paesi occidentali, però, la crescita si è fermata e in alcuni casi si è invertita.

Il primo segnale è venuto dalla Norvegia, dove tutti i ragazzi venivano valutati alla visita di leva: i dati mostravano un rallentamento a partire dagli anni Settanta e poi i primi segni di declino (Sundet et al., 2004). Oggi un **effetto Flynn inverso** è documentato in diversi paesi del Nord Europa, come Norvegia, Danimarca e Finlandia, oltre che in Francia e in altri contesti, con cali che in alcune stime arrivano a diversi punti di QI dagli anni Novanta (Dutton et al., 2016). Dati statunitensi raccolti online su quasi quattrocentomila adulti fra il 2006 e il 2018 mostrano cali in alcune abilità, come le serie di lettere e numeri e il ragionamento con matrici, ma un aumento nella rotazione mentale tridimensionale (Dworak et al., 2023). Proprio perché riguarda item tra i più difficili, questo aumento rende poco plausibile che il calo dipenda solo da un minore impegno dei partecipanti.

Si è proposta anche una spiegazione genetica: in molte società le persone con QI più alto hanno in media meno figli, e questo produrrebbe un lento effetto «disgenico». L'associazione esiste, ma è debole e il suo effetto stimato è piccolo; inoltre agiva già durante il Novecento, quando era ampiamente compensata dall'effetto Flynn. Un'analisi decisiva è venuta ancora dalla Norvegia. Se il calo fosse dovuto a chi fa più figli, dovrebbe emergere fra famiglie diverse. Invece emerge **dentro** le famiglie: fratelli nati in anni successivi hanno in media QI più bassi dei loro fratelli maggiori, e il fenomeno non dipende dall'ordine di nascita (Bratsberg & Rogeberg, 2018). Sia l'effetto Flynn sia la sua inversione sono quindi di origine ambientale.

13.5 Perché scendiamo?

Le ipotesi sono numerose e quasi tutte da verificare. È probabile che si sia esaurita la spinta dei fattori che hanno fatto crescere i punteggi, e che ora emergano anche effetti contrari. Fra quelli materiali si citano la sedentarietà, la qualità della dieta, l'esposizione a nuovi inquinanti, la riduzione del sonno. Fra quelli culturali, scuole che chiedono meno memorizzazione e lettura approfondita, l'abitudine a delegare alla tecnologia ciò che prima si doveva ricordare, un'attenzione più frammentata. È possibile anche un problema di misura: alcuni test potrebbero essere invecchiati e non cogliere abilità oggi rilevanti.

Un indizio a favore di una spiegazione ambientale e culturale è che non tutte le abilità scendono allo stesso modo: nei dati statunitensi citati, serie di lettere e numeri e matrici calano mentre la rotazione mentale cresce (Dworak et al., 2023). Un declino biologico generale non produrrebbe andamenti così divergenti. Nello stesso periodo si osserva un calo nei punteggi delle indagini internazionali sulle competenze scolastiche e, in alcuni studi, nelle prove di ragionamento formale di tipo piagetiano proposte agli adolescenti (Shayer & Ginsburg, 2009).

La tentazione di attribuire tutto agli smartphone è forte. Va resistita, almeno nella forma monocausale. Le associazioni fra uso delle tecnologie digitali e benessere o cognizione negli adolescenti, nei grandi studi, sono in media piccole (Orben & Przybylski, 2019), e il calo dei punteggi è iniziato in alcuni paesi prima della loro diffusione. Lo stesso Flynn, negli ultimi scritti, prevedeva che il QI medio sarebbe diminuito se la società avesse

ridotto le proprie richieste cognitive: meno lavori complessi, meno lettura, un'istruzione meno esigente (Flynn, 2020). È una previsione, non una spiegazione dimostrata. Ma ha il pregio di ricordare la lezione principale dell'effetto Flynn: l'intelligenza media di una popolazione dipende da ciò che quella popolazione chiede alle proprie menti.

In breve

- Per gran parte del Novecento i punteggi ai test di intelligenza sono cresciuti di circa tre-quattro punti di QI per decennio in molti paesi.
- Le cause sono ambientali: salute e nutrizione, scolarizzazione, ambienti più complessi e nuove abitudini di pensiero astratto, oltre a bias di misura.
- I guadagni sono disomogenei e non rispettano l'invarianza di misura: è probabile che siano aumentate soprattutto abilità specifiche, ma la plasticità dimostrata è reale.
- In diversi paesi occidentali l'effetto si è fermato o invertito; il calo avviene dentro le famiglie ed è quindi ambientale, non genetico.
- Usare test con norme recenti è indispensabile per non sovrastimare o sottostimare il funzionamento di una persona.

Per una presentazione divulgativa dello stesso tema si veda anche la pagina L'effetto Flynn.

Riferimenti bibliografici

14 Si può potenziare l'intelligenza?

Le differenze di intelligenza sono fortemente ereditabili e il QI è molto stabile dalla preadolescenza in poi. Eppure l'effetto Flynn mostra che le prestazioni cognitive di intere popolazioni possono crescere di molto. Ne nasce una domanda pratica: possiamo fare qualcosa, attivamente, per aumentare l'intelligenza di una persona?

La risposta breve è: sì, ma poco, e solo in certe circostanze. Guadagni ampi sono possibili soprattutto quando si interviene su bambini che vivono in condizioni di forte deprivazione. Per chi vive già in un ambiente favorevole, interventi come programmi prescolari aggiuntivi o giochi di allenamento cerebrale producono di solito effetti minimi o temporanei (Warne, 2020). La risposta lunga è più interessante, perché mostra come una letteratura scientifica possa produrre per anni risultati entusiasmanti che poi si dissolvono.

14.1 Effetti sicuri: la scuola

L'intervento più efficace che conosciamo è anche il più banale: andare a scuola. Più anni di istruzione si associano a QI più alti, e almeno in parte la relazione è causale. Una meta-analisi ha raccolto tre tipi di studi che permettono di avvicinarsi a una stima causale: studi longitudinali che controllano il QI misurato prima; studi che confrontano bambini nati a pochi giorni di distanza ma finiti in anni scolastici diversi a causa della data limite di iscrizione; studi su riforme che hanno allungato l'obbligo scolastico. La stima è di un aumento fra uno e cinque punti di QI per ogni anno di scuola in più (Ritchie & Tucker-Drob, 2018).

Non tutto è chiaro. Non sappiamo se l'effetto si cumuli in modo lineare per molti anni, né se riguardi l'abilità generale o soprattutto abilità specifiche. Uno studio longitudinale suggerisce la seconda ipotesi (Ritchie et al., 2015). Sembra che l'unica area priva di effetti apprezzabili sia la velocità di elaborazione. Ma una conclusione pratica è solida: la scuola non serve solo a trasmettere conoscenze. Aumenta le capacità con cui le si acquisisce.

14.2 Effetti sicuri: deprivazione e cura

Il secondo insieme di evidenze riguarda l'altro estremo: che cosa succede quando l'ambiente manca di cure di base. Una meta-analisi di 75 studi su quasi quattromila bambini cresciuti in istituti in 19 paesi ha trovato un QI medio attorno a 84, contro circa 104 dei coetanei cresciuti in famiglia. Il ritardo era maggiore per i bambini istituzionalizzati prima dei 12 mesi e nei paesi meno sviluppati (van IJzendoorn et al., 2008).

Uscire da queste condizioni verso un ambiente emotivamente e cognitivamente più ricco produce recuperi notevoli. Già negli anni Trenta Harold Skeels documentò aumenti di decine di punti in bambini trasferiti da un orfanotrofio a contesti più stimolanti (Skeels, 1966). L'adozione, in generale, è associata a un recupero sostanziale rispetto ai bambini rimasti nelle condizioni d'origine (van IJzendoorn et al., 2005). In uno studio svedese su fratelli separati, quelli adottati in famiglie con livello di istruzione più elevato avevano in media circa quattro punti di QI in più dei fratelli rimasti con i genitori biologici (Kendler et al., 2015).

Sono risultati importanti. Mostrano che ambienti molto diversi producono intelligenze diverse. Ma non sono facilmente traducibili in un intervento: non si può proporre l'adozione come trattamento.

14.3 Effetti probabili: interventi precoci in contesti svantaggiati

Si può allora portare il buon ambiente al bambino? Negli Stati Uniti, a partire dagli anni Sessanta, diversi progetti hanno offerto a bambini di famiglie molto povere servizi prescolari di alta qualità, spesso insieme a sostegno alle madri, cure mediche e pasti regolari. Alcuni, come il Carolina Abecedarian Project e il Perry Preschool Project, avevano un disegno sperimentale con assegnazione casuale.

I risultati iniziali erano promettenti: guadagni di diversi punti di QI, talvolta più di dieci, all'ingresso nella scuola primaria. Poi è arrivato il **fadeout**: negli anni successivi la differenza fra bambini trattati e di controllo si riduceva, fino a scomparire o quasi (Campbell et al., 2002). Le meta-analisi

degli studi randomizzati su interventi prescolari confermano lo schema: guadagni iniziali di alcuni punti, persi in gran parte entro pochi anni dalla fine dell'intervento (Protzko, 2015).

Questi studi lasciano alcuni punti fermi.

- Gli interventi funzionano meglio se precoci, in età prescolare.
- L'effetto sul QI svanisce quando l'intervento finisce. Per mantenerlo, l'ambiente migliore dovrebbe proseguire.
- Gli studi più recenti trovano effetti più piccoli di quelli storici. Una possibile ragione è che i contesti svantaggiati di oggi sono meno svantaggiati di allora: vaccinazioni, alimentazione e controlli medici, che i vecchi programmi includevano, sono ormai più accessibili a tutti (Duncan & Magnuson, 2013).
- Alcuni programmi hanno avuto effetti di lungo periodo su esiti diversi dal QI: più anni di istruzione, reddito più alto, meno reati. Per questo sono stati considerati economicamente vantaggiosi anche se il guadagno cognitivo era svanito (Heckman et al., 2010).

14.4 Effetti improbabili: la ricerca del Santo Graal

Da più di trent'anni ricercatori e aziende cercano un modo per aumentare l'intelligenza con attività comuni, senza cambiare drasticamente la vita di nessuno: ascoltare musica, allenarsi con giochi al computer, giocare a scacchi o ai videogiochi, prendere una pillola. Tre storie illustrano come è andata.

14.4.1 L'effetto Mozart

Nel 1993 uno studio su 36 studenti universitari riportò che dieci minuti di ascolto di una sonata di Mozart miglioravano la prestazione in alcune prove di ragionamento spaziale (Rauscher et al., 1993). L'effetto, se reale, era piccolo e durava pochi minuti. Ma la notizia fece il giro del mondo. Negli anni successivi lo stato della Georgia finanziò la distribuzione di dischi di musica classica a ogni neonato, e la Florida raccomandò musica classica nei servizi per l'infanzia.

Le repliche fallirono o diedero risultati contraddittori, spesso giustificati con dettagli sulla scelta dei brani anziché con l'ammissione che l'effetto era fragile. Una meta-analisi di circa 40 studi e oltre 3.000 partecipanti ha concluso che non esiste alcun effetto specifico di Mozart né della musica: si osserva solo un modesto miglioramento immediato dopo una stimolazione piacevole, compatibile con un aumento dell'attivazione e del buonumore, insieme a forti segni di pubblicazione selettiva (Pietschnig et al., 2010; Thompson et al., 2001).

E chi fa musica per anni? I musicisti esperti ottengono in media punteggi un po' più alti in diverse prove cognitive (Talamini et al., 2017). Un recente studio condotto in decine di laboratori di molti paesi, con circa 600 musicisti e altrettanti controlli, ha trovato vantaggi in molte prove, dalla memoria al vocabolario alle matrici (Grassi & Talamini, 2025). Una rianalisi con variabili latenti suggerisce che il quadro corrisponda soprattutto a un vantaggio di quasi mezza deviazione standard nel fattore generale, più un forte vantaggio specifico nella memoria per le melodie (Toffalini & Feraco, 2026). Non è chiaro se sia la musica a causare il vantaggio o il vantaggio a favorire chi sceglie di diventare musicista. È chiaro però che non è un trattamento: è uno stile di vita. Le meta-analisi sugli interventi musicali di breve durata nei bambini non trovano benefici cognitivi o scolastici apprezzabili, una volta considerata la qualità degli studi (Sala & Gobet, 2020).

14.4.2 I training di memoria di lavoro

La seconda storia è più seria, perché aveva una teoria. Molti psicologi cognitivi hanno pensato che *g* dipendesse da un processo di base, come la memoria di lavoro o il controllo esecutivo. Se l'intelligenza fluida richiede di mantenere e manipolare regole in memoria di lavoro, allenando la memoria di lavoro si dovrebbe migliorare l'intelligenza fluida.

Nel 2008 uno studio molto citato riportò che alcune settimane di allenamento con un compito di memoria di lavoro, il *dual n-back*, miglioravano i punteggi in una prova di matrici (Jaeggi et al., 2008). Altri studi riportarono miglioramenti nei sintomi di ADHD dopo un allenamento simile (Klingberg et al., 2005). Seguirono un'ondata di ricerche e un'industria dell'allenamento cerebrale che ha promesso di migliorare lo studio, il lavoro, la salute mentale e di contrastare il declino cognitivo (Simons et al., 2016).

Nel frattempo si sono diffusi anche i videogiochi d'azione, presentati come allenamento per attenzione e velocità.

Le meta-analisi hanno ridimensionato tutto. Gli allenamenti migliorano molto la prestazione nel compito allenato e, in misura minore, in compiti simili: è il **trasferimento vicino**. Ma il **trasferimento lontano**, verso abilità diverse, è minimo o nullo (Melby-Lervåg et al., 2016; Sala & Gobet, 2017). Lo stesso vale per scacchi, musica e videogiochi (Sala et al., 2018). Già nel 2010 un esperimento online con oltre diecimila partecipanti aveva trovato miglioramenti solo nei compiti allenati (Owen et al., 2010).

Perché la letteratura iniziale era così ottimista? Per una combinazione di problemi metodologici ricorrenti.

- **Controlli passivi.** Il gruppo allenato riceveva attenzione, aveva aspettative di miglioramento, si familiarizzava con le prove. Il gruppo di controllo aspettava. Senza un **controllo attivo**, che svolga un'attività di pari impegno e creda anch'esso di essere allenato, ogni differenza può derivare da motivazione e aspettative.
- **Abbandoni selettivi.** Chi non era motivato abbandonava il training più spesso di chi aspettava, lasciando nel gruppo allenato i più motivati.
- **Flessibilità analitica.** Molte misure, molte analisi possibili, pochi studi preregistrati: le possibilità di trovare qualcosa di «significativo» per caso erano altissime.
- **Pubblicazione selettiva.** Gli studi con risultati significativi venivano pubblicati più facilmente di quelli nulli.

L'ultimo problema lascia una traccia riconoscibile (Figura 14.1). Se si pubblicano soprattutto i risultati significativi, gli studi piccoli, che hanno stime imprecise, entrano in letteratura solo quando trovano effetti grandi. Gli studi grandi, più precisi, riportano effetti piccoli. Il risultato è un'asimmetria: l'effetto stimato cresce al diminuire della precisione. Esistono metodi per correggere la distorsione, stimando l'effetto che avrebbe uno studio infinitamente preciso.

Una volta corretta la pubblicazione selettiva e considerati solo gli studi con controlli attivi, il trasferimento lontano di qualsiasi tipo di allenamento cognitivo risulta praticamente nullo (Gobet & Sala, 2023). Nel 2016 la Federal Trade Commission statunitense ha multato una nota azienda di

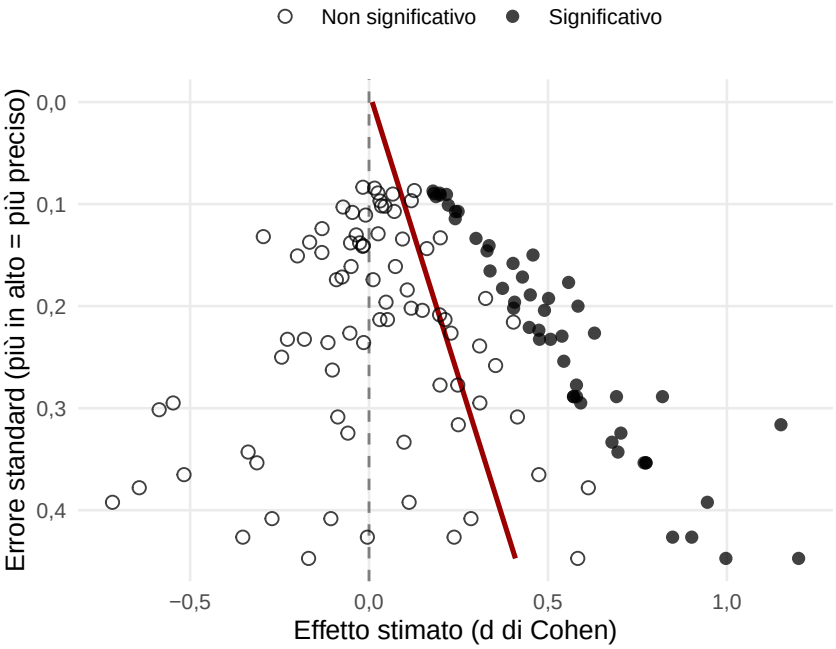


Figura 14.1: Simulazione di pubblicazione selettiva. 1.500 studi di numerosità diversa stimano un effetto vero pari a zero; quelli con un risultato positivo significativo vengono sempre pubblicati, gli altri solo nel 6% dei casi. La media degli effetti pubblicati è circa 0,2; gli studi piccoli riportano gli effetti più grandi. La retta che lega effetto ed errore standard incontra l'asse degli effetti, dove l'errore è nullo, vicino a zero.

giochi di allenamento cerebrale per pubblicità ingannevole: prometteva di migliorare il rendimento scolastico e lavorativo e di proteggere dal declino cognitivo, senza prove adeguate (Federal Trade Commission, 2016).

14.4.3 Pillole e stimolazione

Nicotina e psicostimolanti, come quelli usati per l'ADHD, possono migliorare in acuto alcune prestazioni, soprattutto in attenzione e memoria di

lavoro. Negli adulti sani gli effetti sono modesti e non modificano stabilmente l'abilità generale (Ilieva et al., 2015). Per chi ha un ADHD questi farmaci possono essere molto utili; come potenziatori dell'intelligenza nelle persone sane, no. Considerazioni simili valgono per le tecniche di stimolazione cerebrale non invasiva: alcune promesse, pochi effetti replicati su campioni ampi, di solito su funzioni specifiche e non sull'abilità generale. Oggi non esiste una pillola dell'intelligenza. Che non possa esistere in futuro è un'altra affermazione, e nessuno è in grado di dimostrarla.

14.5 Perché allenare una parte non migliora il tutto

Il fallimento dei training cognitivi è una delusione, ma era prevedibile. Attenzione però a come lo si spiega. Si dice spesso che nel modello gerarchico le frecce vanno dal fattore generale alle abilità specifiche, e che quindi l'effetto di un allenamento non può risalire (Warne, 2020). L'argomento vale solo se si prende il modello alla lettera, come un meccanismo che opera dentro ogni persona. Ma g, come si è visto, è il riassunto statistico di molte cause comuni, non un organo con un'uscita e un'entrata.

L'argomento più solido è un altro. Se le prove correlano perché dipendono dalle stesse cause comuni, migliorare una prova senza toccare quelle cause lascia intatto tutto il resto. Allenarsi al *dual n-back* rende più bravi nel *dual n-back*: cambia strategie e familiarità con un compito, non la biologia o l'esperienza accumulata che sostengono anche il vocabolario e le matrici. Ed è esattamente ciò che i dati mostrano. Chi ha promesso il contrario ha confuso la prestazione in un compito con la capacità che quel compito dovrebbe misurare. La Figura 14.2 riassume l'argomento.

Gli interventi che spostano davvero i punteggi, come la scuola o l'uscita da una deprivazione grave, sono invece cambiamenti ampi, che agiscono su molte cause insieme; quanto del guadagno riguardi g, e quanto abilità specifiche, resta discusso.

I risultati positivi, del resto, raccontano la stessa storia in forma opposta. Ciò che aumenta davvero le capacità cognitive sono cambiamenti ampi e duraturi dell'ambiente: anni di scuola, uscita da una deprivazione grave, una vita intera dedicata a un'attività complessa. Costano molto più di un'applicazione sul telefono, e funzionano.

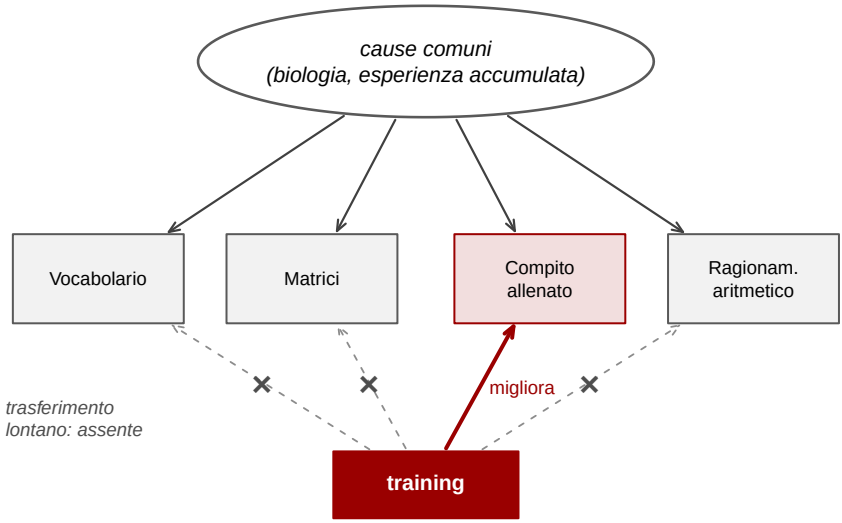


Figura 14.2: Perché l'allenamento su un compito non si trasferisce agli altri. Le prove correlano perché dipendono dalle stesse cause comuni; un training agisce sulla prova allenata (strategie, familiarità), non sulle cause comuni, e lascia quindi intatte le altre prove. Schema originale.

In breve

- La scolarizzazione aumenta causalmente i punteggi cognitivi, con stime fra uno e cinque punti di QI per anno.
- Deprivazione grave e cura carente abbassano il QI; l'uscita verso ambienti migliori, come l'adozione, produce recuperi sostanziali.
- Gli interventi prescolari in contesti svantaggiati producono guadagni iniziali che svaniscono in pochi anni, pur con alcuni benefici di lungo periodo su altri esiti.
- Effetto Mozart, training di memoria di lavoro e videogiochi non producono trasferimento lontano, una volta corretti controlli passivi e pubblicazione selettiva.
- Allenare un compito specifico non tocca le cause comuni che sostengono tutte le prove: per questo migliora quel compito e

poco altro.

Riferimenti bibliografici

Parte V

Scuola, salute e lavoro

15 Intelligenza, scuola e condizioni sociali

I test di intelligenza sono nati per prevedere. Binet voleva sapere quali bambini avrebbero avuto difficoltà a trarre profitto dalla scuola. I test dell'esercito dovevano indicare chi avrebbe sostenuto ruoli complessi. Wechsler cercava di stimare la capacità di vivere in autonomia. Questa parte del libro verifica quanto quelle previsioni funzionino davvero, partendo dall'ambito per cui i test sono stati inventati: la scuola.

Una premessa vale per i tre capitoli. Le correlazioni fra QI ed esiti rilevanti vanno da circa 0,20 a 0,50, e superano quella soglia solo nella scuola. Per la psicologia sono valori da medi a molto alti, e si indeboliscono man mano che l'esito si allontana dalle aule: forti con i voti, moderate con la prestazione lavorativa, modeste con il reddito. Ma anche una correlazione di 0,50 lascia la maggior parte della varianza non spiegata. Il QI pesa, a volte molto. Non è un destino.

15.1 Una previsione robusta

Il QI prevede il rendimento scolastico in qualsiasi materia. In uno studio su oltre 70.000 studenti inglesi, i punteggi a una batteria cognitiva somministrata a 11 anni sono stati confrontati con i risultati degli esami nazionali sostenuti a 16. Le correlazioni con le singole materie andavano da circa 0,4 nelle discipline artistiche a quasi 0,8 in matematica. Fra il fattore cognitivo generale e un fattore generale di rendimento negli esami la correlazione era circa 0,8 (Deary et al., 2007). Una meta-analisi su studi di tutto il mondo colloca la correlazione fra intelligenza e voti scolastici attorno a 0,54 (Roth et al., 2015).

Perché una relazione così forte? Il QI riflette capacità che la scuola richiede continuamente: memorizzare, astrarre, cogliere regole implicite, adattarsi a situazioni poco chiare, generalizzare ciò che si è imparato. Il QI, inoltre, misura queste capacità in modo più preciso di quanto possano fare osservatori esperti. Il giudizio degli insegnanti sulle abilità cognitive degli studenti correla con i test in misura apprezzabile, ma lontana dalla perfezione (Machts et al., 2016).

15.2 Una correlazione non è un'identità

Data una relazione così stretta, alcuni ricercatori usano direttamente voti, punteggi nelle indagini come PISA o anni di istruzione come indicatori dell'intelligenza. I punteggi PISA, in effetti, riflettono in larga parte un fattore generale (Pokropek et al., 2022). Ma la scorciatoia è pericolosa. Il QI, misurato bene, è una stima del funzionamento cognitivo attuale, non di un potenziale innato: anch'esso risente della scolarizzazione, come mostra il capitolo sul potenziamento. Ma ne risente molto meno del rendimento scolastico, che dipende direttamente dalla qualità delle scuole, dai programmi, dalla motivazione, dalle condizioni familiari, dal modo in cui una prova viene presentata.

Un caso italiano mostra il rischio. Lo psicologo Richard Lynn sostenne che gli italiani del Sud avessero un QI medio di circa dieci punti inferiore a quello degli italiani del Nord, e propose una spiegazione genetica. A sostegno citava correlazioni con reddito, mortalità infantile, statura e livelli di istruzione (Lynn, 2010). Ma i suoi «QI regionali» non erano QI: erano punteggi PISA di quindicenni in lettura, matematica e scienze.

Le repliche hanno messo in luce molti problemi (Cornoldi et al., 2010). Il divario Nord-Sud nei risultati scolastici diventa evidente nella scuola secondaria, dove il sistema educativo del Sud è storicamente più debole; se riflettesse l'intelligenza, dovrebbe essere visibile già alla primaria. Gli studenti del Sud ottengono buoni risultati nelle prove somministrate individualmente e peggiori in quelle collettive, segno di un diverso coinvolgimento nel compito. Fra un'edizione e l'altra di PISA i punteggi del Sud cambiavano in modo troppo rapido per riflettere differenze stabili di capacità. E i dati non coincidevano con quelli delle prove nazionali INVALSI. La lezione è generale: si può inferire l'intelligenza dagli apprendimenti solo dove le condizioni di apprendimento sono uniformi. Fra regioni con sistemi scolastici e contesti diversi non lo sono.

15.3 Intelligenza e istruzione: chi causa chi?

Il QI misurato nell'infanzia e il livello di istruzione raggiunto da adulti sono fortemente correlati, con valori oltre 0,50 (Strenze, 2007). Le spiegazioni possibili sono le solite tre.

L'intelligenza favorisce l'istruzione. Chi apprende più facilmente riceve più rinforzi positivi, sviluppa più fiducia nelle proprie capacità, sperimenta meno fallimenti, viene incoraggiato a proseguire. Nelle coorti britanniche nate nel Novecento, un QI di una deviazione standard più alto a 10–11 anni si associava a una probabilità circa tre volte maggiore di ottenere una laurea («Childhood cognitive ability and adult academic attainment», 2010). È un esempio di **effetto Matteo**, dal versetto evangelico secondo cui a chi ha sarà dato ancora: piccoli vantaggi iniziali si accumulano e si amplificano (Stanovich, 1986).

L'istruzione aumenta l'intelligenza. Come si è visto nel capitolo sul potenziamento, la scuola produce stimoli cognitivi, abitua all'astrazione, fornisce conoscenze e familiarità con le situazioni di valutazione. Le stime causali vanno da uno a cinque punti di QI per anno di istruzione (Ritchie & Tucker-Drob, 2018).

Cause comuni. Lo status socioeconomico della famiglia influenza sia lo sviluppo cognitivo sia le opportunità di studio. È certamente un fattore confondente. Nei paesi occidentali con istruzione, sanità e opportunità relativamente universali, tenerne conto riduce le stime, ma non le stravolge.

Le tre spiegazioni non si escludono. Le evidenze indicano che sono tutte e tre all'opera, e che si rinforzano a vicenda nel tempo.

15.4 Dall'istruzione allo status sociale

Se il QI prevede l'istruzione, prevede anche lo status lavorativo e il reddito? Una meta-analisi di studi longitudinali, in cui l'intelligenza era misurata prima degli esiti, ha stimato correlazioni attorno a 0,56 con il livello di istruzione, 0,43 con il prestigio della professione e 0,20 con il reddito (Strenze, 2007). L'intelligenza prevede quindi il successo socioeconomico, ma il legame si indebolisce man mano che ci si allontana dalla scuola.

Il mediatore principale è l'istruzione. Nei paesi industrializzati ogni anno di istruzione in più si associa in media a un reddito più alto di circa il 10% (Psacharopoulos & Patrinos, 2018). Il percorso tipico è quindi: intelligenza, rendimento scolastico, livello di istruzione, posizione lavorativa, reddito. L'intelligenza ha anche un effetto diretto, a parità di istruzione, ma più

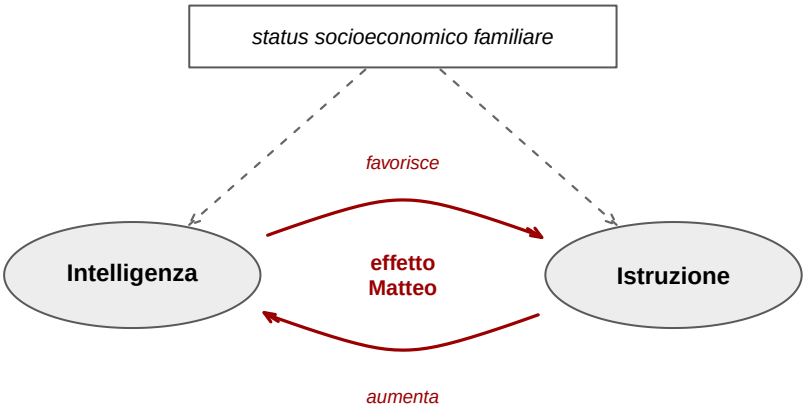


Figura 15.1: Le tre spiegazioni della correlazione fra intelligenza e istruzione non si escludono: intelligenza e istruzione si rinforzano a vicenda nel tempo (effetto Matteo), e lo status socioeconomico della famiglia agisce su entrambe come causa comune. Schema originale.

piccolo. Il suo ruolo principale è creare le condizioni perché gli altri passaggi avvengano.

La forza di questi legami non è fissa. Nelle coorti britanniche più recenti la correlazione fra QI nell'infanzia e durata degli studi si è ridotta: con l'espansione dell'istruzione, proseguire gli studi è diventato meno selettivo («Childhood cognitive ability and adult academic attainment», 2010). È un cambiamento che solleva domande scomode: quando un titolo di studio diventa la norma, smette di distinguere, e la selezione si sposta altrove, per esempio sul tipo di scuola o di università frequentata.

15.5 In cima alla distribuzione

Finora si è parlato della media e della parte bassa della distribuzione. Ma la stessa correlazione vale anche in alto, e qui circola un mito tenace: oltre una certa soglia, diciamo un QI di 120, l'intelligenza non farebbe più differenza, e conterebbero solo impegno, creatività e carattere.

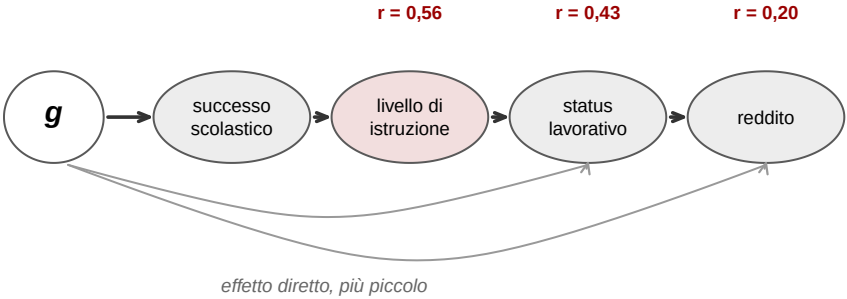


Figura 15.2: Dall'intelligenza al reddito. Il percorso principale passa per rendimento scolastico, livello di istruzione e posizione lavorativa; l'effetto diretto dell'intelligenza, a parità di istruzione, è più piccolo (frecce sottili). Le correlazioni longitudinali con istruzione, prestigio professionale e reddito sono circa 0,56, 0,43 e 0,20 (Strenze, 2007). Schema originale.

I dati più convincenti sul punto vengono dallo *Study of Mathematically Precocious Youth*, che dagli anni Settanta segue negli Stati Uniti migliaia di ragazzi selezionati a 13 anni perché si trovavano nell'1% più alto in prove di ragionamento. Anche dentro quell'1%, chi stava nel quarto superiore aveva da adulto probabilità sensibilmente maggiori di ottenere un dottorato, pubblicare in ambito scientifico o registrare un brevetto rispetto a chi stava nel quarto inferiore (Lubinski & Benbow, 2006). Fra i ragazzi identificati nell'uno su diecimila più alto, molti sono arrivati a posizioni di grande rilievo nelle università, nelle aziende e nelle professioni (Kell et al., 2013). La soglia oltre la quale «non conta più» non si trova. Si trova, semmai, una differenza di probabilità che continua ad agire anche fra persone già eccezionali.

Questo non trasforma la **plusdotazione** in una diagnosi. Non esiste un confine naturale fra alto potenziale e normalità, così come non esiste fra disabilità intellettiva e funzionamento limite; le soglie usate, spesso un QI di 130, sono convenzioni di rarità. E dire che «ogni bambino è dotato a modo suo», per quanto gentile, svuota la parola del suo significato: se tutti sono rari, nessuno lo è (Warne, 2020).

La domanda pratica è che cosa farne a scuola. Un secolo di ricerca indica che l'accelerazione, cioè anticipare l'ingresso a scuola o saltare un anno o

una materia, e alcune forme di raggruppamento per livello hanno effetti positivi sul rendimento degli studenti più dotati (Steenbergen-Hu et al., 2016). Non sono privilegi. Sono il riconoscimento che un programma tarato sulla media è troppo lento per chi sta molto sopra, esattamente come è troppo veloce per chi sta molto sotto. Resta infine il caso dei bambini con un'abilità generale alta e un disturbo dell'apprendimento: due rarità che si mascherano a vicenda, e che il capitolo sulla valutazione nel neurosviluppo aiuta a riconoscere.

15.6 Che cosa significa, e che cosa no

L'intelligenza è il miglior singolo predittore del rendimento scolastico che si conosca, e attraverso l'istruzione contribuisce alla posizione sociale. Questo non significa che la scuola sia una formalità o che i risultati siano già scritti. Significa, piuttosto, che le differenze cognitive si traducono in differenze sociali attraverso istituzioni concrete: classi, programmi, selezioni, titoli. Istituzioni diverse possono amplificare o attenuare quella traduzione. E chi usa i risultati scolastici come se fossero un test di intelligenza dimentica proprio queste istituzioni.

In breve

- Il QI prevede il rendimento scolastico in tutte le materie, con correlazioni attorno a 0,5 e fino a 0,8 a livello di fattori latenti.
- Rendimento scolastico e intelligenza non sono la stessa cosa: usare i risultati scolastici come proxy del QI fra contesti diversi porta a conclusioni sbagliate, come nel caso del divario Nord-Sud in Italia.
- Intelligenza e istruzione si influenzano a vicenda e condividono cause comuni, come lo status socioeconomico familiare.
- L'intelligenza prevede status lavorativo e reddito soprattutto attraverso l'istruzione; il legame si indebolisce allontanandosi dalla scuola.
- Anche ai livelli più alti l'abilità continua a fare differenza; per gli studenti più dotati, accelerazione e raggruppamento per livello migliorano il rendimento.

Riferimenti bibliografici

16 Salute e longevità

Un test somministrato a 11 anni prevede la probabilità di essere vivi a 76. Detta così, sembra una provocazione. È invece uno dei risultati più solidi della ricerca sull'intelligenza, e ha dato origine a un campo di studi con un nome proprio: l'**epidemiologia cognitiva**, che studia le associazioni prospettiche fra abilità cognitive ed esiti di salute (Deary et al., 2021).

Prospettiche significa che l'intelligenza viene misurata prima, spesso nell'infanzia, e gli esiti di salute molti anni dopo. Questo esclude una spiegazione ovvia: che siano le malattie dell'età adulta ad abbassare il QI. Non esclude però molte altre spiegazioni, ed è proprio sulla loro natura che conviene ragionare.

16.1 La sorpresa scozzese

Nel 1932 il Consiglio scozzese per la ricerca educativa somministrò un test di intelligenza a quasi tutti i bambini delle scuole scozzesi nati nel 1921. Più di sessant'anni dopo, un gruppo di ricercatori cercò di rintracciare i 2.792 bambini dell'area di Aberdeen per sapere se fossero ancora vivi. Chi era morto prima del 1997 aveva ottenuto a 11 anni un punteggio medio di circa quattro punti inferiore a quello di chi era ancora in vita (Whalley & Deary, 2001). Fra le donne, circa il 70% del quarto con i punteggi più alti era vivo a 76 anni, contro circa il 45% del quarto con i punteggi più bassi. Fra gli uomini la differenza era simile, con un andamento complicato dalle morti nella Seconda guerra mondiale, che avevano colpito di più chi aveva punteggi alti.

Lo stesso schema si è ripetuto in molte coorti: coscritti in Svezia, Danimarca, Norvegia e Israele, campioni statunitensi e britannici. Una meta-analisi di 16 studi, con oltre un milione di partecipanti seguiti per periodi fra 17 e 69 anni, ha stimato che un punteggio cognitivo più alto di una deviazione standard si associa a un rischio di morte inferiore del 24% (Calvin et al., 2011). L'associazione era simile per uomini e donne e non mostrava segni evidenti di pubblicazione selettiva.

16.2 Di che cosa si muore meno

Il secondo grande studio scozzese, del 1947, ha permesso di guardare alle cause. Più di 65.000 persone testate a 11 anni sono state seguite per 68 anni. Un QI infantile più alto di una deviazione standard si associava a un rischio minore di morte per quasi tutte le cause principali (Figura 16.1): malattie respiratorie, malattie coronariche, ictus, tumori legati al fumo, malattie dell'apparato digerente, demenza, incidenti (Calvin et al., 2017). Il legame era quasi lineare lungo tutta la distribuzione: non riguardava solo chi aveva punteggi molto bassi.

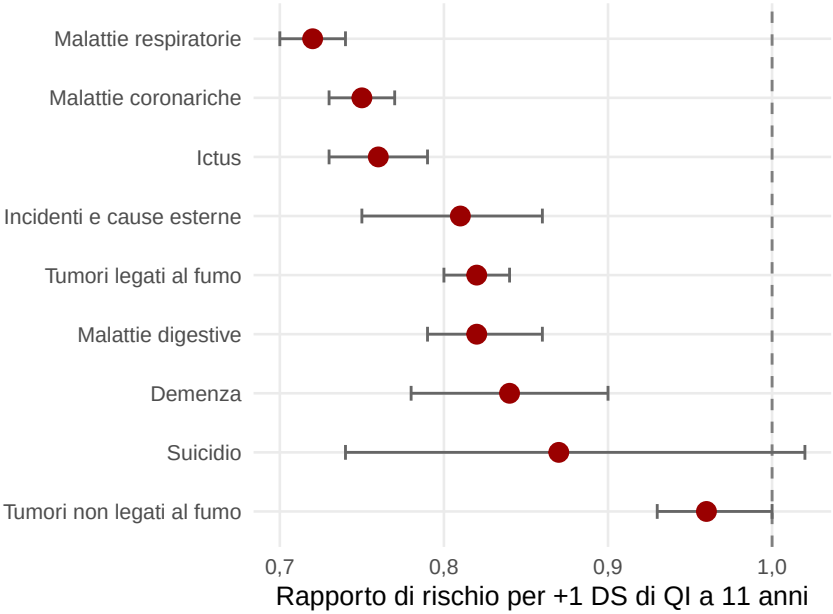


Figura 16.1: Rapporti di rischio di morte associati a un QI a 11 anni più alto di una deviazione standard, per causa, nella coorte scozzese del 1936 seguita fino a 79 anni. Valori inferiori a 1 indicano un rischio minore; le barre orizzontali sono intervalli di confidenza al 95%. Elaborazione da Calvin et al. (2017).

Un rapporto di rischio di 0,75 significa che, a ogni momento del periodo osservato, chi aveva un QI infantile più alto di quindici punti aveva un

rischio di morire per quella causa pari a circa tre quarti di quello di chi stava nella media. Non è una piccola differenza. È però una differenza di probabilità fra gruppi, non una previsione sul singolo: moltissime persone con QI alto muoiono giovani, moltissime con QI basso vivono a lungo.

16.3 Perché? Quattro percorsi

L'associazione fra intelligenza e longevità è complessa, piena di mediatori e in parte dovuta a cause comuni. Sono stati proposti quattro percorsi principali, non alternativi fra loro.

Il percorso socioeconomico. Un QI più alto favorisce più istruzione, che porta a lavori più sicuri, meno logoranti e meglio pagati, che a loro volta danno accesso ad abitazioni più salubri, quartieri meno inquinati e cure migliori. I dati sono istruttivi. Nella meta-analisi citata, tenere conto dello status socioeconomico della famiglia d'origine non modificava quasi l'associazione: le condizioni dell'infanzia non sembrano la causa comune di QI e longevità. Tenere conto della posizione sociale da adulti e del livello di istruzione la riduceva invece di circa un terzo e di circa la metà (Calvin et al., 2011). È compatibile con l'idea che istruzione e lavoro siano in parte la strada attraverso cui l'intelligenza si traduce in salute. Ma una riduzione statistica non distingue un mediatore da un fattore confondente, e il resto dell'associazione chiede comunque altre spiegazioni.

Il percorso dei comportamenti. Mantenersi in salute è anche un compito cognitivo. Richiede di capire informazioni mediche, seguire istruzioni sui farmaci, valutare rischi, pianificare, rinunciare a gratificazioni immediate. Le persone con punteggi più alti tendono a fumare meno, a bere meno, a fare più attività fisica, ad avere una dieta migliore. Linda Gottfredson ha proposto che l'intelligenza sia una delle cause fondamentali delle disuguaglianze di salute, proprio perché la gestione della propria salute è, di fatto, una lunga serie di problemi da risolvere (Gottfredson, 2004).

Il percorso dell'integrità del sistema. Un'ipotesi diversa è che punteggi cognitivi alti e buona salute siano entrambi segni di un organismo ben costruito e ben funzionante. Un sistema nervoso efficiente sarebbe un indicatore di un organismo resistente in generale (Deary, 2012b). In questo caso l'intelligenza non causerebbe la salute: entrambe rifletterebbero la stessa qualità di base.

Il percorso genetico. Una parte di quella qualità di base potrebbe avere origine genetica. Analisi su gemelli e su dati genetici molecolari suggeriscono che l'associazione fra intelligenza e durata della vita sia in buona parte dovuta a fattori genetici comuni (Arden et al., 2016). È un esempio della pleiotropia vista nel capitolo sulla genetica molecolare.

Un elemento in più complica il quadro: la salute fisica nell'infanzia influenza lo sviluppo cognitivo, e si collega a sua volta alla salute adulta. Alcune condizioni dei primi anni potrebbero quindi abbassare sia il QI misurato a 11 anni sia l'aspettativa di vita, senza che l'uno causi l'altra.

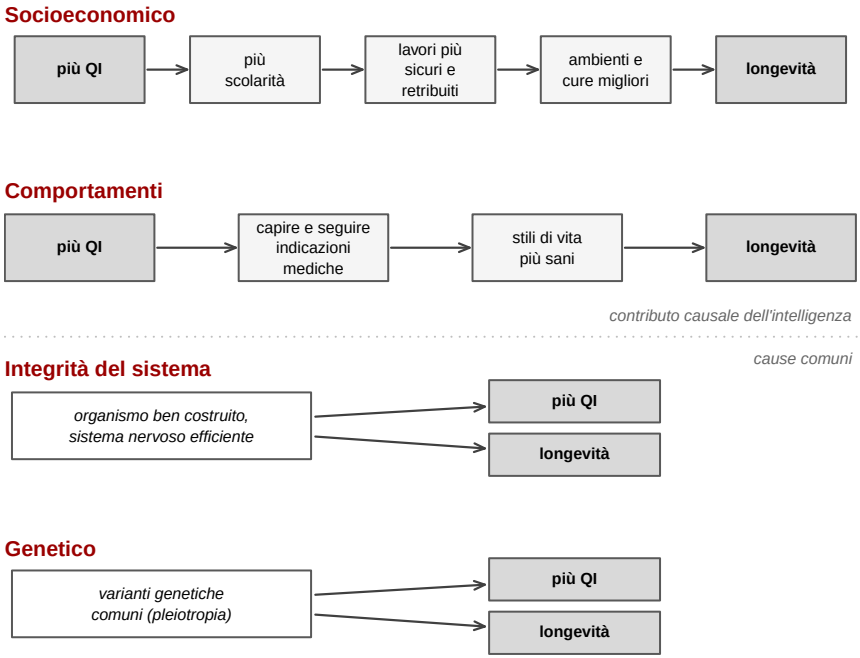


Figura 16.2: Quattro percorsi, non alternativi, che possono legare intelligenza e longevità. Nei primi due l'intelligenza contribuisce causalmente alla salute; negli altri due intelligenza e longevità hanno cause comuni. Schema originale.

16.4 Invecchiamento e demenza

Un capitolo a parte riguarda l'invecchiamento cognitivo. Il QI infantile prevede anche il rischio di morte per demenza, come si è visto nella coorte scozzese. Una parte di questa associazione è probabilmente legata al concetto di **riserva**. A parità di alterazioni cerebrali dovute all'età o alla malattia, alcune persone mantengono un funzionamento migliore di altre. Si distingue fra una riserva cerebrale, legata a caratteristiche strutturali come il volume del cervello, e una riserva cognitiva, legata al modo in cui i compiti vengono svolti e alle strategie disponibili. Studi epidemiologici indicano che istruzione, complessità del lavoro e attività intellettuali nel tempo libero si associano a un rischio di demenza più basso (Y. Stern, 2012).

Il quadro ha una conseguenza pratica per la valutazione. Una persona con un livello cognitivo di partenza elevato può mostrare punteggi ancora nella media quando il declino è già in corso; una con un livello di partenza basso può sembrare compromessa senza esserlo. Interpretare un punteggio nell'età anziana richiede quindi di stimare, quando possibile, il livello precedente, per esempio attraverso istruzione, professione o prove di conoscenze cristallizzate, che risentono meno dell'invecchiamento.

16.5 Che cosa se ne può concludere

L'associazione fra intelligenza e salute è robusta, replicata e di dimensioni non trascurabili. Le sue implicazioni pratiche sono però diverse da quelle che si potrebbero immaginare.

Non suggerisce di usare il QI per fare previsioni sanitarie individuali: la previsione sarebbe troppo imprecisa. Suggerisce invece che la complessità delle informazioni e delle procedure sanitarie è un fattore di disuguaglianza. Istruzioni più semplici, percorsi di cura meno faticosi, sistemi che non richiedono di districarsi da soli fra burocrazie e prescrizioni possono ridurre lo svantaggio di chi ha più difficoltà a risolvere problemi, qualunque ne sia la causa. Come per la scuola, il percorso dal punteggio all'esito passa per istituzioni costruite dagli esseri umani, e quindi modificabili.

Resta infine una distinzione da tenere sempre presente. Queste associazioni descrivono differenze fra individui all'interno di una popolazione. Non si

possono trasferire, senza altre evidenze, alle differenze medie fra gruppi o fra paesi, nelle quali la salute dipende da molte altre condizioni.

In breve

- Il QI misurato nell'infanzia prevede la longevità: in diverse coorti, una deviazione standard in più si associa a circa un quarto di rischio di morte in meno.
- L'associazione riguarda quasi tutte le principali cause di morte ed è approssimativamente lineare.
- I percorsi ipotizzati sono socioeconomici, comportamentali, di integrità del sistema e genetici, e probabilmente agiscono insieme.
- Si tratta di differenze di probabilità fra gruppi, non di previsioni individuali; la complessità delle cure è essa stessa una fonte di disuguaglianza.

Riferimenti bibliografici

17 Intelligenza e lavoro

Il capitolo su scuola e condizioni sociali ha mostrato che l'intelligenza prevede la posizione lavorativa e il reddito, soprattutto attraverso l'istruzione. Questo capitolo cambia prospettiva. Mettiamoci dal lato di chi deve assumere: un QI più alto è una caratteristica da cercare? E se sì, quanto conta rispetto ad altre?

Nella selezione del personale i test di intelligenza raramente si chiamano così. Prove di «problem solving», di «attitudine» o di «conoscenze generali» sono spesso prove di intelligenza fluida o cristallizzata con un altro nome. Anche il titolo di studio richiesto in un annuncio funziona in parte come filtro cognitivo indiretto, che evita di misurare il QI esplicitamente (Warne, 2020). Le batterie complete, invece, sono poco pratiche e in alcuni paesi pongono problemi legali.

Perché usarle? Perché sono economiche: rapide da somministrare, facili da correggere, standardizzate. Perché colgono la capacità di imparare compiti nuovi, più che ciò che si sa già fare. E perché offrono un criterio basato su dati. A condizione, naturalmente, che chi le usa sappia valutarne validità, attendibilità e adeguatezza al contesto.

17.1 Un caso estremo: l'esercito statunitense

L'esercito degli Stati Uniti è un'organizzazione con più di un milione di persone e centinaia di specializzazioni: analisti, informatici, meccanici, autisti, cuochi, medici, interpreti, contabili. La grande maggioranza non ha un ruolo direttamente legato al combattimento, e molti ruoli richiedono di imparare procedure tecniche complesse. Per questo, oltre ai filtri medici e legali, le reclute vengono valutate con una batteria di attitudini, da cui si ricava un punteggio di qualificazione con soglie minime fissate dal Dipartimento della Difesa.

Fra il 1966 e il 1971, durante la guerra del Vietnam, il segretario alla Difesa Robert McNamara abbassò quelle soglie con un programma chiamato «Project 100,000». Circa 354.000 uomini che in precedenza sarebbero stati esclusi, molti con punteggi corrispondenti a un QI inferiore a 92 e in

parte fino a circa 70, furono arruolati. La motivazione ufficiale era offrire disciplina, formazione e opportunità di integrazione a giovani di contesti svantaggiati (Warne, 2020).

Il programma fu un fallimento. Le nuove reclute dovevano ripetere l'addestramento molto più spesso, venivano congedate con maggiore frequenza e, secondo le ricostruzioni disponibili, morivano in combattimento a un tasso sensibilmente più alto. Anche dopo il ritorno alla vita civile, i loro esiti in termini di occupazione, reddito e stabilità familiare risultavano peggiori di quelli di coetanei con capacità simili che non avevano prestato servizio (Gregory, 2015). L'errore non stava nella mancanza di risorse per l'addestramento, ma nell'idea che chiunque possa essere formato per qualunque compito con sufficiente impegno. Il caso è diventato un esempio di come ignorare le differenze cognitive possa danneggiare proprio le persone che si vorrebbe aiutare.

17.2 Le stime classiche

Nella vita civile, il riferimento per decenni sono state le meta-analisi di Frank Schmidt e John Hunter. Secondo le loro stime, l'abilità mentale generale correlava circa 0,6 con il successo nella formazione professionale e circa 0,5 con la prestazione lavorativa: il miglior singolo predittore conosciuto (Schmidt & Hunter, 2004; Schmidt & Hunter, 1998).

Quei valori però non erano correlazioni osservate. Le correlazioni grezze erano spesso meno della metà. Erano state corrette per due fattori.

Il primo è l'**attendibilità**. Se il QI o la valutazione della prestazione contengono errore di misura, la correlazione osservata è più bassa di quella fra le grandezze vere. Conoscendo l'attendibilità delle misure si può stimare la correlazione «disattenuata».

Il secondo è la **restrizione del range**. Le correlazioni vengono calcolate su persone già assunte, cioè già selezionate, anche in base alle loro capacità. In un gruppo omogeneo la correlazione si riduce, come mostra la Figura 17.1.

In linea di principio, entrambe le correzioni sono legittime. Il problema è come sono state applicate. Revisioni recenti hanno mostrato che la correzione per restrizione del range era spesso basata su assunzioni arbitrarie e

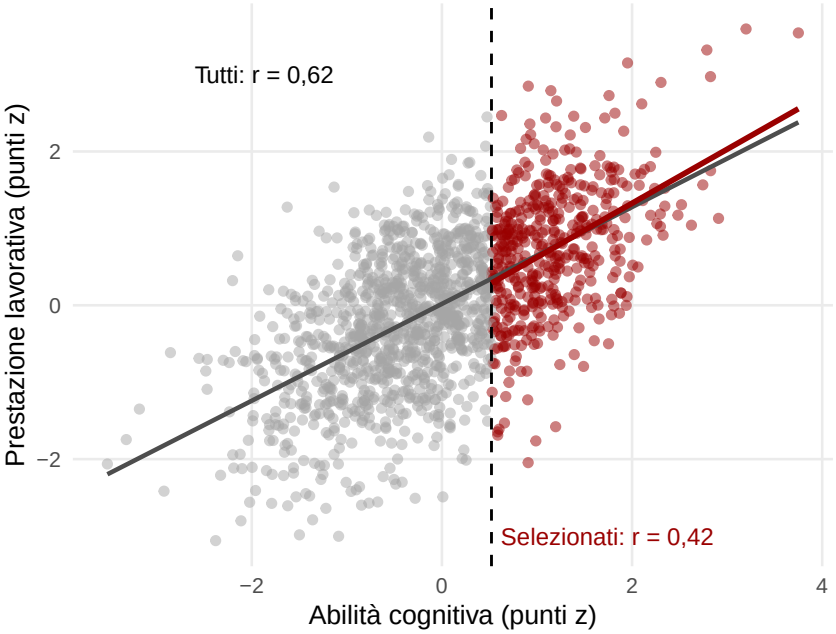


Figura 17.1: Restrizione del range in dati simulati. Nella popolazione completa la correlazione fra abilità e prestazione è circa 0,6; fra le sole persone selezionate, il 30% con l'abilità più alta, scende a circa 0,4.

veniva applicata anche quando la selezione era stata modesta, con un effetto sistematico di sovrastima. Rifacendo i calcoli con correzioni più prudenti, la validità dei test cognitivi per prevedere la prestazione lavorativa scende attorno a 0,3 (Sackett et al., 2022). Resta un predittore utile, ma non più nettamente superiore a tutti gli altri.

La revisione non ha chiuso la questione. Altri specialisti della selezione sostengono che rinunciare alla correzione porti all'errore opposto, cioè a sottostimare sistematicamente la validità (Oh et al., 2023). Il punto di consenso è più modesto, ma solido: l'abilità cognitiva prevede la prestazione lavorativa, con una validità almeno moderata, e lo 0,5 delle sintesi classiche va trattato come un limite superiore piuttosto che come un dato acquisito.

17.3 Dipende dal compito, e dal criterio

Le stime variano molto con il tipo di lavoro e con ciò che si vuole prevedere.

La complessità del lavoro. L'intelligenza prevede la prestazione in modo più forte nei lavori complessi, che richiedono di analizzare informazioni, decidere e coordinare, e in modo più debole in quelli semplici e ripetitivi. Durante la formazione, invece, la sua capacità predittiva è elevata quasi per qualsiasi lavoro: imparare un compito nuovo richiede sempre capacità cognitive (Schmidt & Hunter, 2004).

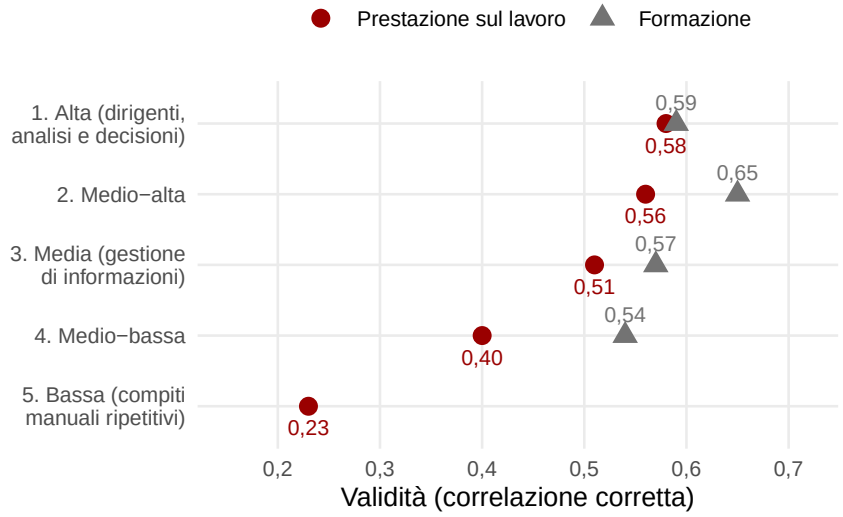


Figura 17.2: Validità dell'abilità cognitiva generale per livello di complessità del lavoro, nella prestazione sul lavoro e nella formazione. Stime classiche corrette per attendibilità e restrizione del range, da considerare limiti superiori; per i lavori di complessità minima manca la stima sulla formazione. Elaborazione da Schmidt e Hunter (2004), tabella 2.

Il criterio di prestazione. La correlazione è più alta con il rendimento nella formazione e con misure oggettive della prestazione nei compiti centrali del ruolo. È più bassa con i giudizi complessivi dei superiori,

che dipendono anche da relazioni e impressioni. È debole, ma presente, con comportamenti di collaborazione spontanea e, in senso negativo, con assenteismo e comportamenti scorretti.

La stratificazione fra professioni. Le professioni differiscono molto nel QI medio di chi le svolge. Uno studio recente su centinaia di professioni ha trovato una differenza superiore a una deviazione standard e mezza fra gli estremi, ma ha mostrato anche che le professioni si differenziano, in misura minore, per tratti di personalità e interessi (Wolfram, 2023). Le gerarchie occupazionali non sono costruite solo sull'intelligenza.

17.4 Oltre *g*

Il quadro che emerge dalle ricerche più recenti è meno centrato sul solo fattore generale.

Le **abilità cognitive specifiche** possono aggiungere informazione. Una meta-analisi ha trovato che conoscenze generali, velocità di elaborazione, abilità quantitative e abilità visive prevedono la prestazione in misura paragonabile o talvolta superiore al ragionamento fluido e all'abilità generale, specialmente quando corrispondono alle richieste della mansione (Nye et al., 2022). È un risultato in parziale tensione con la prevalenza di g vista nei capitoli sui modelli, e la discussione è aperta. Nel lavoro, a differenza che in un test, conta anche ciò che si è già imparato.

La **personalità** aggiunge un contributo indipendente. La coscienziosità, cioè l'affidabilità, l'organizzazione e la perseveranza, è un predittore della prestazione in quasi tutti i tipi di lavoro (Barrick & Mount, 1991; Wilmot & Ones, 2019). La stabilità emotiva conta soprattutto nel lavoro di gruppo; estroversione e amicalità nei ruoli a contatto con il pubblico o di guida. Onestà e umiltà sono utili soprattutto per prevedere, in negativo, comportamenti scorretti.

Molto popolari sono oggi le cosiddette **soft skills**: pensiero analitico, flessibilità, adattabilità, creatività, curiosità, capacità di apprendere. Il problema è che questa etichetta raccoglie costrutti che si sovrappongono in gran parte a intelligenza e personalità, con la differenza di essere presentati come intrinsecamente allenabili. Sono un esempio del rischio discusso negli approfondimenti finali: dare nomi nuovi a costrutti già noti.

17.5 Una valutazione equilibrata

L'intelligenza è un buon predittore della capacità di imparare un lavoro e di svolgerlo, soprattutto quando il lavoro è complesso. Le stime classiche erano probabilmente gonfiate da correzioni troppo generose, e oggi la si considera un predittore importante fra altri, non l'unico che conta. Per chi seleziona, la conclusione pratica è combinare misure: abilità generale, abilità specifiche rilevanti per la mansione, tratti di personalità. Per chi viene selezionato, la conclusione è un'altra: un test cognitivo può dire qualcosa di vero su quanto facilmente si impara, ma dice poco su quanto si sarà affidabili, collaborativi o motivati.

In breve

- I test cognitivi sono molto usati nella selezione del personale, spesso con altri nomi, perché sono rapidi, standardizzati e prevedono la capacità di apprendere compiti nuovi.
- Il caso del Project 100,000 mostra i costi di ignorare le differenze cognitive nell'assegnazione a ruoli complessi e rischiosi.
- Le stime classiche di validità, attorno a 0,5, erano gonfiate da correzioni eccessive per restrizione del range; stime più prudenti si collocano attorno a 0,3.
- La capacità predittiva è maggiore nei lavori complessi e durante la formazione; abilità specifiche e coscienziosità aggiungono informazione utile.

Riferimenti bibliografici

Parte VI

Intelligenza e condizioni del neurosviluppo

18 Dalle categorie alle dimensioni

Una diagnosi sembra una risposta: c'è o non c'è. Nel neurosviluppo, però, la risposta è quasi sempre una questione di grado. Essere molto distanti dalla media in qualche aspetto del funzionamento cognitivo, emotivo, comportamentale o sociale può creare difficoltà di adattamento al contesto in cui si vive. Ma quella distanza raramente si lascia chiudere negli inquadramenti netti che la medicina usa per le malattie.

Questo capitolo e il prossimo riguardano le **condizioni del neurosviluppo**: disabilità intellettiva, autismo, ADHD, disturbi specifici dell'apprendimento. Il loro legame con l'intelligenza è stretto, per due ragioni. La prima è pratica: la valutazione dell'intelligenza fa parte di quasi ogni percorso diagnostico. La seconda è teorica, ed è il tema di questo capitolo: le condizioni del neurosviluppo hanno la stessa struttura delle abilità cognitive, fatta di dimensioni continue e correlate. Capirlo cambia il modo di pensare la diagnosi.

Le definizioni diagnostiche riportate qui servono a orientarsi e vanno sempre verificate nelle versioni aggiornate dei manuali. Non sono una guida clinica.

18.1 Un caso illustrativo

Una bambina di nove anni viene valutata per difficoltà scolastiche marcate. La lettura è lenta e poco accurata, l'ortografia fragile, la matematica fonte di ansia. Genitori e insegnanti riferiscono distrazione frequente. Per il resto ragiona, ricorda e si relaziona come i coetanei. Il caso è costruito a scopo illustrativo, ma è molto tipico.

La valutazione cognitiva restituisce un QI totale di 84. Il dato, letto da solo, indicherebbe un funzionamento generale sotto la media. Ma gli indici raccontano altro: comprensione verbale e ragionamento sono nella media, memoria di lavoro e velocità di elaborazione molto sotto. L'indice di abilità generale, che esclude memoria di lavoro e velocità, è 100. Le prove di lettura e scrittura sono molto deboli, quelle di matematica deboli soprattutto nel calcolo scritto. Il questionario sull'ansia per la matematica dà valori elevati.

I questionari sull'attenzione compilati da genitori e insegnanti indicano difficoltà rilevanti, non confermate in modo netto dalle prove attentive.

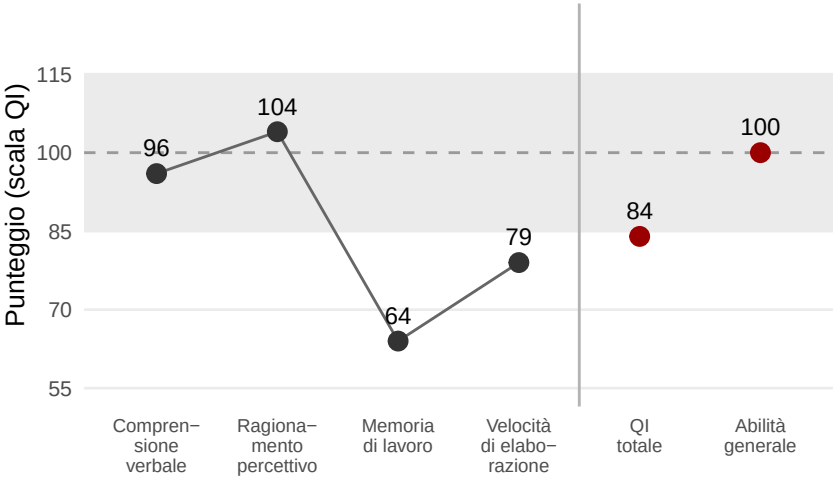


Figura 18.1: Il profilo del caso illustrativo. Il QI totale (84) risente delle cadute in memoria di lavoro e velocità di elaborazione; l'indice di abilità generale (100), che le esclude, è nella media come comprensione verbale e ragionamento percettivo. La fascia grigia indica l'intervallo fra 85 e 115. Dati costruiti a scopo illustrativo.

La conclusione sarà probabilmente una diagnosi di disturbo misto delle abilità scolastiche, con una segnalazione di difficoltà attentive. Ma il caso solleva domande che nessuna etichetta risolve. Dislessia e discalculia sono davvero condizioni distinte, se si presentano quasi sempre insieme? Le difficoltà in matematica sono cognitive o emotive? L'ADHD c'è o non c'è, se i sintomi riferiti sono chiari e le prove meno? Il quadro è misto, spurio, ed è del tutto reale.

18.2 Le categorie dei manuali

La pratica clinica inquadra queste difficoltà in categorie prefissate, quasi si trattasse di sindromi mediche. I manuali di riferimento, il DSM-5-TR

e l'ICD-11, definiscono i disturbi del neurosviluppo come condizioni che esordiscono nel periodo dello sviluppo e comportano difficoltà significative nell'acquisizione o nell'esecuzione di funzioni intellettive, motorie, linguistiche o sociali (Association, 2022; World Health Organization, 2019). La classificazione si basa sul quadro osservabile, non sulle cause.

Le categorie principali sono queste:

- **disabilità intellettiva**: limitazioni nel funzionamento intellettivo generale e nel comportamento adattivo nella vita quotidiana;
- **disturbo dello spettro dell'autismo**: difficoltà persistenti nella comunicazione e interazione sociale, insieme a comportamenti, interessi e attività ristretti e ripetitivi;
- **ADHD**: disattenzione e/o iperattività-impulsività persistenti, presenti in più contesti e tali da compromettere il funzionamento;
- **disturbi specifici dell'apprendimento**: difficoltà persistenti in lettura, scrittura o calcolo, non spiegate da disabilità intellettiva, deficit sensoriali o scolarizzazione insufficiente. In Italia la legge 170 del 2010 li riconosce come dislessia, disgrafia, disortografia e discalculia;
- disturbi della comunicazione e del movimento.

Nella disabilità intellettiva si distingue da sempre fra forme **sindromiche**, con cause genetiche identificate e segni fisici riconoscibili, come la sindrome di Down o dell'X fragile, e forme **non sindromiche**, senza una causa unica individuabile. Le seconde rappresentano in buona parte la coda inferiore della distribuzione normale delle abilità, prodotta dagli stessi innumerevoli fattori che generano le differenze nella popolazione generale. Questa distinzione è la chiave per capire tutte le altre condizioni.

18.3 L'illusione del deficit centrale

Per decenni la ricerca ha cercato per ogni disturbo un **deficit centrale**: un modulo cognitivo difettoso in uno sviluppo altrimenti normale. Un disturbo, un deficit. L'intelligenza contava solo come inquadramento generale o come criterio di esclusione. Oggi questo approccio è sostanzialmente abbandonato (Astle & Fletcher-Watson, 2020). I candidati non sono mancati.

Per l'**autismo** si sono proposti un deficit nella capacità di rappresentarsi gli stati mentali altrui, la cosiddetta teoria della mente; un malfunzionamento del sistema dei neuroni specchio; una tendenza a elaborare i dettagli perdendo la visione d'insieme; un orientamento estremo verso la sistematizzazione a scapito dell'empatia. Le differenze medie osservate sono reali, e nei compiti classici di teoria della mente possono essere ampie; ma variano molto da persona a persona e non bastano a definire la condizione. Le prime evidenze sui neuroni specchio non sono state confermate (Hamilton, 2013). Una meta-analisi non ha trovato né una superiorità nell'elaborazione locale né un deficit in quella globale (Van der Hallen et al., 2015). Anche l'idea di un deficit sociale tutto interno alla persona autistica è stata messa in discussione. Secondo l'ipotesi della **doppia empatia**, le difficoltà nascono soprattutto nell'incontro fra modi diversi di comunicare (Milton, 2012). Un esperimento ha trovato che catene di persone autistiche si trasmettevano un'informazione con la stessa efficacia di catene di persone non autistiche, mentre le catene miste funzionavano peggio (Crompton et al., 2020). È un risultato interessante, non ancora una teoria consolidata.

Per l'**ADHD** si sono proposti deficit di inibizione, di funzioni esecutive, di tolleranza dell'attesa. Le differenze medie esistono, di solito attorno a mezza deviazione standard, ma nessuna distingue in modo affidabile chi ha la diagnosi da chi non ce l'ha. E differenze di entità simile si trovano anche in compiti non specifici: memoria a breve termine, velocità, perfino ragionamento astratto (Sjöwall et al., 2013).

Per la **dislessia** il candidato più forte è il deficit fonologico, insieme alla lentezza nella denominazione rapida. Qui le differenze medie sono grandi, oltre una deviazione standard. Ma molti casi di dislessia non presentano quei deficit, e nessun marcatore singolo è necessario o sufficiente (Pennington, 2006). Per la **discalculia** il presunto deficit del senso del numero mostra differenze medie modeste, mentre molti processi generali, come memoria di lavoro, velocità e ragionamento, risultano ugualmente o più compromessi.

Il bilancio è netto. Nessun marcatore genetico, di neuroimmagine, neurofisiologico, cognitivo o neuropsicologico ha oggi una capacità diagnostica adeguata per nessuna delle condizioni del neurosviluppo (Astle et al., 2022).

18.4 Soglie arbitrarie

C'è una ragione profonda per cui i deficit centrali non si trovano. È la stessa per cui le abilità cognitive hanno una distribuzione continua. Ogni comportamento umano è il risultato di moltissimi fattori genetici, neurobiologici, ambientali ed esperienziali. Che si sommino o, in parte, si moltiplichino, il risultato di molti fattori è comunque una distribuzione continua. E in una distribuzione continua non esiste una soglia naturale.

La lettura ne è l'esempio classico. Già all'inizio degli anni Novanta uno studio longitudinale mostrò che l'abilità di lettura nella popolazione si distribuisce lungo un unico continuo, senza un punto in cui finisca la distribuzione dei lettori tipici e cominci quella dei dislessici (Shaywitz et al., 1992). La dislessia, in questo senso, non è una categoria naturale: è il nome che diamo alla parte bassa della distribuzione di un'abilità che la scuola richiede. Anche per l'ADHD, uno studio su gemelli ha trovato che l'ereditabilità dei sintomi è la stessa lungo tutto il continuo, dai livelli più alti fino alla piena normalità: non esiste un nucleo genetico distinto del disturbo (Levy et al., 1997).

Ne segue che la prevalenza di questi disturbi dipende dalla soglia scelta (Figura 18.2). Le soglie riflettono convenzioni di rarità, come il 5° percentile o due deviazioni standard sotto la media, e considerazioni pragmatiche sul bisogno di supporto. Sono decisioni ragionevoli, non scoperte.

Questo porta a un rovesciamento della causalità che conviene rendere esplicito. Non si legge con fatica a causa della dislessia: si riceve la diagnosi di dislessia perché si legge con fatica, per ragioni non altrimenti spiegate. Non si è iperattivi a causa dell'ADHD: si riceve l'etichetta di ADHD perché si è molto iperattivi. L'etichetta descrive un comportamento osservato, non ne individua la causa. E poiché il comportamento è a valle di innumerevoli concause, non si troveranno mai poche variabili fortemente associate, ma molte variabili associate debolmente.

18.5 Comorbilità ovunque

Il secondo problema per l'approccio categoriale è la **comorbilità**. Le condizioni del neurosviluppo si presentano insieme molto più spesso di quanto

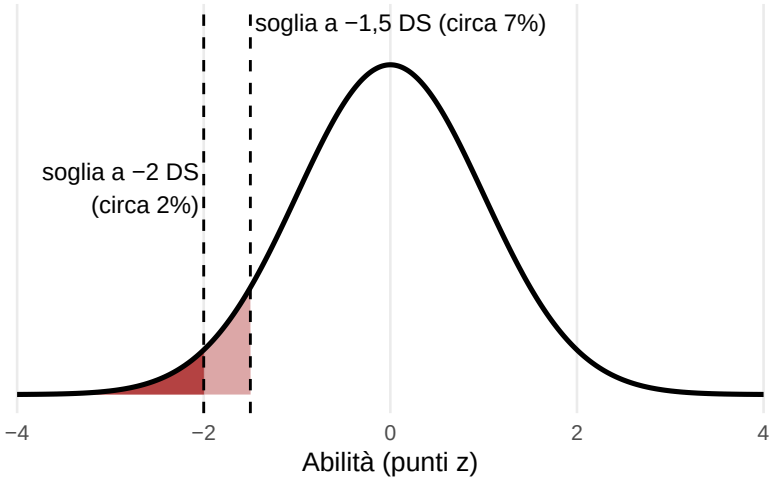


Figura 18.2: Distribuzione continua di un'abilità e due possibili soglie diagnostiche. Una soglia a −1,5 deviazioni standard identifica circa il 7% della popolazione; una a −2 circa il 2%. La distribuzione non contiene alcun punto di discontinuità.

ci si aspetterebbe se fossero indipendenti. Una parte consistente delle persone autistiche ha anche una disabilità intellettiva o un ADHD; la dislessia si associa spesso alla disortografia e a difficoltà in matematica; ADHD e disturbi dell'apprendimento co-occorrono con frequenza elevata. Nelle casistiche cliniche dei disturbi dell'apprendimento, i quadri misti sono la norma più che l'eccezione (Toffalini et al., 2017).

Sotto le etichette troviamo quindi tratti **continui**, con soglie arbitrarie, e **correlati**, con comorbilità estese. È esattamente la struttura delle abilità cognitive: distribuzioni gaussiane e positive manifold. E, come per le abilità, la spiegazione più semplice della correlazione è l'esistenza di cause comuni.

18.6 Verso modelli dimensionali

Nella psicopatologia dell'adulto questa consapevolezza ha portato a proposte alternative ai manuali categoriali. La più sviluppata è la **tassonomia**

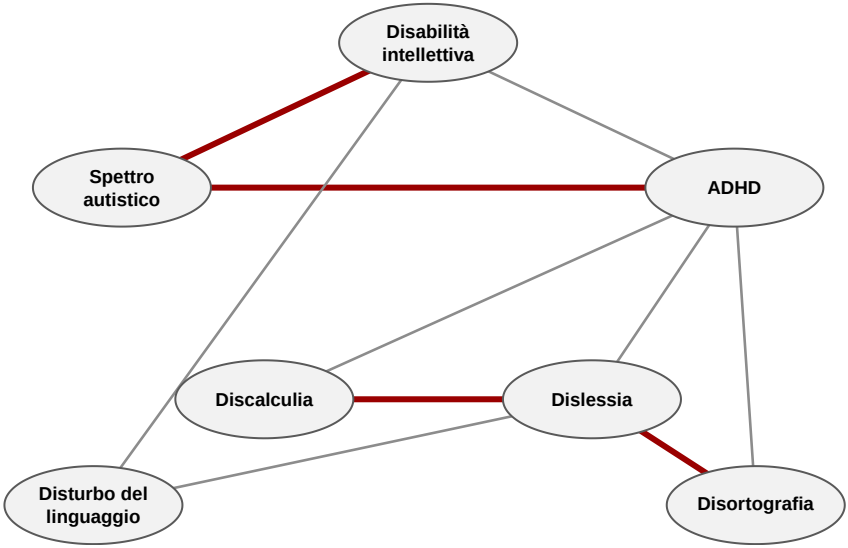


Figura 18.3: Le principali sovrapposizioni fra condizioni del neurosviluppo. Ogni linea indica una co-occorrenza molto più frequente di quanto ci si aspetterebbe se le condizioni fossero indipendenti; le linee più spesse indicano le sovrapposizioni più ampie. Schema originale e semplificato.

gerarchica della psicopatologia (HiTOP), che organizza sintomi e tratti in dimensioni a diversi livelli di generalità, fino a un possibile fattore generale p (Caspi et al., 2014; Kotov et al., 2017). Un modello del genere accoglie come naturali la comorbilità, la variabilità all'interno di uno stesso disturbo e i casi sottosoglia. Invece di chiedersi quale disturbo abbia una persona, si chiede quale sia il suo profilo su più dimensioni.

È stato proposto di includere le condizioni del neurosviluppo in questi modelli come un'ulteriore dimensione, in continuità con la psicopatologia adulta e in relazione con la struttura dell'intelligenza (Astle et al., 2022). I legami esistono. Nello studio che ha proposto il fattore p, punteggi più alti in p si associavano a un funzionamento cognitivo un po' più basso già nell'infanzia e a un declino maggiore in età adulta (Caspi et al., 2014). La direzione causale resta da chiarire: un livello cognitivo più alto potrebbe proteggere, la psicopatologia potrebbe danneggiare, ed entrambe le cose

possono essere vere.

Il problema non riguarda solo la clinica. Anche la ricerca pensa ancora per categorie, e le categorie creano un dilemma: i campioni diagnostici «puri» non sono rappresentativi, e i campioni rappresentativi non sono puri. Profili cognitivi simili si trovano in condizioni diverse, e profili diversi nella stessa condizione. Studiare i profili e le dimensioni è più informativo che studiare le etichette.

18.7 Neurodivergenza e adattamento

Resta una domanda. Se tratti come quelli autistici o legati all'ADHD sono così diffusi ed ereditabili, perché l'evoluzione non li ha eliminati? Una risposta possibile è che non siano solo disfunzionali. La selezione naturale non produce fenotipi perfetti, ma compromessi. Alta attività, ricerca di novità, decisioni rapide ed esplorazione sono poco adatte alle aule scolastiche moderne, ma potrebbero essere state vantaggiose in altri ambienti. Un'attenzione sistematica alle regolarità e ai dettagli può essere una risorsa in molti contesti. Sono ipotesi, non conclusioni; ma ricordano che la stessa caratteristica può essere un problema in un ambiente e una risorsa in un altro.

Per questo il termine **neurodivergenza** si è diffuso per indicare una differenza rilevante rispetto al funzionamento tipico, senza presupporre che sia un deficit. Il termine **disturbo** resta appropriato quando la differenza si traduce in disagio o compromissione significativa del funzionamento. Le due parole non si escludono: descrivono livelli diversi dello stesso fenomeno.

In breve

- Le condizioni del neurosviluppo sono classificate dai manuali come categorie, ma i loro confini con la normalità e fra di loro non sono netti.
- La ricerca di un deficit cognitivo centrale per ciascun disturbo è fallita: nessun marcatore ha una capacità diagnostica adeguata.
- I tratti sottostanti sono continui, con soglie diagnostiche convenzionali, e correlati, con comorbilità estese: la stessa struttura

delle abilità cognitive.
- I modelli dimensionali e gerarchici, come HiTOP, descrivono questa struttura meglio delle categorie e collegano neurosviluppo, psicopatologia e intelligenza.

Riferimenti bibliografici

19 Valutare l'intelligenza nel neurosviluppo

La valutazione dell'intelligenza è parte integrante, e spesso obbligatoria, di quasi ogni percorso diagnostico nel neurosviluppo. Serve a escludere o confermare una disabilità intellettiva, a descrivere punti di forza e di debolezza, a orientare gli interventi. Ma una batteria di intelligenza è stata costruita e tarata su una popolazione generale. Quando la si usa con persone che hanno un funzionamento diverso dalla media proprio negli aspetti che il test misura, sorgono problemi specifici.

Questo capitolo esamina come si valuta l'intelligenza nelle principali condizioni, quali profili medi emergono dalla ricerca e perché quei profili vanno interpretati con cautela. Un avvertimento preliminare: i profili medi descrivono gruppi. Dedurre una diagnosi dal profilo di un singolo individuo è un errore.

19.1 Disabilità intellettiva

La disabilità intellettiva richiede tre elementi: limitazioni nel funzionamento intellettivo, confermate dalla valutazione clinica e da test standardizzati individuali; limitazioni nel **comportamento adattivo**, cioè nella capacità di soddisfare le richieste di autonomia e responsabilità sociale attese per l'età e il contesto; esordio durante lo sviluppo (Association, 2022).

Tradizionalmente la gravità veniva stabilita in base al QI: lieve sotto 70, moderata sotto 50–55, grave sotto 35–40, profonda sotto 20–25. Gli approcci attuali la determinano soprattutto in base al funzionamento adattivo e al bisogno di supporto, valutati in tre aree: concettuale, che comprende linguaggio, apprendimenti e memoria; sociale, che comprende comunicazione, relazioni, rispetto delle regole e vulnerabilità alla manipolazione; pratica, che comprende cura di sé, gestione della casa e del denaro, lavoro e vita autonoma. Il comportamento adattivo si misura con scale standardizzate, di solito compilate attraverso un'intervista a chi conosce bene la persona, ed espresse sulla stessa metrica del QI. Il QI resta un criterio di fatto necessario ma non sufficiente.

Le forme **sindromiche** tendono a mostrare profili cognitivi caratteristici, pur con grande variabilità individuale. Nella sindrome di Down sono descritte difficoltà particolarmente marcate nel linguaggio espressivo e nella memoria verbale a breve termine, con componenti visuospaziali relativamente meno compromesse; nella sindrome di Williams il quadro è spesso opposto, con abilità verbali relativamente preservate e difficoltà visuospaziali gravi (Grieco et al., 2015; Martens et al., 2008). Anche questi profili «tipici» sono tendenze di gruppo, da verificare sui casi concreti. Le forme **non sindromiche** sono estremamente eterogenee e non hanno profili caratteristici: ogni caso fa storia a sé, e il profilo va valutato sempre.

19.2 Autismo: un paradosso

Fra le persone con una diagnosi di autismo, una quota consistente, attorno a un terzo nelle stime epidemiologiche statunitensi, ha anche una disabilità intellettiva (Maenner et al., 2023). Eppure le varianti genetiche comuni associate all'autismo sono, in media, associate a un'intelligenza leggermente **più alta**: la correlazione genetica fra i due tratti è debolmente positiva (Savage et al., 2018). Come si conciliano i due dati?

Una possibile spiegazione è un'eziologia mista. Una parte dei casi, spesso con disabilità intellettiva, sarebbe legata a varianti genetiche rare o mutazioni nuove di grande effetto, simili per meccanismo alle forme sindromiche (Satterstrom et al., 2020). Il resto rifletterebbe la coda di un tratto poligenico diffuso, in parte associato a varianti favorevoli alle abilità cognitive.

Un'altra ipotesi parla di **intelligenza sbilanciata** (Crespi, 2016): uno sviluppo disarmonico, con alcune abilità forti, talvolta eccezionali, e un funzionamento quotidiano deludente, soprattutto rispetto alle richieste sociali. Le abilità visuospaziali, il ragionamento fluido e alcune funzioni sensoriali risultano spesso buone; le conoscenze verbali e l'uso del linguaggio più deboli; l'attenzione molto focalizzata ma poco flessibile.

Nelle scale Wechsler le cadute più evidenti riguardano memoria di lavoro e velocità di elaborazione, che possono scendere di circa una deviazione standard. È però anche il profilo più comune di tutta la neurodivergenza, quindi poco specifico.

C'è infine un problema di campionamento. Una meta-analisi degli studi di ricerca sull'autismo ha stimato che circa il 94% dei partecipanti non aveva una disabilità intellettiva (Russell et al., 2019). Le casistiche cliniche epidemiologiche ne contano molti di più. La ricerca descrive soprattutto la parte ad alto funzionamento dello spettro, oppure le casistiche cliniche ne descrivono soprattutto la parte a basso funzionamento? Con un tratto dimensionale e confini diagnostici in movimento, la domanda potrebbe non avere una risposta semplice.

19.3 ADHD

Per l'ADHD la situazione genetica è opposta a quella dell'autismo: la correlazione genetica con l'intelligenza è moderatamente **negativa** (Demontis et al., 2023). A livello dei punteggi, però, la differenza è meno marcata. La comorbilità con la disabilità intellettiva è contenuta. Una meta-analisi ha stimato per i gruppi con ADHD un QI totale medio inferiore di circa 0,6 deviazioni standard, quasi dieci punti (Frazier et al., 2004). Una parte della differenza dipende però dalle prove che chiedono proprio attenzione sostenuta e memoria di lavoro, cioè dalle stesse difficoltà che definiscono il disturbo.

Il profilo tipico alle scale Wechsler mostra una compromissione marcata della memoria di lavoro, di circa una deviazione standard, e una compromissione parziale della velocità di elaborazione. L'osservazione qualitativa dei protocolli rivela spesso una buona velocità accompagnata da molti errori. Se però si considerano tutti i tipi di compito cognitivo studiati nelle meta-analisi, il profilo medio appare più piatto di quanto suggerirebbe l'idea di un deficit esecutivo specifico.

19.4 Disturbi specifici dell'apprendimento

In teoria i disturbi specifici dell'apprendimento rappresentano il livello più circoscritto della compromissione cognitiva. Il **modello a cono** proposto da Cornoldi e Vecchi lo rende visibile: in cima stanno le compromissioni di alto livello, come la disabilità intellettiva, con effetti a cascata su qualsiasi compito; nel mezzo quelle di livello intermedio, come autismo e ADHD, che

colpiscono diversi domini; alla base quelle che riguardano processi molto specifici, come lettura, scrittura e calcolo (Cornoldi & Vecchi, 2003).

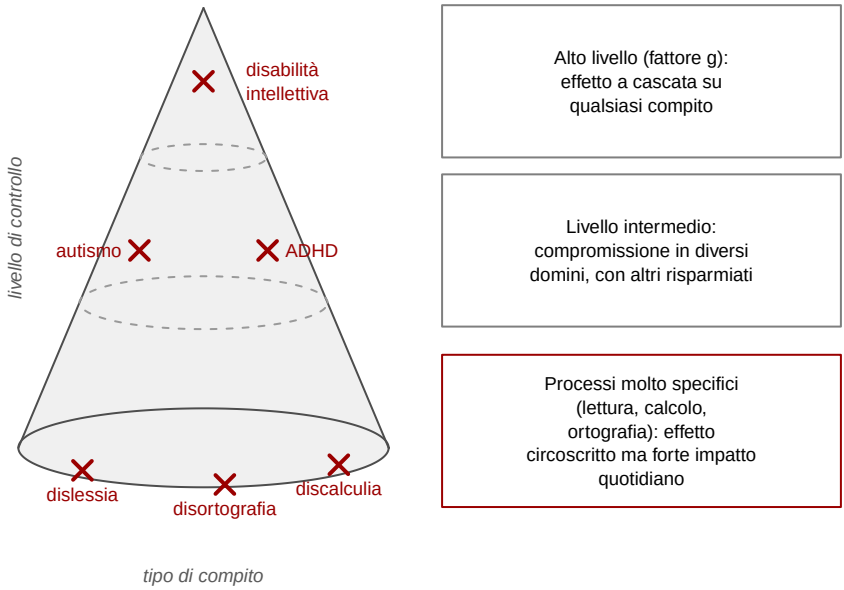


Figura 19.1: Il modello a cono delle difficoltà cognitive. In verticale il livello di controllo richiesto dal compito, in orizzontale il tipo di compito: una compromissione di alto livello, come nella disabilità intellettiva, si estende a tutto il cono; le compromissioni di livello intermedio colpiscono diversi domini; quelle di base riguardano processi molto specifici. Elaborazione da Cornoldi e Vecchi (2003).

La specificità, però, è imposta per definizione. La disabilità intellettiva è un criterio di esclusione esplicito; il funzionamento intellettivo limite, con QI fra 70 e 85, è un elemento di attenzione, e spesso si richiede che almeno alcune aree dell'intelligenza siano nella norma. In passato si richiedeva una discrepanza fra QI e abilità scolastica. Ma le abilità scolastiche sono correlate con il fattore generale sia a livello fenotipico sia genetico. Un disturbo del calcolo è «specifico» non perché il calcolo sia indipendente dall'intelligenza, ma perché lo si definisce escludendo chi ha un'intelligenza bassa (Figura 19.2).

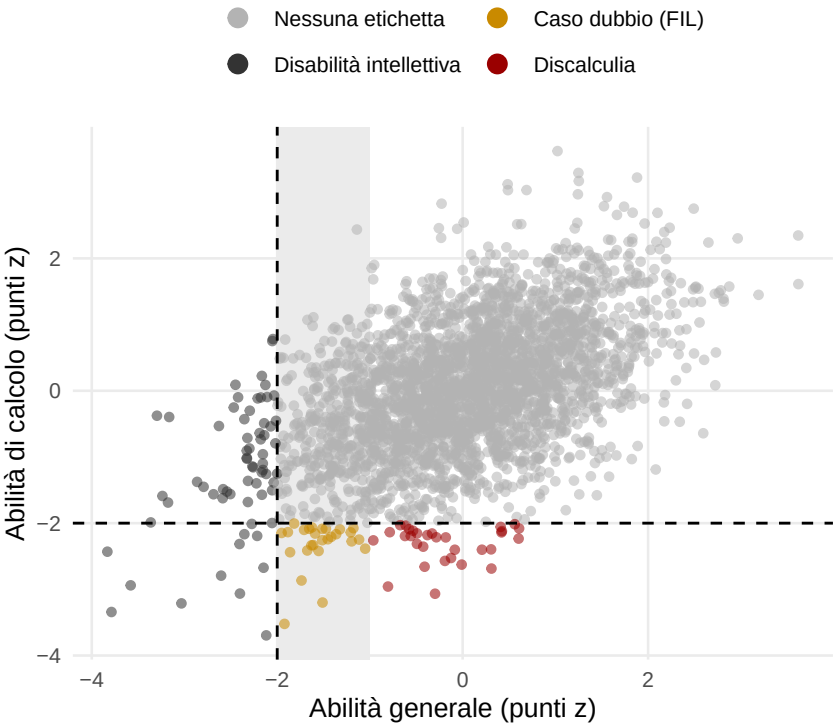


Figura 19.2: Dati simulati di una popolazione in cui l'abilità di calcolo correla 0,50 con l'abilità generale. Le etichette derivano da soglie applicate a due dimensioni continue: chi ha un'abilità generale molto bassa rientra nella disabilità intellettiva; fra gli altri, chi ha un calcolo molto debole rientra nella discalculia.

L'incoerenza dei criteri di inclusione ed esclusione fra gli studi, inevitabile perché i criteri stessi sono arbitrari, produce risultati incoerenti. Studiare dimensioni continue in modo multivariato, senza imporre confini che in natura non esistono, è più informativo.

Nei dati clinici italiani, i profili medi dei bambini con diagnosi di disturbo dell'apprendimento mostrano un andamento ricorrente: comprensione verbale e ragionamento percettivo nella norma o vicini, memoria di lavoro e

velocità di elaborazione più bassi. La forma è simile nella dislessia, nella disortografia, nella discalculia e nei quadri misti; cambiano piuttosto l'entità delle cadute e la posizione complessiva (Giofrè et al., 2017; Toffalini et al., 2017). Un andamento analogo si osserva negli adulti con diagnosi di disturbo dell'apprendimento (Pizzigallo et al., 2023).

19.5 Il problema dell'invarianza di misura

Quando si usa una batteria in una popolazione diversa da quella su cui è stata costruita, bisogna chiedersi se i punteggi abbiano lo stesso significato. È la questione dell'**invarianza di misura**, che si articola in livelli successivi (Meredith, 1993; Putnick & Bornstein, 2016).

Tabella 19.1: Livelli di invarianza di misura.

Livello	Domanda	Situazione tipica nei gruppi clinici
Configurale	La struttura dei fattori è la stessa?	Di solito garantita dalla costruzione della batteria
Metrica	I legami fra subtest, indici e fattore generale sono uguali?	Spesso violata, con conseguente incertezza interpretativa
Scalare	A parità di abilità vera si ottiene lo stesso punteggio?	Spesso violata: lo stesso QI non indica lo stesso livello di g
Stretta	L'errore di misura è lo stesso?	Spesso violata, ma con conseguenze minori

L'invarianza scalare è la più importante per l'interpretazione. Se un gruppo ottiene punteggi più bassi in alcuni subtest a parità di abilità generale, il QI totale di quel gruppo sottostima l'abilità generale. E la mancanza di invarianza non riguarda solo i gruppi clinici: può interessare fasce d'età, generi, gruppi linguistici e culturali, persone bilingui.

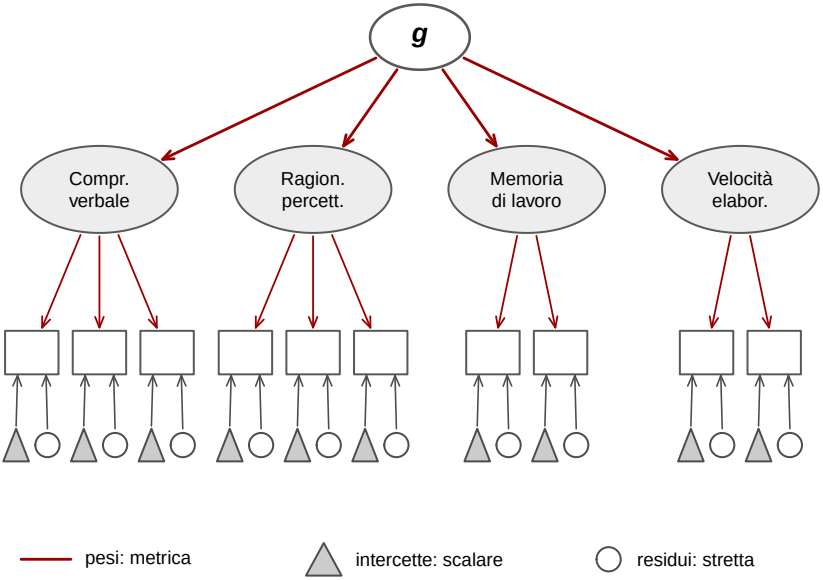


Figura 19.3: Dove si collocano i parametri che l'invarianza di misura confronta fra gruppi, in un modello gerarchico di una batteria con quattro indici. Pesi (frecce): invarianza metrica. Intercette, cioè il punteggio atteso in un subtest quando l'abilità è nella media (triangoli): invarianza scalare. Varianze residue, cioè la parte non spiegata dai fattori (cerchi): invarianza stretta. Schema originale.

Una lettura rigida concluderebbe che senza invarianza completa non si possa usare lo strumento. In pratica lo si usa comunque, perché spesso è l'unico disponibile o perché le alternative presentano lo stesso problema; perché tarature separate per ogni gruppo non sarebbero praticabili; perché lo scopo può essere solo escludere una disabilità intellettiva; perché la violazione può essere parziale e incidere poco sul calcolo dei punteggi. Serve allora sapere dove sta il problema.

Analisi su dati italiani della WISC-IV, che confrontano il campione normativo con ampi campioni clinici di bambini con disturbi dell'apprendimento o ADHD, indicano che in entrambi i gruppi i subtest di memoria di lavoro e velocità di elaborazione hanno medie più basse di quanto l'abilità

generale farebbe prevedere, mentre gli altri no. Nei disturbi dell'apprendimento, inoltre, il fattore generale è rappresentato meno bene in quasi tutti gli indici, tranne il ragionamento percettivo (Toffalini et al., 2022). Per l'autismo, uno studio sulla WISC-V ha trovato una buona invarianza dei legami fattoriali ma non dei punteggi attesi: a parità di abilità generale, i bambini autistici ottenevano punteggi più bassi nella memoria di cifre e nel cifrario. Un modello basato sul solo indice di abilità generale risultava invece pienamente invariante (Stephenson et al., 2021).

La conseguenza pratica è la stessa nei tre casi. Quando memoria di lavoro e velocità sono compromesse per ragioni specifiche, il QI totale sottostima il funzionamento intellettivo generale, e l'**indice di abilità generale**, che le esclude, ne è una stima migliore. È ciò che accadeva nel caso illustrativo del capitolo precedente: un QI totale di 84 e un indice di abilità generale di 100 descrivono la stessa bambina in modo molto diverso, e il secondo è più vicino alle sue capacità di ragionamento.

Lo stesso meccanismo può nascondere un'abilità molto alta. Un bambino con un ragionamento eccellente e un disturbo dell'apprendimento può ottenere un QI totale soltanto nella media, perché le cadute in memoria di lavoro e velocità abbassano il totale; e un rendimento scolastico accettabile, perché il ragionamento compensa in parte la difficoltà specifica. Le due rarità si mascherano a vicenda. Leggere gli indici, in questi casi, non è un vezzo da profilo: è l'unico modo di vedere entrambe.

19.6 Valutare bene

La valutazione dell'intelligenza nel neurosviluppo richiede più attenzione che nella popolazione generale, non meno. Il QI resta indispensabile per escludere o confermare una disabilità intellettiva. Il profilo può orientare gli interventi. Ma i profili medi dei gruppi non sono marcatori diagnostici; i punteggi possono non avere lo stesso significato che hanno nella popolazione di riferimento; e l'indice più informativo dipende dalla persona che si ha davanti. Scegliere quale numero riportare è già un atto interpretativo, e va motivato.

In breve

- La disabilità intellettiva richiede limitazioni sia intellettive sia adattive; la gravità si stabilisce oggi soprattutto in base al bisogno di supporto.
- Nell'autismo convivono un'alta frequenza di disabilità intellettiva nelle casistiche cliniche e una correlazione genetica debolmente positiva con l'intelligenza; la ricerca sottorappresenta i casi a basso funzionamento.
- In ADHD e disturbi dell'apprendimento le cadute medie più evidenti riguardano memoria di lavoro e velocità di elaborazione; la specificità dei disturbi dell'apprendimento è imposta per definizione.
- Nei gruppi clinici manca spesso l'invarianza scalare: il QI totale può sottostimare l'abilità generale, e l'indice di abilità generale è spesso preferibile.
- I profili medi descrivono gruppi e non permettono inferenze diagnostiche sul singolo caso.

Riferimenti bibliografici

Parte VII

Approfondimenti: oltre g

20 Altre intelligenze o vecchi costrutti con un nome nuovo?

La visione dominante dell'intelligenza è potente. Un singolo fattore generale riassume gran parte della varianza interpretabile nei test cognitivi, si misura in modo rapido e affidabile, prevede esiti importanti. Proprio questa potenza alimenta due domande. Il fattore generale è davvero tutto? Esistono altre intelligenze che i test non colgono? Questo approfondimento affronta la seconda domanda attraverso il caso più noto, l'intelligenza emotiva. Il prossimo affronta una domanda ancora più radicale: se g esista davvero.

20.1 Una buona idea

Le emozioni esistono e contano. Regolare le proprie emozioni aiuta a funzionare meglio. Capire quelle degli altri e comportarsi di conseguenza è altrettanto importante. Nessuno lo contesta. L'idea di **intelligenza emotiva** nasce qui: esisterebbe una capacità di percepire, comprendere, usare e regolare le emozioni, diversa dall'intelligenza cognitiva e altrettanto importante (Salovey & Mayer, 1990). Negli anni Novanta un libro di grande successo la presentò al pubblico come fattore decisivo del successo nella vita, persino più del QI (Goleman, 1995).

Le domande da porre sono quelle che si pongono per qualsiasi costrutto. Esiste davvero una capacità mentale identificabile dietro questa etichetta? È misurabile in modo abbastanza attendibile per la ricerca e la clinica? Aggiunge qualcosa a ciò che sappiamo già misurare? E, se sì, è necessario chiamarla «intelligenza»?

20.2 Due modi di misurarla

L'intelligenza emotiva si misura in due modi molto diversi, che corrispondono in pratica a due costrutti diversi.

Il primo la tratta come un'**abilità**. Si presentano scenari e si chiede di riconoscere l'emozione più probabile di un personaggio, o di valutare quanto una certa azione aiuterebbe qualcuno a mantenere il buon umore. Le risposte vengono confrontate con un criterio. Qui sorge il primo problema: qual è la risposta corretta? Spesso quella scelta dalla maggioranza, o da un gruppo di esperti. È un criterio molto diverso dalla soluzione di una matrice.

Il secondo la tratta come un **tratto** e la misura con questionari autodescrittivi. Le affermazioni riguardano l'autostima, la soddisfazione per la propria vita, la facilità a calmarsi, il controllo degli impulsi, la capacità di esprimere affetto, l'assertività (Petrides & Furnham, 2001). Chi conosce i questionari di personalità vi riconoscerà molti contenuti familiari.

20.3 Che cosa misurano davvero

Gli stessi proponenti della versione come abilità hanno ridimensionato gli entusiasmi giornalistici (Mayer et al., 2008). I punteggi correlano attorno a 0,2–0,3 con il rendimento scolastico e la prestazione lavorativa: valori apprezzabili, ma lontani dalle promesse. Le prove di abilità emotiva correlano in misura moderata con l'intelligenza verbale, e le loro diverse componenti correlano fra loro in modo molto variabile, da deboli a moderate.

Per la versione come tratto il problema è la sovrapposizione con la personalità. I punteggi correlano fortemente, in senso negativo, con il nevroticismo e, positivamente, con estroversione e coscienziosità. Una meta-analisi ha trovato che l'intelligenza emotiva di tratto coincide quasi completamente con un fattore generale della personalità, che riassume i poli socialmente desiderabili dei cinque grandi tratti (van der Linden et al., 2017).

La domanda decisiva è quindi quella della **validità incrementale**: tolti il fattore cognitivo generale e i tratti di personalità già noti, resta qualcosa che prevede gli esiti? Le analisi più accurate rispondono che resta poco. Nel lavoro, l'intelligenza emotiva aggiunge una piccola quota di previsione rispetto ad abilità cognitive e personalità, più per i questionari che per le prove di abilità, e in parte proprio perché i questionari includono contenuti di autovalutazione e motivazione che altri strumenti non misurano (Joseph & Newman, 2010).

C'è poi un problema pratico, rilevante soprattutto nella selezione del personale, dove questi strumenti sono molto usati. Un questionario autodescrittivo si può falsare: chi vuole fare buona impressione sa quali risposte sono desiderabili. In un esperimento, i partecipanti a cui era stato chiesto di presentarsi nel modo migliore possibile hanno alzato in modo sensibile i propri punteggi in un questionario di intelligenza emotiva, mentre non sono riusciti a farlo in una prova di abilità emotiva (Day & Carroll, 2008). È lo stesso motivo per cui nessuno misurerebbe l'intelligenza cognitiva chiedendo alle persone quanto si ritengono brillanti. Una misura di prestazione ha i suoi problemi di criterio; una misura autodescrittiva ha quelli di sincerità e di conoscenza di sé.

20.4 Una lista di qualità desiderabili

Il problema di fondo è concettuale. Nelle versioni più diffuse, l'intelligenza emotiva è un insieme troppo ampio e malleabile per essere un costrutto unitario: empatia, autoregolazione, ottimismo, leadership, abilità sociali, motivazione, resilienza. Assomiglia più a un elenco di caratteristiche desiderabili che a una capacità mentale con una struttura propria.

E perché chiamarla «intelligenza»? Già per il fattore cognitivo generale la parola è un'etichetta che accettiamo per la sua utilità pratica, consapevoli del rischio di reificazione. Estenderla a costrutti psicometricamente più deboli non aggiunge chiarezza. Aggiunge prestigio.

Questo non significa che competenze emotive e sociali non esistano o non contino. Significa che, per studiarle bene, conviene descriverle con costrutti precisi e misure valide, e verificare ogni volta che non siano vecchie conoscenze travestite.

20.5 Jingle, jangle e la proliferazione delle etichette

L'intelligenza emotiva non è un caso isolato. Autoefficacia, grinta, resilienza, mentalizzazione, soft skills, flessibilità, competenza emotiva, agency: la psicologia della personalità, della motivazione, del benessere e del lavoro produce di continuo nuove etichette. Due errori classici aiutano a orientarsi.

- La **fallacia jingle** consiste nel dare lo stesso nome a costrutti diversi: due questionari di «resilienza» possono misurare cose differenti.
- La **fallacia jangle** consiste nel dare nomi diversi allo stesso costrutto: una nuova scala con un nome nuovo può misurare, nella sostanza, un tratto di personalità noto da decenni (Lawson & Robins, 2021).

La seconda è particolarmente frequente in psicologia, dove ogni gruppo di ricerca tende a costruirsi i propri strumenti. Un'analisi di migliaia di questionari ha mostrato che la maggior parte delle misure psicologiche viene usata pochissime volte, spesso solo dagli autori che le hanno create (Elson et al., 2023). Il risultato è una letteratura frammentata, difficile da cumulare, in cui la novità del nome sostituisce la novità della scoperta.

Il rimedio non è vietare i nuovi costrutti, ma chiedere loro tre cose: una definizione che li distingua da quelli esistenti; una misura che non correli così tanto con costrutti noti da esserne un duplicato; e la prova che prevedano qualcosa di rilevante al di là di ciò che quei costrutti già prevedono. Il fattore generale dell'intelligenza ha superato queste prove. Le altre «intelligenze», per ora, molto meno.

In breve

- L'intelligenza emotiva come abilità si sovrappone in parte all'intelligenza cognitiva; come tratto autodescritto, quasi completamente alla personalità.
- La sua validità incrementale rispetto a intelligenza e personalità è piccola.
- Il costrutto è spesso un insieme eterogeneo di qualità desiderabili; chiamarlo «intelligenza» aggiunge prestigio più che chiarezza.
- Le fallacie jingle e jangle e la proliferazione di strumenti poco usati sono problemi diffusi; ogni nuovo costrutto deve dimostrare di essere distinto e utile.

Riferimenti bibliografici

21 Si può spiegare la positive manifold senza un fattore generale?

La positive manifold è uno dei risultati più solidi della psicologia. Su questo non c'è disaccordo. Il disaccordo riguarda la spiegazione. Quella standard, presentata nei capitoli sui modelli dell'intelligenza, ipotizza un insieme di cause comuni riassunte dal fattore generale *g*. Ma quelle cause restano in buona parte misteriose, e a molti ricercatori l'idea di una variabile latente non osservata sembra un'ipotesi troppo comoda.

Negli ultimi vent'anni sono emerse almeno due teorie che cercano di spiegare le correlazioni fra abilità senza un fattore generale. Sono alternative serie, che meritano di essere conosciute. Sono anche, a oggi, minoritarie. Questo approfondimento spiega perché.

21.1 Un vecchio precedente

L'idea non è nuova. Già nel 1916 Godfrey Thomson mostrò che una positive manifold può emergere anche senza un fattore generale: basta che ogni prova attinga a un campione casuale di molti processi elementari, e che prove diverse condividano in parte gli stessi processi (Thomson, 1916). Più processi due prove hanno in comune, più correlano. La **teoria del campionamento** di Thomson è stata riproposta in forma moderna, ed è compatibile con molti dei dati che sostengono *g* (Bartholomew et al., 2009). Mostra un punto importante: il fatto che un modello a un fattore descriva bene i dati non dimostra, da solo, che esista una singola causa comune.

21.2 La teoria della sovrapposizione dei processi

La **teoria della sovrapposizione dei processi** (POT) aggiorna l'idea di Thomson con il linguaggio della psicologia cognitiva (Kovacs & Conway, 2016). Ogni prova richiede sia processi specifici del dominio, sia processi esecutivi generali, come il controllo dell'attenzione e la memoria di lavoro. Questi ultimi sono coinvolti in molte prove e funzionano come un collo

di bottiglia: limitano la prestazione ovunque. Le prove correlano perché condividono quei limiti.

La teoria spiega alcuni fatti noti. Il primo è che le prove più complesse, come i problemi di ragionamento con molte regole da tenere a mente, sono le più legate al fattore generale: sono anche quelle che richiedono più controllo esecutivo.

Il secondo fatto è noto da quasi un secolo come **legge dei rendimenti decrescenti** di Spearman: nei gruppi con abilità più alta le correlazioni fra prove diverse, e quindi il peso del fattore generale, tendono a essere più basse. Una meta-analisi ne ha confermato l'esistenza, con un effetto di entità modesta (Blum & Holling, 2017). La teoria della sovrapposizione dei processi lo spiega in modo naturale: se i processi esecutivi limitano la prestazione soprattutto quando sono deboli, le prove dipendono più spesso dagli stessi limiti nelle persone meno capaci. Anche un modello con un fattore generale può però accomodare il dato, ammettendo che il suo peso vari con il livello.

Ma a uno sguardo attento non è una vera alternativa all'ipotesi delle cause comuni. Sostituisce un fattore generale con un insieme di processi generali, cioè con altre cause comuni, descritte con maggiore dettaglio cognitivo. Ed è rimasta minoritaria soprattutto perché quei processi esecutivi non sono stati isolati e misurati in modo abbastanza chiaro da metterla alla prova.

21.3 Il mutualismo

Il **mutualismo** propone qualcosa di concettualmente più radicale (van der Maas et al., 2006). Immaginiamo che, all'inizio dello sviluppo, abilità diverse siano indipendenti. Durante la crescita, però, si sostengono a vicenda. Un vocabolario più ricco aiuta a capire concetti e spiegazioni, quindi a rappresentarsi meglio i problemi e a ragionare. Un ragionamento migliore aiuta a ricavare il significato di parole nuove dal contesto, quindi ad arricchire il vocabolario. Ripetuti per anni, questi scambi reciproci producono abilità correlate anche partendo da abilità indipendenti. La positive manifold sarebbe un fenomeno emergente, non il segno di una causa comune.

Il mutualismo spiega anche perché, con il tempo, abilità inizialmente indipendenti finiscano per correlare (Figura 21.2).

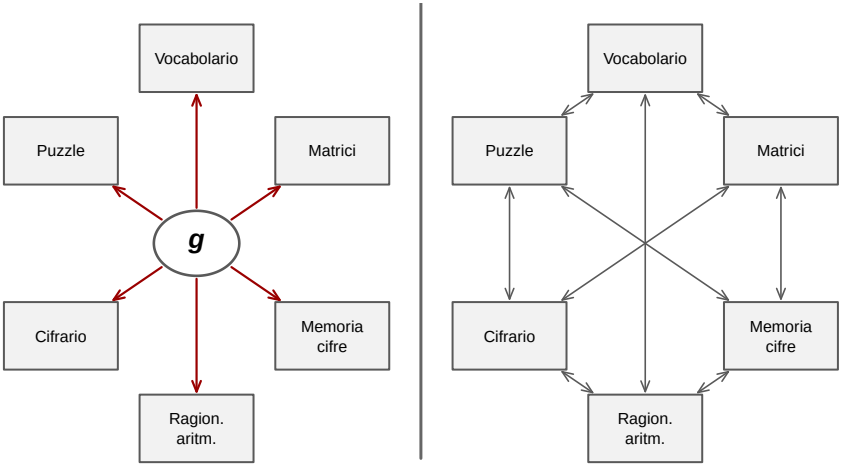


Figura 21.1: Due spiegazioni della positive manifold. Nel primo pannello, la spiegazione standard: una causa comune, g, influenza tutte le prove. Nel secondo, un modello di rete: le abilità si influenzano direttamente a vicenda, senza una causa comune. Schema originale.

È l'unica vera alternativa logica alle cause comuni: se due variabili correlano e nessuna terza variabile le influenza entrambe, devono influenzarsi fra loro. Il mutualismo appartiene alla famiglia dei modelli di rete, che hanno avuto una certa fortuna nella psicologia della personalità e sono molto vivi in quella clinica, dove i disturbi vengono descritti come reti di sintomi che si mantengono a vicenda (Robinaugh et al., 2020).

Alcuni studi longitudinali hanno trovato andamenti compatibili con il mutualismo. In adolescenti e giovani adulti, per esempio, un vocabolario migliore prevedeva una crescita successiva del ragionamento e viceversa, al netto dei livelli di partenza (Kievit et al., 2017).

21.4 Le critiche

Le critiche al mutualismo come teoria generale dell'intelligenza sono però numerose.

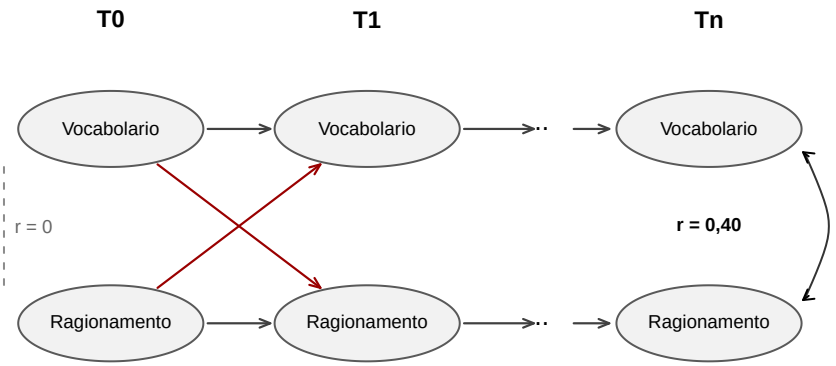


Figura 21.2: Il meccanismo del mutualismo in due abilità. All'inizio dello sviluppo vocabolario e ragionamento non sono correlati; a ogni passo ciascuna abilità contribuisce alla crescita dell'altra, e dopo molti scambi le due abilità risultano correlate. La correlazione finale è illustrativa. Schema originale, ispirato a Kievit et al. (2017).

- **La positive manifold c'è fin dall'inizio.** Emerge appena le abilità diventano misurabili, nei primi anni di vita, e non sembra rafforzarsi in modo marcato con l'età, come il mutualismo prevederebbe (Gignac, 2014).
- **Il fattore generale resta più parsimonioso.** Una volta considerato g, le relazioni residue fra abilità specifiche sono minime o nulle. Una rete complessa di influenze reciproche non aggiunge capacità esplicativa (Gignac, 2016). Anche nei dati sui gemelli, i modelli fattoriali descrivono le relazioni fra abilità almeno altrettanto bene dei modelli di rete (Knyspel & Plomin, 2024).
- **Le previsioni sono imprecise.** Quali abilità influenzano quali? In quale periodo? Con quale intensità? Senza risposte precise, la teoria è difficile da falsificare.
- **Le evidenze longitudinali sono limitate.** Riguardano di solito due o tre abilità alla volta e usano modelli, come quelli a ritardi incrociati, che non distinguono bene fra influenze reciproche e differenze stabili fra persone (Hamaker et al., 2015).

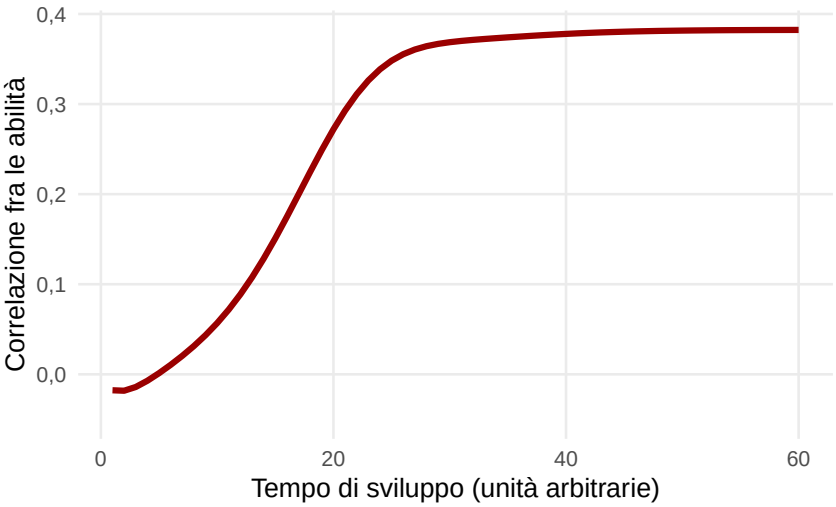


Figura 21.3: Simulazione di un processo mutualistico. Due abilità partono indipendenti e crescono nel tempo verso un livello massimo diverso per ogni persona e per ogni abilità, scelto a caso; a ogni passo ciascuna riceve una piccola spinta proporzionale al livello dell'altra. La correlazione fra le due, inizialmente nulla, cresce durante lo sviluppo. Parametri scelti a scopo illustrativo.

21.5 Che cosa sopravvive

Il mutualismo sopravvive soprattutto in una versione compatibilista: un fattore generale e una rete di influenze reciproche possono coesistere (Savi et al., 2019). È plausibile che abilità diverse si rinforzino a vicenda in alcuni periodi critici dello sviluppo, in misura diversa da persona a persona, anche in presenza di cause comuni. Come cornice concettuale resta utile per pensare lo sviluppo in modo dinamico, e in particolare il neurosviluppo, dove difficoltà in un'area possono propagarsi ad altre. Il prezzo della versione compatibilista è che perde la sua radicalità: se servono anche variabili latenti, la rete non è più un'alternativa al fattore generale, ma un'aggiunta.

Il bilancio, oggi, è questo. Le alternative a g hanno il merito di ricordare che un fattore statistico non è una spiegazione causale e che la positive

manifold potrebbe avere origini diverse da una singola causa comune. Ma nessuna ha ancora prodotto previsioni precise che il modello gerarchico non riesca a spiegare altrettanto bene. Finché non lo faranno, restano ipotesi da seguire con interesse, non sostituti del fattore generale.

In breve

- La teoria del campionamento di Thomson mostra che una positive manifold può emergere anche senza un singolo fattore generale.
- La teoria della sovrapposizione dei processi attribuisce le correlazioni a processi esecutivi generali: aggiunge dettaglio cognitivo, ma resta una teoria di cause comuni.
- Il mutualismo spiega la positive manifold con influenze reciproche fra abilità durante lo sviluppo: è l'unica vera alternativa logica alle cause comuni.
- Le critiche riguardano la presenza precoce della positive manifold, la maggiore parsimonia di g e l'imprecisione delle previsioni; la versione compatibilista sopravvive come cornice per lo sviluppo.

Riferimenti bibliografici

Riferimenti bibliografici

American Educational Research Association, American Psychological Association, & National Council on Measurement in Education. (2014). *Standards for Educational and Psychological Testing*. American Educational Research Association. https://www.testingstandards.net/uploads/7/6/6/4/76643089/standards_2014edition.pdf

Arden, R., Luciano, M., Deary, I. J., Reynolds, C. A., Pedersen, N. L., Plassman, B. L., McGue, M., Christensen, K., & Visscher, P. M. (2016). The association between intelligence and lifespan is mostly genetic. *International Journal of Epidemiology*, *45*(1), 178–185. https://doi.org/10.1093/ije/dyv112

Association, A. P. (2022). *Diagnostic and Statistical Manual of Mental Disorders*. American Psychiatric Association Publishing. https://doi.org/10.1176/appi.books.9780890425787

Astle, D. E., & Fletcher-Watson, S. (2020). Beyond the core-deficit hypothesis in developmental disorders. *Current Directions in Psychological Science*, *29*(5), 431–437.

Astle, D. E., Holmes, J., Kievit, R., & Gathercole, S. E. (2022). Annual Research Review: The transdiagnostic revolution in neurodevelopmental disorders. *Journal of Child Psychology and Psychiatry*, *63*(4), 397–417. https://doi.org/10.1111/jcpp.13481

Baron, R. M., & Kenny, D. A. (1986). The Moderator-Mediator Variable Distinction in Social Psychological Research: Conceptual, Strategic, and Statistical Considerations. *Journal of Personality and Social Psychology*, *51*(6), 1173–1182. https://doi.org/10.1037/0022-3514.51.6.1173

Barrick, M. R., & Mount, M. K. (1991). The Big Five personality dimensions and job performance: A meta-analysis. *Personnel Psychology*, *44*(1), 1–26. https://doi.org/10.1111/j.1744-6570.1991.tb00688.x

Bartholomew, D. J., Deary, I. J., & Lawn, M. (2009). A new lease of life for Thomson's bonds model of intelligence. *Psychological Review*, *116*(3), 567–579. https://doi.org/10.1037/a0016262

Basten, U., Hilger, K., & Fiebach, C. J. (2015). Where smart brains are different: A quantitative meta-analysis of functional and structural brain imaging studies on intelligence. *Intelligence*, *51*, 10–27. https://doi.org/10.1016/j.intell.2015.04.009

Basten, U., Stelzel, C., & Fiebach, C. J. (2013). Intelligence is differentially related to neural effort in the task-positive and the task-negative brain network. *Intelligence*, *41*(5), 517–528. https://doi.org/10.1016/j.intell.2013.07.006

Bates, T. C., & Gignac, G. E. (2022). Effort Impacts IQ Test Scores in a Minor Way: A Multi-Study Investigation with Healthy Adult Volunteers. *Intelligence*, *92*, 101652. https://doi.org/10.1016/j.intell.2022.101652

Binet, A., & Simon, T. (1904). Méthodes nouvelles pour le diagnostic du niveau intellectuel des anormaux. *L'année psychologique*, *11*(1), 191–244. https://doi.org/10.3406/psy.1904.3675

Blau, N., van Spronsen, F. J., & Levy, H. L. (2010). Phenylketonuria. *The Lancet*, *376*(9750), 1417–1427. https://doi.org/10.1016/S0140-6736(10)60961-0

Blum, D., & Holling, H. (2017). Spearman's law of diminishing returns. A meta-analysis. *Intelligence*, *65*, 60–66. https://doi.org/10.1016/j.intell.2017.07.004

Bratsberg, B., & Rogeberg, O. (2018). Flynn effect and its reversal are both environmentally caused. *Proceedings of the National Academy of Sciences*, *115*(26), 6674–6678. https://doi.org/10.1073/pnas.1718793115

Brigham, C. C. (1923). *A Study of American Intelligence*. Princeton University Press.

Brigham, C. C. (1930). Intelligence tests of immigrant groups. *Psychological Review*, *37*(2), 158–165. https://doi.org/10.1037/h0072570

Briley, D. A., & Tucker-Drob, E. M. (2013). Explaining the Increasing Heritability of Cognitive Ability Across Development: A Meta-Analysis of Longitudinal Twin and Adoption Studies. *Psychological Science*, *24*(9), 1704–1713. https://doi.org/10.1177/0956797613478618

Button, K. S., Ioannidis, J. P. A., Mokrysz, C., Nosek, B. A., Flint, J., Robinson, E. S. J., & Munafò, M. R. (2013). Power failure: why small sample size undermines the reliability of neuroscience. *Nature Reviews Neuroscience*, *14*(5), 365–376. https://doi.org/10.1038/nrn3475

Calvin, C. M., Batty, G. D., Der, G., Brett, C. E., Taylor, A., Pattie, A., Čukić, I., & Deary, I. J. (2017). Childhood intelligence in relation to major causes of death in 68 year follow-up: prospective population study. *BMJ*, j2708. https://doi.org/10.1136/bmj.j2708

Calvin, C. M., Deary, I. J., Fenton, C., Roberts, B. A., Der, G., Lecken-

by, N., & Batty, G. D. (2011). Intelligence in youth and all-cause-mortality: systematic review with meta-analysis. *International Journal of Epidemiology*, *40*(3), 626–644. https://doi.org/10.1093/ije/dyq190

Campbell, F. A., Ramey, C. T., Pungello, E., Sparling, J., & Miller-Johnson, S. (2002). Early Childhood Education: Young Adult Outcomes From the Abecedarian Project. *Applied Developmental Science*, *6*(1), 42–57. https://doi.org/10.1207/S1532480XADS0601_05

Canivez, G. L., Watkins, M. W., & Dombrowski, S. C. (2017). Structural validity of the Wechsler Intelligence Scale for Children–Fifth Edition: Confirmatory factor analyses with the 16 primary and secondary subtests. *Psychological Assessment*, *29*(4), 458–472. https://doi.org/10.1037/pas0000358

Carroll, J. B. (1993). *Human Cognitive Abilities: A Survey of Factor-Analytic Studies*. Cambridge University Press. https://doi.org/10.1017/CBO9780511571312

Caspi, A., Houts, R. M., Belsky, D. W., Goldman-Mellor, S. J., Harrington, H., Israel, S., Meier, M. H., Ramrakha, S., Shalev, I., Poulton, R., & Moffitt, T. E. (2014). The p Factor: One General Psychopathology Factor in the Structure of Psychiatric Disorders? *Clinical Psychological Science*, *2*(2), 119–137. https://doi.org/10.1177/2167702613497473

Cattell, R. B. (1963). Theory of fluid and crystallized intelligence: A critical experiment. *Journal of Educational Psychology*, *54*(1), 1–22. https://doi.org/10.1037/h0046743

Chabris, C. F., Lee, J. J., Cesarini, D., Benjamin, D. J., & Laibson, D. I. (2015). The Fourth Law of Behavior Genetics. *Current Directions in Psychological Science*, *24*(4), 304–312. https://doi.org/10.1177/0963721415580430

Childhood cognitive ability and adult academic attainment: evidence from three British cohort studies. (2010). *Longitudinal and Life Course Studies*, *1*(3). https://doi.org/10.14301/llcs.v1i3.93

Cornoldi, C., Belacchi, C., Giofrè, D., Martini, A., & Tressoldi, P. (2010). The mean Southern Italian children IQ is not particularly low: A reply to R. Lynn (2010). *Intelligence*, *38*(5), 462–470. https://doi.org/10.1016/j.intell.2010.06.003

Cornoldi, C., & Vecchi, T. (2003). *Visuo-spatial Working Memory and Individual Differences*. Psychology Press.

Cox, S. R., Ritchie, S. J., Fawns-Ritchie, C., Tucker-Drob, E. M., & Deary, I. J. (2019). Structural brain imaging correlates of general intelligence

in UK Biobank. *Intelligence*, *76*, 101376. https://doi.org/10.1016/j.intell.2019.101376

Crespi, B. J. (2016). Autism as a disorder of high intelligence. *Frontiers in Neuroscience*, *10*, 300. https://doi.org/10.3389/fnins.2016.00300

Crompton, C. J., Ropar, D., Evans-Williams, C. V. M., Flynn, E. G., & Fletcher-Watson, S. (2020). Autistic peer-to-peer information transfer is highly effective. *Autism*, *24*(7), 1704–1712. https://doi.org/10.1177/1362361320919286

Cronbach, L. J. (1957). The two disciplines of scientific psychology. *American Psychologist*, *12*(11), 671–684. https://doi.org/10.1037/h0043943

Davies, G., Lam, M., Harris, S. E., Trampush, J. W., Luciano, M., Hill, W. D., Hagenaars, S. P., Ritchie, S. J., Marioni, R. E., Fawns-Ritchie, C., Liewald, D. C. M., Okely, J. A., Ahola-Olli, A. V., Barnes, C. L. K., Bertram, L., Bis, J. C., Burdick, K. E., Christoforou, A., DeRosse, P., … Deary, I. J. (2018). Study of 300,486 individuals identifies 148 independent genetic loci influencing general cognitive function. *Nature Communications*, *9*(1), 2098. https://doi.org/10.1038/s41467-018-04362-x

Davies, G., Tenesa, A., Payton, A., Yang, J., Harris, S. E., Liewald, D., Ke, X., Le Hellard, S., Christoforou, A., Luciano, M., McGhee, K., Lopez, L., Gow, A. J., Corley, J., Redmond, P., Fox, H. C., Haggarty, P., Whalley, L. J., McNeill, G., … Deary, I. J. (2011). Genome-wide association studies establish that human intelligence is highly heritable and polygenic. *Molecular Psychiatry*, *16*(10), 996–1005. https://doi.org/10.1038/mp.2011.85

Day, A. L., & Carroll, S. A. (2008). Faking emotional intelligence (EI): comparing response distortion on ability and trait-based EI measures. *Journal of Organizational Behavior*, *29*(6), 761–784. https://doi.org/10.1002/job.485

Deary, I. J. (2012a). Intelligence. *Annual Review of Psychology*, *63*(1), 453–482. https://doi.org/10.1146/annurev-psych-120710-100353

Deary, I. J. (2012b). Looking for «System Integrity» in Cognitive Epidemiology. *Gerontology*, *58*(6), 545–553. https://doi.org/10.1159/000341157

Deary, I. J., Cox, S. R., & Hill, W. D. (2022). Genetic variation, brain, and intelligence differences. *Molecular Psychiatry*, *27*(1), 335–353. https://doi.org/10.1038/s41380-021-01027-y

Deary, I. J., Hill, W. D., & Gale, C. R. (2021). Intelligence, health and death. *Nature Human Behaviour*, *5*(4), 416–430. https://doi.org/10.1038/s41562-021-01078-9

Deary, I. J., Strand, S., Smith, P., & Fernandes, C. (2007). Intelligence and educational achievement. *Intelligence*, *35*(1), 13–21. https://doi.org/10.1016/j.intell.2006.02.001

Deary, I. J., Whalley, L. J., Lemmon, H., Crawford, J. R., & Starr, J. M. (2000). The Stability of Individual Differences in Mental Ability from Childhood to Old Age: Follow-up of the 1932 Scottish Mental Survey. *Intelligence*, *28*(1), 49–55. https://doi.org/10.1016/S0160-2896(99)00031-8

Deary, I. J., Whiteman, M. C., Starr, J. M., Whalley, L. J., & Fox, H. C. (2004). The Impact of Childhood Intelligence on Later Life: Following Up the Scottish Mental Surveys of 1932 and 1947. *Journal of Personality and Social Psychology*, *86*(1), 130–147. https://doi.org/10.1037/0022-3514.86.1.130

Demontis, D., Walters, G. B., Athanasiadis, G., Walters, R., Therrien, K., Nielsen, T. T., Farajzadeh, L., Voloudakis, G., Bendl, J., Zeng, B., Zhang, W., Grove, J., Als, T. D., Duan, J., Satterstrom, F. K., Bybjerg-Grauholm, J., Bækved-Hansen, M., Gudmundsson, O. O., Magnusson, S. H., … Børglum, A. D. (2023). Genome-wide analyses of ADHD identify 27 risk loci, refine the genetic architecture and implicate several cognitive domains. *Nature Genetics*, *55*(2), 198–208. https://doi.org/10.1038/s41588-022-01285-8

Duncan, G. J., & Magnuson, K. (2013). Investing in Preschool Programs. *Journal of Economic Perspectives*, *27*(2), 109–132. https://doi.org/10.1257/jep.27.2.109

Dutton, E., van der Linden, D., & Lynn, R. (2016). The negative Flynn Effect: A systematic literature review. *Intelligence*, *59*, 163–169. https://doi.org/10.1016/j.intell.2016.10.002

Dworak, E. M., Revelle, W., & Condon, D. M. (2023). Looking for Flynn effects in a recent online U. S. adult sample: Examining shifts within the SAPA Project. *Intelligence*, *98*, 101734. https://doi.org/10.1016/j.intell.2023.101734

Elson, M., Hussey, I., Alsalti, T., & Arslan, R. C. (2023). Psychological measures aren't toothbrushes. *Communications Psychology*, *1*(1), 25. https://doi.org/10.1038/s44271-023-00026-9

Federal Trade Commission. (2016). *Lumosity to Pay $2 Million to Settle*

FTC Deceptive Advertising Charges for Its «Brain Training» Program. Comunicato stampa. https://www.ftc.gov/news-events/news/press-releases/2016/01/lumosity-pay-2-million-settle-ftc-deceptive-advertising-charges-its-brain-training-program

Flore, P. C., & Wicherts, J. M. (2015). Does stereotype threat influence performance of girls in stereotyped domains? A meta-analysis. *Journal of School Psychology*, *53*(1), 25–44. https://doi.org/10.1016/j.jsp.2014.10.002

Flynn, J. R. (1984). The mean IQ of Americans: Massive gains 1932 to 1978. *Psychological Bulletin*, *95*(1), 29–51. https://doi.org/10.1037/0033-2909.95.1.29

Flynn, J. R. (1987). Massive IQ gains in 14 nations: What IQ tests really measure. *Psychological Bulletin*, *101*(2), 171–191. https://doi.org/10.1037/0033-2909.101.2.171

Flynn, J. R. (2020). *Secular Changes in Intelligence: The "Flynn Effect"* (R. J. Sternberg, A c. Di; 2ª ed., pp. 940–963). Cambridge University Press. https://doi.org/10.1017/9781108770422.040

Frazier, T. W., Demaree, H. A., & Youngstrom, E. A. (2004). Meta-analysis of intellectual and neuropsychological test performance in attention-deficit/hyperactivity disorder. *Neuropsychology*, *18*(3), 543–555. https://doi.org/10.1037/0894-4105.18.3.543

Frinco, M., Sironi, E. M., & Frinco, R. (2024). The Psychometric Properties of Test. Why They Are Essential for Clinical and Academic Purposes. *Psicologia clinica dello sviluppo*, *1/2024*. https://doi.org/10.1449/113146

Funder, D. C., & Ozer, D. J. (2019). Evaluating Effect Size in Psychological Research: Sense and Nonsense. *Advances in Methods and Practices in Psychological Science*, *2*(2), 156–168. https://doi.org/10.1177/2515245919847202

Galton, F. (1869). *Hereditary Genius: An Inquiry into Its Laws and Consequences*. Macmillan.

Gardner, H. (1983). *Frames of Mind: The Theory of Multiple Intelligences*. Basic Books.

Genç, E., Fraenz, C., Schlüter, C., Friedrich, P., Hossiep, R., Voelkle, M. C., Ling, J. M., Güntürkün, O., & Jung, R. E. (2018). Diffusion markers of dendritic density and arborization in gray matter predict differences in intelligence. *Nature Communications*, *9*(1), 1905. https://doi.org/10.1038/s41467-018-04268-8

Gignac, G. E. (2014). Dynamic mutualism versus g factor theory: An empirical test. *Intelligence*, *42*, 89–97. https://doi.org/10.1016/j.intell.2013.11.004

Gignac, G. E. (2016). Residual group-level factor associations: Possibly negative implications for the mutualism theory of general intelligence. *Intelligence*, *55*, 69–78. https://doi.org/10.1016/j.intell.2016.01.007

Gignac, G. E., & Kretzschmar, A. (2017). Evaluating dimensional distinctness with correlated-factor models: Limitations and suggestions. *Intelligence*, *62*, 138–147. https://doi.org/10.1016/j.intell.2017.04.001

Gignac, G. E., & Szodorai, E. T. (2016). Effect size guidelines for individual differences researchers. *Personality and Individual Differences*, *102*, 74–78. https://doi.org/10.1016/j.paid.2016.06.069

Giofrè, D., Pastore, M., Cornoldi, C., & Toffalini, E. (2019). Lumpers vs. splitters: Intelligence in children with specific learning disorders. *Intelligence*, *76*, 101380. https://doi.org/10.1016/j.intell.2019.101380

Giofrè, D., Toffalini, E., Altoè, G., & Cornoldi, C. (2017). Intelligence measures as diagnostic tools for children with specific learning disabilities. *Intelligence*, *61*, 140–145. https://doi.org/10.1016/j.intell.2017.01.014

Gobet, F., & Sala, G. (2023). Cognitive Training: A Field in Search of a Phenomenon. *Perspectives on Psychological Science*, *18*(1), 125–141. https://doi.org/10.1177/17456916221091830

Goleman, D. (1995). *Emotional Intelligence*. Bantam Books.

Gottfredson, L. S. (1997). Mainstream Science on Intelligence: An Editorial with 52 Signatories, History, and Bibliography. *Intelligence*, *24*(1), 13–23. https://doi.org/10.1016/S0160-2896(97)90011-8

Gottfredson, L. S. (2004). Intelligence: Is It the Epidemiologists' Elusive "Fundamental Cause" of Social Class Inequalities in Health? *Journal of Personality and Social Psychology*, *86*(1), 174–199. https://doi.org/10.1037/0022-3514.86.1.174

Grassi, M., & Talamini, F. (2025). *Do musicians have better short-term memory than nonmusicians? A multi-lab study*. Preprint, PsyArXiv. https://doi.org/10.31234/osf.io/kghua_v1

Gregory, H. (2015). *McNamara's Folly: The Use of Low-IQ Troops in the Vietnam War*. Infinity Publishing.

Grieco, J., Pulsifer, M., Seligsohn, K., Skotko, B., & Schwartz, A. (2015). Down syndrome: Cognitive and behavioral functioning across the lifespan. *American Journal of Medical Genetics Part C: Seminars in Medical Genetics*, *169*(2), 135–149. https://doi.org/10.1002/ajmg.c.3

1439

Guilford, J. P. (1967). *The Nature of Human Intelligence*. McGraw-Hill.

Haier, R. J. (2017). *The Neuroscience of Intelligence*. Cambridge University Press.

Haier, R. J., Siegel, B. V., MacLachlan, A., Soderling, E., Lottenberg, S., & Buchsbaum, M. S. (1992). Regional glucose metabolic changes after learning a complex visuospatial/motor task: a positron emission tomographic study. *Brain Research*, *570*(1-2), 134–143. https://doi.org/10.1016/0006-8993(92)90573-R

Haier, R. J., Siegel, B. V., Nuechterlein, K. H., Hazlett, E., Wu, J. C., Paek, J., Browning, H. L., & Buchsbaum, M. S. (1988). Cortical glucose metabolic rate correlates of abstract reasoning and attention studied with positron emission tomography. *Intelligence*, *12*(2), 199–217. https://doi.org/10.1016/0160-2896(88)90016-5

Halpern, D. F., Benbow, C. P., Geary, D. C., Gur, R. C., Hyde, J. S., & Gernsbacher, M. A. (2007). The Science of Sex Differences in Science and Mathematics. *Psychological Science in the Public Interest*, *8*(1), 1–51. https://doi.org/10.1111/j.1529-1006.2007.00032.x

Hamaker, E. L., Kuiper, R. M., & Grasman, R. P. P. P. (2015). A critique of the cross-lagged panel model. *Psychological Methods*, *20*(1), 102–116. https://doi.org/10.1037/a0038889

Hamilton, A. F. de C. (2013). Reflecting on the mirror neuron system in autism: A systematic review of current theories. *Developmental Cognitive Neuroscience*, *3*, 91–105. https://doi.org/10.1016/j.dcn.2012.09.008

Haworth, C. M. A., Wright, M. J., Luciano, M., Martin, N. G., de Geus, E. J. C., van Beijsterveldt, C. E. M., Bartels, M., Posthuma, D., Boomsma, D. I., Davis, O. S. P., Kovas, Y., Corley, R. P., DeFries, J. C., Hewitt, J. K., Olson, R. K., Rhea, S.-A., Wadsworth, S. J., Iacono, W. G., McGue, M., … Plomin, R. (2010). The heritability of general cognitive ability increases linearly from childhood to young adulthood. *Molecular Psychiatry*, *15*(11), 1112–1120. https://doi.org/10.1038/mp.2009.55

Heckman, J. J., Moon, S. H., Pinto, R., Savelyev, P. A., & Yavitz, A. (2010). The rate of return to the HighScope Perry Preschool Program. *Journal of Public Economics*, *94*(1-2), 114–128. https://doi.org/10.1016/j.jpubeco.2009.11.001

Howe, L. J., Nivard, M. G., Morris, T. T., Hansen, A. F., Rasheed, H., Cho, Y., Chittoor, G., Ahlskog, R., Lind, P. A., Palviainen, T., van der Zee,

M. D., Cheesman, R., Mangino, M., Wang, Y., Li, S., Klaric, L., Ratliff, S. M., Bielak, L. F., Nygaard, M., … Davies, N. M. (2022). Within-sibship genome-wide association analyses decrease bias in estimates of direct genetic effects. *Nature Genetics*, *54*(5), 581–592. https://doi.org/10.1038/s41588-022-01062-7

Ilieva, I. P., Hook, C. J., & Farah, M. J. (2015). Prescription Stimulants' Effects on Healthy Inhibitory Control, Working Memory, and Episodic Memory: A Meta-analysis. *Journal of Cognitive Neuroscience*, *27*(6), 1069–1089. https://doi.org/10.1162/jocn_a_00776

Jaeggi, S. M., Buschkuehl, M., Jonides, J., & Perrig, W. J. (2008). Improving fluid intelligence with training on working memory. *Proceedings of the National Academy of Sciences*, *105*(19), 6829–6833. https://doi.org/10.1073/pnas.0801268105

Johnson, W., Bouchard, T. J., Krueger, R. F., McGue, M., & Gottesman, I. I. (2004). Just one g: consistent results from three test batteries. *Intelligence*, *32*(1), 95–107. https://doi.org/10.1016/S0160-2896(03)00062-X

Johnson, W., Carothers, A., & Deary, I. J. (2008). Sex differences in variability in general intelligence: A new look at the old question. *Perspectives on Psychological Science*, *3*(6), 518–531. https://doi.org/10.1111/j.1745-6924.2008.00096.x

Joseph, D. L., & Newman, D. A. (2010). Emotional intelligence: An integrative meta-analysis and cascading model. *Journal of Applied Psychology*, *95*(1), 54–78. https://doi.org/10.1037/a0017286

Jung, R. E., & Haier, R. J. (2007). The Parieto-Frontal Integration Theory (P-FIT) of intelligence: Converging neuroimaging evidence. *Behavioral and Brain Sciences*, *30*(2), 135–154. https://doi.org/10.1017/S0140525X07001185

Kaufman, A. S. (2009). *IQ Testing 101*. Springer Publishing Company.

Kell, H. J., Lubinski, D., & Benbow, C. P. (2013). Who rises to the top? Early indicators. *Psychological Science*, *24*(5), 648–659. https://doi.org/10.1177/0956797612457784

Kendler, K. S., Turkheimer, E., Ohlsson, H., Sundquist, J., & Sundquist, K. (2015). Family environment and the malleability of cognitive ability: A Swedish national home-reared and adopted-away cosibling control study. *Proceedings of the National Academy of Sciences*, *112*(15), 4612–4617. https://doi.org/10.1073/pnas.1417106112

Kievit, R. A., Lindenberger, U., Goodyer, I. M., Jones, P. B., Fonagy, P.,

Bullmore, E. T., the Neuroscience in Psychiatry Network, & Dolan, R. J. (2017). Mutualistic Coupling Between Vocabulary and Reasoning Supports Cognitive Development During Late Adolescence and Early Adulthood. *Psychological Science*, *28*(10), 1419–1431. https://doi.org/10.1177/0956797617710785

Kilpeläinen, T. O., Qi, L., Brage, S., Sharp, S. J., Sonestedt, E., Demerath, E., Ahmad, T., Mora, S., Kaakinen, M., Sandholt, C. H., Holzapfel, C., Autenrieth, C. S., Hyppönen, E., Cauchi, S., He, M., Kutalik, Z., Kumari, M., Stančáková, A., Meidtner, K., … Loos, R. J. F. (2011). Physical Activity Attenuates the Influence of FTO Variants on Obesity Risk: A Meta-Analysis of 218,166 Adults and 19,268 Children. *PLoS Medicine*, *8*(11), e1001116. https://doi.org/10.1371/journal.pmed.1001116

Klingberg, T., Fernell, E., Olesen, P. J., Johnson, M., Gustafsson, P., Dahlström, K., Gillberg, C. G., Forssberg, H., & Westerberg, H. (2005). Computerized Training of Working Memory in Children With ADHD-A Randomized, Controlled Trial. *Journal of the American Academy of Child & Adolescent Psychiatry*, *44*(2), 177–186. https://doi.org/10.1097/00004583-200502000-00010

Knyspel, J., & Plomin, R. (2024). Comparing factor and network models of cognitive abilities using twin data. *Intelligence*, *104*, 101833. https://doi.org/10.1016/j.intell.2024.101833

Kotov, R., Krueger, R. F., Watson, D., Achenbach, T. M., Althoff, R. R., Bagby, R. M., Brown, T. A., Carpenter, W. T., Caspi, A., Clark, L. A., Eaton, N. R., Forbes, M. K., Forbush, K. T., Goldberg, D., Hasin, D., Hyman, S. E., Ivanova, M. Y., Lynam, D. R., Markon, K., … Zimmerman, M. (2017). The Hierarchical Taxonomy of Psychopathology (HiTOP): A dimensional alternative to traditional nosologies. *Journal of Abnormal Psychology*, *126*(4), 454–477. https://doi.org/10.1037/abn0000258

Kovacs, K., & Conway, A. R. A. (2016). Process Overlap Theory: A Unified Account of the General Factor of Intelligence. *Psychological Inquiry*, *27*(3), 151–177. https://doi.org/10.1080/1047840X.2016.1153946

Kovas, Y., & Plomin, R. (2006). Generalist genes: implications for the cognitive sciences. *Trends in Cognitive Sciences*, *10*(5), 198–203. https://doi.org/10.1016/j.tics.2006.03.001

Kush, J. C., & Canivez, G. L. (2019). Construct validity of the WISC–IV Italian edition: A bifactor examination of the standardization sample.

International Journal of School & Educational Psychology, *9*(1), 73–87. https://doi.org/10.1080/21683603.2019.1638854

Lawson, K. M., & Robins, R. W. (2021). Sibling Constructs: What Are They, Why Do They Matter, and How Should You Handle Them? *Personality and Social Psychology Review*, *25*(4), 344–366. https://doi.org/10.1177/10888683211047101

Lee, J. J., Wedow, R., Okbay, A., et al. (2018). Gene discovery and polygenic prediction from a genome-wide association study of educational attainment in 1.1 million individuals. *Nature Genetics*, *50*(8), 1112–1121. https://doi.org/10.1038/s41588-018-0147-3

Levy, F., Hay, D. A., McStephen, M., Wood, C., & Waldman, I. (1997). Attention-Deficit Hyperactivity Disorder: A Category or a Continuum? Genetic Analysis of a Large-Scale Twin Study. *Journal of the American Academy of Child & Adolescent Psychiatry*, *36*(6), 737–744. https://doi.org/10.1097/00004583-199706000-00009

Lubinski, D., & Benbow, C. P. (2006). Study of Mathematically Precocious Youth after 35 years: Uncovering antecedents for the development of math-science expertise. *Perspectives on Psychological Science*, *1*(4), 316–345. https://doi.org/10.1111/j.1745-6916.2006.00019.x

Lynn, R. (2010). In Italy, north–south differences in IQ predict differences in income, education, infant mortality, stature, and literacy. *Intelligence*, *38*(1), 93–100. https://doi.org/10.1016/j.intell.2009.07.004

Machts, N., Kaiser, J., Schmidt, F. T. C., & Möller, J. (2016). Accuracy of teachers' judgments of students' cognitive abilities: A meta-analysis. *Educational Research Review*, *19*, 85–103. https://doi.org/10.1016/j.edurev.2016.06.003

Maenner, M. J., Warren, Z., Williams, A. R., Amoakohene, E., Bakian, A. V., Bilder, D. A., Durkin, M. S., Fitzgerald, R. T., Furnier, S. M., Hughes, M. M., Ladd-Acosta, C. M., McArthur, D., Pas, E. T., Salinas, A., Vehorn, A., Williams, S., Esler, A., Grzybowski, A., Hall-Lande, J., … Shaw, K. A. (2023). Prevalence and Characteristics of Autism Spectrum Disorder Among Children Aged 8 Years — Autism and Developmental Disabilities Monitoring Network, 11 Sites, United States, 2020. *MMWR. Surveillance Summaries*, *72*(2), 1–14. https://doi.org/10.15585/mmwr.ss7202a1

Manolio, T. A., Collins, F. S., Cox, N. J., Goldstein, D. B., Hindorff, L. A., Hunter, D. J., McCarthy, M. I., Ramos, E. M., Cardon, L. R., Chakravarti, A., Cho, J. H., Guttmacher, A. E., Kong, A., Kruglyak,

L., Mardis, E., Rotimi, C. N., Slatkin, M., Valle, D., Whittemore, A. S., … Visscher, P. M. (2009). Finding the missing heritability of complex diseases. *Nature*, *461*(7265), 747–753. https://doi.org/10.1038/nature08494

Marek, S., Tervo-Clemmens, B., Calabro, F. J., Montez, D. F., Kay, B. P., Hatoum, A. S., Donohue, M. R., Foran, W., Miller, R. L., Hendrickson, T. J., Malone, S. M., Kandala, S., Feczko, E., Miranda-Dominguez, O., Graham, A. M., Earl, E. A., Perrone, A. J., Cordova, M., Doyle, O., … Dosenbach, N. U. F. (2022). Reproducible brain-wide association studies require thousands of individuals. *Nature*, *603*(7902), 654–660. https://doi.org/10.1038/s41586-022-04492-9

Martens, M. A., Wilson, S. J., & Reutens, D. C. (2008). Research Review: Williams syndrome: a critical review of the cognitive, behavioral, and neuroanatomical phenotype. *Journal of Child Psychology and Psychiatry*, *49*(6), 576–608. https://doi.org/10.1111/j.1469-7610.2008.01887.x

Maxwell, S. E., & Cole, D. A. (2007). Bias in Cross-Sectional Analyses of Longitudinal Mediation. *Psychological Methods*, *12*(1), 23–44. https://doi.org/10.1037/1082-989X.12.1.23

Mayer, J. D., Roberts, R. D., & Barsade, S. G. (2008). Human Abilities: Emotional Intelligence. *Annual Review of Psychology*, *59*(1), 507–536. https://doi.org/10.1146/annurev.psych.59.103006.093646

McArdle, J. J., Ferrer-Caja, E., Hamagami, F., & Woodcock, R. W. (2002). Comparative longitudinal structural analyses of the growth and decline of multiple intellectual abilities over the life span. *Developmental Psychology*, *38*(1), 115–142. https://doi.org/10.1037/0012-1649.38.1.115

McGrew, K. S. (2009). CHC theory and the human cognitive abilities project: Standing on the shoulders of the giants of psychometric intelligence research. *Intelligence*, *37*(1), 1–10. https://doi.org/10.1016/j.intell.2008.08.004

McNeish, D. (2018). Thanks coefficient alpha, we'll take it from here. *Psychological Methods*, *23*(3), 412–433. https://doi.org/10.1037/met0000144

Melby-Lervåg, M., Redick, T. S., & Hulme, C. (2016). Working Memory Training Does Not Improve Performance on Measures of Intelligence or Other Measures of "Far Transfer". *Perspectives on Psychological Science*, *11*(4), 512–534. https://doi.org/10.1177/1745691616635612

Meredith, W. (1993). Measurement Invariance, Factor Analysis and Factorial Invariance. *Psychometrika*, *58*(4), 525–543. https://doi.org/10.1007/BF02294825

Milton, D. E. M. (2012). On the ontological status of autism: the «double empathy problem». *Disability & Society*, *27*(6), 883–887. https://doi.org/10.1080/09687599.2012.710008

Neisser, U., Boodoo, G., Bouchard, T. J., Jr., Boykin, A. W., Brody, N., Ceci, S. J., Halpern, D. F., Loehlin, J. C., Perloff, R., Sternberg, R. J., & Urbina, S. (1996). Intelligence: Knowns and Unknowns. *American Psychologist*, *51*(2), 77–101. https://doi.org/10.1037/0003-066X.51.2.77

Neubauer, A. C., & Fink, A. (2009). Intelligence and neural efficiency. *Neuroscience & Biobehavioral Reviews*, *33*(7), 1004–1023. https://doi.org/10.1016/j.neubiorev.2009.04.001

Nye, C. D., Ma, J., & Wee, S. (2022). Cognitive Ability and Job Performance: Meta-analytic Evidence for the Validity of Narrow Cognitive Abilities. *Journal of Business and Psychology*, *37*(6), 1119–1139. https://doi.org/10.1007/s10869-022-09796-1

Oh, I.-S., Le, H., & Roth, P. L. (2023). Revisiting Sackett et al.'s (2022) rationale behind their recommendation against correcting for range restriction in concurrent validation studies. *Journal of Applied Psychology*, *108*(8), 1300–1310. https://doi.org/10.1037/apl0001078

Orben, A., & Przybylski, A. K. (2019). The association between adolescent well-being and digital technology use. *Nature Human Behaviour*, *3*(2), 173–182. https://doi.org/10.1038/s41562-018-0506-1

Owen, A. M., Hampshire, A., Grahn, J. A., Stenton, R., Dajani, S., Burns, A. S., Howard, R. J., & Ballard, C. G. (2010). Putting brain training to the test. *Nature*, *465*(7299), 775–778. https://doi.org/10.1038/nature09042

Penke, L., Maniega, S. M., Bastin, M. E., Valdés Hernández, M. C., Murray, C., Royle, N. A., Starr, J. M., Wardlaw, J. M., & Deary, I. J. (2012). Brain white matter tract integrity as a neural foundation for general intelligence. *Molecular Psychiatry*, *17*(10), 1026–1030. https://doi.org/10.1038/mp.2012.66

Pennington, B. (2006). From single to multiple deficit models of developmental disorders. *Cognition*, *101*(2), 385–413. https://doi.org/10.1016/j.cognition.2006.04.008

Petrides, K. V., & Furnham, A. (2001). Trait emotional intelligence: psy-

chometric investigation with reference to established trait taxonomies. *European Journal of Personality*, *15*(6), 425–448. https://doi.org/10.1002/per.416

Pietschnig, J., Penke, L., Wicherts, J. M., Zeiler, M., & Voracek, M. (2015). Meta-analysis of associations between human brain volume and intelligence differences: How strong are they and what do they mean? *Neuroscience & Biobehavioral Reviews*, *57*, 411–432. https://doi.org/10.1016/j.neubiorev.2015.09.017

Pietschnig, J., & Voracek, M. (2015). One Century of Global IQ Gains: A Formal Meta-Analysis of the Flynn Effect (1909–2013). *Perspectives on Psychological Science*, *10*(3), 282–306. https://doi.org/10.1177/1745691615577701

Pietschnig, J., Voracek, M., & Formann, A. K. (2010). Mozart effect–Shmozart effect: A meta-analysis. *Intelligence*, *38*(3), 314–323. https://doi.org/10.1016/j.intell.2010.03.001

Pizzigallo, E., Cornoldi, C., Buono, S., Città, S., Viola, F., & Toffalini, E. (2023). The Intellectual Profile of Adults with Specific Learning Disabilities. *Journal of Intelligence*, *11*(12), 223. https://doi.org/10.3390/jintelligence11120223

Plomin, R., & Deary, I. J. (2015). Genetics and intelligence differences: five special findings. *Molecular Psychiatry*, *20*(1), 98–108. https://doi.org/10.1038/mp.2014.105

Plomin, R., DeFries, J. C., McClearn, G. E., & McGuffin, P. (2001). *Behavioral Genetics* (4ª ed.). Worth Publishers.

Plomin, R., & von Stumm, S. (2018). The new genetics of intelligence. *Nature Reviews Genetics*, *19*(3), 148–159. https://doi.org/10.1038/nrg.2017.104

Pohl, K. M., Thompson, W. K., Adeli, E., & Linguraru, M. G. (A c. Di). (2019). *Adolescent Brain Cognitive Development Neurocognitive Prediction: First Challenge, ABCD-NP 2019, Held in Conjunction with MICCAI 2019, Shenzhen, China, October 13, 2019, Proceedings*. Springer International Publishing. https://doi.org/10.1007/978-3-030-31901-4

Pokropek, A., Marks, G. N., Borgonovi, F., Koc, P., & Greiff, S. (2022). General or specific abilities? Evidence from 33 countries participating in the PISA assessments. *Intelligence*, *92*, 101653. https://doi.org/10.1016/j.intell.2022.101653

Protzko, J. (2015). The environment in raising early intelligence: A meta-analysis of the fadeout effect. *Intelligence*, *53*, 202–210. https://doi.or

g/10.1016/j.intell.2015.10.006

Psacharopoulos, G., & Patrinos, H. A. (2018). Returns to investment in education: a decennial review of the global literature. *Education Economics*, *26*(5), 445–458. https://doi.org/10.1080/09645292.2018.1484426

Putnick, D. L., & Bornstein, M. H. (2016). Measurement invariance conventions and reporting: The state of the art and future directions for psychological research. *Developmental Review*, *41*, 71–90. https://doi.org/10.1016/j.dr.2016.06.004

Rauscher, F. H., Shaw, G. L., & Ky, C. N. (1993). Music and spatial task performance. *Nature*, *365*(6447), 611–611. https://doi.org/10.1038/365611a0

Raven, J. (2000). The Raven's Progressive Matrices: Change and Stability over Culture and Time. *Cognitive Psychology*, *41*(1), 1–48. https://doi.org/10.1006/cogp.1999.0735

Ritchie, S. J., Bates, T. C., & Deary, I. J. (2015). Is education associated with improvements in general cognitive ability, or in specific skills? *Developmental Psychology*, *51*(5), 573–582. https://doi.org/10.1037/a0038981

Ritchie, S. J., Cox, S. R., Shen, X., Lombardo, M. V., Reus, L. M., Alloza, C., Harris, M. A., Alderson, H. L., Hunter, S., Neilson, E., Liewald, D. C. M., Auyeung, B., Whalley, H. C., Lawrie, S. M., Gale, C. R., Bastin, M. E., McIntosh, A. M., & Deary, I. J. (2018). Sex Differences in the Adult Human Brain: Evidence from 5216 UK Biobank Participants. *Cerebral Cortex*, *28*(8), 2959–2975. https://doi.org/10.1093/cercor/bhy109

Ritchie, S. J., & Tucker-Drob, E. M. (2018). How Much Does Education Improve Intelligence? A Meta-Analysis. *Psychological Science*, *29*(8), 1358–1369. https://doi.org/10.1177/0956797618774253

Robinaugh, D. J., Hoekstra, R. H. A., Toner, E. R., & Borsboom, D. (2020). The network approach to psychopathology: a review of the literature 2008–2018 and an agenda for future research. *Psychological Medicine*, *50*(3), 353–366. https://doi.org/10.1017/S0033291719003404

Rodriguez, A., Reise, S. P., & Haviland, M. G. (2016). Evaluating bifactor models: Calculating and interpreting statistical indices. *Psychological Methods*, *21*(2), 137–150. https://doi.org/10.1037/met0000045

Rohrer, J. M. (2018). Thinking Clearly About Correlations and Causation: Graphical Causal Models for Observational Data. *Advances in Methods and Practices in Psychological Science*, *1*(1), 27–42. https://doi.org/10

.1177/2515245917745629

Roth, B., Becker, N., Romeyke, S., Schäfer, S., Domnick, F., & Spinath, F. M. (2015). Intelligence and school grades: A meta-analysis. *Intelligence*, *53*, 118–137. https://doi.org/10.1016/j.intell.2015.09.002

Russell, G., Mandy, W., Elliott, D., White, R., Pittwood, T., & Ford, T. (2019). Selection bias on intellectual ability in autism research: a cross-sectional review and meta-analysis. *Molecular Autism*, *10*(1), 9. https://doi.org/10.1186/s13229-019-0260-x

Sackett, P. R., Zhang, C., Berry, C. M., & Lievens, F. (2022). Revisiting meta-analytic estimates of validity in personnel selection: Addressing systematic overcorrection for restriction of range. *Journal of Applied Psychology*, *107*(11), 2040–2068. https://doi.org/10.1037/apl0000994

Sala, G., & Gobet, F. (2017). Does Far Transfer Exist? Negative Evidence From Chess, Music, and Working Memory Training. *Current Directions in Psychological Science*, *26*(6), 515–520. https://doi.org/10.1177/0963721417712760

Sala, G., & Gobet, F. (2020). Cognitive and academic benefits of music training with children: A multilevel meta-analysis. *Memory & Cognition*, *48*(8), 1429–1441. https://doi.org/10.3758/s13421-020-01060-2

Sala, G., Tatlidil, K. S., & Gobet, F. (2018). Video game training does not enhance cognitive ability: A comprehensive meta-analytic investigation. *Psychological Bulletin*, *144*(2), 111–139. https://doi.org/10.1037/bul0000139

Salovey, P., & Mayer, J. D. (1990). Emotional Intelligence. *Imagination, Cognition and Personality*, *9*(3), 185–211. https://doi.org/10.2190/DUGG-P24E-52WK-6CDG

Satterstrom, F. K., Kosmicki, J. A., Wang, J., Breen, M. S., De Rubeis, S., An, J.-Y., Peng, M., Collins, R., Grove, J., Klei, L., Stevens, C., Reichert, J., Mulhern, M. S., Artomov, M., Gerges, S., Sheppard, B., Xu, X., Bhaduri, A., Norman, U., … Buxbaum, J. D. (2020). Large-Scale Exome Sequencing Study Implicates Both Developmental and Functional Changes in the Neurobiology of Autism. *Cell*, *180*(3), 568–584.e23. https://doi.org/10.1016/j.cell.2019.12.036

Savage, J. E., Jansen, P. R., Stringer, S., Watanabe, K., Bryois, J., de Leeuw, C. A., Nagel, M., Awasthi, S., Barr, P. B., Coleman, J. R. I., Grasby, K. L., Hammerschlag, A. R., Kaminski, J. A., Karlsson, R., Krapohl, E., Lam, M., Nygaard, M., Reynolds, C. A., Trampush, J. W., … Posthuma, D. (2018). Genome-wide association meta-analysis in

269,867 individuals identifies new genetic and functional links to intelligence. *Nature Genetics*, *50*(7), 912–919. https://doi.org/10.1038/s41588-018-0152-6

Savi, A. O., Marsman, M., van der Maas, H. L. J., & Maris, G. K. J. (2019). The Wiring of Intelligence. *Perspectives on Psychological Science*, *14*(6), 1034–1061. https://doi.org/10.1177/1745691619866447

Schmidt, F. L., & Hunter, J. (2004). General Mental Ability in the World of Work: Occupational Attainment and Job Performance. *Journal of Personality and Social Psychology*, *86*(1), 162–173. https://doi.org/10.1037/0022-3514.86.1.162

Schmidt, F. L., & Hunter, J. E. (1998). The validity and utility of selection methods in personnel psychology: Practical and theoretical implications of 85 years of research findings. *Psychological Bulletin*, *124*(2), 262–274. https://doi.org/10.1037/0033-2909.124.2.262

Schober, P., Boer, C., & Schwarte, L. A. (2018). Correlation Coefficients: Appropriate Use and Interpretation. *Anesthesia & Analgesia*, *126*(5), 1763–1768. https://doi.org/10.1213/ANE.0000000000002864

Serpico, D. (2022). *L'intelligenza tra natura e cultura*. Rosenberg & Sellier.

Shayer, M., & Ginsburg, D. (2009). Thirty years on – a large anti-Flynn effect/ (II): 13- and 14-year-olds. Piagetian tests of formal operations norms 1976–2006/7. *British Journal of Educational Psychology*, *79*(3), 409–418. https://doi.org/10.1348/978185408X383123

Shaywitz, S. E., Escobar, M. D., Shaywitz, B. A., Fletcher, J. M., & Makuch, R. (1992). Evidence That Dyslexia May Represent the Lower Tail of a Normal Distribution of Reading Ability. *New England Journal of Medicine*, *326*(3), 145–150. https://doi.org/10.1056/NEJM199201163260301

Shewach, O. R., Sackett, P. R., & Quint, S. (2019). Stereotype threat effects in settings with features likely versus unlikely in operational test settings: A meta-analysis. *Journal of Applied Psychology*, *104*(12), 1514–1534. https://doi.org/10.1037/apl0000420

Simons, D. J., Boot, W. R., Charness, N., Gathercole, S. E., Chabris, C. F., Hambrick, D. Z., & Stine-Morrow, E. A. L. (2016). Do «Brain-Training» Programs Work? *Psychological Science in the Public Interest*, *17*(3), 103–186. https://doi.org/10.1177/1529100616661983

Sjöwall, D., Roth, L., Lindqvist, S., & Thorell, L. B. (2013). Multiple deficits in ADHD: executive dysfunction, delay aversion, reaction time variability, and emotional deficits. *Journal of Child Psychology and*

Psychiatry, *54*(6), 619–627. https://doi.org/10.1111/jcpp.12006

Skeels, H. M. (1966). Adult Status of Children with Contrasting Early Life Experiences: A Follow-Up Study. *Monographs of the Society for Research in Child Development*, *31*(3), 1. https://doi.org/10.2307/1165791

Snyderman, M., & Herrnstein, R. J. (1983). Intelligence tests and the Immigration Act of 1924. *American Psychologist*, *38*(9), 986–995. https://doi.org/10.1037/0003-066X.38.9.986

Spearman, C. (1904). "General Intelligence," Objectively Determined and Measured. *The American Journal of Psychology*, *15*(2), 201. https://doi.org/10.2307/1412107

Spearman, C. (1927). *The Abilities of Man: Their Nature and Measurement*. Macmillan.

Stanovich, K. E. (1986). Matthew Effects in Reading: Some Consequences of Individual Differences in the Acquisition of Literacy. *Reading Research Quarterly*, *21*(4), 360–407. https://doi.org/10.1598/RRQ.21.4.1

Steenbergen-Hu, S., Makel, M. C., & Olszewski-Kubilius, P. (2016). What one hundred years of research says about the effects of ability grouping and acceleration on K–12 students' academic achievement: Findings of two second-order meta-analyses. *Review of Educational Research*, *86*(4), 849–899. https://doi.org/10.3102/0034654316675417

Stephenson, K. G., Beck, J. S., South, M., Norris, M., & Butter, E. (2021). Validity of the WISC-V in Youth with Autism Spectrum Disorder: Factor Structure and Measurement Invariance. *Journal of Clinical Child & Adolescent Psychology*, *50*(5), 669–681. https://doi.org/10.1080/15374416.2020.1846543

Stern, W. (1912). *Die psychologischen Methoden der Intelligenzprüfung*. Barth.

Stern, Y. (2012). Cognitive reserve in ageing and Alzheimer's disease. *The Lancet Neurology*, *11*(11), 1006–1012. https://doi.org/10.1016/S1474-4422(12)70191-6

Sternberg, R. J. (1985). *Beyond IQ: A Triarchic Theory of Human Intelligence*. Cambridge University Press.

Strenze, T. (2007). Intelligence and socioeconomic success: A meta-analytic review of longitudinal research. *Intelligence*, *35*(5), 401–426. https://doi.org/10.1016/j.intell.2006.09.004

Sundet, J. M., Barlaug, D. G., & Torjussen, T. M. (2004). The end of

the Flynn effect?: A study of secular trends in mean intelligence test scores of Norwegian conscripts during half a century. *Intelligence*, *32*(4), 349–362. https://doi.org/10.1016/j.intell.2004.06.004

Szucs, D., & Ioannidis, J. Pa. (2020). Sample size evolution in neuroimaging research: An evaluation of highly-cited studies (1990–2012) and of latest practices (2017–2018) in high-impact journals. *NeuroImage*, *221*, 117164. https://doi.org/10.1016/j.neuroimage.2020.117164

Talamini, F., Altoè, G., Carretti, B., & Grassi, M. (2017). Musicians have better memory than nonmusicians: A meta-analysis. *PLOS ONE*, *12*(10), e0186773. https://doi.org/10.1371/journal.pone.0186773

te Nijenhuis, J., & van der Flier, H. (2013). Is the Flynn effect on g?: A meta-analysis. *Intelligence*, *41*(6), 802–807. https://doi.org/10.1016/j.intell.2013.03.001

Terman, L. M. (1916). *The Measurement of Intelligence*. Houghton Mifflin.

Thiele, J. A., Faskowitz, J., Sporns, O., & Hilger, K. (2022). Multitask brain network reconfiguration is inversely associated with human intelligence. *Cerebral Cortex*, *32*(19), 4172–4182. https://doi.org/10.1093/cercor/bhab473

Thompson, W. F., Schellenberg, E. G., & Husain, G. (2001). Arousal, Mood, and The Mozart Effect. *Psychological Science*, *12*(3), 248–251. https://doi.org/10.1111/1467-9280.00345

Thomson, G. H. (1916). A hierarchy without a general factor. *British Journal of Psychology*, *8*(3), 271–281. https://doi.org/10.1111/j.2044-8295.1916.tb00133.x

Thurstone, L. L. (1938). *Primary Mental Abilities*. University of Chicago Press.

Toffalini, E., Buono, S., & Cornoldi, C. (2022). The structure, profile, and diagnostic significance of intelligence in children with ADHD are impressively similar to those of children with a specific learning disorder. *Research in Developmental Disabilities*, *129*, 104306. https://doi.org/10.1016/j.ridd.2022.104306

Toffalini, E., & Cornoldi, C. (2026). *Oltre il QI globale nell'IDS-2: Proposta di due nuovi indici per l'abilità intellettiva*. Presentazione al convegno ICAP 2026, Firenze. https://enricotoffalini.github.io/slides/Toffalini-ICAP2026-IT.pdf

Toffalini, E., & Feraco, T. (2026). Musicians, Memory, and General Cognitive Ability: A Commentary on Grassi et al. (2025). *Advances in Methods and Practices in Psychological Science*, *9*(3), 25152459261452948.

https://doi.org/10.1177/25152459261452948

Toffalini, E., Giofrè, D., & Cornoldi, C. (2017). Strengths and Weaknesses in the Intellectual Profile of Different Subtypes of Specific Learning Disorder: A Study on 1,049 Diagnosed Children. *Clinical Psychological Science*, *5*(2), 402–409. https://doi.org/10.1177/2167702616672038

Tucker-Drob, E. M., & Bates, T. C. (2016). Large Cross-National Differences in Gene × Socioeconomic Status Interaction on Intelligence. *Psychological Science*, *27*(2), 138–149. https://doi.org/10.1177/0956797615612727

Turkheimer, E. (2000). Three Laws of Behavior Genetics and What They Mean. *Current Directions in Psychological Science*, *9*(5), 160–164. https://doi.org/10.1111/1467-8721.00084

Turkheimer, E., Haley, A., Waldron, M., D'Onofrio, B., & Gottesman, I. I. (2003). Socioeconomic Status Modifies Heritability of IQ in Young Children. *Psychological Science*, *14*(6), 623–628. https://doi.org/10.1046/j.0956-7976.2003.psci_1475.x

van den Heuvel, M. P., Stam, C. J., Kahn, R. S., & Hulshoff Pol, H. E. (2009). Efficiency of Functional Brain Networks and Intellectual Performance. *Journal of Neuroscience*, *29*(23), 7619–7624. https://doi.org/10.1523/JNEUROSCI.1443-09.2009

Van der Hallen, R., Evers, K., Brewaeys, K., Van den Noortgate, W., & Wagemans, J. (2015). Global processing takes time: A meta-analysis on local–global visual processing in ASD. *Psychological Bulletin*, *141*(3), 549–573. https://doi.org/10.1037/bul0000004

van der Linden, D., Pekaar, K. A., Bakker, A. B., Schermer, J. A., Vernon, P. A., Dunkel, C. S., & Petrides, K. V. (2017). Overlap between the general factor of personality and emotional intelligence: A meta-analysis. *Psychological Bulletin*, *143*(1), 36–52. https://doi.org/10.1037/bul0000078

van der Maas, H. L. J., Dolan, C. V., Grasman, R. P. P. P., Wicherts, J. M., Huizenga, H. M., & Raijmakers, M. E. J. (2006). A dynamical model of general intelligence: The positive manifold of intelligence by mutualism. *Psychological Review*, *113*(4), 842–861. https://doi.org/10.1037/0033-295X.113.4.842

van IJzendoorn, M. H., Juffer, F., & Poelhuis, C. W. K. (2005). Adoption and Cognitive Development: A Meta-Analytic Comparison of Adopted and Nonadopted Children's IQ and School Performance. *Psychological Bulletin*, *131*(2), 301–316. https://doi.org/10.1037/0033-2909.131.2.3

01

van IJzendoorn, M. H., Luijk, M. P. C. M., & Juffer, F. (2008). IQ of Children Growing Up in Children's Homes: A Meta-Analysis on IQ Delays in Orphanages. *Merrill-Palmer Quarterly*, *54*(3), 341–366. https://doi.org/10.1353/mpq.0.0002

Vernon, P. E. (1950). *The Structure of Human Abilities*. Methuen.

Visser, B. A., Ashton, M. C., & Vernon, P. A. (2006). Beyond g: Putting multiple intelligences theory to the test. *Intelligence*, *34*(5), 487–502. https://doi.org/10.1016/j.intell.2006.02.004

Warne, R. T. (2020). *In the Know: Debunking 35 Myths about Human Intelligence*. Cambridge University Press. https://doi.org/10.1017/9781108593298

Wasserstein, R. L., & Lazar, N. A. (2016). The ASA Statement on p-Values: Context, Process, and Purpose. *The American Statistician*, *70*(2), 129–133. https://doi.org/10.1080/00031305.2016.1154108

Waterhouse, L. (2006). Multiple Intelligences, the Mozart Effect, and Emotional Intelligence: A Critical Review. *Educational Psychologist*, *41*(4), 207–225. https://doi.org/10.1207/s15326985ep4104_1

Watkins, M. W. (2006). Orthogonal higher order structure of the Wechsler Intelligence Scale for Children–Fourth edition. *Psychological Assessment*, *18*(1), 123–125. https://doi.org/10.1037/1040-3590.18.1.123

Watkins, M. W., & Smith, L. G. (2013). Long-term stability of the Wechsler Intelligence Scale for Children—Fourth Edition. *Psychological Assessment*, *25*(2), 477–483. https://doi.org/10.1037/a0031653

Wechsler, D. (1939). *The Measurement of Adult Intelligence*. Williams & Wilkins.

Wechsler, D. (1958). *The Measurement and Appraisal of Adult Intelligence* (4ª ed.). Williams & Wilkins.

Whalley, L. J., & Deary, I. J. (2001). Longitudinal cohort study of childhood IQ and survival up to age 76. *BMJ*, *322*(7290), 819. https://doi.org/10.1136/bmj.322.7290.819

Wicherts, J. M., Dolan, C. V., Hessen, D. J., Oosterveld, P., van Baal, G. C. M., Boomsma, D. I., & Span, M. M. (2004). Are intelligence tests measurement invariant over time? Investigating the nature of the Flynn effect. *Intelligence*, *32*(5), 509–537. https://doi.org/10.1016/j.intell.2004.07.002

Wilmot, M. P., & Ones, D. S. (2019). A century of research on conscien-

tiousness at work. *Proceedings of the National Academy of Sciences*, *116*(46), 23004–23010. https://doi.org/10.1073/pnas.1908430116

Wissler, C. (1901). The correlation of mental and physical tests. *The Psychological Review: Monograph Supplements*, *3*(6), i–62. https://doi.org/10.1037/h0092995

Wolfram, T. (2023). (Not just) Intelligence stratifies the occupational hierarchy: Ranking 360 professions by IQ and non-cognitive traits. *Intelligence*, *98*, 101755. https://doi.org/10.1016/j.intell.2023.101755

World Health Organization. (2019). *International Classification of Diseases, 11th Revision (ICD-11)*. https://icd.who.int/

Yerkes, R. M. (A c. Di). (1921). *Psychological Examining in the United States Army* (Vol. 15). Government Printing Office.

Zajonc, R. B. (1965). Social Facilitation: A solution is suggested for an old unresolved social psychological problem. *Science*, *149*(3681), 269–274. https://doi.org/10.1126/science.149.3681.269

Zanon, F., & Priftis, K. (2025). Psychologists Must Be against the Use of Tests without Accessible Norms. *Giornale italiano di psicologia*, *2/2025*. https://doi.org/10.1421/116921